Capítulo 2

Fundamentos da imagem digital

Quem deseja o sucesso deve fazer as perguntas preliminares certas.
Aristóteles

Apresentação

O objetivo deste capítulo é apresentar uma série de conceitos básicos do processamento digital de imagens que serão utilizados ao longo do livro. A Seção 2.1 resume a mecânica do sistema visual humano, incluindo a formação de imagens no olho e os recursos de discriminação e adaptação ao brilho. A Seção 2.2 analisa a luz, outros componentes do espectro eletromagnético e suas características de formação de imagens. A Seção 2.3 discute os sensores de imagens e como eles são utilizados para gerar imagens digitais. A Seção 2.4 apresenta os conceitos da amostragem de imagens e quantização de intensidade. Tópicos adicionais discutidos nessa seção incluem representação da imagem digital, os efeitos da variação do número de amostras e níveis de intensidade em uma imagem, os conceitos da resolução espacial e de intensidade e os princípios da interpolação de imagens. A Seção 2.5 lida com uma variedade de relações básicas entre pixels. Por fim, a Seção 2.6 constitui uma introdução às principais ferramentas matemáticas que utilizaremos no livro todo. Um segundo objetivo dessa seção é ajudá-lo a começar a desenvolver uma "ideia" de como essas ferramentas são utilizadas em uma variedade de tarefas básicas de processamento de imagens. O escopo dessas ferramentas e sua aplicação serão explicados mais detalhadamente conforme for necessário no restante do livro.

2.1 Elementos da percepção visual

Apesar de o processamento digital de imagens se basear em fórmulas matemáticas e probabilísticas, a intuição e a análise humana desempenham um papel central na escolha de uma técnica em detrimento de outra, e a escolha, muitas vezes, se baseia em critérios visuais subjetivos. Dessa forma, é apropriado desenvolver uma compreensão básica da percepção visual humana como um primeiro passo da nossa jornada. Dada a complexidade e o alcance desse tópico, só temos como cobrir os aspectos mais rudimentares da visão humana. Em particular, nosso interesse se concentrará na mecânica e nos parâmetros relacionados à formação e percepção das imagens pelos humanos. Estamos interessados em conhecer as limitações físicas da visão humana em relação aos fatores que também são utilizados em nosso trabalho com imagens digitais. Assim, fatores como de que forma os humanos e os dispositivos eletrônicos de formação de imagem se comparam em termos de resolução e a capacidade de se adaptar a mudanças na iluminação não são apenas interessantes, mas também importantes do ponto de vista prático.

2.1.1 A estrutura do olho humano

A Figura 2.1 mostra um corte transversal simplificado do olho humano. O olho é praticamente uma esfera, com um diâmetro médio de aproximadamente 20 mm. Três membranas o revestem: a *córnea* e a cobertura externa da *esclera*; a *coroide*; e a *retina*. A córnea é um tecido resistente e transparente que cobre a superfície anterior do olho. Como um prolongamento da córnea, temos a esclera, uma membrana opaca que reveste o restante do globo ocular.

A coroide situa-se diretamente abaixo da esclera. Essa membrana contém uma rede de vasos sanguíneos que atua como a principal fonte de nutrição para o olho.

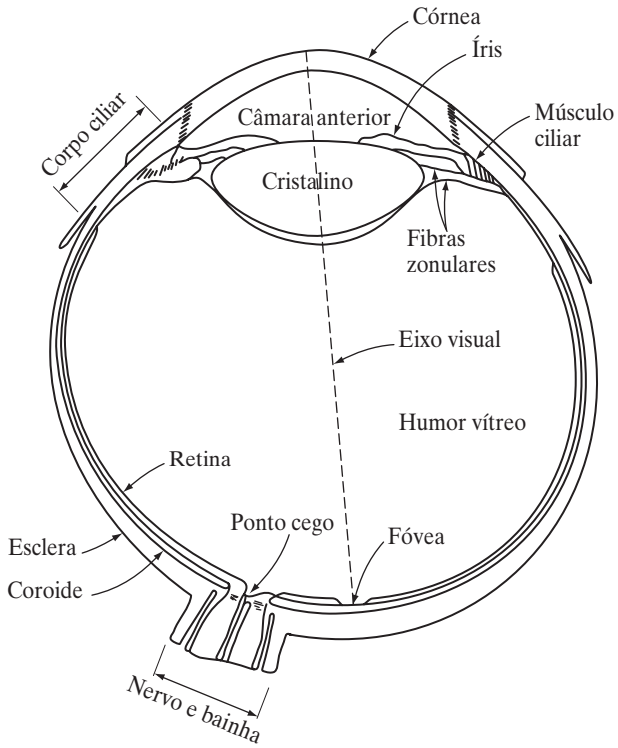


Figura 2.1 Diagrama simplificado de um corte transversal do olho humano.

Até mesmo um dano superficial na coroide, muitas vezes não considerado sério, pode levar a um grave dano ocular como resultado de uma inflamação que reduz o fluxo sanguíneo. O revestimento da coroide é substancialmente pigmentado, ajudando a reduzir a quantidade de luz indesejável que entra no olho e se espalha pelo globo ocular. Em seu extremo anterior, a coroide se divide em *corpo ciliar* e *íris*. A íris se contrai ou se expande para controlar a quantidade de luz que entra no olho. A abertura central da íris (a pupila) varia em diâmetro de aproximadamente 2 a 8 mm. A parte frontal da íris contém o pigmento visível do olho, ao passo que a parte de trás contém um pigmento negro.

O *cristalino* é composto de camadas concêntricas de células fibrosas e é suspenso por fibras que se ligam ao corpo ciliar. Ele contém entre 60 e 70% de água, cerca de 6% de gordura e mais proteína do que qualquer outro tecido do olho. É colorido por uma pigmentação ligeiramente amarelada, que se intensifica com a idade. Em casos extremos, a opacidade excessiva do cristalino, provocada pela doença comumente chamada de *catarata*, pode levar a problemas de discriminação de cores e perda de nitidez da visão. O cristalino absorve aproximadamente 8% do espectro da luz visível, com uma absorção relativamente superior de comprimentos de onda mais curtos. Tanto a luz infravermelha quanto a ultravioleta são absorvidas consideravelmente por proteínas contidas na estrutura do cristalino e, em quantidades excessivas, podem danificar o olho.

A membrana mais interna do olho é a *retina*, que se estende por toda a porção posterior da parede do olho. Quando o olho está adequadamente focalizado, a luz de um objeto externo ao olho forma uma imagem na retina. A visão de padrões é obtida pela distribuição de receptores discretos de luz ao longo da superfície da retina. Há duas classes de receptores: *cones* e *bastonetes*. Cada olho possui cerca de 6 a 7 milhões de cones. Eles se localizam principalmente na porção central da retina, chamada de *fóvea*, e são muito sensíveis à cor. Os humanos podem distinguir pequenos detalhes com esses cones, em grande parte porque cada um deles está conectado à sua própria terminação nervosa. Os músculos que controlam o olho giram o globo ocular até que a imagem de um objeto de interesse incida na fóvea. A visão pelos cones é chamada de visão *fotópica* ou visão de luz clara.

O número de bastonetes é muito maior: cerca de 75 a 150 milhões são distribuídos pela superfície da retina. A ampla área de distribuição e o fato de vários bastonetes serem conectados a uma única terminação nervosa reduzem a quantidade de detalhes discerníveis por esses receptores. Os bastonetes servem para dar uma imagem geral do campo de visão. Eles não estão envolvidos na visualização de cores e são sensíveis a baixos níveis de iluminação. Por exemplo, objetos que aparecem brilhantemente coloridos à luz do Sol, aparecem como formas descoloridas quando iluminados pela luz de uma lua cheia, porque só os bastonetes são estimulados. Esse fenômeno é conhecido como visão *escotópica* ou visão de luz escura.

A Figura 2.2 mostra a densidade de bastonetes e cones em um corte transversal do olho direito, passando pela região de saída do nervo ótico. A ausência de receptores nessa área resulta no assim chamado *ponto cego* (veja a Figura 2.1). Com exceção dessa região, a distribuição de receptores é radialmente simétrica em torno da fóvea. A densidade de receptores é medida em função do ângulo formado pelo eixo visual e a linha que passa através do centro do cristalino e cruza a retina. Observe, na Figura 2.2, que os cones são mais densos no centro da retina (na área central da fóvea). Observe, também, que os bastonetes aumentam em densidade a partir do centro até aproximadamente 20° do eixo e, então, diminuem em densidade até a periferia extrema da retina.

A fóvea é uma depressão circular na retina de cerca de 1,5 mm de diâmetro. Entretanto, para futuras considerações neste livro, é mais útil falarmos em termos de arranjos quadrados ou retangulares de elementos sen-

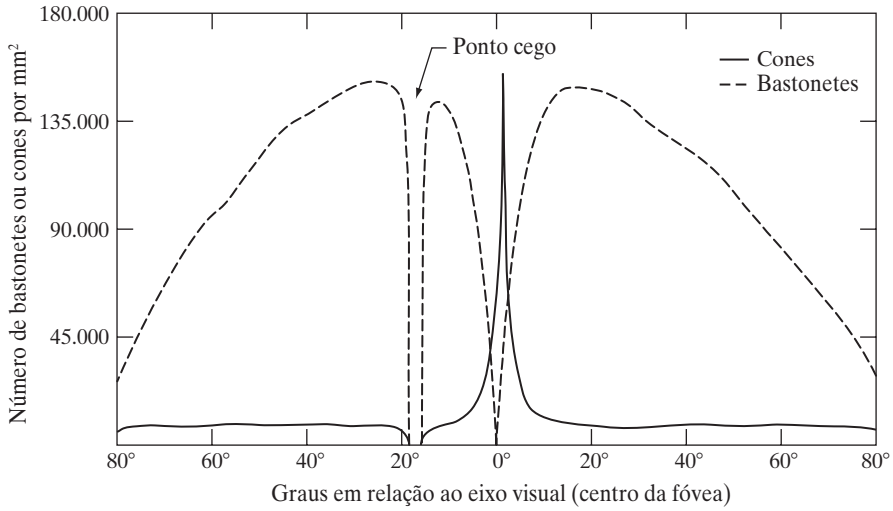


Figura 2.2 Distribuição de bastonetes e cones na retina.

sores. Dessa forma, com alguma liberdade interpretativa, podemos entender a fóvea como uma matriz sensora quadrada de tamanho 1,5 mm × 1,5 mm. A densidade de cones nessa região da retina é de aproximadamente 150.000 elementos por mm². Com base nessas aproximações, o número de cones na região de maior acuidade visual no olho é de aproximadamente 337.000 elementos. Considerando apenas o poder de resolução, um chip de aquisição de imagens do tipo CCD (dispositivo de carga acoplada) de média resolução pode conter esse número de elementos em uma matriz receptora de até 5 mm × 5 mm. Apesar de a habilidade dos seres humanos de integrar a inteligência e a experiência com a visão tornar esse tipo de comparação numérica de certa forma superficial, tenha em mente que a capacidade básica do olho de distinguir detalhes é, sem dúvida, comparável aos atuais sensores eletrônicos de aquisição de imagem.

2.1.2 Formação da imagem no olho

Em uma câmera fotográfica comum, a lente tem uma distância focal fixa, e a focalização para diferentes distâncias é obtida variando a distância entre a lente e o plano-imagem, onde o filme (ou o chip de captura de imagem, no caso de uma câmera digital) se localiza. No olho humano, ocorre o oposto: a distância entre a lente e o plano-imagem (a retina) é fixa, e a distância focal necessária para atingir uma focalização adequada é obtida variando o formato do cristalino (que equivale a uma lente flexível). Isso é realizado pelas fibras zonulares, que achatam ou espessam o cristalino para focalização de objetos distantes ou próximos, respectivamente. A distância entre o centro do cristalino e a retina ao longo do eixo visual é de aproximadamente 17 mm. A distância focal varia de 14 mm a 17 mm aproximadamente, e a última variação ocorre quando o olho está relaxado e focado em distâncias maiores do que cerca de 3 m.

A disposição geométrica apresentada na Figura 2.3 ilustra como calcular as dimensões de uma imagem formada na retina. Por exemplo, suponha que uma pessoa esteja olhando para uma árvore de 15 m de altura a uma distância de 100 m. Se h for a altura do objeto na imagem formada na retina, a disposição geométrica da Figura 2.3 nos leva a $15/100 = h/17$ ou $h = 2{,}55$ mm. Como observamos na Seção 2.1.1, a imagem na retina é focalizada principalmente na área da fóvea. A percepção ocorre, então, pela excitação relativa dos receptores de luz, que transformam a energia radiante em impulsos elétricos, que são posteriormente decodificados pelo cérebro.

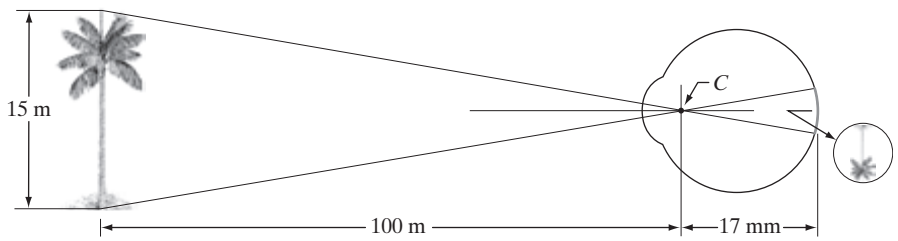


Figura 2.3 Representação gráfica do olho focalizando uma árvore. O ponto C é o centro ótico do cristalino.

2.1.3 Adaptação ao brilho e discriminação

Como as imagens digitais são exibidas em níveis discretos de intensidades, a capacidade do olho para discriminar diferentes níveis de intensidade é uma consideração importante na apresentação de resultados de processamento de imagens. A escala de níveis de intensidade luminosa aos quais o sistema visual humano pode se adaptar é enorme — da ordem de 10^{10} — do limiar escotópico ao limite de ofuscamento. Consideráveis evidências experimentais indicam que o *brilho subjetivo* (o brilho *percebido* pelo sistema visual humano) é uma função logarítmica da intensidade de luz incidente no olho. A Figura 2.4, um gráfico da intensidade da luz em relação ao brilho subjetivo, ilustra essa característica. A longa curva sólida representa a escala de níveis de intensidade à qual o sistema visual pode se adaptar. Considerando apenas a visão fotópica, a escala é de cerca de 10^6. A transição da visão escotópica para fotópica é gradual ao longo da escala, aproximadamente de 0,001 a 0,1 mililambert (–3 a –1 mL na escala logarítmica), como mostra a dupla ramificação da curva de adaptação nessa escala.

O ponto crucial ao interpretar a impressionante escala dinâmica mostrada na Figura 2.4 é que o sistema visual não pode operar *simultaneamente* ao longo dessa escala. Pelo contrário, essa grande variação é obtida por meio de mudanças na sensibilidade global, um fenômeno conhecido como *adaptação ao brilho*. A escala total de níveis distintos de intensidade que podem ser simultaneamente discriminados pelo olho é bastante pequena quando comparada à escala total de adaptação. Para qualquer conjunto de condições, o nível atual de sensibilidade do sistema visual é denominado *nível de adaptação ao brilho*, e pode corresponder, por exemplo, ao brilho B_a na Figura 2.4. A curva mais curta representa a escala de brilho subjetivo que o olho pode perceber quando adaptado a esse nível. Essa variação é bastante restrita, com um nível B_b abaixo do qual todos os estímulos são percebidos como variações indistinguíveis de preto. A porção superior (tracejada) da curva não é de fato restrita mas, quando muito estendida, perde seu significado, porque intensidades muito mais altas simplesmente elevariam o nível de adaptação para cima de B_a.

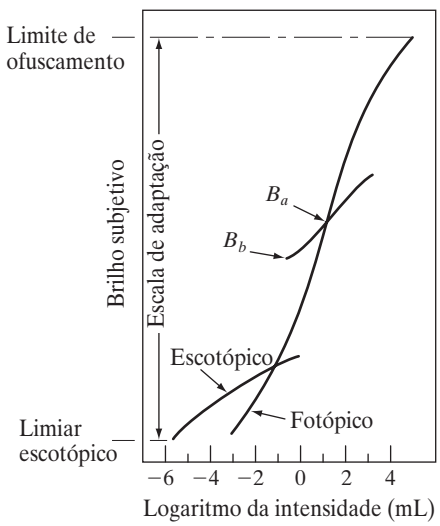


Figura 2.4 Escala de sensações subjetivas ao brilho mostrando um nível particular de adaptação.

A habilidade do olho para discriminar *mudanças* de intensidade da luz em qualquer nível específico de adaptação também é de considerável interesse. Um experimento clássico, usado para determinar a capacidade do sistema visual humano na discriminação de brilho, consiste em fazer uma pessoa olhar para uma área plana e uniformemente iluminada que seja grande o bastante para ocupar todo o campo visual. Essa área é tipicamente um difusor, tal como um vidro opaco iluminado por trás por uma fonte de luz, cuja intensidade, I, pode ser variada. A esse campo é acrescentado um incremento de iluminação, ΔI, na forma de um "flash" de curta duração que aparece como um círculo no centro do campo uniformemente iluminado, como mostra a Figura 2.5.

Se ΔI não for brilhante o suficiente, a pessoa diz "não", indicando que a mudança não foi percebida. Assim que ΔI for ficando mais forte, pode haver a resposta "sim", indicando uma mudança percebida. Finalmente, quando ΔI for suficientemente forte, a pessoa responderá sempre "sim". A quantidade $\Delta I_c/I$, em que ΔI_c é o incremento de iluminação, o qual é discriminável em 50% das vezes com iluminação de fundo I, é chamada de *razão de Weber*. Um baixo valor de $\Delta I_c/I$ significa que uma pequena mudança percentual de intensidade é discriminável. Isso representa uma "boa" discriminação de brilho. Por outro lado, um alto valor de $\Delta I_c/I$ indica que uma grande mudança percentual de intensidade é necessária. Isso representa uma discriminação "ruim" de brilho.

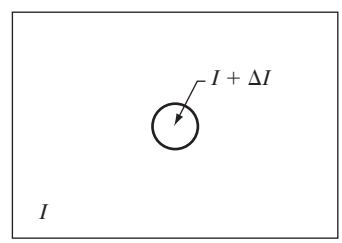


Figura 2.5 Configuração experimental básica utilizada para caracterizar a discriminação de brilho.

A forma geral do gráfico de log $\Delta I_c/I$ como uma função de log I é apresentada na Figura 2.6. Essa curva mostra que a discriminação de brilho é ruim (a razão de Weber é grande) em baixos níveis de iluminação e melhora significativamente (a razão de Weber diminui) com o aumento da iluminação de fundo. As duas ramificações na curva refletem o fato de que, em baixos níveis de iluminação, a visão é desempenhada pela atividade dos bastonetes, ao passo que, em níveis elevados (apresentando melhor discriminação), a visão é função dos cones.

Se a iluminação de fundo for mantida constante e a intensidade da outra fonte agora puder variar de forma incremental do imperceptível ao sempre perceptível, em vez de piscar como um flash, o observador típico poderá discernir um total de uma a duas dúzias de variações de intensidade. *De uma forma geral*, esse resultado está relacionado ao número de diferentes níveis de cinza que uma pessoa pode ver em qualquer ponto de uma imagem monocromática. Esse resultado não significa que uma imagem poderá ser representada por um número tão pequeno de valores de intensidade porque, à medida que o olho se desloca pela imagem, a intensidade média do fundo varia, permitindo, assim, que um conjunto *diferente* de mudanças incrementais seja detectado a cada novo nível de adaptação. Por conseguinte, o olho se torna capaz de discriminar uma escala *geral* de níveis de intensidade muito mais ampla. De fato, mostramos na Seção 2.4.3 que o olho é capaz de detectar efeitos de contorno indesejados em imagens monocromáticas se a intensidade geral for representada por menos que aproximadamente duas dúzias de níveis de cinza.

Dois fenômenos demonstram claramente que o brilho percebido não é uma simples função da intensidade. O primeiro se baseia no fato de o sistema visual tender a subestimar ou superestimar os contornos entre as regiões de diferentes intensidades. A Figura 2.7(a) ilustra um exemplo notável desse fenômeno. Embora o nível de cinza das linhas seja constante, na realidade percebe-se um padrão de brilho que é fortemente alterado próximo às bordas (Figura 2.7(c)). Essas linhas aparentemente recortadas são chamadas de *bandas de Mach*, em homenagem a Ernst Mach, quem primeiro descreveu esse fenômeno, em 1865.

O segundo fenômeno, chamado de *contraste simultâneo*, está relacionado ao fato de o brilho percebido de uma região não depender simplesmente de sua intensidade, como demonstra a Figura 2.8. Todos os quadrados centrais têm exatamente o mesmo nível de cinza. Entretanto, eles parecem se tornar mais escuros à medida que o fundo se torna mais claro. Um exemplo mais comum é um pedaço de papel que parece branco quando está sobre uma mesa, mas pode parecer totalmente negro quando utilizado para proteger os olhos enquanto se olha diretamente para um céu brilhante.

Outros exemplos de fenômenos da percepção humana são as ilusões de ótica, nas quais o olho preenche lacunas de informação ou percebe propriedades geométricas de objetos de maneira equivocada. A Figura 2.9 mostra alguns exemplos. Na Figura 2.9(a), o contorno de um quadrado é visto claramente, apesar do fato de que nenhuma linha definindo um quadrado faz parte da imagem. O mesmo efeito, dessa vez com um círculo, pode ser visto na Figura 2.9(b);

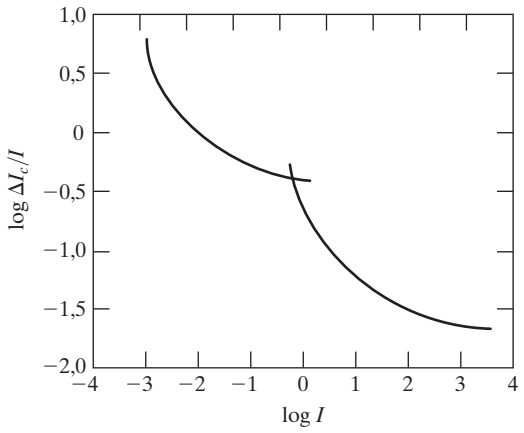


Figura 2.6 Razão de Weber típica como uma função da intensidade.

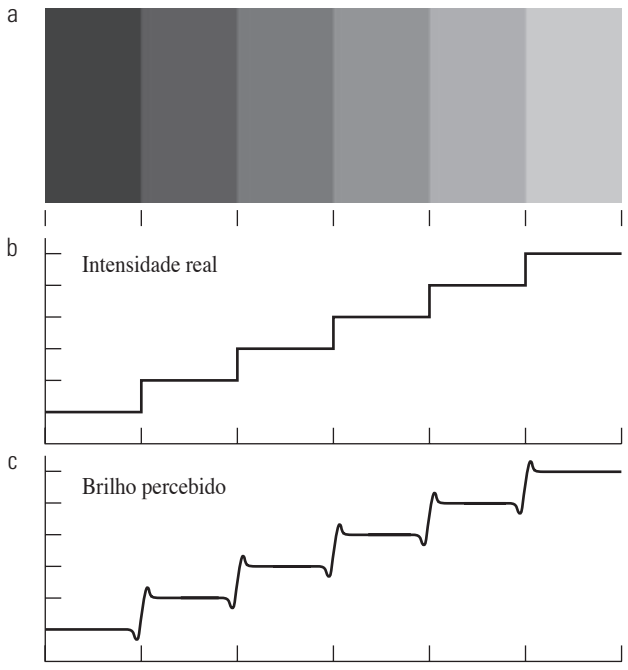


Figura 2.7 Ilustração do efeito de bandas de Mach. O brilho percebido não é uma simples função da intensidade real.

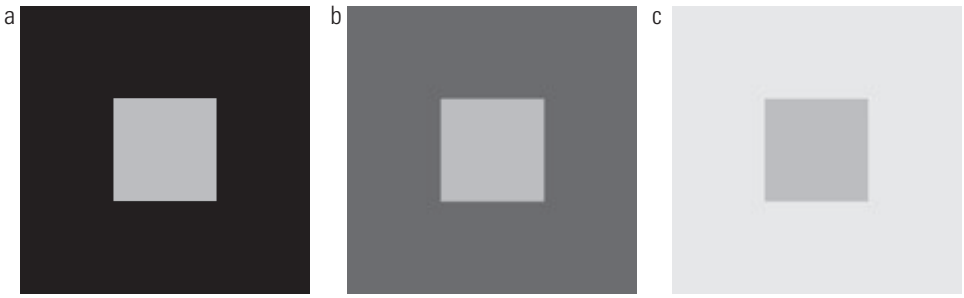


Figura 2.8 Exemplos de contraste simultâneo. Todos os quadrados menores possuem exatamente o mesmo nível de cinza, mas parecem progressivamente mais escuros à medida que o fundo da imagem fica mais claro.

observe como apenas algumas linhas bastam para dar a ilusão de um círculo completo. Os dois segmentos de linha horizontal na Figura 2.9(c) têm o mesmo comprimento, mas um deles parece ser mais curto do que o outro. Por fim, todas as linhas da Figura 2.9(d) orientadas a 45° são equidistantes e paralelas. No entanto, o padrão de linhas cruzadas cria a ilusão de que essas linhas estão longe de ser paralelas. As ilusões de óptica são uma característica do sistema visual humano que ainda não é totalmente compreendida.

2.2 A luz e o espectro eletromagnético

O espectro eletromagnético foi apresentado na Seção 1.3. Nesta seção, vamos analisar esse tópico em mais detalhes. Em 1666, Sir Isaac Newton descobriu que, quando um feixe de luz solar passa através de um prisma de vidro, o feixe de luz emergente não é branco, mas consiste em um espectro contínuo de cores, que varia do violeta em uma extremidade ao vermelho na outra. Como mostra a Figura 2.10, a variedade de cores que percebemos na luz visível representa uma parcela muito pequena do espectro eletromagnético. Em uma extremidade do espectro estão as ondas de rádio, com comprimentos de onda bilhões de vezes maiores que os da luz visível. Na outra extremidade do espectro estão os raios gama, com comprimentos de onda bilhões de vezes menores que os da luz visível. O espectro eletromagnético pode ser expresso em termos de comprimento de onda, frequência ou energia. O comprimento de onda (λ) e a frequência (v) se relacionam por meio da expressão:

$$\lambda = \frac{c}{v} \tag{2.2-1}$$

onde c é a velocidade da luz (2.998×10^8 m/s). A energia dos vários componentes do espectro eletromagnético é dada pela expressão:

$$E = hv \tag{2.2-2}$$

onde h é a constante de Planck. As unidades de comprimento de onda são metros, com os termos *mícrons* (simbolizados por μm e equivalentes a 10^{-6} m) e *nanômetros* (simbolizados por nm e equivalentes a 10^{-9} m) também sendo utilizados constantemente. A frequência é medida em Hertz (Hz), com um Hertz sendo igual a um ciclo de onda senoidal por segundo. Uma unidade de energia comumente utilizada é o elétron-volt.

As ondas eletromagnéticas podem ser visualizadas como ondas senoidais que se propagam com o comprimento de onda λ (Figura 2.11), ou podem ser vistas como um fluxo de partículas sem massa, cada uma se deslocando em um padrão similar ao de uma onda e se movendo na velocidade da luz. Cada partícula sem massa contém uma certa quantidade (ou *quantum*) de energia. Cada quantum de energia é chamado de *fóton*. Vemos na Equação 2.2-2 que a energia é proporcional à frequência, de forma que os fenômenos eletromagnéticos de frequência

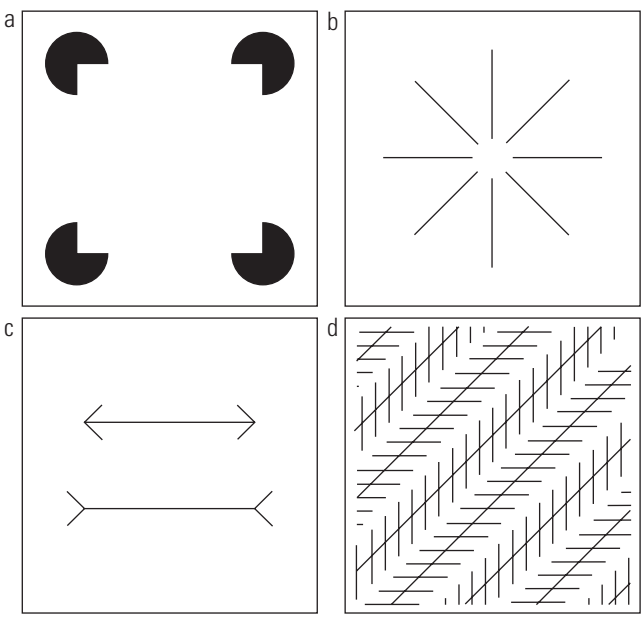


Figura 2.9 Algumas ilusões de ótica conhecidas.

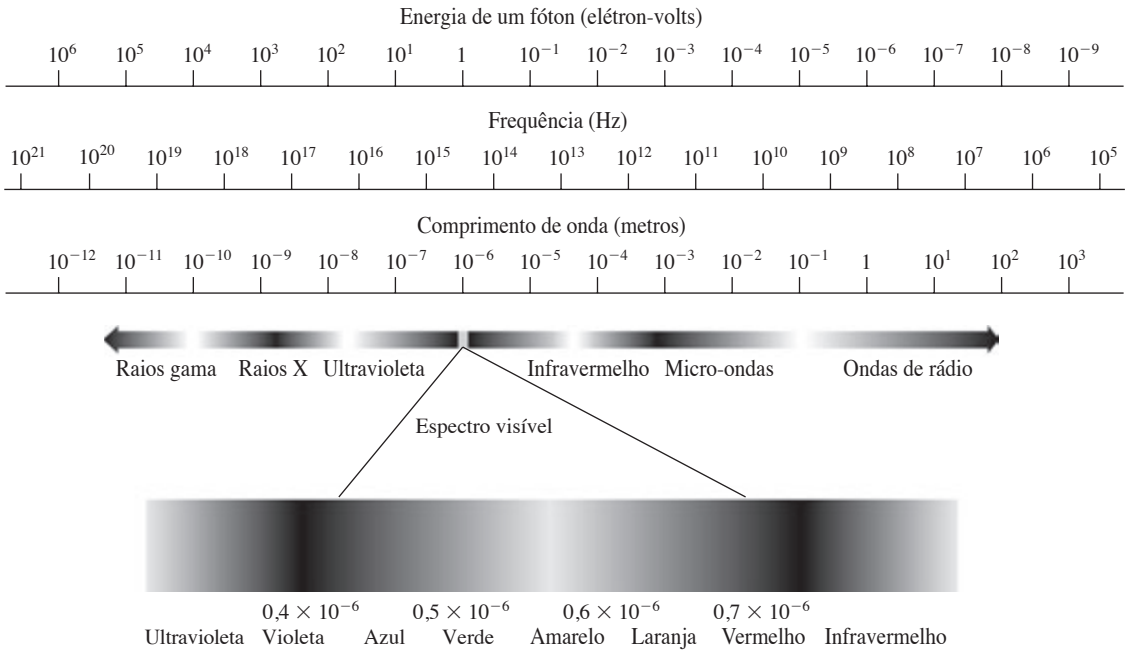


Figura 2.10 Espectro eletromagnético. O espectro visível foi ampliado na figura para facilitar a explicação, mas observe que o espectro visível representa uma parcela relativamente estreita do espectro EM.

mais alta (comprimento de onda mais curto) apresentam mais energia por fóton. Dessa forma, as ondas de rádio possuem fótons de baixa energia, as micro-ondas têm mais energia que as ondas de rádio, o infravermelho tem ainda mais energia, seguido do espectro visível, ultravioleta, raios X e, finalmente, os raios gama, os que possuem energia mais alta entre todos. Essa é a razão pela qual os raios gama são tão perigosos aos organismos vivos.

A luz é um tipo particular de radiação eletromagnética que pode ser percebida pelo olho humano. O espectro visível (de cores) é mostrado expandido na Figura 2.10 para fins desta discussão (analisaremos as cores em muito mais detalhes no Capítulo 6). A banda visível do espectro eletromagnético cobre a faixa que vai de 0,43 μm (violeta) até 0,79 μm (vermelho) aproximadamente. Por conveniência, o espectro de cores é dividido em seis grandes regiões: violeta, azul, verde, amarelo, laranja e vermelho. Nenhuma cor (ou outro componente do espectro eletromagnético) termina abruptamente, mas cada faixa se mistura gradativamente à próxima, como mostra a Figura 2.10.

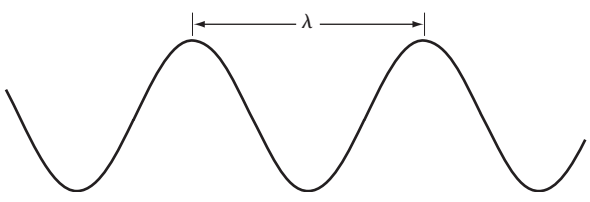


Figura 2.11 Representação gráfica de um comprimento de onda.

As cores percebidas pelos humanos em um objeto são determinadas pela natureza da luz *refletida* pelo objeto. Um corpo que reflete uma luz relativamente equilibrada em todos os comprimentos de onda visíveis é percebido como branco pelo observador. No entanto, um corpo que favorece a refletância em uma faixa limitada do espectro visível exibe alguns tons de cor. Por exemplo, objetos verdes refletem principalmente a luz com comprimentos de onda na faixa entre 500 e 570 nm, enquanto absorvem a maior parte da energia em outros comprimentos de onda.

A luz sem cor é chamada de *luz monocromática* (ou *acromática*). O único atributo da luz monocromática é sua *intensidade* ou quantidade. Pelo fato de a intensidade da luz monocromática ser percebida como variações de preto a tons de cinza até chegar ao branco, o termo *nível de cinza* costuma ser utilizado para denotar a intensidade monocromática. Utilizamos os termos *intensidade* e *nível de cinza* como sinônimos nas discussões subsequentes. A variedade de valores mensurados de luz monocromática do preto ao branco costuma ser chamada de *escala de cinza*, e as imagens monocromáticas são comumente chamadas de *imagens em escala de cinza*.

A *luz cromática* (*colorida*) cobre o espectro de energia eletromagnética na faixa de 0,43 a 0,79 μm, aproximadamente, como observado anteriormente. Além da fre-

quência, três medidas básicas são utilizadas para descrever a qualidade de uma fonte de luz cromática: radiância, luminância e brilho. A *radiância* é a quantidade total de energia que é emitida pela fonte de luz e é normalmente medida em watts (W). A *luminância*, medida em lumens (lm), mede a quantidade de energia que um observador *percebe* de uma fonte de luz. Por exemplo, a luz emitida de uma fonte operando na região infravermelha do espectro pode ter uma energia significativa (radiância), mas um observador mal a perceberia; sua luminância seria praticamente igual a zero. Por fim, como discutimos na Seção 2.1, o *brilho* é um descritor subjetivo da percepção da luz que é praticamente impossível de mensurar. Ele incorpora a noção acromática de intensidade e é um dos principais fatores na descrição da sensação de cores.

Prosseguindo com a análise da Figura 2.10, notamos que, no extremo dos comprimentos de onda curtos do espectro eletromagnético, temos os raios gama e os raios X. Como vimos na Seção 1.3.1, a radiação gama é importante para a geração de imagens na área médica e na astronomia e para a geração de imagens por radiação em ambientes nucleares. Raios X de alta energia são utilizados em aplicações industriais. Imagens de raios X de tórax e de raios X odontológicos estão no extremo de energia mais baixa da banda de raios X. A banda de raios X de baixa energia faz a transição para a região de ultravioleta que, por sua vez, se mistura ao espectro visível em comprimentos de onda maiores. Passando para comprimentos de onda ainda maiores, encontramos a banda infravermelha, que irradia calor, um fato que faz com que ela seja útil em aplicações de geração de imagens baseadas em "assinaturas de calor". A parte da banda infravermelha mais próxima do espectro visível é chamada de região de *infravermelho próximo*. O extremo oposto dessa banda é chamado de região de *infravermelho distante*. Esta última região se mistura à banda de micro-ondas, a qual é bem conhecida como a fonte de energia dos fornos de micro-ondas, mas tem muitas outras utilizações, incluindo a área das comunicações e radares. Por fim, a banda de ondas de rádio inclui a televisão, além do rádio AM e FM. Nos níveis de energia mais altos, sinais de rádio emanando de alguns corpos estelares são úteis em observações astronômicas. Exemplos de imagens na maioria das bandas que acabamos de discutir são dados na Seção 1.3.

Em princípio, se um sensor capaz de detectar energia irradiada por uma banda do espectro eletromagnético puder ser desenvolvido, é possível criar imagens de eventos de interesse nessa banda. É importante notar, contudo, que o comprimento de onda de uma onda eletromagnética que é necessário para "ver" um objeto deve ser do mesmo tamanho ou menor que o objeto. Por exemplo, uma molécula de água tem um diâmetro na ordem de 10^{-10} m. Dessa forma, para estudar as moléculas, precisaríamos de uma fonte capaz de emitir na região do ultravioleta distante ou na região de raios X de baixa energia. Essa limitação, além das propriedades físicas do material do sensor, define os limites fundamentais da capacidade dos sensores de aquisição de imagens, como os sensores de luz visível, o infravermelho e outros sensores utilizados hoje em dia.

Apesar de a aquisição de imagens se basear predominantemente na energia irradiada por ondas eletromagnéticas, esse não é o único método para gerar imagens. Por exemplo, como vimos na Seção 1.3.7, o som refletido de um objeto pode ser utilizado para formar imagens de ultrassom. Outras importantes fontes de imagens digitais são feixes de elétrons para a microscopia eletrônica e imagens sintéticas utilizadas em elementos gráficos e visualização.

2.3 Sensores e aquisição de imagens

A maioria das imagens nas quais estamos interessados é gerada pela combinação de uma fonte de "iluminação" e a reflexão ou absorção de energia dessa fonte pelos elementos da "cena" cuja imagem está sendo gerada. Colocamos *iluminação* e *cena* entre aspas para enfatizar o fato de que elas são consideravelmente mais genéricas que a situação habitual na qual uma fonte de luz visível ilumina uma cena 3-D (tridimensional) comum. Por exemplo, a iluminação pode se originar de uma fonte de energia eletromagnética, como um sistema de raios X, de radar ou infravermelho. Mas, como observado anteriormente, ela pode se originar de fontes menos tradicionais, como ultrassom ou até mesmo um padrão de iluminação gerado por computador. De forma similar, os elementos da cena poderiam ser objetos cotidianos, mas também poderiam ser moléculas, formações rochosas subterrâneas ou um cérebro humano. Dependendo da natureza da fonte, a energia da iluminação é refletida dos objetos ou transmitida através deles. Um exemplo da primeira categoria é a luz refletida de uma superfície plana. Um exemplo da segunda categoria é quando raios X passam através do corpo de um paciente para gerar uma imagem radiográfica para diagnóstico. Em algumas aplicações, a energia refletida ou transmitida é direcionada para um fotoconversor (por exemplo, uma tela fluorescente), que converte a energia recebida em luz visível. A microscopia eletrônica e algumas aplicações da geração de imagens na faixa de raios gama utilizam esse método.

A Figura 2.12 mostra os três principais arranjos de sensores utilizados para transformar a *energia* de iluminação em imagens digitais. A ideia é simples: a energia que entra é transformada em tensão pela combinação da energia elétrica de entrada e do material do sensor, sensível a um tipo específico de energia que está sendo detectado. A forma de onda da tensão de saída é a resposta do(s) sensor(es), e uma quantidade digital é obtida de cada sensor por meio da digitalização de sua resposta. Nesta seção, analisaremos as principais modalidades de sensores e de aquisição de imagens. A digitalização de imagens será discutida na Seção 2.4.

2.3.1 Aquisição de imagens utilizando um único sensor

A Figura 2.12(a) mostra os componentes de um único sensor. Talvez o sensor mais conhecido desse tipo seja o fotodiodo, construído com materiais semicondutores cuja forma de onda da tensão de saída é proporcional à intensidade da luz. A utilização de um filtro na entrada de um sensor melhora sua seletividade. Por exemplo, um filtro passa-banda para a luz verde, colocado na entrada de um sensor de luz, favorece a luz na banda verde do espectro de cores. Em consequência, a saída do sensor será mais intensa para a luz verde que para outros componentes do espectro visível.

Para gerar uma imagem bidimensional (2-D) utilizando um único sensor, deve haver deslocamentos relativos, tanto na direção x quanto na y entre o sensor e a área de aquisição da imagem. A Figura 2.13 mostra um arranjo utilizado no escaneamento de alta precisão, no qual um filme negativo é montado em um tambor cuja rotação mecânica realiza o deslocamento em uma dimensão. Um único sensor é montado em um eixo que realiza o movimento na direção perpendicular. Como o movimento mecânico pode ser controlado com alto nível de precisão, esse método representa uma forma acessível (apesar de lenta) de obter imagens de alta resolução. Outros arranjos mecânicos similares utilizam uma base plana com o sensor se movimentando em duas direções

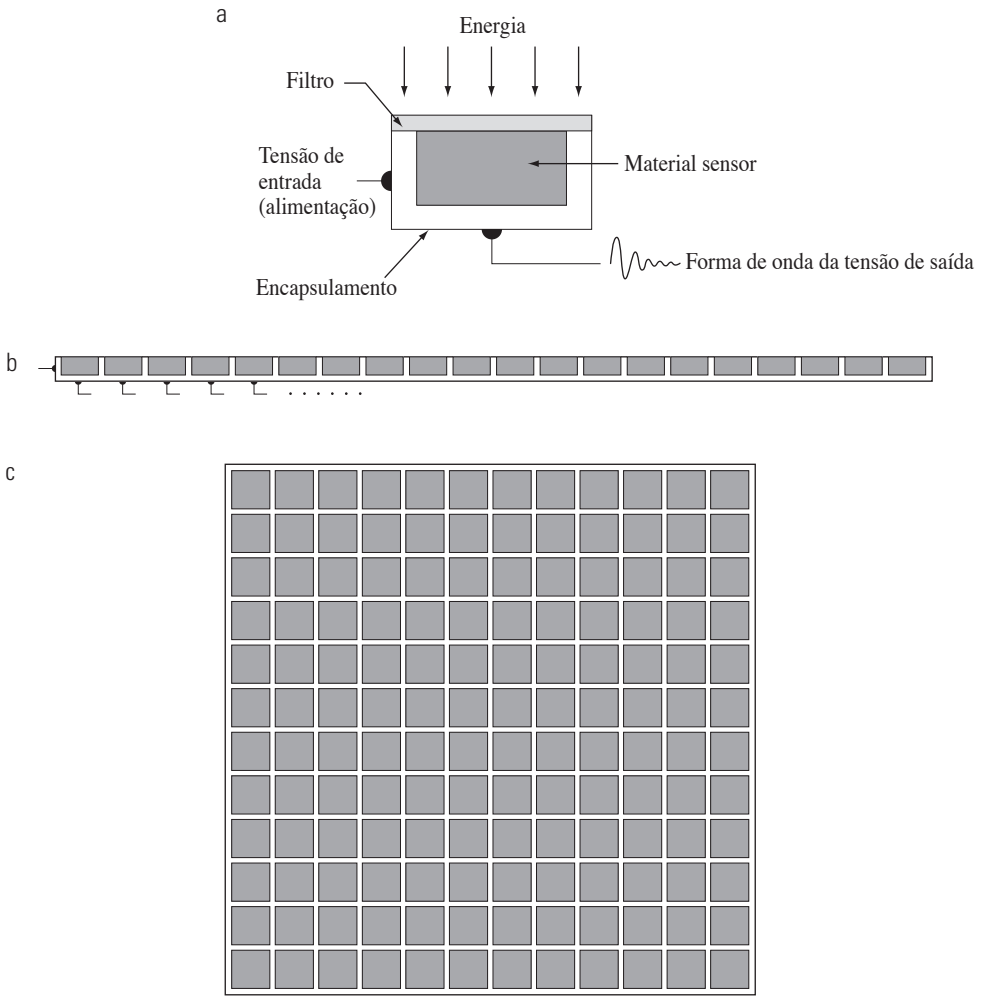


Figura 2.12 (a) Um único sensor de aquisição de imagens. (b) Sensores de linha. (c) Sensores de área (matricial).

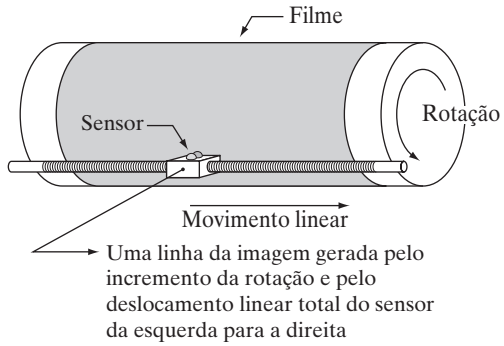


Figura 2.13 Combinação de um único sensor com movimento para gerar uma imagem bidimensional (2-D).

lineares. Esses tipos de digitalizadores mecânicos são algumas vezes chamados de *microdensitômetros*.

Outro exemplo de aquisição de imagens com um único sensor utiliza uma fonte de raio laser que coincide com o sensor. Espelhos móveis são utilizados para controlar o feixe de saída em um padrão de escaneamento e para direcionar o raio laser refletido ao sensor. Esse arranjo também pode ser utilizado na aquisição de imagens utilizando sensores por varredura de linha e sensores de área ou matriciais, que discutiremos nas duas seções a seguir.

2.3.2 Aquisição de imagens utilizando sensores por varredura de linha

Uma disposição geométrica utilizada com muito mais frequência que os sensores únicos consiste em um arranjo linear de sensores na forma de uma faixa de sensores, como mostra a Figura 2.12(b). O arranjo linear dos sensores fornece elementos para a aquisição de imagens em uma direção. Movimentos na direção perpendicular à linha de sensores geram imagens na outra direção, como mostra a Figura 2.14(a). Esse é o tipo de arranjo utilizado na maioria dos scanners de mesa. É possível construir dispositivos de varredura de linha com 4.000 ou mais sensores alinhados. Os sensores por varredura de linha costumam ser utilizados em aplicações de aquisição de imagens aéreas, nas quais o sistema de geração de imagens é montado em um avião que voa em uma altitude e velocidade constantes sobre a área geográfica cuja imagem será gerada. Sensores por varredura de linha, unidimensionais, sensíveis a diversas bandas do espectro eletromagnético, são instalados perpendicularmente à direção do voo. Eles fornecem uma linha de uma imagem por vez e o movimento do arranjo de sensores completa a outra dimensão de uma imagem bidimensional. Lentes ou outros dispositivos de focalização são utilizados para projetar nos sensores a região a ser escaneada.

Os sensores por varredura de linha instalados em uma configuração em forma de anel são utilizados na aquisição de imagens médicas e industriais, com o intuito de obter imagens de corte transversal ("fatias" de objetos tridimensionais), como mostra a Figura 2.14(b). Uma fonte giratória de raios X fornece a radiação, e os sensores opostos à fonte coletam a energia dos raios X que passa através do objeto (os sensores obviamente precisam ser sensíveis à energia dos raios X). Essa é a base da geração de imagens pela tomografia axial com-

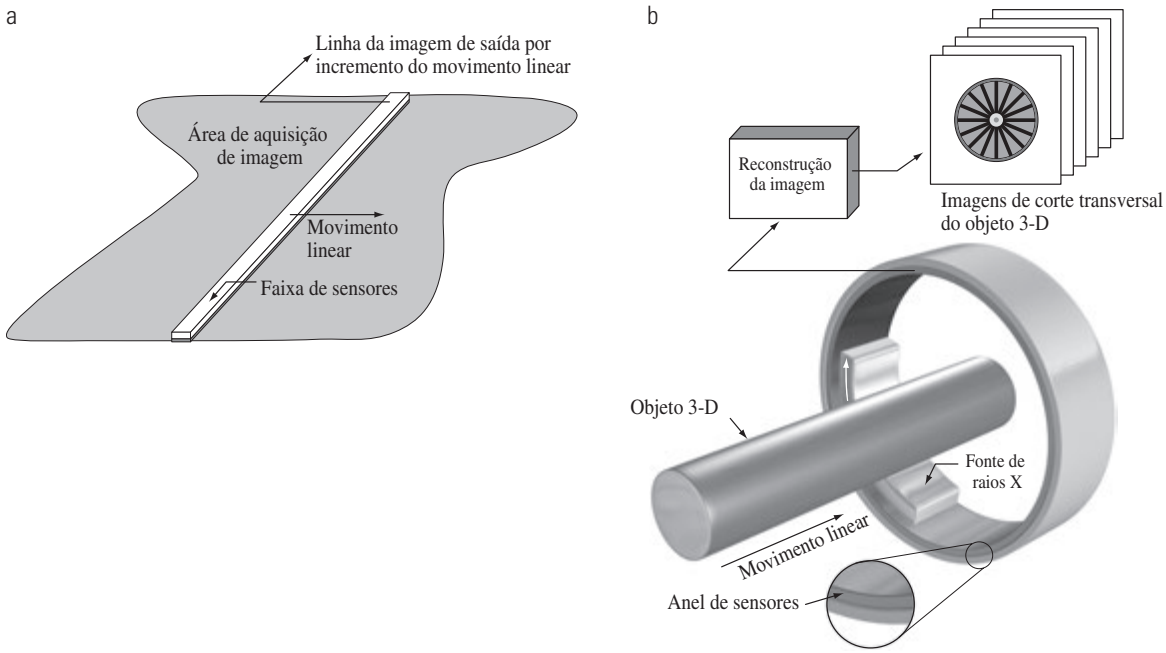


Figura 2.14 (a) Aquisição de imagens utilizando um arranjo plano de sensores por varredura de linha. (b) Aquisição de imagens utilizando um arranjo circular de sensores por varredura de linha.

putadorizada (CAT, de *computerized axial tomography*) médica e industrial, como mostrado nas seções 1.2 e 1.3.2. É importante notar que a saída dos sensores deve ser processada por algoritmos de reconstrução cujo objetivo é transformar os dados coletados em imagens de corte transversal que possam ser compreendidas (veja a Seção 5.11). Em outras palavras, as imagens não são obtidas diretamente dos sensores somente pelo movimento; elas requerem extensivo processamento computacional. Um volume digital 3-D que consiste de diversas imagens empilhadas é gerado à medida que o objeto é deslocado em uma direção perpendicular ao anel de sensores. Outras modalidades de aquisição de imagens baseadas no princípio CAT incluem a geração de imagens por ressonância magnética (MRI, de *magnetic resonance imaging*) e a tomografia por emissão de pósitrons (PET, de *pósitron emission tomography*). As fontes de radiação, os sensores e os tipos de imagens são diferentes, mas conceitualmente são muito similares ao procedimento básico de aquisição de imagens mostrado na Figura 2.14(b).

2.3.3 Aquisição de imagens utilizando sensores matriciais

A Figura 2.12(c) mostra sensores individuais dispostos em forma de uma matriz bidimensional. Numerosos dispositivos sensores eletromagnéticos e alguns ultrassônicos são frequentemente dispostos na forma matricial. Esse também é o arranjo predominante encontrado nas câmeras digitais. Um sensor típico para essas câmeras é uma matriz CCD, que pode ser fabricada com uma grande variedade de propriedades sensoras e dispostas em arranjos matriciais de 4.000 $\times$ 4.000 elementos ou mais. Os sensores CCD são amplamente utilizados em câmeras digitais e outros instrumentos que utilizam sensores de luz. A resposta de cada sensor é proporcional à integral da energia luminosa projetada sobre a superfície do sensor, uma propriedade que é utilizada em aplicações astronômicas e outras que requerem imagens de baixo nível de ruído. A redução de ruídos é realizada fazendo com que o sensor integre o sinal luminoso de entrada em um intervalo de minutos ou mesmo horas. Pelo fato de a matriz de sensores da Figura 2.12(c) ser bidimensional, sua principal vantagem é que uma imagem completa pode ser obtida projetando o padrão de energia na superfície da matriz. Obviamente, o movimento não é necessário, como é o caso dos arranjos de sensores discutidos nas duas seções anteriores.

A principal forma na qual os sensores matriciais são utilizados é mostrada na Figura 2.15. Essa figura mostra a energia de uma fonte de iluminação sendo refletida de um elemento de uma cena (como mencionado no início desta seção, a energia também poderia ser transmitida através dos elementos da cena).* A primeira função realizada pelo sistema de aquisição de imagens da Figura 2.15(c) é coletar a

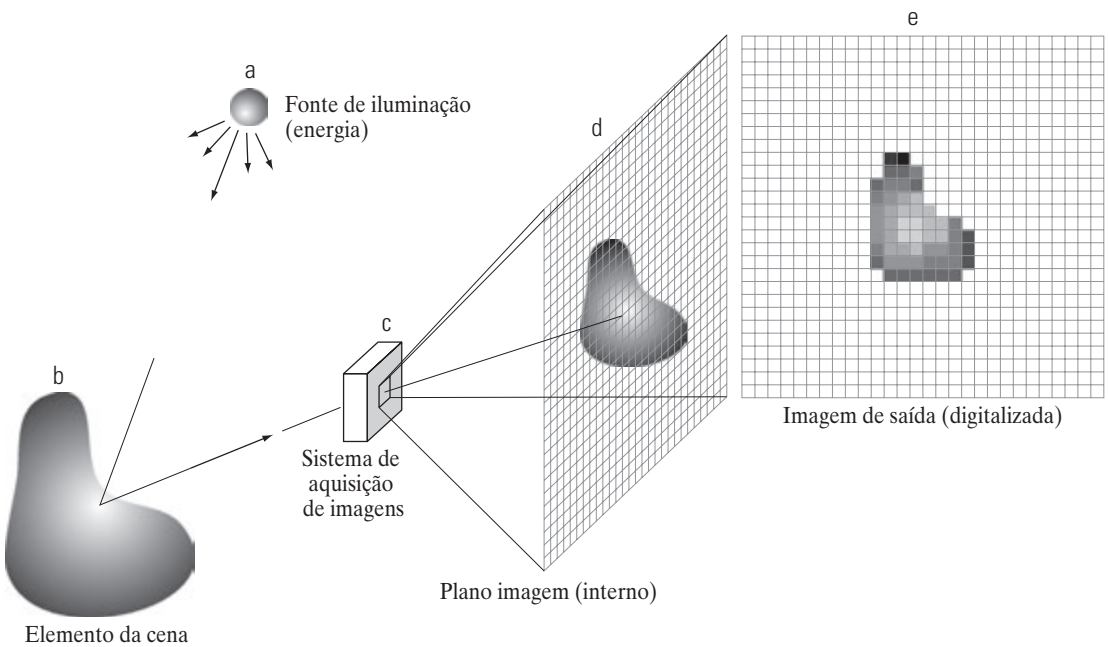


Figura 2.15 Exemplo do processo de aquisição de uma imagem digital (a) Fonte de energia ("iluminação"). (b) Um elemento de uma cena. (c) Sistema de aquisição de imagens. (d) Projeção da cena no plano imagem. (e) Imagem digitalizada.

* Em alguns casos, geramos a imagem diretamente da fonte, como na obtenção de imagens do Sol.

energia de entrada e projetá-la em um plano imagem. Se a iluminação for luz, a entrada frontal do sistema de aquisição de imagens é uma lente ótica que projeta a cena vista sobre o plano focal da lente, como mostra a Figura 2.15(d). O arranjo de sensores, que coincide com o plano focal, produz saídas proporcionais à integral da luz recebida em cada sensor. Circuitos digitais e analógicos realizam uma varredura nessas saídas e as convertem em um sinal analógico, que é então digitalizado por um outro componente do sistema de aquisição de imagens. A saída é uma imagem digital, como mostra o esquema da Figura 2.15(e). A conversão de uma imagem em formato digital será explicada na Seção 2.4.*

2.3.4 Um modelo simples de formação de imagem

Como vimos na Seção 1.1, expressamos imagens como funções bidimensionais na forma $f(x, y)$. O valor ou a amplitude de f nas coordenadas espaciais (x, y) é uma quantidade escalar positiva cujo significado físico é determinado pela origem da imagem. Quando uma imagem é gerada a partir de um processo físico, seus valores de intensidade são proporcionais à energia irradiada por uma fonte real (por exemplo, ondas eletromagnéticas). Em consequência, $f(x, y)$ deve ser diferente de zero e finito; ou seja,

$$0 < f(x, y) < \infty \tag{2.3-1}$$

A função $f(x, y)$ pode ser caracterizada por dois componentes: (1) a quantidade de iluminação da fonte que incide na cena que está sendo vista; e (2) a quantidade de iluminação refletida pelos objetos na cena. Esses elementos são chamados de componentes de *iluminação* e *refletância* e são expressos por $i(x, y)$ e $r(x, y)$, respectivamente. As duas funções se combinam como um produto para formar $f(x, y)$:

$$f(x, y) = i(x, y)\, r(x, y) \tag{2.3-2}$$

onde

$$0 < i(x, y) < \infty \tag{2.3-3}$$

e

$$0 < r(x, y) < 1 \tag{2.3-4}$$

A Equação 2.3-4 indica que a refletância está entre 0 (absorção total) e 1 (refletância total). A natureza de $i(x, y)$ é determinada pela fonte de iluminação, e $r(x, y)$ é determinado pelas características dos objetos da cena. Note que essas expressões também são aplicáveis a imagens formadas pela transmissão de iluminação através de um objeto, como uma radiografia de tórax. Nesse caso, teríamos uma função de *transmissividade* em vez de *refletividade*, mas os limites seriam iguais aos da Equação 2.3-4 e a função que definiria a imagem formada seria representada como o produto na Equação 2.3-2.

■

Exemplo 2.1 Alguns valores típicos de iluminação e refletância.

Os valores dados nas equações 2.3-3 e 2.3-4 são limites teóricos. As *médias* a seguir ilustram algumas faixas típicas de $i(x, y)$ para a luz visível. Em um dia claro, o Sol pode produzir mais do que 90.000 lm/m² de iluminação sobre a superfície da Terra. Esse número cai para menos de 10.000 lm/m² em um dia nublado. Em uma noite clara, a Lua cheia gera uma iluminação de cerca de 0,1 lm/m². O nível típico de iluminação em um escritório comercial é de cerca de 1.000 lm/m². De forma similar, veja a seguir valores típicos de $r(x, y)$: 0,01 para o veludo preto; 0,65 para o aço inoxidável; 0,80 para a tinta branca em uma parede plana; 0,90 para o metal prateado; e 0,93 para a neve.

■

Expressamos a intensidade (nível de cinza) de uma imagem monocromática em quaisquer coordenadas (x_0, y_0) por:

$$\ell = f(x_0, y_0) \tag{2.3-5}$$

A partir das equações 2.3-2 a 2.3-4, fica claro que ℓ está na faixa:

$$L_{\text{mín}} \leq \ell \leq L_{\text{máx}} \tag{2.3-6}$$

Teoricamente, o único requisito para $L_{\text{mín}}$ é que ele seja positivo e para $L_{\text{máx}}$ é que ele seja finito. Na prática, $L_{\text{mín}} = i_{\text{mín}} r_{\text{mín}}$ e $L_{\text{máx}} = i_{\text{máx}} r_{\text{máx}}$. Utilizando o valor médio mostrado anteriormente para a iluminação de escritório e a faixa de valores de refletância como diretrizes, podemos esperar que os limites típicos para valores em recintos fechados sem iluminação adicional seja $L_{\text{mín}} \approx 10$ e $L_{\text{máx}} \approx 1.000$.

O intervalo $[L_{\text{mín}}, L_{\text{máx}}]$ é chamado de *escala* (ou *intensidade*) *de cinza*. Costuma-se deslocar numericamente esse intervalo para o intervalo $[0, L - 1]$, onde $\ell = 0$ é considerado preto, e $\ell = L - 1$ é considerado branco na escala de cinza. Todos os valores intermediários são tons de cinza variando do preto ao branco.

* As intensidades da imagem podem se tornar negativas durante o processamento ou como um resultado da interpretação. Por exemplo, em imagens de radar, os objetos que se aproximam de um sistema de radar muitas vezes são interpretados como tendo velocidades negativas ao passo que objetos que se distanciam são interpretados como tendo velocidades positivas. Dessa forma, a velocidade da imagem pode ser codificada como tendo valores tanto positivos quanto negativos. Ao armazenar e exibir imagens, nós normalmente ajustamos as intensidades de forma que o menor valor negativo seja igual a 0 (veja a Seção 2.6.3 sobre o ajuste de intensidades).

2.4 Amostragem e quantização de imagens*

Da discussão feita na seção anterior, vemos que existem várias formas de aquisição de imagens, mas nosso objetivo em todas elas é o mesmo: gerar imagens digitais a partir de dados captados por sensores. A saída da maioria dos sensores consiste de uma forma de onda de tensão contínua cuja amplitude e o comportamento no espaço estão relacionados ao fenômeno físico que está sendo captado pelos sensores. Para criar uma imagem digital, precisamos converter os dados contínuos que foram captados para o formato digital. Isso envolve dois processos: *amostragem* e *quantização*.

2.4.1 Os conceitos básicos da amostragem e da quantização

A ideia básica por trás da amostragem e da quantização é ilustrada na Figura 2.16. A Figura 2.16(a) mostra uma imagem contínua *f* que queremos converter em formato digital. Uma imagem pode ser contínua em relação às coordenadas *x* e *y* e também em relação à amplitude. Para convertê-la ao formato digital, temos de fazer a amostragem da função em ambas a coordenadas e na amplitude. A digitalização dos valores de coordenada é chamada de *amostragem*. A digitalização dos valores de amplitude é chamada de *quantização*.

A função unidimensional da Figura 2.16(b) é um gráfico que representa os valores de amplitude (nível de intensidade) da imagem contínua ao longo do segmento de reta *AB* na Figura 2.16(a). As variações aleatórias se devem ao ruído da imagem. Para realizar a amostragem dessa função, colhemos amostras igualmente espaçadas ao longo da linha *AB*, como mostra a Figura 2.16(c). A posição de cada amostra no espaço é indicada por uma pequena marca vertical na parte inferior da figura. As amostras são representadas por pequenos quadrados brancos superpostos na função. O conjunto dessas localizações discretas nos dá a função de amostragem. No entanto, os valores das amostras ainda cobrem (verticalmente) uma faixa contínua de valores de intensidade. Para formar uma função digital, os valores de intensidade também devem ser convertidos (*quantizados*) em quantidades discretas. O lado direito da Figura 2.16(c) mostra a escala de intensidade dividida em oito intervalos discretos, variando do preto ao branco. As marcas verticais indicam o valor específico atribuído a cada um dos oito níveis de intensidade. Os níveis de intensidade contínuos são quantizados atribuindo um dos oito valores para cada amostra. Essa atribuição é feita dependendo da proximidade vertical de uma amostra a uma marca indicadora. As amostras digitais resultantes da amostragem e

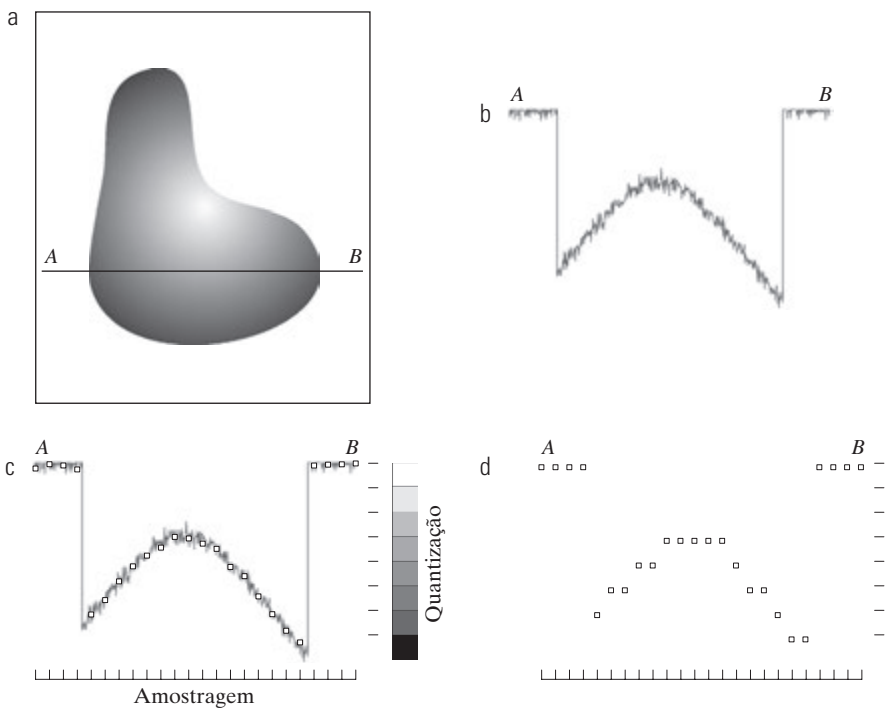


Figura 2.16 Produzindo uma imagem digital. (a) Imagem contínua. (b) Linha de varredura de A a B na imagem contínua utilizada para ilustrar os conceitos de amostragem e quantização. (c) Amostragem e quantização. (d) Linha de varredura digital.

* A discussão sobre a amostragem nesta seção é de uma natureza intuitiva. Analisaremos esse tópico com mais profundidade no Capítulo 4.

da quantização são mostradas na Figura 2.16(d). Ao começar na parte superior da imagem e realizar esse procedimento linha por linha, produz-se uma imagem digital bidimensional. Está implícito na Figura 2.16 que, além do número discreto de níveis utilizados, a precisão atingida na quantização depende muito do conteúdo de ruído do sinal da amostragem.

A amostragem da forma que acabamos de descrever presume que temos uma imagem contínua em ambas as direções das coordenadas, bem como na amplitude. Na prática, o método de amostragem é determinado pelo arranjo dos sensores utilizados para gerar a imagem. Quando uma imagem é gerada por um único elemento sensor combinado com um movimento mecânico, como na Figura 2.13, a saída do sensor é quantizada da forma descrita anteriormente. No entanto, a amostragem espacial é realizada selecionando-se o número de incrementos mecânicos individuais em que o sensor será ativado para a coleta de dados. O movimento mecânico pode ser muito exato, de forma que, em princípio, praticamente não existe um limite da precisão com a qual podemos amostrar uma imagem com esse procedimento. Na prática, os limites da precisão de amostragem são determinados por outros fatores, como a qualidade dos componentes óticos do sistema.

Quando sensores por varredura de linha são utilizados para a aquisição da imagem, o número de sensores da linha define as limitações da amostragem na direção da imagem. O movimento mecânico na outra direção pode ser controlado com mais precisão, mas faz pouco sentido tentar atingir uma densidade de amostragem em uma direção que exceda os limites de amostragem definidos pelo número de sensores na outra. A quantização das saídas do sensor completa o processo de formação de uma imagem digital.

Quando uma matriz de sensores é utilizada para a aquisição de imagem, não há movimento, e o número de sensores na matriz determina os limites da amostragem em ambas as direções. A quantização das saídas do sensor é realizada como no exemplo anterior. A Figura 2.17 ilustra esse conceito. A Figura 2.17(a) mostra uma imagem contínua projetada sobre o plano de uma matriz de sensores. A Figura 2.17(b) mostra a imagem após a amostragem e a quantização. A qualidade da imagem digital é claramente determinada, em grande parte, pelo número de amostras e de níveis discretos de intensidade utilizados na amostragem e na quantização. No entanto, como mostraremos na Seção 2.4.3, o conteúdo da imagem também é um fator importante na escolha desses parâmetros.

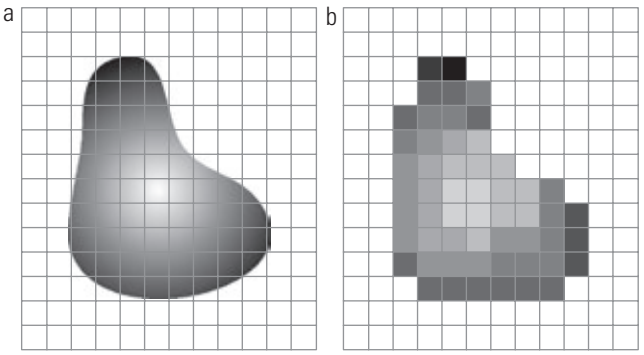


Figura 2.17 (a) Imagem contínua projetada em uma matriz de sensores. (b) Resultado da amostragem e quantização da imagem.

2.4.2 Representação de imagens digitais

Fazemos com que $f(s, t)$ represente uma função de imagem contínua de duas variáveis contínuas, s e t. Convertemos essa função em uma *imagem digital* por meio da amostragem e quantização, como explicado na seção anterior. Suponha que realizemos a amostragem da imagem contínua em uma matriz 2-D, $f(x, y)$, contendo M linhas e N colunas, sendo que (x, y) são coordenadas discretas. Para fins de praticidade e clareza na notação, utilizamos números inteiros para essas coordenadas discretas: $x = 0, 1, 2, \ldots, M - 1$ e $y = 0, 1, 2, \ldots, N - 1$. Dessa forma, por exemplo, o valor da imagem digital na origem é $f(0, 0)$, e o próximo valor de coordenada ao longo da primeira linha é $f(0, 1)$. No caso, a notação $(0, 1)$ é utilizada para representar a segunda amostra ao longo da primeira linha. Isso *não* significa que esses são os valores físicos das coordenadas quando a imagem foi amostrada. Em geral, o valor da imagem em quaisquer coordenadas (x, y) é expresso por $f(x, y)$, onde x e y são números inteiros. A seção do plano real que se expande pelas coordenadas de uma imagem é chamada de *domínio espacial*, com x e y sendo chamadas de *variáveis espaciais* e *coordenadas espaciais*.

Como mostra a Figura 2.18, há três formas básicas de representar $f(x, y)$. A Figura 2.18(a) é uma representação gráfica da imagem, com dois eixos determinando a localização espacial e o terceiro eixo representando os valores de f (intensidades) como uma função das duas variáveis espaciais x e y. Apesar de ser possível conhecer a estrutura da imagem nesse exemplo analisando essa representação gráfica, imagens complexas em geral são muito detalhadas e de difícil interpretação a partir dessas representações. A representação gráfica é útil ao trabalhar com conjuntos em escala de cinza cujos elementos são expressos em um grupo de três variáveis na forma (x, y, z), onde x e y são coordenadas espaciais e z é o valor da

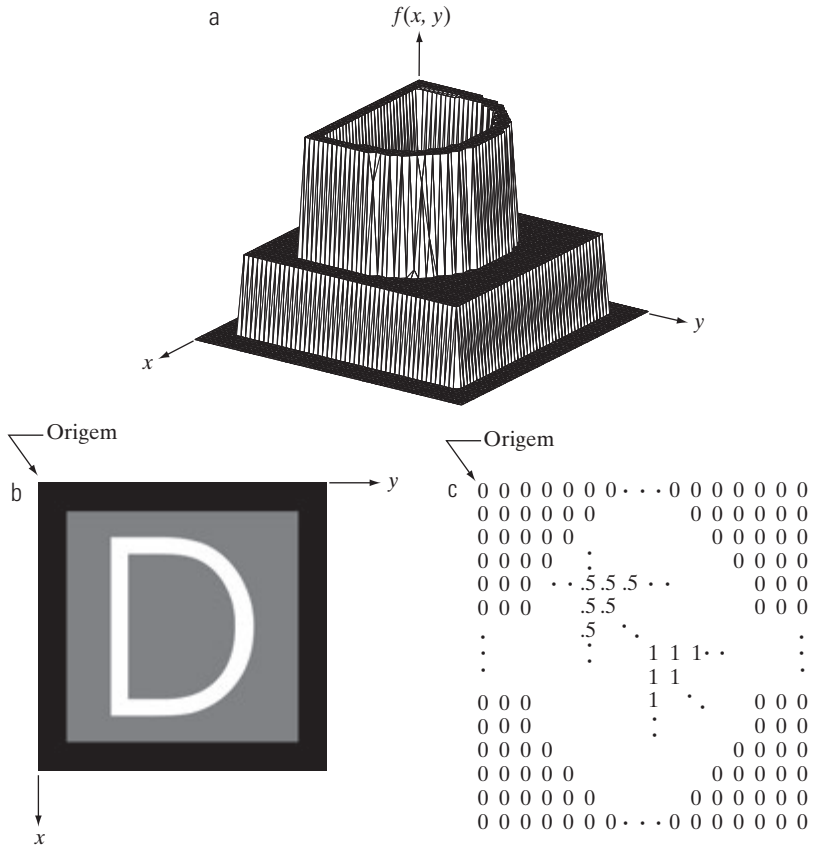


Figura 2.18 (a) Imagem representada graficamente como uma superfície. (b) Imagem representada como uma matriz de intensidade visual. (c) Imagem representada como uma matriz numérica 2-D (0, .5 e 1 correspondem ao preto, cinza e branco, respectivamente).

intensidade f nas coordenadas (x, y). Trabalharemos com essa representação na Seção 2.6.4.

A representação da Figura 2.18(b) é muito mais comum. Ela mostra $f(x, y)$ como uma imagem seria visualizada em um monitor ou uma fotografia. Aqui, o nível de cinza de cada ponto é proporcional ao valor da intensidade f desse ponto. Nessa figura, temos apenas três valores de intensidade igualmente espaçados. Se a intensidade for normalizada para o intervalo [0, 1], cada ponto da imagem tem o valor 0, 0,5 ou 1. Um monitor ou impressora simplesmente converte esses três valores em preto, cinza ou branco, respectivamente, como mostra a Figura 2.18(b). A terceira representação é somente para mostrar os valores numéricos $f(x, y)$ na forma de uma matriz. Nesse exemplo, o tamanho de f é de 600 × 600 elementos, ou 360.000 números. Claramente, imprimir a matriz inteira seria inconveniente e transmitiria pouca informação. No entanto, no desenvolvimento de algoritmos essa representação é bastante útil quando apenas algumas partes da imagem são impressas e analisadas como valores numéricos. A Figura 2.18(c) representa esse conceito.

Do parágrafo anterior podemos concluir que as representações das figuras 2.18(b) e (c) são as mais úteis. As imagens nos permitem ver rapidamente os resultados. Matrizes numéricas são utilizadas para processamento e desenvolvimento de algoritmos. Na forma de equação, escrevemos a representação de uma matriz numérica $M \times N$ como

$$f(x,y)=\begin{bmatrix} f(0,0) & f(0,1) & \cdots & f(0,N-1) \\ f(1,0) & f(1,1) & \cdots & f(1,N-1) \\ \vdots & \vdots & & \vdots \\ f(M-1,0) & f(M-1,1) & \cdots & f(M-1,N-1) \end{bmatrix} \tag{2.4-1}$$

Os dois lados dessa equação são formas equivalentes de representar quantitativamente uma imagem digital. O lado direito é uma matriz de números reais. Cada elemento dessa matriz é chamado de *elemento de imagem*, *elemento pictórico*, *pixel* ou *pel*. Os termos *imagem* e *pixel* são utilizados ao longo deste livro para expressar uma imagem digital e seus elementos.

Em algumas discussões é vantajoso utilizar uma notação matricial mais tradicional para expressar uma imagem digital e seus elementos:

$$\mathbf{A} = \begin{bmatrix} a_{0,0} & a_{0,1} & \cdots & a_{0,N-1} \\ a_{1,0} & a_{1,1} & \cdots & a_{1,N-1} \\ \vdots & \vdots & & \vdots \\ a_{M-1,0} & a_{M-1,1} & \cdots & a_{M-1,N-1} \end{bmatrix} \quad (2.4\text{-}2)$$

Claramente, $a_{ij} = f(x = i, y = j) = f(i, j)$, de forma que as equações 2.4-1 e 2.4-2 são matrizes idênticas. Podemos até representar uma imagem como um vetor, **v**. Por exemplo, um vetor coluna de tamanho $MN \times 1$ é formado fazendo com que os primeiros M elementos de **v** correspondam à primeira coluna de **A**, os próximos M elementos correspondam à segunda coluna e assim por diante. Da mesma forma, também podemos utilizar as linhas em vez das colunas de **A** para formar um vetor desse tipo. As duas representações são válidas desde que sejam consistentes.

Retomando rapidamente a Figura 2.18, observe que a origem de uma imagem digital se localiza na parte superior esquerda, com o eixo x positivo se estendendo para baixo e o eixo y positivo se estendendo para a direita. Essa é uma representação convencional baseada no fato de que muitos dispositivos de visualização de imagem (por exemplo, monitores de TV) varrem uma imagem começando do canto superior esquerdo e se movendo para direita, uma linha por vez. Mais importante é o fato de que o primeiro elemento de uma matriz é, por convenção, o elemento do canto superior esquerdo, de forma que a escolha da origem de $f(x, y)$ nesse ponto faz sentido matematicamente. Tenha em mente que essa representação é o sistema padrão de coordenadas cartesianas que você já conhece.* Nós simplesmente mostramos os eixos apontando para baixo e para a direita, em vez de para a direita e para cima.

Expressar a amostragem e a quantização em termos matemáticos mais formais pode ser útil algumas vezes. Considere Z e R um conjunto de números inteiros e um conjunto de números reais respectivamente. O processo de amostragem pode ser entendido como uma divisão do plano xy em relação a uma grade, com as coordenadas do centro de cada elemento dessa grade representando um par de elementos do produto cartesiano Z^2, que é o conjunto de todos os pares ordenados (z_i, z_j), com z_i e z_j sendo elementos de Z. Dessa forma, $f(x, y)$ é uma imagem digital se (x, y) forem elementos de Z^2 e f for uma função que atribui um valor de intensidade (isto é, um número real do conjunto R) a cada par distinto de coordenadas (x, y). Essa atribuição funcional é o processo de quantização descrito anteriormente. Se os níveis de intensidade também forem números inteiros (como geralmente é o caso neste e em capítulos subsequentes), Z substitui R e uma imagem digital se torna uma função bidimensional cujas coordenadas e valores de amplitude são números inteiros.

Esse processo de digitalização requer que decisões sejam tomadas em relação aos valores de M, N e para o número, L, de níveis discretos de intensidade. Não há restrições para M e N, além do fato de que eles precisam ser números inteiros positivos. No entanto, em virtude de algumas considerações de hardware no processo de armazenamento e quantização, o número de níveis de intensidade costuma ser uma potência inteira de 2:**

$$L = 2^k \quad (2.4\text{-}3)$$

Assumimos que os níveis discretos sejam igualmente espaçados e que sejam números inteiros no intervalo $[0, L - 1]$. Algumas vezes, a faixa de valores cobertos pela escala de cinza é chamada informalmente de faixa dinâmica. Esse é um termo utilizado de forma distinta em diferentes áreas. Aqui, definimos a *faixa dinâmica* de um sistema de aquisição de imagens como a razão da intensidade máxima mensurável pela intensidade mínima detectável no sistema. Como regra, o limite superior é determinado pela *saturação* e o limite inferior pelo *ruído* (veja a Figura 2.19). Basicamente, a faixa dinâmica define os níveis inferior e superior de intensidade que um sistema pode representar e, consequentemente, que uma imagem pode ter. Estreitamente associado a esse conceito temos o *contraste* da imagem, que definimos como a diferença entre os níveis superior e inferior de intensidade presentes em uma imagem. Quando um número significativo de pixels em uma imagem possui uma alta faixa dinâmica, podemos esperar que a imagem tenha um alto contraste. Por outro lado, uma imagem com baixa faixa dinâmica normalmente tem uma aparência embaçada, sem brilho. Discutiremos esses conceitos em mais detalhes no Capítulo 3.

O número, b, de bits necessários para armazenar uma imagem digitalizada é

$$b = M \times N \times k \quad (2.4\text{-}4)$$

Quando $M = N$, essa equação passa a ser

$$b = N^2 k \quad (2.4\text{-}5)$$

* Lembre-se de que um sistema de coordenadas destro é aquele cujo dedo indicador da mão direita aponta para a direção do eixo positivo x, o dedo médio aponta para a direção (perpendicular) do eixo positivo y e o polegar aponta para cima. Conforme a Figura 2.18(a) demonstra, esse é o caso do nosso sistema de coordenadas de imagem.

** Muitas vezes, é útil para fins computationais o no desenvolvimento de algoritmos ajustar os valores de intensidade de L para o intervalo [0, 1], caso no qual eles deixam de ser números inteiros. No entanto, na maioria dos casos, esses valores são novamente ajustados para o intervalo de números ineiros $[0, L - 1]$ para o armazenamento e a exibição de imagens.

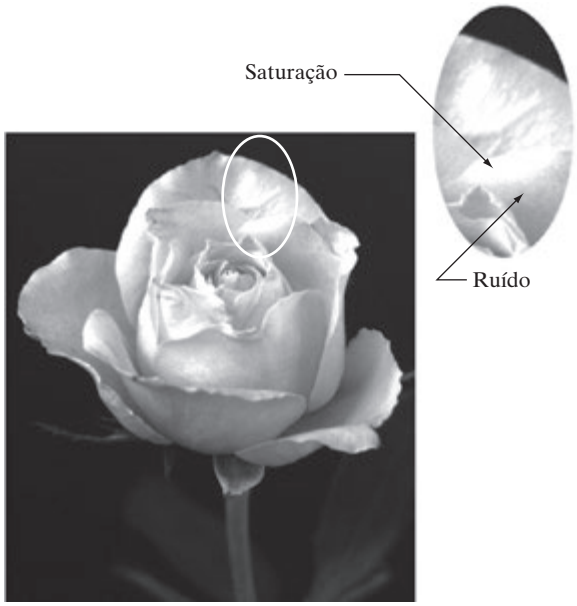


Figura 2.19 Uma imagem ilustrando a saturação e o ruído. A saturação é o valor mais alto além do qual todos os níveis de intensidade são cortados (observe como toda a área saturada tem um nível de intensidade constante e alto). O ruído nesse caso aparece com um padrão de textura granulada. O ruído, especialmente nas regiões mais escuras de uma imagem (por exemplo, o caule da rosa) mascara o menor nível real de intensidade detectável.

A Tabela 2.1 mostra o número de bits necessário para armazenar imagens quadradas com vários valores de N e k. O número de níveis de intensidade correspondente a cada valor de k é mostrado entre parênteses. Quando uma imagem pode ter 2^k níveis de intensidade, é comum nos referirmos a ela como uma "imagem de k bits". Por exemplo, uma imagem com 256 valores discretos possíveis de intensidade é chamada de uma imagem de 8 bits. Observe que os requisitos de armazenamento para imagens de 8 bits de tamanho 1.024×1.024 ou superior são significativos.

2.4.3 Resolução espacial e de intensidade

Intuitivamente, a resolução espacial é uma medida do menor detalhe discernível em uma imagem. Quantitativamente, a *resolução espacial* pode ser expressa em várias formas, sendo que as mais comuns são *pares de linha por unidade de distância* e *pontos* (*pixels*) *por unidade de distância*. Suponha que elaboremos um diagrama com linhas verticais pretas e brancas dispostas alternadamente, cada uma com uma largura de W unidades (W pode ser menor que 1). A largura de um *par de linhas* é, dessa forma, igual a $2W$ e há $1/2W$, e pares de linha por unidade de distância. Por exemplo, se a largura de uma linha for 0,1 mm, temos 5 pares de linha por unidade de distância (mm). Uma definição amplamente utilizada de resolução de imagem é o maior número de pares de linha *discerníveis* por unidade de distância (por exemplo, 100 pares de linha por mm). Pontos por unidade de distância é uma medida de resolução de imagem comumente utilizada por editoras e industrias gráficas. Nos Estados Unidos, essa medida é normalmente expressa como *dots per inch* (pontos por polegada ou dpi). Para dar uma ideia de qualidade, jornais são impressos com uma resolução de 75 dpi, as revistas, com 133 dpi, brochuras em papel couchê em 175 dpi e a página do livro que você está lendo agora é impressa com 2.400 dpi.

O ponto principal do parágrafo anterior é que, para serem significativas, as medidas de resolução espacial devem ser expressas com relação a unidades espaciais. O tamanho da imagem por si só não diz tudo. Dizer que uma imagem tem, digamos, uma resolução de 1.024×1.024 pixels não faz muito sentido se as dimensões espaciais da imagem não forem especificadas. O tamanho sozinho só é útil ao fazer comparações entre capacidade de sistemas de aquisição de imagens. Por exemplo, é possível esperar que uma câmera digital com uma placa de aquisição de

Tabela 2.1 Número de bits de armazenamento para vários valores de N e k. L é o número de níveis de intensidade.

N/k	1 ($L = 2$)	2 ($L = 4$)	3 ($L = 8$)	4 ($L = 16$)	5 ($L = 32$)	6 ($L = 64$)	7 ($L = 128$)	8 ($L = 256$)
32	1.024	2.048	3.072	4.096	5.120	6.144	7.168	8.192
64	4.096	8.192	12.288	16.384	20.480	24.576	28.672	32.768
128	16.384	32.768	49.152	65.536	81.920	98.304	114.688	131.072
256	65.536	131.072	196.608	262.144	327.680	393.216	458.752	524.288
512	262.144	524.288	786.432	1.048.576	1.310.720	1.572.864	1.835.008	2.097.152
1.024	1.048.576	2.097.152	3.145.728	4.194.304	5.242.880	6.291.456	7.340.032	8.388.608
2.048	4.194.304	8.388.608	12.582.912	16.777.216	20.971.520	25.165.824	29.369.128	33.554.432
4.096	16.777.216	33.554.432	50.331.648	67.108.864	83.886.080	100.663.296	117.440.512	134.217.728
8.192	67.108.864	134.217.728	201.326.592	268.435.456	335.544.320	402.653.184	469.762.048	536.870.912

imagens CCD de 20 megapixels tenha mais capacidade de distinguir detalhes do que uma câmera de 8 megapixels, presumindo que as duas câmeras sejam equipadas com lentes similares e que as imagens de comparação sejam obtidas à mesma distância.

De forma similar, a *resolução de intensidade* refere-se à menor variação discernível de nível de intensidade na imagem. Temos considerável liberdade de decisão em relação ao número de amostras utilizadas para gerar uma imagem digital, mas o mesmo não se aplica em relação ao número de níveis de intensidade. Com base em algumas considerações relativas ao hardware, o número de níveis de intensidade normalmente é igual a 2^k, sendo k um número inteiro, como mencionado na seção anterior. O número mais comum é 8 bits, com 16 bits sendo utilizados em algumas aplicações nas quais o realce em determinadas faixas de intensidade é necessária. A quantização de intensidade utilizando 32 bits é rara. Algumas vezes, é possível encontrar sistemas capazes de digitalizar os níveis de intensidade de uma imagem utilizando 10 ou 12 bits, mas essas são as exceções, e não a regra. Diferentemente da resolução espacial, que deve se referir a uma unidade de distância para fazer sentido, é comum se referir ao número de bits utilizados para quantizar a intensidade como *resolução de intensidade*. Por exemplo, é comum dizer que uma imagem cuja intensidade é quantizada em 256 níveis tem 8 bits de resolução de intensidade. Pelo fato de as variações reais de níveis de intensidade discerníveis em uma imagem serem influenciadas não apenas pelo ruído e pela saturação, mas também pelos recursos da percepção humana (veja a Seção 2.1), dizer que uma imagem tem 8 bits de resolução de intensidade não é nada mais do que uma afirmação referente à capacidade de um sistema de 8 bits de quantizar a intensidade em incrementos fixos de 1/256 unidades de amplitude de intensidade.

Os dois exemplos a seguir ilustram individualmente um comparativo dos efeitos do tamanho e da resolução de intensidade da imagem em relação aos detalhes discerníveis. Mais adiante, nesta seção, discutiremos como esses dois parâmetros interagem na determinação da qualidade percebida da imagem.

■

Exemplo 2.2 Exemplo dos efeitos da redução da resolução espacial da imagem.

A Figura 2.20 mostra os efeitos da redução da resolução espacial em uma imagem. As imagens das figuras 2.20(a) a (d) são mostradas em 1.250, 300, 150 e 72 dpi, respectivamente. Naturalmente, as imagens de resolução mais baixa são menores do que a original. Por exemplo, o tamanho da imagem original é de 3.692×2.812 pixels, mas a imagem de 72 dpi é uma matriz de tamanho 213×162. Para facilitar as comparações, todas as imagens menores foram ampliadas (*zoom*) de volta ao tamanho original (o método utilizado para o redimensionamento é discutido na Seção 2.4.4). Isso de certa forma equivale a "se aproximar" das imagens menores para fazer afirmações comparativas sobre os detalhes visíveis.

Observamos algumas pequenas diferenças visuais entre as figuras 2.20(a) e (b), sendo que a mais perceptível é uma ligeira distorção no ponteiro grande preto. Na maior parte, contudo, a Figura 2.20(b) é relativamente aceitável. Com efeito, 300 dpi é a mínima resolução espacial típica de imagem utilizada na publicação de livros, de forma que não se esperaria ver muita diferença aqui. A Figura 2.20(c) começa a mostrar uma degradação visível (veja, por exemplo, as bordas arredondadas do cronômetro e o pequeno ponteiro apontando para o número 60 no lado direito). A Figura 2.20(d) mostra uma degradação visível na maioria dos elementos da imagem. Como discutiremos na Seção 4.5.4, ao imprimir em resoluções tão baixas, as editoras e industrias gráficas utilizam uma série de "truques" (como variar o tamanho dos pixels localmente) para produzir resultados muito melhores do que os da Figura 2.20(d). Além disso, como mostraremos na Seção 2.4.4, é possível melhorar os resultados da Figura 2.20 escolhendo um método de interpolação para ser utilizado.

■

■

Exemplo 2.3 Efeitos típicos da variação do número de níveis de intensidade em uma imagem digital.

Neste exemplo, mantemos constante o número de amostras e reduzimos o número de níveis de cinza (intensidade) de 256 a 2, em potências de 2 com números inteiros. A Figura 2.21(a) é uma imagem de projeção de tomografia computadorizada (CT) de 452×374 pixels, exibida com $k = 8$ (256 níveis de cinza). Imagens como essas são obtidas fixando a fonte de raios X em uma posição e produzindo, dessa forma, uma imagem 2-D em qualquer direção desejada. As imagens de projeção são utilizadas como guias para configurar os parâmetros de um scanner de CT, incluindo a inclinação, o número de fatias e o intervalo.

As figuras 2.21(b) a (h) foram obtidas reduzindo o número de bits de $k = 7$ a $k = 1$ enquanto o tamanho da imagem foi mantido constante em 452×374 pixels. As imagens de 256, 128 e 64 níveis são visualmente idênticas para todas as aplicações práticas. A imagem de 32 níveis mostrada na Figura 2.21(d), entretanto, apresenta uma série imperceptível de pequenos sulcos em áreas de intensidade constante ou praticamente constante (particularmente no crânio). Esse efeito, causado pela utilização de um número insuficiente de níveis de intensidade em áreas suaves de uma imagem digital, é chamado de *falso contorno*, expressão que se deve



Figura 2.20 Efeitos típicos da redução da resolução espacial. Imagens mostradas em: (a) 1.250 dpi, (b) 300 dpi, (c) 150 dpi e (d) 72 dpi. Os quadros foram acrescentados para melhor visualização. Eles não fazem parte dos dados.

ao fato de os sulcos se parecerem com contornos topográfi cos em um mapa. O falso contorno costuma ser bastante visível em imagens exibidas utilizando 16 níveis ou menos níveis de intensidade uniformemente espaçados, como mostram as imagens das figuras 2.21(e) a (h).

Como uma regra bastante aproximada e presumindo, por conveniência, potências inteiras de 2, imagens de tamanho 256 $\times$ 256 pixels com 64 níveis de intensidade e impressas em um formato de tamanho 5 $\times$ 5 cm são praticamente as imagens de menor resolução espacial e de intensidade que é possível se obter razoavelmente livres de falso contorno e do efeito "quadriculado" na amostragem.

Os resultados nos exemplos 2.2 e 2.3 ilustram os efeitos produzidos sobre a qualidade de imagem variando N e k independentemente. No entanto, esses resultados só respondem parcialmente à questão de como a variação de N e k afeta as imagens, porque ainda não levamos em consideração nenhum relacionamento que possa existir entre esses dois parâmetros. Um estudo preliminar conduzido por Huang [1965] tentou quantificar experimentalmente os efeitos sobre a qualidade da imagem produzidos por meio da variação simultânea de N e k. O experimento consistiu em uma série de testes subjetivos. Foram utilizadas imagens similares às mostradas na Figura 2.22. A face da mulher é representativa de imagens com relativamente poucos detalhes; a imagem do cinegrafista contém uma quantidade intermediária de detalhes; e a fotografia da multidão contém, em comparação, uma grande quantidade de detalhes.

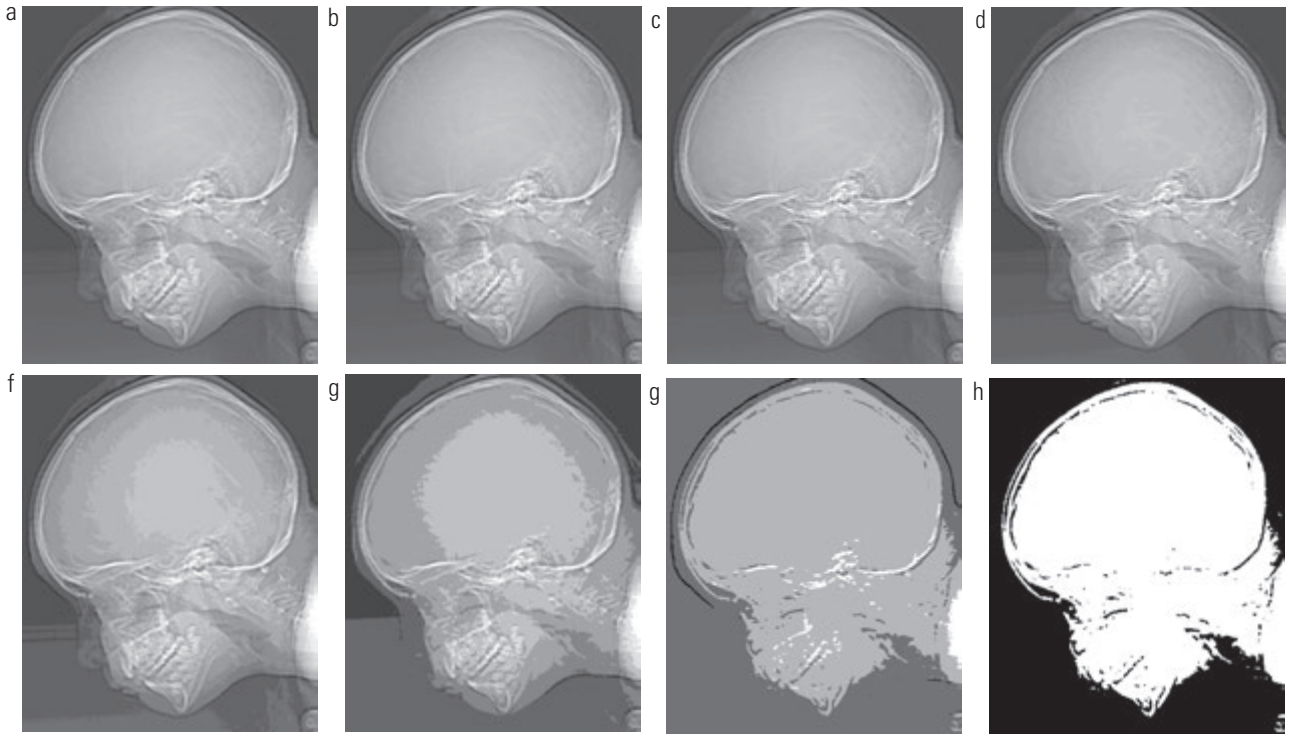


Figura 2.21 (a) Imagem de 452 ×374 com 256 níveis de cinza (intensidade). (b)-(d) Imagem exibida em 128, 64 e 32 níveis de cinza enquanto o tamanho da imagem é mantido constante. (e)-(h) Imagem exibida em 16, 8, 4 e 2 níveis de cinza. (Cortesia original do Dr. David R. Pickens, Departamento de Radiologia e Ciências Radiológicas, Centro Médico da Universidade de Vanderbilt.)

Grupos desses três tipos de imagens foram gerados por meio da variação de N e k, e solicitou-se que os observadores as classificassem de acordo com sua qualidade subjetiva. Os resultados foram resumidos na forma de *curvas de isopreferência* no plano Nk. (A Figura 2.23 mostra curvas de isopreferência média representativas das curvas correspondentes às imagens da Figura 2.22.) Cada ponto do plano Nk representa uma imagem com valores de N e k iguais às coordenadas desse ponto. Os pontos na curva de isopreferência correspondem a imagens de mesma qualidade subjetiva. Durante os experimentos, descobriu-se que as curvas de isopreferência tendiam a se deslocar para a direita e para cima, mas suas formas em cada uma das três categorias de imagem eram similares às da Figura 2.23. Esse não é um resultado inesperado, já que um deslocamento para cima e para direita nas curvas significa simplesmente valores maiores de N e k, o que implica uma melhor qualidade de imagem.



Figura 2.22 (a) Imagem com baixo nível de detalhes. (b) Imagem com nível médio de detalhes. (c) Imagem com uma quantidade relativamente grande de detalhes. (Imagem (b) cortesia do Instituto de Tecnologia de Massachusetts.)

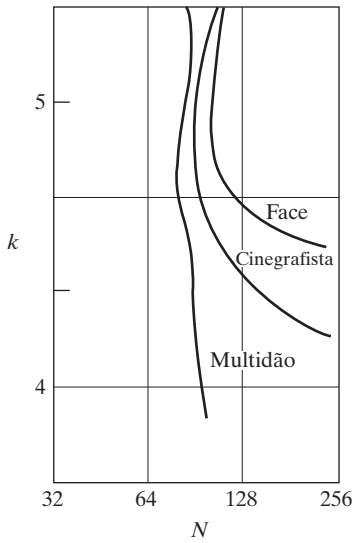


Figura 2.23 Curvas de isopreferência típicas para os três tipos de imagens da Figura 2.22.

O principal ponto de interesse no contexto desta discussão é que as curvas de isopreferência tendem a se tornar mais verticais à medida que os detalhes da imagem aumentam. Esse resultado sugere que, para imagens com um grande número de detalhes, só alguns poucos níveis de intensidade podem ser necessários. Por exemplo, a curva de isopreferência da Figura 2.23 correspondente à multidão é praticamente vertical. Isso indica que, para um valor fixo de N, a qualidade percebida desse tipo de imagem é praticamente independente do número de níveis de intensidade utilizados (para a faixa de níveis de cinza mostrada na Figura 2.23). Também é interessante notar que a qualidade percebida nas outras duas categorias de imagem permaneceu a mesma em alguns intervalos nos quais o número de amostras foi aumentado, mas o número de níveis de intensidade na verdade diminuiu. A razão mais provável para esse resultado é que uma redução de k tende a aumentar o contraste aparente, um efeito visual que os humanos muitas vezes percebem como uma melhoria na qualidade de uma imagem.

2.4.4 Interpolação de imagens

A interpolação é uma ferramenta básica utilizada extensivamente em tarefas como ampliação, redução, rotação e correções geométricas. Nosso principal objetivo nesta seção é apresentar a interpolação e aplicá-la ao redimensionamento de imagens (redução e ampliação), que são basicamente métodos de *reamostragem* de imagens. As utilizações da interpolação em aplicações como rotação e correções geométricas serão discutidas na Seção 2.6.5. Retomaremos esse tópico também no Capítulo 4, quando discutiremos a reamostragem de imagens em mais detalhes.

Essencialmente, a *interpolação* é o processo que utiliza dados conhecidos para estimar valores em pontos desconhecidos. Damos início à discussão desse tópico com um exemplo simples. Suponha que uma imagem de tamanho 500 × 500 pixels deva ser ampliada uma vez e meia, resultando em uma imagem de 750 × 750 pixels (ampliação de 1,5 ×). Uma maneira simples de visualizar a ampliação é criar uma grade imaginária 750 × 750 com o mesmo espaçamento de pixels da imagem original e, então, reduzi-la de forma que se encaixe exatamente sobre a imagem original. Obviamente, o espaçamento de pixels na grade 750 × 750 após a redução será menor que o espaçamento de pixels na imagem original. Para realizar a atribuição de nível de intensidade para os pontos da imagem sobreposta, procuramos o pixel mais próximo na imagem original e atribuímos a intensidade desse pixel ao novo pixel na grade 750 × 750 reduzida. Quando terminamos de atribuir as intensidades a todos os pontos da grade sobreposta, nós a expandimos para o tamanho original a fim de obter a imagem ampliada.

O método que acabamos de discutir é chamado de *interpolação por vizinho mais próximo* porque atribui a cada nova posição a intensidade de seu vizinho mais próximo na imagem original (as vizinhanças de pixels serão descritas formalmente na Seção 2.5). Esse método é simples, mas, como mostraremos mais adiante nesta seção, tem a tendência de produzir artefatos indesejáveis na imagem, como uma grande distorção nas bordas retas. Por essa razão, ela é pouco utilizada na prática. Uma abordagem mais apropriada é a *interpolação bilinear*, na qual utilizamos os quatro vizinhos mais próximos para estimar a intensidade de uma dada posição. Digamos que (x, y) expresse as coordenadas da posição na qual queremos atribuir um valor de intensidade (pense nela como um ponto da grade descrita anteriormente), e que $v(x, y)$ expresse o valor da intensidade. Para a interpolação bilinear* o valor atribuído é obtido utilizando a equação:

$$v(x, y) = ax + by + cxy + d \qquad (2.4\text{-}6)$$

onde os quatro coeficientes são determinados a partir das quatro equações de quatro incógnitas que podem ser escritas utilizando os quatro vizinhos mais próximos do ponto (x, y). Como veremos em breve, a interpolação bi-

* Ao contrário do que o nome sugere, observe que a interpolação bilinear *não* é linear em virtude do termo xy.

linear proporciona resultados muito melhores do que a interpolação por vizinho mais próximo, com um pequeno aumento de custo computacional.

O próximo nível de complexidade é a *interpolação bicúbica*, que inclui os 16 vizinhos mais próximos de um ponto. O valor da intensidade atribuído ao ponto (x, y) é obtido utilizando a equação:

$$v(x, y) = \sum_{i=0}^{3} \sum_{j=0}^{3} a_{ij} x^i y^j \qquad (2.4\text{-}7)$$

onde os 16 coeficientes são determinados a partir das 16 equações de 16 incógnitas que podem ser escritas utilizando os 16 vizinhos mais próximos do ponto (x, y). Observe que a Equação 2.4-7 tem sua forma reduzida à Equação 2.4-6 se os limites de ambos os somatórios da equação anterior forem de 0 a 1. Em geral, a interpolação bicúbica é melhor na preservação de detalhes finos em comparação com a interpolação bilinear. A interpolação bicúbica é o padrão utilizado em programas comerciais de edição de imagens, como o Adobe Photoshop e o Corel Photopaint.

■

Exemplo 2.4 Comparação dos métodos de interpolação para a redução e a ampliação de imagens.

A Figura 2.24(a) mostra a mesma imagem da Figura 2.20(d), que foi obtida reduzindo a resolução da imagem de 1.250 dpi da Figura 2.20(a) para 72 dpi (o tamanho foi reduzido do tamanho original de 3.692 × 2.812 para 213 × 162 pixels) e depois ampliando a imagem reduzida de volta a seu tamanho original. Para gerar a Figura 2.20(d), utilizamos a interpolação por vizinho mais próximo tanto para reduzir quanto para ampliar a imagem. Como observado anteriormente, o resultado da Figura 2.24(a) é relativamente insatisfatório. As figuras 2.24(b) e (c) são os resultados da repetição do mesmo procedimento, mas desta vez utilizando, respectivamente, a interpolação bilinear e bicúbica tanto para a redução quanto para a ampliação. O resultado obtido pela utilização da interpolação bilinear representa uma melhoria significativa em relação à interpolação por vizinho mais próximo. O resultado da interpolação bicúbica é ligeiramente mais nítido que a imagem bilinear. A Figura 2.24(d) mostra a mesma imagem que a Figura 2.20(c), que foi obtida utilizando a interpolação por vizinho mais próximo tanto para a redução quanto para a ampliação. Comentamos na discussão dessa figura que a redução da resolução

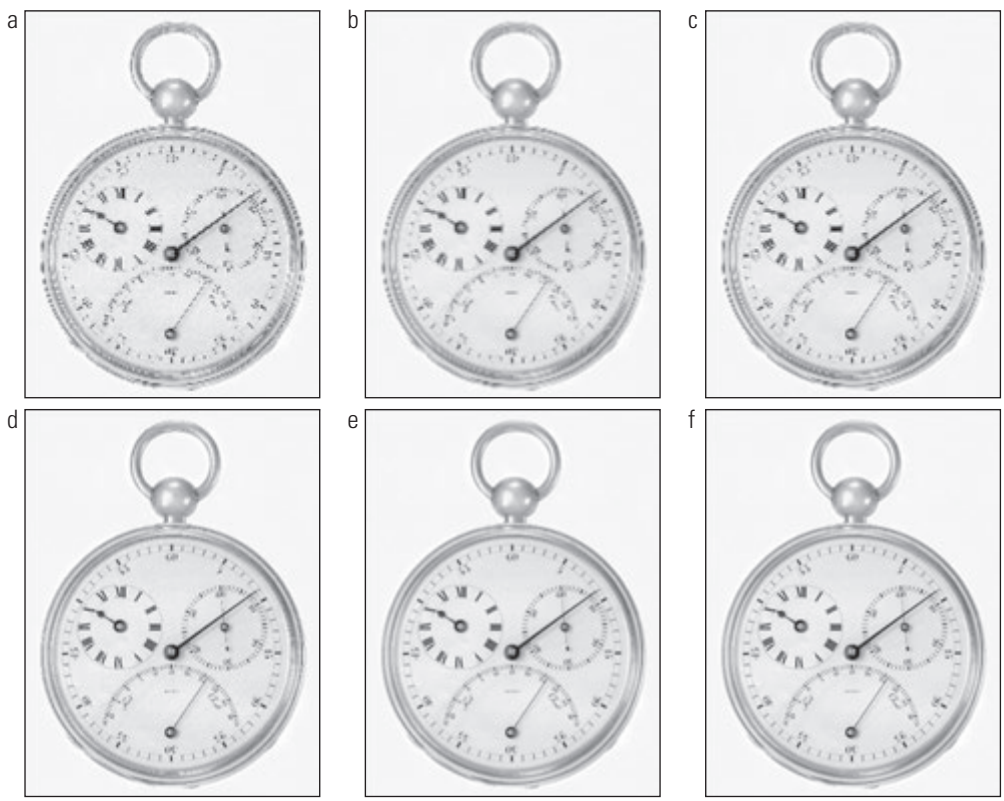


Figura 2.24 (a) Imagem com resolução reduzida para 72 dpi e tamanho ampliado de volta ao original (3.692 × 2.812 pixels) utilizando a interpolação por vizinho mais próximo. A figura mostra a mesma imagem que a Figura 2.20(d). (b) Imagem reduzida e ampliada utilizando a interpolação bilinear. (c) O mesmo que (b), mas utilizando a interpolação bicúbica. (d)-(f) Mesma sequência, mas reduzindo a resolução para 150 dpi em vez de 72 dpi (A Figura 2.24(d) é a mesma que a Figura 2.20(c)). Compare as figuras 2.24(e) e (f), especialmente a última, com a imagem original na Figura 2.20(a).

para 150 dpi começou a mostrar degradações na imagem. As figuras 2.24(e) e (f) mostram os resultados da utilização da interpolação bilinear e bicúbica, respectivamente, para reduzir e ampliar essa imagem. Apesar de uma redução de resolução de 1.250 a 150 dpi, essas duas últimas imagens se comparam de forma razoavelmente favorável com a original, demonstrando mais uma vez o poder desses dois métodos de interpolação. Como no caso anterior, a interpolação bicúbica gerou resultados ligeiramente mais nítidos.

■

É possível utilizar mais vizinhos na interpolação e existem técnicas mais complexas, como a utilização de *splines* e *wavelets*, que, em alguns casos, podem gerar resultados melhores do que os métodos que acabamos de discutir. Apesar de a preservação dos detalhes finos ser um fator excepcionalmente importante na geração de imagens para gráficos 3-D (Watt [1993], Shirley [2002]) e no processamento de imagens médicas (Lehmann et al. [1999]), o custo computacional adicional raramente se justifica para o processamento digital de imagens de uso geral, no qual a interpolação bilinear ou bicúbica normalmente são os métodos preferidos.

2.5 Alguns relacionamentos básicos entre pixels

Nesta seção, levaremos em consideração várias relações importantes entre pixels em uma imagem digital. Como mencionado anteriormente, uma imagem é expressa por $f(x, y)$. Nesta seção, ao nos referirmos a um pixel particular, utilizaremos letras minúsculas, como p e q.

2.5.1 Vizinhos de um pixel

Um pixel p na coordenada (x, y) tem quatro vizinhos *horizontais* e *verticais* cujas coordenadas são dadas por:

$$(x + 1, y), (x - 1, y), (x, y + 1), (x, y - 1)$$

Esse conjunto de pixels, chamado de *vizinhança-4* de p, é expresso por $N_4(p)$. Cada pixel é uma unidade de distância de (x, y), e alguns vizinhos de p ficarão para fora da imagem digital se (x, y) estiver na borda da imagem. Lidaremos com esta questão no Capítulo 3.

Os quatro vizinhos *diagonais* de p têm coordenadas:

$$(x + 1, y + 1), (x + 1, y - 1), (x - 1, y + 1), (x - 1, y - 1)$$

que são expressas por $N_D(p)$. Esses pontos, junto com a vizinhança-4, são chamados de *vizinhança-8* de p, expressos por $N_8(p)$. Como no caso anterior, alguns vizinhos em $N_D(p)$ e $N_8(p)$ ficarão para fora da imagem se (x, y) se localizar na borda da imagem.

2.5.2 Adjacência, conectividade, regiões e fronteiras

Expressamos por V o conjunto de valores de intensidade utilizados para definir a adjacência. Em uma imagem binária, $V = \{1\}$, se estivermos nos referindo à adjacência de pixels com valor igual a 1. Em uma imagem de escala de cinza, a ideia é a mesma, mas o conjunto V normalmente contém mais elementos. Por exemplo, na adjacência de pixels com uma variação de possíveis valores de nível de cinza de 0 a 255, o conjunto V poderia ser qualquer subconjunto desses 256 valores. Consideramos três tipos de adjacência:*

(a) *Adjacência-4*. Dois pixels p e q com valores pertencendo a V são adjacentes-4 se q estiver no conjunto $N_4(p)$.

(b) *Adjacência-8*. Dois pixels p e q com valores pertencendo a V são adjacentes-8 se q estiver no conjunto $N_8(p)$.

(c) *Adjacência-m* (adjacência mista). Dois pixels p e q com valores pertencendo a V são adjacentes-m se

(i) q estiver em $N_4(p)$, *ou*

(ii) q estiver em $N_D(p)$ e o conjunto $N_4(p) \cap N_4(q)$ não contiver nenhum pixel cujos valores pertençam a V.

A adjacência mista é uma modificação da adjacência-8. Ela foi criada para eliminar as ambiguidades que muitas vezes surgem com a utilização da adjacência-8. Por exemplo, considere o arranjo de pixels mostrado na Figura 2.25(a) para $V = \{1\}$. Os três pixels da parte superior da Figura 2.25(b) mostram uma adjacência-8 múltipla (ambígua), como indica as linhas tracejadas. Essa ambiguidade é eliminada utilizando a adjacência-m, como mostra a Figura 2.25(c).

Um *caminho* (ou *curva*) *digital* do pixel p com coordenadas (x, y) ao pixel q com coordenadas (s, t) é uma sequência de pixels distintos com coordenadas:

$$(x_0, y_0), (x_1, y_1), \ldots, (x_n, y_n)$$

onde $(x_0, y_0) = (x, y)$, $(x_n, y_n) = (s, t)$, e os pixels (x_i, y_i) e (x_{i-1}, y_{i-1}) são adjacentes para $1 \leq i \leq n$. Nesse caso, n é o *comprimento* do caminho. Se $(x_0, y_0) = (x_n, y_n)$, o caminho é *fechado*. Podemos definir caminhos –4, –8 ou –m, dependendo do tipo da adjacência especificada. Por exemplo, os caminhos mostrados na Figura 2.25(b) entre os pontos

* Utilizamos os símbolos ∩ e ∪, para expressar interseção e união, respectivamente. Dados os conjuntos A e B, lembre-se que a *interseção* entre eles equivale ao conjunto de elementos pertencentes tanto a A quanto a B. A *união* desses dois conjuntos é o conjunto de elementos que pertencem a A, a B ou a ambos. Discutiremos os conjuntos em mais detalhes na Seção 2.6.4.

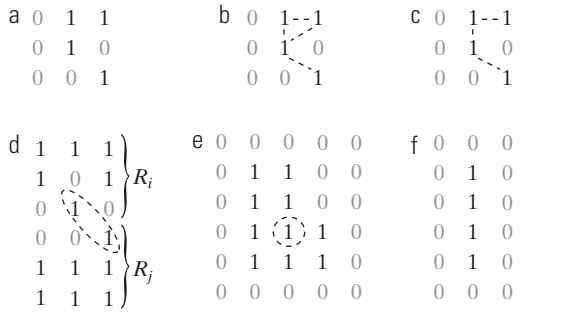


Figura 2.25 (a) Um arranjo de pixels. (b) Pixels que são adjacentes-8 (a adjacência é mostrada em linhas tracejadas; observe a ambiguidade). (c) adjacência-m. (d) Duas regiões (de 1s) que são adjacentes se a adjacência-8 for utilizada. (e) O ponto circulado é parte da fronteira dos pixels de valor 1 somente se a adjacência-8 entre a região e o fundo for utilizada. (f) A fronteira interna da região de valor 1 não forma um caminho fechado, mas sua fronteira externa, sim.

superior direito e inferior direito são caminhos –8 e o caminho na Figura 2.25(c) é um caminho-*m*.

Com S representando um subconjunto de pixels em uma imagem, dizemos que dois pixels p e q são *conexos* em S se houver um caminho entre eles consistindo inteiramente de pixels em S. Para qualquer pixel p em S, o *conjunto* de pixels que são conectados a ele em S é chamado de um *componente conexo* de S. Se existir apenas um componente conectado, o conjunto S é chamado de um *conjunto conexo*.

Com R representando um subconjunto de pixels em uma imagem, chamamos de R uma *região* da imagem se R for um conjunto conexo. Dizemos que duas regiões, R_i e R_j, são consideradas *adjacentes* se sua união formar um conjunto conexo. Dizemos que as regiões que não são adjacentes são *disjuntas*. Consideramos a adjacência-4 e -8 ao nos referirmos a regiões. Para que nossa definição faça sentido, o tipo de adjacência utilizada deve ser especificado. Por exemplo, as duas regiões (de 1 s) na Figura 2.25(d) são adjacentes somente se a adjacência-8 for utilizada (de acordo com a definição apresentada no parágrafo anterior, não existe um caminho-4 entre as duas regiões, de forma que sua união não é um conjunto conexo).

Suponha que uma imagem contenha K regiões disjuntas, R_k, $k = 1, 2, \ldots, K$, nenhuma das quais toca a borda da imagem.* Expressamos por R_u a união de todas as regiões K e por $(R_u)^c$, seu complemento (lembre que o *complemento* de um conjunto S é o conjunto de pontos que não estão em S). Chamamos todos os pontos em R_u de *frente* (*foreground*) e todos os pontos em $(R_u)^c$ de *fundo* (*background*) da imagem.

A *fronteira* (também chamada de *borda* ou *contorno*) de uma região R é o conjunto de pontos adjacentes aos pontos do complemento de R. Dito de outra forma, a fronteira de uma região é o conjunto de pixels da região que tem pelo menos um vizinho no fundo da imagem. Mais uma vez, devemos especificar a conectividade sendo utilizada para definir a adjacência. Por exemplo, o ponto circulado na Figura 2.25(e) não pertence à fronteira da região de valor 1 se a conectividade-4 for utilizada entre a região e seu fundo. Como regra, a adjacência entre pontos em uma região e seu fundo é definida em termos de conectividade-8 para lidar com situações como essas.

A definição anterior algumas vezes é chamada de *contorno interno* da região, para distingui-la do *contorno externo*, que é o contorno correspondente no fundo. Essa distinção é importante no desenvolvimento de algoritmos chamados de seguidores de contorno (*border following*). Esses algoritmos costumam ser formulados para seguir o contorno externo de uma região de modo a garantir que o resultado formará um caminho fechado. Por exemplo, o contorno interno da região de valor 1 da Figura 2.25(f) é a própria região. Esse contorno não satisfaz a definição de um caminho fechado apresentada anteriormente. Por outro lado, o contorno externo da região acaba formando um caminho fechado ao redor dessa região.

Se R for a imagem inteira (que, lembramos, é um conjunto retangular de pixels), sua fronteira será definida como o conjunto de pixels da primeira e última linha e da primeira e última coluna da imagem. Essa definição adicional é necessária porque uma imagem não tem vizinhos além de sua fronteira. Normalmente, quando nos referimos a uma região, estamos nos referindo a um subconjunto de uma imagem e quaisquer pixels na fronteira da região que coincidirem com a fronteira da imagem são incluídos implicitamente como parte da fronteira da região.

O conceito de *borda* é encontrado com frequência em discussões sobre regiões e fronteiras. No entanto, existe uma importante diferença entre esses conceitos. A *fronteira* de uma região finita forma um caminho fechado e, assim, é um conceito "global". Como discutiremos em detalhes no Capítulo 10, as *bordas* são formadas por pixels com valores cujas derivadas excedem um limiar pré-definido. Dessa maneira, a ideia de uma borda é um conceito "local" baseado em uma medida de descontinuidade de

* Usamos essa premissa para evitar ter de lidar com casos especiais. Isso é feito sem perda de generalização porque, se uma ou mais regiões tocarem a fronteira de uma imagem, podemos simplesmente preencher a imagem com uma borda de 1 pixel de largura com valores do fundo.

nível de intensidade em um ponto. É possível ligar os pontos da borda em segmentos de borda e, algumas vezes, esses segmentos são ligados de modo a corresponder a uma fronteira, mas nem sempre esse é o caso. A única exceção na qual as bordas e as fronteiras se correspondem é em imagens binárias. Dependendo do tipo da conectividade e dos operadores de borda utilizados (discutiremos esses fatores no Capítulo 10), a borda extraída de uma região binária será a mesma que a fronteira da região.

Isso é intuitivo. Conceitualmente, até chegarmos ao Capítulo 10, é útil pensar nas bordas como descontinuidade de intensidade e nas fronteiras como caminhos fechados.

2.5.3 Medidas de distância

Para os pixels p, q e z, com coordenadas (x, y), (s, t) e (v, w), respectivamente, D é uma *função distância* ou *medida de distância* se

(a) $D(p, q) \geq 0 \quad (D(p, q) = 0 \text{ se } p = q)$,

(b) $D(p, q) = D(q, p)$ e

(c) $D(p, z) \leq D(p, q) + D(q, z)$.

A *distância euclidiana* entre p e q é definida como:

$$D_e(p, q) = \left[(x - s)^2 + (y - t)^2\right]^{\frac{1}{2}} \tag{2.5-1}$$

Para essa medida de distância, os pixels que possuem distância de (x, y) menor ou igual a um valor r são os pontos contidos em um disco de raio r centrado em (x, y).

A *distância* D_4 (chamada de *distância city block*) entre p e q é definida como:

$$D_4(p, q) = |x - s| + |y - t| \tag{2.5-2}$$

Neste caso, os pixels que têm uma distância D_4 de (x, y) menor ou igual a um valor r formam um losango centrado em (x, y). Por exemplo, os pixels com uma distância $D_4 \leq 2$ de (x, y) (o ponto central) formam os seguintes contornos de distância constante:

$$\begin{array}{ccccc} & & 2 & & \\ & 2 & 1 & 2 & \\ 2 & 1 & 0 & 1 & 2 \\ & 2 & 1 & 2 & \\ & & 2 & & \end{array}$$

Os pixels com $D_4 = 1$ são os vizinhos-4 de (x, y).

A *distância* D_8 (chamada de *distância chessboard*) entre p e q é definida como:

$$D_8(p, q) = \text{máx}\,(|x - s|, |y - t|) \tag{2.5-3}$$

Neste caso, os pixels que têm uma distância D_8 de (x, y) menor ou igual a um valor r formam um quadrado centrado em (x, y). Por exemplo, os pixels com uma distância $D_8 \leq 2$ de (x, y) (o ponto central) formam os seguintes contornos de distância constante:

$$\begin{array}{ccccc} 2 & 2 & 2 & 2 & 2 \\ 2 & 1 & 1 & 1 & 2 \\ 2 & 1 & 0 & 1 & 2 \\ 2 & 1 & 1 & 1 & 2 \\ 2 & 2 & 2 & 2 & 2 \end{array}$$

Os pixels com $D_8 = 1$ são os vizinhos-8 de (x, y).

Observe que as distâncias D_4 e D_8 entre p e q são independentes de quaisquer caminhos que possam existir entre os pontos porque essas distâncias envolvem apenas as coordenadas dos pontos. Se optarmos por considerar a adjacência-m, contudo, a distância D_m entre dois pontos é definida como o caminho-m mais curto entre os pontos. Nesse caso, a distância entre dois pixels dependerá dos valores dos pixels ao longo do caminho, bem como dos valores dos pixels vizinhos. Por exemplo, para o arranjo de pixels mostrado a seguir, assuma que p, p_2 e p_4 tenham valor 1 e que p_1 e p_3 possam ter valor 0 ou 1:

$$\begin{array}{cc} p_3 & p_4 \\ p_1 & p_2 \\ p & \end{array}$$

Suponha que consideremos que o valor da adjacência de pixels seja igual a 1 (isto é, $V = \{1\}$). Se p_1 e p_3 são 0, a extensão do caminho-m mais curto (a distância D_m) entre p e p_4 é igual a 2. Se p_1 é 1, então p_2 e p não serão mais adjacentes-m (veja a definição da adjacência-m) e a extensão do caminho-m mais curto passa a ser 3 (o caminho passa pelos pontos $pp_1p_2p_4$). O mesmo ocorre se p_3 for 1 (e p_1 for 0); então, a extensão do caminho-m mais curto também é 3. Finalmente, se tanto p_1 quanto p_3 forem iguais a 1, a extensão do caminho-m mais curto entre p e p_4 é igual a 4. Nesse caso, o caminho passa pela sequência de pontos $pp_1p_2p_3p_4$.

2.6 Uma introdução às ferramentas matemáticas utilizadas no processamento digital de imagens*

Esta seção tem dois objetivos principais: (1) apresentar as várias ferramentas matemáticas que utilizamos ao longo

* Antes de continuar, pode ser útil para você baixar e estudar o material de revisão disponível na seção de Tutoriais no site do livro. A revisão cobre o material introdutório sobre matrizes e vetores, sistemas lineares, teoria de conjuntos e probabilidade.

deste livro; e (2) ajudá-lo a começar a ter uma "ideia" de como essas ferramentas são utilizadas aplicando-as a uma série de tarefas básicas de processamento de imagens, algumas das quais serão utilizadas várias vezes em discussões subsequentes. Expandiremos o escopo das ferramentas e suas aplicações quando necessário nos capítulos a seguir.

2.6.1 Operações de arranjos matriciais *versus* matrizes

Uma operação de *arranjo matricial* envolvendo uma ou mais imagens é realizada *pixel a pixel*. Mencionamos anteriormente, neste capítulo, que as imagens podem ser vistas de modo equivalente como matrizes. De fato, há muitas situações nas quais as operações entre as imagens são realizadas utilizando a teoria das matrizes (veja a Seção 2.6.6). É por essa razão que deve ser feita uma distinção clara entre operações de arranjos matriciais e matrizes. Por exemplo, vejamos as seguintes imagens 2×2:

$$\begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} \quad \text{e} \quad \begin{bmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \end{bmatrix}$$

O *produto do arranjo matricial* dessas duas imagens é:

$$\begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} \begin{bmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \end{bmatrix} = \begin{bmatrix} a_{11}b_{11} & a_{12}b_{12} \\ a_{21}b_{21} & a_{22}b_{22} \end{bmatrix}$$

Por outro lado, o *produto da matriz* é dado por:

$$\begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} \begin{bmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \end{bmatrix} = \begin{bmatrix} a_{11}b_{11} + a_{12}b_{21} & a_{11}b_{12} + a_{12}b_{22} \\ a_{21}b_{11} + a_{22}b_{21} & a_{21}b_{12} + a_{22}b_{22} \end{bmatrix}$$

Utilizaremos as operações de arranjo matricial ao longo deste livro, a não ser que seja especificado de outra forma. Por exemplo, quando nos referimos a elevar uma imagem a uma potência, queremos dizer que cada pixel individual é elevado a essa potência; quando nos referimos a dividir uma imagem por outra, queremos dizer que a divisão é feita entre os pares de pixels correspondentes, e assim por diante.

2.6.2 Operações lineares *versus* não lineares

Uma das classificações mais importantes de um método de processamento de imagens é em *linear* ou *não linear*. Considere um operador geral, H, que produza uma imagem de saída, $g(x, y)$, para uma dada imagem de entrada, $f(x, y)$:

$$H[f(x, y)] = g(x, y) \tag{2.6-1}$$

Diz-se que H é um *operador linear* se

$$\begin{aligned} H\left[a_i f_i(x, y) + a_j f_j(x, y)\right] &= a_i H\left[f_i(x, y)\right] + a_j H\left[f_j(x, y)\right] \\ &= a_i g_i(x, y) + a_j g_j(x, y) \end{aligned} \tag{2.6-2}$$

onde a_i, a_j, $f_i(x, y)$ e $f_j(x, y)$ são, respectivamente, constantes e imagens arbitrárias (do mesmo tamanho). A Equação 2.6-2 indica que a saída de uma operação linear em decorrência da soma de duas entradas é o mesmo que realizar essa operação para as entradas individualmente e depois somar os resultados. Além disso, a saída de uma operação linear da multiplicação de uma constante por uma entrada é igual à saída da operação em virtude da entrada original multiplicada por essa constante. A primeira propriedade é chamada de propriedade de *aditividade* e a segunda é chamada de propriedade da *homogeneidade*.

A título de um exemplo simples, suponha que H seja o operador de somatória, Σ; isto é, que a função desse operador seja simplesmente somar suas entradas. Para testar a linearidade, começamos com o lado esquerdo da Equação 2.6-2 e tentamos provar que ele é igual ao lado direito:*

$$\begin{aligned} \sum\left[a_i f_i(x, y) + a_j f_j(x, y)\right] &= \sum a_i f_i(x, y) + \sum a_j f_j(x, y) \\ &= a_i \sum f_i(x, y) + a_j \sum f_j(x, y) \\ &= a_i g_i(x, y) + a_j g_j(x, y) \end{aligned}$$

sendo que o primeiro passo resulta do fato de que o somatório é distributivo. Dessa forma, uma expansão do lado esquerdo é igual ao lado direito da Equação 2.6-2 e concluímos que o operador de soma é linear.

Por outro lado, considere a operação *máx*, cuja função é calcular o valor máximo dos pixels em uma imagem. Para nossos propósitos aqui, a forma mais simples de provar que esse operador é não linear é encontrar um exemplo que não passe no teste da Equação 2.6-2. Consideremos as duas imagens a seguir

$$f_1 = \begin{bmatrix} 0 & 2 \\ 2 & 3 \end{bmatrix} \quad \text{e} \quad f_2 = \begin{bmatrix} 6 & 5 \\ 4 & 7 \end{bmatrix}$$

e suponha que $a_1 = 1$ e $a_2 = -1$. Para testar a linearidade, mais uma vez começamos com o lado esquerdo da Equação 2.6-2:

* Esses são somatórios de arranjo, não as somas de todos os elementos das imagens. Dessa forma, a soma de uma única imagem é a própria imagem.

$$\text{máx}\left\{(1)\begin{bmatrix} 0 & 2 \\ 2 & 3 \end{bmatrix}+(-1)\begin{bmatrix} 6 & 5 \\ 4 & 7 \end{bmatrix}\right\}$$
$$=\text{máx}\left\{\begin{bmatrix} -6 & -3 \\ -2 & -4 \end{bmatrix}\right\}=-2$$

Passando em seguida para o lado direto, temos

$$(1)\text{máx}\left\{\begin{bmatrix} 0 & 2 \\ 2 & 3 \end{bmatrix}\right\}+(-1)\text{máx}\left\{\begin{bmatrix} 6 & 5 \\ 4 & 7 \end{bmatrix}\right\}$$
$$=3+(-1)7=-4$$

Os lados esquerdo e direito da Equação 2.6-2 não são iguais neste caso, logo provamos que em geral o operador *máx* é não linear.

Como veremos nos três capítulos a seguir, especialmente nos capítulos 4 e 5, as operações lineares são extremamente importantes porque se baseiam em um grande volume de resultados teóricos e práticos aplicáveis ao processamento de imagens. Os sistemas não lineares não são tão bem compreendidos, de forma que seu escopo de aplicação é mais limitado. No entanto, veremos nos capítulos seguintes vários operadores não lineares de processamento de imagens cujo desempenho excede significativamente o que pode ser realizado pelos operadores lineares correspondentes.

2.6.3 Operações aritméticas

As operações aritméticas entre imagens são operações de arranjo matricial que, como discutimos na Seção 2.6.1, significam que as operações aritméticas são realizadas entre pares de pixels correspondentes. As quatro operações aritméticas são expressas como

$$\begin{aligned} s(x, y) &= f(x, y) + g(x, y) \\ d(x, y) &= f(x, y) - g(x, y) \\ p(x, y) &= f(x, y) \times g(x, y) \\ v(x, y) &= f(x, y) \div g(x, y) \end{aligned} \tag{2.6-3}$$

Sabe-se que as operações são realizadas entre pares de pixels correspondentes em f e g para $x = 0, 1, 2,\ldots, M-1$ e $y = 0, 1, 2,\ldots, N-1$, sendo M e N, respectivamente, os tamanhos de linha e coluna das imagens. Claramente, s, d, p e v também são imagens de tamanho $M \times N$. Observe que a aritmética de imagem da forma que acabamos de definir envolve imagens do mesmo tamanho. Os exemplos a seguir indicam o importante papel exercido pelas operações aritméticas no processamento digital de imagens.

■

Exemplo 2.5 Adição (para cálculo da média) de imagens ruidosas para a redução de ruídos.*

Com $g(x, y)$ expressando uma imagem corrompida formada pela adição de ruído, $\eta(x, y)$, a uma imagem sem ruído $f(x, y)$, isto é:

$$g(x,y) = f(x,y) + \eta(x,y) \tag{2.6-4}$$

onde assumimos que, para cada par de coordenadas (x, y), o ruído não tem correlação** e tem valor médio zero. O objetivo do procedimento a seguir é reduzir o ruído por meio da adição de um conjunto de imagens ruidosas, $\{g_i(x, y)\}$. Esta é uma técnica utilizada frequentemente para o realce de imagens.

Se o ruído satisfizer as condições mencionadas anteriormente, pode ser demonstrado (Exercício 2.20) que, se uma imagem $\bar{g}(x,y)$ for formada pela média de K diferentes imagens ruidosas:

$$\bar{g}(x, y) = \frac{1}{K}\sum_{i=1}^{K} g_i(x, y) \tag{2.6-5}$$

segue-se que

$$E\{\bar{g}(x, y)\} = f(x, y) \tag{2.6-6}$$

e

$$\sigma^2_{\bar{g}(x,y)} = \frac{1}{K}\sigma^2_{\eta(x,y)} \tag{2.6-7}$$

onde $E\{\bar{g}(x,y)\}$ é o valor esperado de $\bar{g}$, e $\sigma^2_{\bar{g}(x,y)}$ e $\sigma^2_{\eta(x,y)}$ são, respectivamente, as variâncias de $\bar{g}$ e η, todas nas coordenadas (x, y). O desvio padrão (raiz quadrada da variância) em qualquer ponto da imagem média é

$$\sigma_{\bar{g}(x,y)} = \frac{1}{\sqrt{K}}\sigma_{\eta(x,y)} \tag{2.6-8}$$

As equações 2.6-7 e 2.6-8 indicam que, à medida que K aumenta, a variabilidade (medida pela variância ou pelo desvio padrão) dos valores de pixels em cada posição (x, y) diminui. Como $E\{\bar{g}(x,y)\} = f(x,y)$, isso significa que $\bar{g}(x,y)$ se aproxima de $f(x,y)$ à medida que o número de imagens ruidosas utilizadas no processo de cálculo da média aumenta. Na prática, as imagens $g_i(x, y)$ devem ser *registradas* (alinhadas) para evitar o acréscimo de borramento e outros artefatos na imagem de saída.

Uma importante aplicação da média de imagens é realizada no campo da astronomia, no qual a aquisição de imagens

* As imagens mostradas neste exemplo são de um par de galáxias chamado de NGC 3314, capturadas pelo telescópio espacial Hubble, da Nasa. O NGC 3314 se localiza a cerca de 140 milhões de anos-luz da Terra, na direção do hemisfério sul da constelação Hydra. As estrelas brilhantes que formam um cata-vento próximo ao centro da galáxia central são formadas de gás e poeira interestelar.

** Lembre-se de que a variância de uma variável aleatória z com média m é definida como $E[(z-m)^2]$, onde $E\{\cdot\}$ é o valor esperado do argumento. A covariância de duas variáveis aleatórias z_i e z_j é definida como $E[(z_i - m_i)\,(z_j - m_j)]$. Se as variáveis não têm correlação, sua covariância é 0.

em níveis muito baixos de iluminação frequentemente provoca ruído de sensores, que faz com que a representação por imagens isoladas seja praticamente inútil para a análise. A Figura 2.26(a) mostra uma imagem de 8 bits na qual a corrupção foi simulada com a adição de ruído gaussiano de média zero e desvio padrão de 64 níveis de intensidade. Essa imagem, típica de imagens com ruído obtidas em condições de baixa iluminação, é inútil para quaisquer objetivos práticos. As figuras 2.26(b) a (f) mostram os resultados da média de 5, 10, 20, 50 e 100 imagens, respectivamente. Vemos que o resultado da Figura 2.26(e), obtida com $K = 50$, é relativamente limpo. A imagem da Figura 2.26(f), resultante do cálculo da média de 100 imagens ruidosas, representa apenas uma pequena melhoria em relação à imagem da Figura 2.26(e).

A adição é uma versão discreta de uma integração contínua. Em observações astronômicas, um processo equivalente ao método que acabamos de descrever é utilizar os recursos de integração do CCD (veja a Seção 2.3.3) ou sensores similares para a redução de ruído observando a mesma cena por longos períodos. O resfriamento também é utilizado para reduzir o ruído do sensor. O efeito geral, entretanto, é análogo ao cálculo da média de um conjunto de imagens digitais com ruído.

■

■

Exemplo 2.6 Subtração de imagens para realce de diferenças.

Uma aplicação frequente da subtração de imagens é no realce de *diferenças* entre as imagens. Por exemplo, a imagem da Figura 2.27(b) foi obtida zerando os bits menos significativos de todos os pixels da Figura 2.27(a). Visualmente, essas imagens são exatamente iguais. Contudo, como mostra a Figura 2.27(c), subtrair uma imagem da outra mostra claramente suas diferenças. Valores em preto (0) nessa imagem de diferença indicam pontos nos quais não há nenhuma diferença entre as imagens das figuras 2.27(a) e (b).

Como outro exemplo, analisaremos rapidamente uma área das imagens médicas chamada de *radiografia em modo máscara*, uma utilização comercialmente bem-sucedida e extremamente benéfica da subtração de imagens.* Consideramos a diferença entre duas imagens da forma:

$$g(x, y) = f(x, y) - h(x, y) \tag{2.6-9}$$

Neste caso, $h(x, y)$, a *máscara*, é uma imagem de raios X de uma região do corpo do paciente, capturada por um intensificador de imagens e uma câmera de TV (em vez de um filme de raios X tradicional) localizada na frente de uma fonte de raios X. O procedimento consiste em injetar uma substância de contraste para raios X na corrente sanguínea do paciente, capturando uma série de imagens chamada de *imagens*

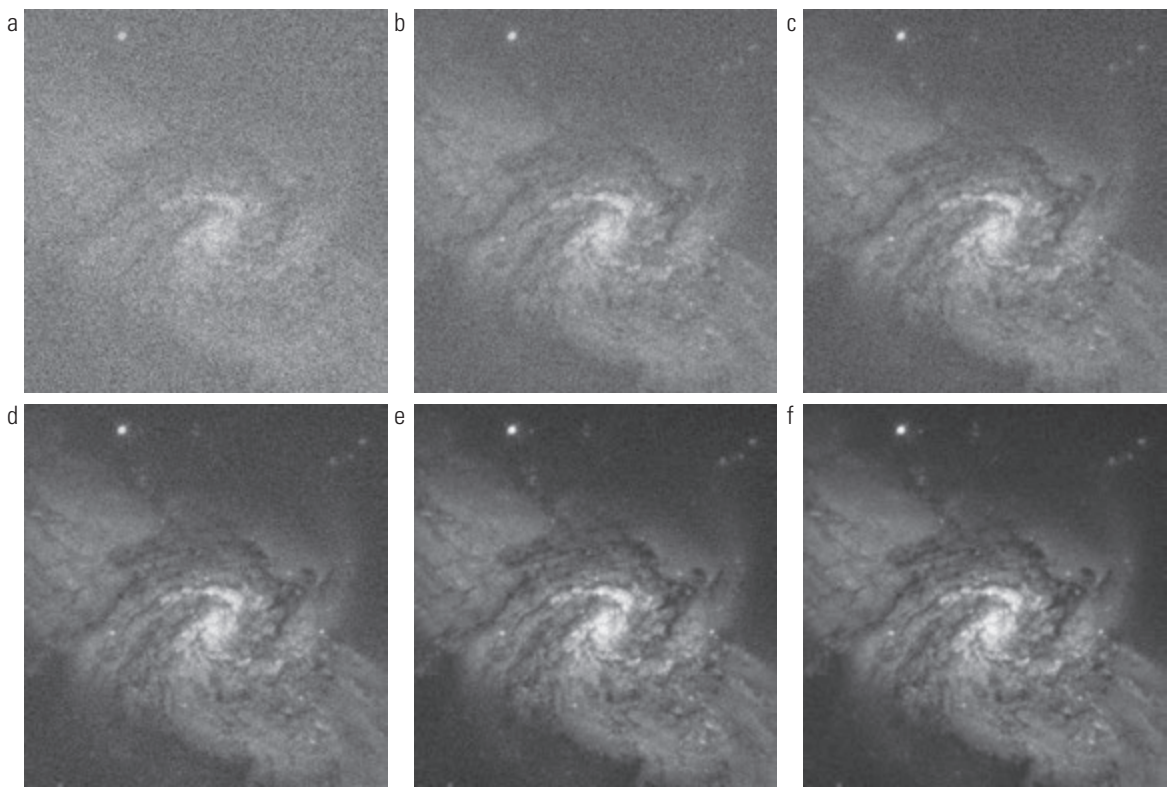


Figura 2.26 (a) Imagem do par de galáxias NGC 3314 corrompida pelo ruído gaussiano aditivo. (b) a (f) Resultados do cálculo da média de 5, 10, 20, 50 e 100 imagens ruidosas, respectivamente. (Imagem original: cortesia da Nasa.)

* A detecção de mudanças por meio da subtração de imagens também é utilizada na segmentação de imagens, que analisaremos no Capítulo 10.

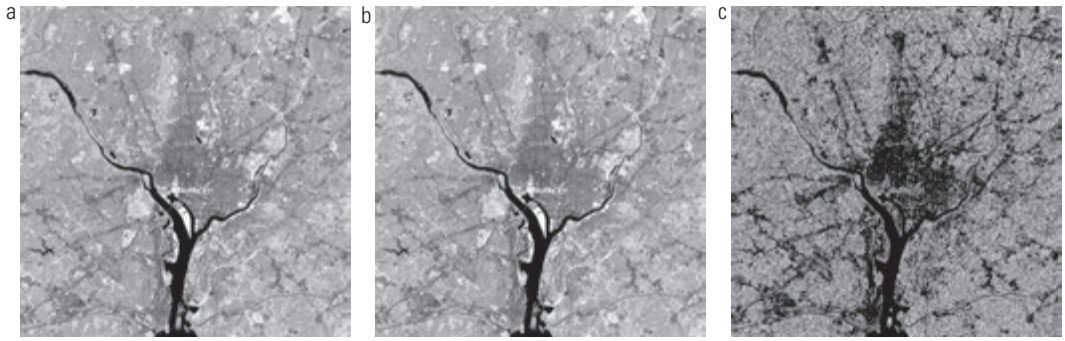


Figura 2.27 (a) Imagem em infravermelho da área de Washington, D.C. (b) Imagem obtida zerando o bit menos significativo de todos os pixels de (a). (c) Diferença entre as duas imagens ajustada para a faixa [0, 255] para melhor visualização.

ativas [amostras que são expressas como $f(x, y)$] da mesma região anatômica que $h(x, y)$ e subtraindo a máscara da série de imagens ativas recebidas após a injeção do contraste. O efeito final da subtração da máscara a partir de cada amostra de imagem ativa é que as áreas entre $f(x, y)$ e $h(x, y)$, que são diferentes, são exibidas na imagem de saída, $g(x, y)$, como detalhes realçados. Como as imagens podem ser capturadas em velocidade de TV, esse procedimento basicamente resulta em um filme mostrando como a substância de contraste se propaga através das várias artérias na área em observação.

A Figura 2.28(a) mostra uma imagem de raios X (máscara) da parte superior da cabeça de um paciente antes da injeção de uma substância à base de iodo (contraste) na corrente sanguínea, e a Figura 2.28(b) é uma amostra de uma imagem ativa obtida depois que o contraste foi injetado. A Figura 2.28(c) mostra a diferença entre (a) e (b). Algumas estruturas detalhadas do vaso sanguíneo são visíveis nessa imagem. A diferença fica clara na Figura 2.28(d), que foi obtida realçando o contraste em (c) (discutiremos o realce do contraste no próximo capítulo). A Figura 2.28(d) apresenta um "mapa" claro de como a substância de contraste se propaga pelos vasos sanguíneos no cérebro do paciente.

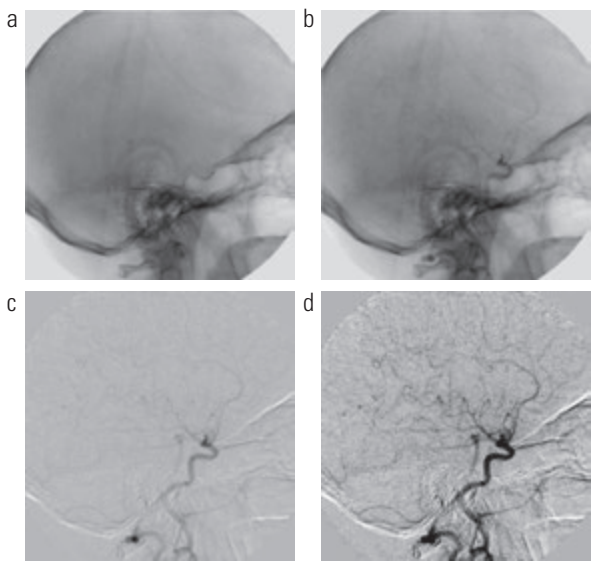


Figura 2.28 Angiografia por subtração digital. (a) Imagem máscara. (b) Uma imagem ativa. (c) Diferença entre (a) e (b). (d) Imagem da diferença realçada. (Figuras (a) e (b): cortesia do Instituto de Ciência de Imagem, Centro Médico da Universidade de Utrecht, Holanda.)

■

Exemplo 2.7 Utilização da multiplicação e divisão de imagens para a correção de sombreamento.

Uma importante aplicação da multiplicação (e divisão) de imagens é a *correção de sombreamento*. Suponha que um sensor de aquisição de imagens produza imagens que possam ser modeladas como o produto de uma "imagem perfeita", expressa por $f(x, y)$, por uma função de sombreamento $h(x, y)$, isto é, $g(x, y) = f(x, y)h(x, y)$. Se $h(x, y)$ for conhecido, podemos obter $f(x, y)$ multiplicando a imagem capturada pelo inverso de $h(x, y)$ (isto é, dividindo g por h). Se $h(x, y)$ não for conhecido, mas o acesso ao sistema de aquisição de imagens for possível, podemos obter uma aproximação da função de sombreamento obtendo uma imagem de um objeto de intensidade constante. Quando o sensor não está disponível, podemos muitas vezes estimar o padrão de sombreamento diretamente da imagem, como veremos na Seção 9.6. A Figura 2.29 mostra um exemplo de correção de sombreamento.

Uma outra utilização comum da multiplicação de imagens é no *mascaramento*, também chamado de *região de interesse* (ROI, de *region of interest*). O processo, ilustrado na Figura 2.30, consiste simplesmente em multiplicar uma determinada imagem por uma imagem máscara que tem 1s na ROI e 0s em outras regiões. Pode haver mais de uma ROI na imagem máscara e a forma da ROI pode ser arbitrária, apesar de formatos retangulares serem utilizados com mais frequência para facilitar a implementação.

■

Antes de concluirmos esta seção, alguns comentários sobre a utilização de operações aritméticas em imagens

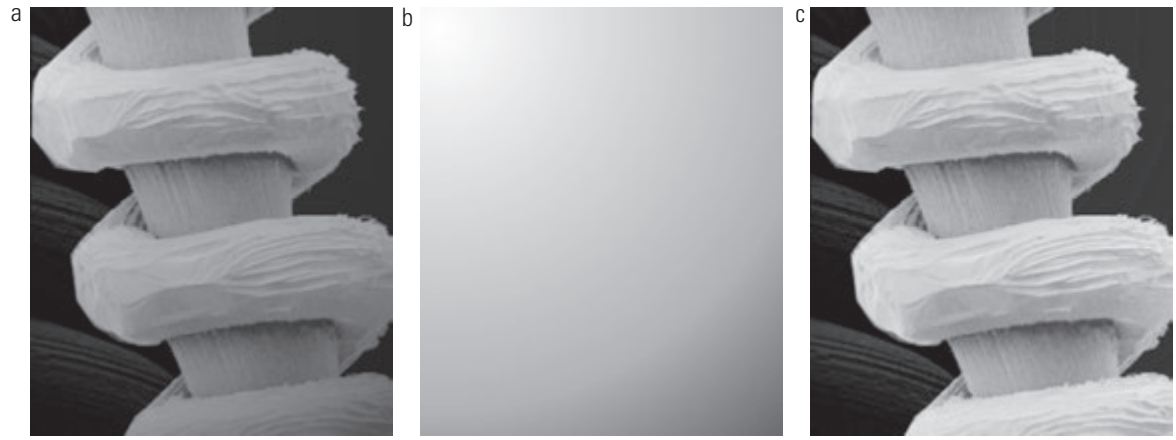


Figura 2.29 Correção de sombreamento. (a) Imagem sombreada de um filamento de tungstênio e suporte gerada por um microscópio eletrônico por varredura, ampliada aproximadamente 130 vezes. (b) O padrão de sombreamento. (c) Produto de (a) pelo inverso de (b). (Imagem original: cortesia de Michael Shaffer, Departamento de Ciências Geológicas, Universidade de Oregon, Eugene.)

são apropriados. Na prática, a maioria das imagens é exibida utilizando 8 bits (mesmo as imagens coloridas de 24 bits consistem em três canais separados de 8 bits). Dessa forma, esperamos que os valores das imagens estejam no intervalo de 0 a 255. Quando as imagens são salvas em um formato padrão, como TIFF ou JPEG, a conversão para esse intervalo é automática. Contudo, o método utilizado para a conversão depende do sistema utilizado. Por exemplo, os valores da diferença de duas imagens de 8 bits pode variar de um mínimo de –255 a um máximo de 255 e os valores de uma imagem obtida a partir de uma soma podem variar de 0 a 510. Muitos aplicativos computacionais, ao converter imagens para 8 bits, simplesmente transformam todos os valores negativos em 0 e todos os valores que excedem esse limite são transformados em 255. Considerando uma imagem f, apresentamos abaixo uma metodologia que garante que todo intervalo de uma operação aritmética entre imagens seja "capturado" em um número fixo de bits. Para começar, realizamos a operação:

$$f_m = f - \text{mín}(f) \tag{2.6-10}$$

o que cria uma imagem cujo valor mínimo é 0. Depois, realizamos a operação

$$f_s = K[f_m / \text{máx}(f_m)] \tag{2.6-11}$$

o que cria uma imagem ajustada, f_s, cujos valores estão no intervalo $[0, K]$. Ao trabalhar com imagens de 8 bits, definir $K = 255$ nos dá uma imagem ajustada às intensidades que cobrem toda a escala de 8 bits, de 0 a 255. Comentários similares se aplicam a imagens de 16 bits ou mais. Essa metodologia pode ser utilizada por todas as operações aritméticas. Ao realizar uma divisão, temos o requisito adicional de que um número pequeno deve ser acrescentado aos pixels da imagem do divisor para evitar a divisão por 0.

2.6.4 Operações com conjuntos e operações lógicas

Nesta seção, apresentamos brevemente algumas importantes operações com conjuntos e operações lógicas. Também apresentamos o conceito de um conjunto *fuzzy*.



Figura 2.30 (a) Imagem digital de uma radiografia odontológica. (b) Máscara com duas regiões de interesse para isolar dentes com obturações (branco corresponde a 1 e preto corresponde a 0). (c) Produto de (a) com (b).

Operações básicas com conjuntos

Seja A um conjunto composto de *pares ordenados* de números reais. Se $a = (a_1, a_2)$ for um *elemento* de A, temos

$$a \in A \tag{2.6-12}$$

Da mesma forma, se a não for um elemento de A, temos

$$a \notin A \tag{2.6-13}$$

O conjunto que não contém elementos é chamado de *conjunto nulo* ou *conjunto vazio* e é expresso pelo símbolo $\varnothing$.

Um conjunto é especificado pelo conteúdo de duas chaves: $\{\cdot\}$. Por exemplo, quando escrevemos uma expressão da forma $C = \{w | w = -d, d \in D\}$, queremos dizer que o conjunto C é o conjunto de elementos, w, de forma que w é formado multiplicando cada um dos elementos do conjunto D por –1. Uma forma na qual os conjuntos são utilizados em processamento de imagens é fazer com que os elementos dos conjuntos sejam *coordenadas* de pixels (pares ordenados de números inteiros) representando regiões (objetos) em uma imagem.

Se cada elemento de um conjunto A também for um elemento de um conjunto B, então se diz que A é um *subconjunto* de B, expresso como

$$A \subseteq B \tag{2.6-14}$$

A *união* dos dois conjuntos A e B é expressa por

$$C = A \cup B \tag{2.6-15}$$

que é o conjunto de elementos que pertencem ou ao conjunto A, ou ao B ou a ambos. De forma similar, a *interseção* de dois conjuntos A e B é expressa por

$$D = A \cap B \tag{2.6-16}$$

que é o conjunto de elementos que pertencem a ambos os conjuntos. Diz-se que dois conjuntos A e B são *disjuntos* ou *mutuamente exclusivos* se não tiverem elementos em comum. Nesse caso:

$$A \cap B = \varnothing \tag{2.6-17}$$

O *conjunto universo*, U, é o conjunto de todos os elementos de uma dada aplicação. Por definição, todos os elementos do conjunto em uma dada aplicação pertencem ao universo definido para essa aplicação. Por exemplo, se você estiver trabalhando com o conjunto de números reais, o conjunto universo é a reta real, que contém todos os números reais. No processamento de imagens, normalmente definimos o conjunto universo como o retângulo que contém todos os pixels de uma imagem.

O *complemento* de um conjunto A é o conjunto de elementos que não estão em A:

$$A^c = \{w | w \notin A\} \tag{2.6-18}$$

A *diferença* entre dois conjuntos A e B, expressa por $A - B$, é definida como

$$A - B = \{w | w \in A, w \notin B\} = A \cap B^c \tag{2.6-19}$$

Vemos que esse é o conjunto de elementos que pertence a A, mas não pertence a B. Poderíamos, por exemplo, definir A^c em termos de U e da operação de diferença: $A^c = U - A$.

A Figura 2.31 ilustra os conceitos apresentados anteriormente, nos quais o universo é o conjunto de coordenadas contidas no retângulo mostrado e os conjuntos A e B são os conjuntos de coordenadas que estão dentro das regiões mostradas na figura. O resultado da operação com conjuntos indicado em cada figura é mostrado em cinza.*

Na discussão anterior, pertencer ao conjunto depende da posição (coordenadas). Uma premissa implícita ao trabalhar com imagens é que a intensidade de todos os pixels dos conjuntos é a mesma, já que não definimos as operações de conjuntos envolvendo valores de intensidade (por exemplo, não especificamos quais são as intensidades na interseção de dois conjuntos). A única forma de as operações ilustradas na Figura 2.31 fazerem sentido é se as imagens que contêm os conjuntos forem

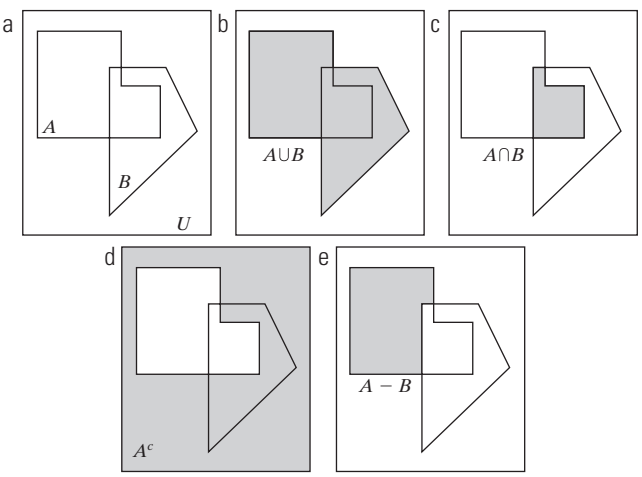


Figura 2.31 (a) Dois conjuntos de coordenadas, A e B, em um espaço 2-D. (b) A união de A e B. (c) A interseção de A e B. (d) O complemento de A. (e) A diferença entre A e B. Em (b)-(e) as áreas em cinza representam os elementos resultantes da operação de conjuntos indicada.

* As operações apresentadas nas equações 2.6-12 a 2.6-19 formam a base para a álgebra dos conjuntos, que começa com propriedades como as *leis comutativas*: $A \cup B = B \cup A$ e $A \cap B = B \cap A$ e, a partir delas, desenvolve uma ampla teoria baseada em operações de conjuntos. Uma explicação da álgebra dos conjuntos está além do escopo da presente discussão, mas você deve estar ciente de sua existência.

binárias e, nesse caso, podemos falar em pertencer ou não ao conjunto dependendo apenas das coordenadas, considerando que todos os elementos dos conjuntos têm a mesma intensidade. Discutiremos isso em mais detalhes na subseção a seguir.

Ao lidar com imagens em escala de cinza, os conceitos anteriores não se aplicam, porque precisamos especificar as intensidades de todos os pixels resultantes de uma operação com conjuntos. Com efeito, como veremos nas seções 3.8 e 9.6, as operações de união e interseção para valores em escala de cinza normalmente são definidas como o valor máximo e o valor mínimo entre cada par de pixel correspondente, respectivamente, ao passo que o complemento é definido como as diferenças entre uma constante e a intensidade de cada pixel em uma imagem. O fato de lidarmos com pares de pixels correspondentes nos informa que as operações com conjuntos em escala de cinza são operações de arranjo matricial, como definido na Seção 2.6.1. O exemplo a seguir é uma breve ilustração de operações de conjuntos envolvendo imagens em escala de cinza. Discutiremos esses conceitos em mais detalhes nas duas seções já mencionadas.

■

Exemplo 2.8 Operações de conjuntos envolvendo intensidades de imagem.

Sejam os elementos de uma imagem em escala de cinza representada por um conjunto A cujos elementos são expressos em um grupo de três variáveis na forma (x, y, z), onde x e y são coordenadas espaciais e z expressa a intensidade, como mencionamos na Seção 2.4.2. Podemos definir o *complemento* de A como o conjunto $A^c = \{(x, y, K - z) \mid (x, y, z) \in A\}$, o que simplesmente expressa o conjunto de pixels de A cujas intensidades foram subtraídas de uma constante K. Essa constante é igual a $2^k - 1$, sendo k o número de bits por pixel utilizado para representar a intensidade z. Seja A a imagem em escala de cinza de 8 bits da Figura 2.32(a), e suponha que queiramos formar o negativo de A utilizando operações com conjuntos. Nós simplesmente formamos o conjunto $A_n = A^c = \{(x, y, 255 - z) \mid (x, y, z) \in A\}$. Observe que as coordenadas são mantidas na mesma posição, de forma que A_n é uma imagem do mesmo tamanho que A. A Figura 2.32(b) mostra o resultado.

A união dos dois conjuntos em escala de cinza A e B pode ser definida com o conjunto

$$A \cup B = \left\{ \max_z(a,b) \middle| a \in A,\ b \in B \right\}$$

Em outras palavras, a união de dois conjuntos em escala de cinza (imagens) é um arranjo matricial formado a partir da intensidade máxima entre os pares de elementos de mesma coordenada espacial. Mais uma vez, observe que as coordenadas são mantidas na mesma posição, de forma que a união de A e B é uma imagem do mesmo tamanho que essas duas imagens. A título de exemplo, suponha que A novamente represente a imagem da Figura 2.32(a), e digamos que B expresse um arranjo matricial retangular, do mesmo tamanho que A, no qual todos os valores de z são iguais a 3 vezes a intensidade média, m, dos elementos de A. A Figura 2.32(c) mostra o resultado ao realizar a união dos conjuntos, na qual todos os valores que excedem $3m$ aparecem como valores de A e todos os outros pixels têm valor $3m$, que corresponde a um nível de cinza médio.

■

Operações lógicas

Quando lidamos com imagens binárias, podemos pensar em grupos de pixels de *frente* (valor 1) e de *fundo* (valor 0). Então, se definirmos regiões (objetos) como sendo compostos de pixels de frente, as operações de conjuntos ilustradas na Figura 2.31 se tornam operações entre as coordenadas dos objetos em uma imagem binária. Ao lidar com imagens binárias, costuma-se referir a união, interseção e complemento como as operações *lógicas* OU (*OR*), E (*AND*) e NÃO (*NOT*), onde "lógicas" provêm da lógica matemática na qual 1 e 0 expressam verdadeiro e falso, respectivamente.

Considere duas regiões (conjuntos) A e B compostas de pixels de frente. A operação OU entre esses dois conjuntos é o conjunto de elementos (coordenadas) pertencentes a A ou a B ou aos dois. A operação E é o conjunto de elementos que são comuns a A e a B. A operação NÃO de um conjunto A é o conjunto de elementos que não pertencem a A. Como estamos lidando com imagens, se A for um dado conjunto de pixels

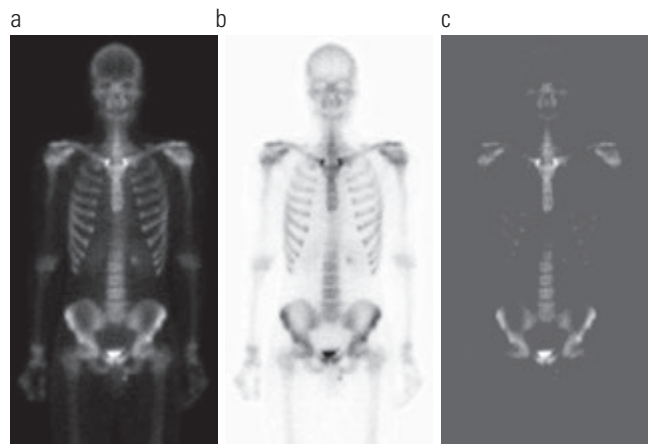


Figura 2.32 Conjunto de operações envolvendo imagens em escala de cinza. (a) Imagem original. (b) Negativo obtido da complementação do conjunto. (c) União de (a) com uma imagem constante. (Imagem original: cortesia da G.E. Medical Systems.)

de frente, NÃO(*A*) é o conjunto de todos os pixels da imagem que não pertencem a *A*, sendo que esses pixels são os pixels de fundo e possivelmente outros pixels de frente. Podemos pensar nessa operação como a transformação de todos os elementos de *A* em 0 (preto) e todos os elementos não pertencentes a *A* em 1 (branco). A Figura 2.33 ilustra essas operações. Observe na quarta linha que o resultado da operação é o conjunto de pixels de frente que pertencem a *A* mas não a *B*, o que é a definição da diferença de conjuntos da Equação 2.6-19. A última linha da figura mostra a operação OU exclusivo (X-OU *ou X-OR*), que é o conjunto de pixels de frente que pertencem a *A* ou a *B*, mas não a ambos. Observe que as operações anteriores são realizadas entre regiões, que claramente podem ser irregulares e de tamanhos diferentes. Isso é o oposto das operações em escala de cinza discutidas anteriormente, que são operações de arranjo matricial e, dessa forma, requerem conjuntos cujas dimensões espaciais são as mesmas. Em outras palavras, as operações com conjuntos em escala de cinza envolvem imagens completas, diferente das operações com regiões de imagens.

Teoricamente, precisamos nos preocupar apenas com a capacidade de implementar os operadores lógicos

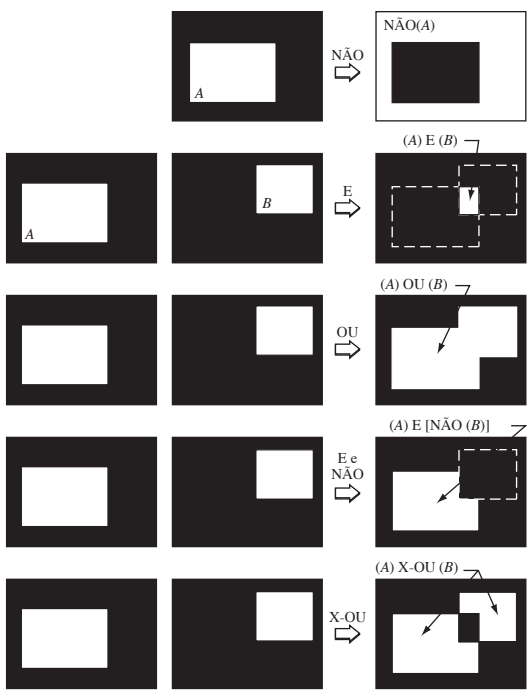


Figura 2.33 Ilustração de operações lógicas envolvendo pixels de frente (brancos). O preto representa binários "0s" e o branco, binários "1s" . As linhas tracejadas são mostradas somente para referência. Elas não fazem parte dos resultados.

E, OU ou NÃO, porque esses três operadores são *funcionalmente completos*. Em outras palavras, qualquer outro operador lógico pode ser implementado a partir dessas três funções básicas, como na quarta linha da Figura 2.33, onde implementamos a operação de diferença de conjuntos utilizando os operadores E e NÃO. As operações lógicas são amplamente utilizadas em morfologia de imagens, o tema do Capítulo 9.

Conjuntos *fuzzy*

O conjunto e os resultados lógicos anteriores são conceitos *clássicos*, no sentido de que os elementos ou pertencem ou não pertencem a um conjunto. Isso representa uma séria limitação em algumas aplicações. Considere um exemplo simples. Suponha que queiramos categorizar todas as pessoas do mundo como jovens ou não jovens. Utilizando os conjuntos clássicos, *U* expressa o conjunto de todas as pessoas, e *A* é um subconjunto de *U*, que chamaremos de *conjunto dos jovens*. Para formar o conjunto *A*, precisamos de uma *função de pertinência* que atribua um valor 1 ou 0 a cada elemento (pessoa) de *U*. Se o valor atribuído a um elemento de *U* for 1, então o elemento pertencerá a *A*; caso contrário, o elemento não pertencerá a *A*. Como estamos lidando com uma lógica de dois valores, a função de pertinência simplesmente define um limiar no qual ou abaixo do qual uma pessoa é considerada jovem, e acima do qual uma pessoa é considerada não jovem. Suponha que definamos como jovem qualquer pessoa com 20 anos de idade ou menos. Vemos imediatamente uma dificuldade. Uma pessoa com 20 anos e 1 segundo de idade não pertenceria ao conjunto de jovens. Essa limitação surge independentemente do limiar de idade utilizado para classificar uma pessoa como jovem. O que precisamos é de mais flexibilidade no que queremos dizer com "jovem", isto é, precisamos de uma transição *gradual* de jovem a não jovem. A teoria dos *conjuntos fuzzy* implementa esse conceito utilizando funções de pertinência que são graduais entre os valores-limite de 1 (definitivamente jovem) a 0 (definitivamente não jovem). Utilizando conjuntos *fuzzy*, podemos dizer, por exemplo, que uma pessoa é 50% jovem (no meio da transição entre jovem e não jovem). Em outras palavras, a idade é um conceito impreciso, e a lógica *fuzzy* nos fornece as ferramentas para lidar com conceitos como esses. Analisaremos os conjuntos *fuzzy* em detalhes na Seção 3.8.

2.6.5 Operações espaciais

As operações espaciais são realizadas diretamente sobre os pixels de uma determinada imagem. Classificamos as operações espaciais em três categorias amplas: (1) operações ponto a ponto; (2) operações por vizinhança; e (3) transformações geométricas.

Operações ponto a ponto

A operação mais simples realizada em uma imagem digital consiste em alterar os valores de seus pixels individuais com base em sua intensidade. Esse tipo de processo pode ser expresso como uma função de transformação, T, com a forma:

$$s = T(z) \tag{2.6-20}$$

onde z é a intensidade de um pixel na imagem original e s é a intensidade (mapeada) do pixel correspondente na imagem processada. Por exemplo, a Figura 2.34 mostra a transformação utilizada para obter o negativo de uma imagem de 8 bits, como mostrado na imagem da Figura 2.32(b), que obtivemos utilizando operações com conjuntos. Discutiremos no Capítulo 3 uma série de técnicas para especificar as funções de transformação de intensidade.

Operações por vizinhança

Seja S_{xy} o conjunto de coordenadas de uma vizinhança centrada em um ponto arbitrário (x, y) em uma imagem f. O processamento por vizinhança gera um pixel correspondente nas mesmas coordenadas em uma imagem de saída (processada), g, de forma que o valor desse pixel é determinado por uma operação específica envolvendo os pixels da imagem de entrada com coordenadas em S_{xy}. Por exemplo, suponha que a operação especificada consista em calcular o valor médio dos pixels em uma vizinhança retangular de tamanho $m \times n$ centrada em (x, y).

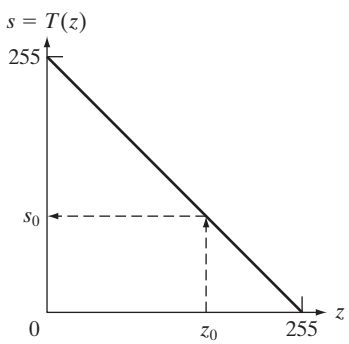


Figura 2.34 Função de transformação de intensidade utilizada para obter o negativo de uma imagem de 8 bits. As setas tracejadas mostram a transformação de um valor arbitrário de entrada com intensidade z_0 em um valor correspondente de saída s_0.

As posições dos pixels nessa região constituem o conjunto S_{xy}. As figuras 2.35(a) e (b) ilustram o processo. Podemos expressar essa operação na forma de equação como:

$$g(x, y) = \frac{1}{mn} \sum_{(r,c) \in S_{xy}} f(r, c) \tag{2.6-21}$$

onde r e c são as coordenadas de linha e coluna dos pixels que pertencem ao conjunto S_{xy}. A imagem g é criada variando-se as coordenadas (x, y), de forma que o centro da vizinhança se mova de pixel a pixel na imagem f repetindo a operação por vizinhança em cada nova posição. Por exemplo, a imagem da Figura 2.35(d) foi criada dessa maneira utilizando uma vizinhança de tamanho 41×41. O efeito final é um borramento local na imagem original. Esse tipo de processo é utilizado, por exemplo, para eliminar detalhes e representar como "borrões" as regiões maiores de uma imagem. Discutiremos o processamento por vizinhança nos capítulos 3 e 5 e em vários outros locais ao longo do livro.

Transformações geométricas e registro de imagens

As transformações geométricas modificam a relação espacial entre os pixels de uma imagem. Essas transformações costumam ser chamadas de transformações do tipo *rubber sheet* (superfície de borracha), porque podem ser vistas de forma análoga à "impressão" de uma imagem em uma superfície de borracha que possa ser esticada de acordo com um conjunto de regras predefinidas. Em termos de processamento de imagens digitais, uma transformação geométrica consiste em duas operações básicas: (1) uma transformação espacial de coordenadas e (2) interpolação de intensidade que atribui níveis de intensidade aos pixels transformados espacialmente.

A transformação das coordenadas pode ser expressa como:

$$(x, y) = T\{(v, w)\} \tag{2.6-22}$$

onde (v, w) são coordenadas de um pixel na imagem original, e (x, y) são as coordenadas do pixel correspondente na imagem transformada. Por exemplo, a transformação $(x, y) = T\{(v, w)\} = (v/2, w/2)$ reduz a dimensão (*shrink*) da imagem original à metade de seu tamanho em ambas as direções espaciais. Uma das transformações em coordenadas espaciais mais comumente utilizadas é a *transformação afim* (Wolberg [1990]), que assume a forma geral:

$$\begin{aligned} [x \;\; y \;\; 1] &= [v \;\; w \;\; 1]\,\mathbf{T} \\ &= [v \;\; w \;\; 1] \begin{bmatrix} t_{11} & t_{12} & 0 \\ t_{21} & t_{22} & 0 \\ t_{31} & t_{32} & 1 \end{bmatrix} \end{aligned} \tag{2.6-23}$$

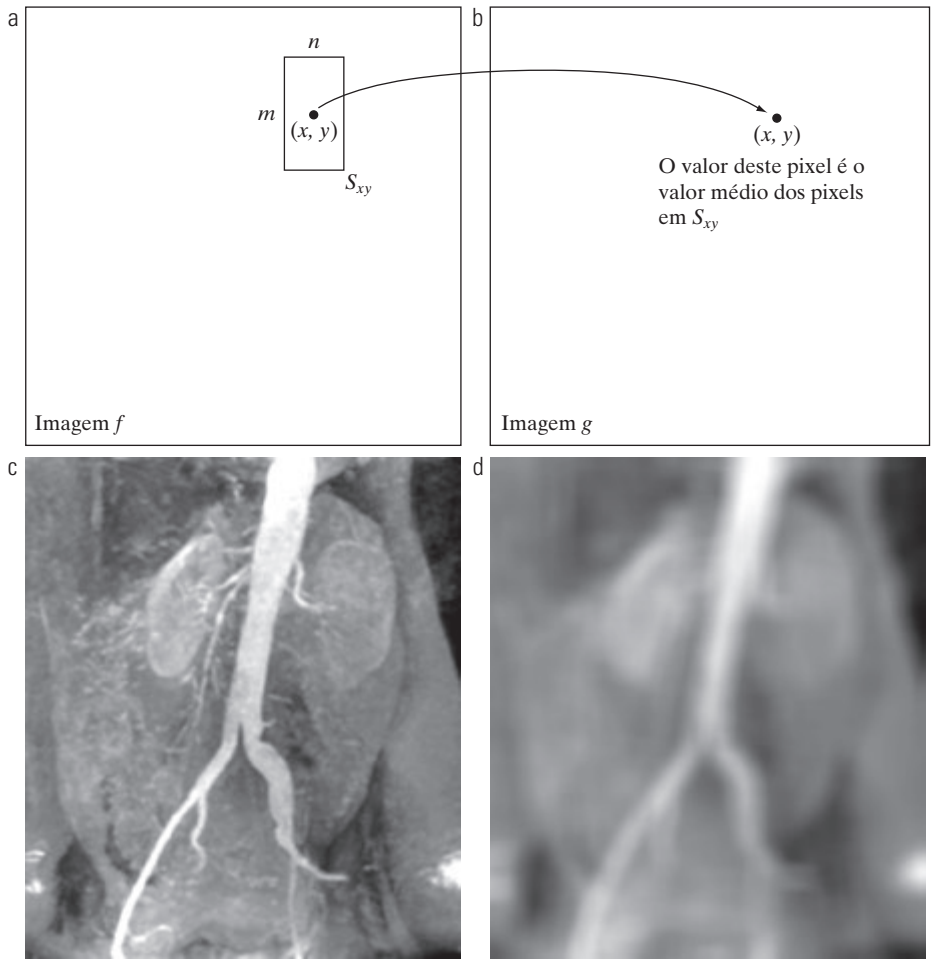


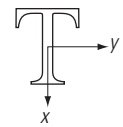
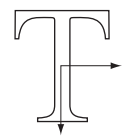
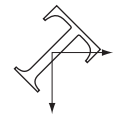
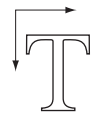
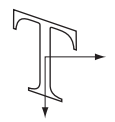
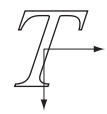
Figura 2.35 Cálculo da média local utilizando processamento por vizinhança. O procedimento é ilustrado em (a) e (b) para uma vizinhança retangular. (c) O angiograma da aorta discutido na Seção 1.3.2. (d) O resultado da utilização da Equação 2.6-21 com $m = n = 41$. As imagens estão no tamanho 790 $\times$ 686 pixels.

Essa transformação pode realizar a operação de escala, rotação, translação ou cisalhamento em um conjunto de pontos coordenados, dependendo do valor escolhido para os elementos da matriz **T**. A Tabela 2.2 ilustra os valores da matriz utilizados para implementar essas transformações. A grande vantagem da representação matricial da Equação 2.6-23 é que ela proporciona a estrutura para concatenar uma sequência de operações. Por exemplo, se quisermos redimensionar uma imagem, rotacioná-la e transferir o resultado para alguma posição, simplesmente formamos uma matriz 3 $\times$ 3 igual ao produto das matrizes de escala, rotação e translação da Tabela 2.2.

As transformações relocam os pixels de uma imagem para novas posições. Para concluir o processo, precisamos atribuir valores de intensidade a essas posições. Essa tarefa é realizada utilizando a interpolação de intensidade. Nós já discutimos esse tópico na Seção 2.4.4. Iniciamos aquela seção com um exemplo de ampliação (*zoom*) de uma imagem e discutimos a questão da atribuição de intensidade a novas posições dos pixels. A ampliação não passa de uma operação de escala, como detalhado na segunda linha da Tabela 2.2, e uma análise similar à desenvolvida para a ampliação é aplicável ao problema da atribuição de valores de intensidade aos pixels relocados que resultaram das outras transformações da Tabela 2.2. Como na Seção 2.4.4, consideramos as técnicas de interpolação bilinear, bicúbica e por vizinho mais próximo ao trabalhar com essas transformações.

Na prática, podemos utilizar a Equação 2.6-23 de duas formas básicas. A primeira, chamada de *mapeamento direto*, consiste na varredura dos pixels da imagem de entrada e, para cada posição (v, w), calcular a nova localização espacial (x, y) do pixel correspondente na imagem de saída utilizando diretamente a Equação 2.6-23. Um problema com o método do mapeamento direto é que dois ou mais pixels da imagem de entrada podem ser transforma-

Tabela 2.2 Transformações afins baseadas na Equação 2.6-23.

Nome da transformação	Matriz afim, T	Equações coordenadas	Exemplo
Identidade	$\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$	$x = v$ $y = w$	
Escala	$\begin{bmatrix} c_x & 0 & 0 \\ 0 & c_y & 0 \\ 0 & 0 & 1 \end{bmatrix}$	$x = c_x v$ $y = c_y w$	
Rotação	$\begin{bmatrix} \cos\theta & \text{sen}\,\theta & 0 \\ -\text{sen}\,\theta & \cos\theta & 0 \\ 0 & 0 & 1 \end{bmatrix}$	$x = v\cos\theta - w\,\text{sen}\,\theta$ $y = v\,\text{sen}\,\theta + w\cos\theta$	
Translação	$\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ t_x & t_y & 1 \end{bmatrix}$	$x = v + t_x$ $y = w + t_y$	
Cisalhamento (vertical)	$\begin{bmatrix} 1 & 0 & 0 \\ s_v & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$	$x = v + s_v w$ $y = w$	
Cisalhamento (horizontal)	$\begin{bmatrix} 1 & s_h & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$	$x = v$ $y = s_h v + w$	

dos para a mesma posição na imagem de saída, levantando a questão de como combinar vários valores de saída em um único pixel de saída. Além disso, é possível que algumas posições de saída não sejam atribuídas a nenhum pixel. A segunda abordagem, chamada de *mapeamento inverso*, realiza uma varredura nas posições dos pixels de saída e, a cada posição (x, y), calcula a posição correspondente na imagem de entrada utilizando $(v, w) = T^{-1}(x, y)$. Depois realiza a interpolação (utilizando uma das técnicas discutidas na Seção 2.4.4) entre os pixels de entrada mais próximos para determinar a intensidade do pixel de saída. Os mapeamentos inversos são de implementação mais eficiente do que os mapeamentos diretos e são utilizados em várias aplicações comerciais de transformações espaciais (por exemplo, o Matlab utiliza essa abordagem).

■

Exemplo 2.9 Rotação da imagem e interpolação de intensidade.

O objetivo deste exemplo é ilustrar a rotação de imagens utilizando uma transformação afim. A Figura 2.36(a) mostra uma imagem de 300 dpi e as figuras 2.36(b) a (d) são os resultados da rotação da imagem original em 21° utilizando a interpolação por vizinho mais próximo, a interpolação bilinear e a interpolação bicúbica, respectivamente. A rotação é uma das transformações geométricas mais exigentes em termos da preservação das características de linhas retas. Como vemos na figura, a interpolação por vizinho mais próximo produziu bordas mais irregulares e, do mesmo modo que na Seção 2.4.4, a interpolação bilinear gerou resultados significativamente melhores. Como antes, a interpolação bicúbica produziu resultados ligeiramente mais nítidos. Na verdade, se você comparar o detalhe ampliado nas figuras 2.36(c) e (d), notará no centro das subimagens que o número de "blocos" verticais em cinza que proporcionam a transição de intensidade do claro ao escuro na Figura 2.36(c) é maior que o número correspondente de blocos em (d), indicando que, neste último caso, a borda é mais nítida. Resultados similares seriam obtidos com outras transformações espaciais da Tabela 2.2 que requerem interpolação (nem a identidade nem a translação requerem interpolação se os incrementos forem números inteiros de pixels). Esse exemplo foi implementado utilizando o método de mapeamento inverso discutido no parágrafo anterior.

■

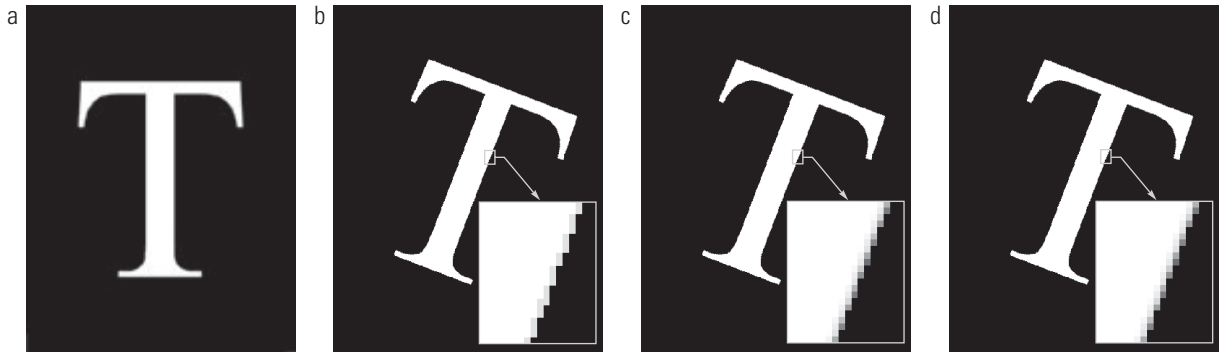


Figura 2.36 (a) Uma imagem de 300 dpi da letra T. (b) Imagem rotacionada a 21° utilizando a interpolação do vizinho mais próximo para atribuir valores de intensidade aos pixels transformados espacialmente. (c) Imagem rotacionada a 21° utilizando a interpolação bilinear. (c) Imagem rotacionada a 21° utilizando a interpolação bicúbica. As seções ampliadas mostram detalhes de borda para os três métodos de interpolação.

O registro de imagens é uma importante aplicação do processamento de imagens digitais utilizada para alinhar duas ou mais imagens da mesma cena. Na discussão anterior, o formato da função de transformação necessária para atingir uma transformação geométrica desejada era conhecido. No registro de imagens, temos disponíveis as imagens de entrada e saída, mas a transformação específica que produziu a imagem de saída a partir da entrada, em geral, é desconhecida. O problema, então, é estimar a função de transformação e utilizá-la para registrar as duas imagens. Para esclarecer a terminologia, a imagem de entrada é a imagem que desejamos transformar, e o que chamamos de imagem de *referência* é a imagem em relação à qual queremos registrar a entrada.

Por exemplo, pode ser útil alinhar (registrar) duas ou mais imagens capturadas aproximadamente ao mesmo tempo, mas utilizando diferentes sistemas de aquisição de imagens, como a ressonância magnética e a PET. Ou, talvez, as imagens tenham sido capturadas em diferentes momentos utilizando o mesmo instrumento, por exemplo imagens de satélite de uma determinada localização obtidas com vários dias, meses ou até anos de diferença. Em qualquer caso, combinar as imagens ou realizar análises quantitativas e comparações entre elas requer a compensação de distorções geométricas provocadas por diferenças no ângulo de visão, distância e orientação; resolução do sensor; deslocamento nas posições do objeto; e outros fatores.

Uma das principais abordagens para solucionar o problema que acabamos de discutir é utilizar *pontos de controle* (*tie points*), que são pontos correspondentes cujas localizações são conhecidas com exatidão nas imagens de entrada e de referência. Existem várias formas de selecionar os pontos de controle, variando da seleção interativa à aplicação de algoritmos que tentam detectar automaticamente esses pontos. Em algumas aplicações, os sistemas de aquisição de imagens possuem artefatos físicos (como pequenos objetos metálicos) incorporados aos sensores de imagem. Eles produzem um conjunto de pontos *conhecidos* (chamados de *marcas reseau*) diretamente em todas as imagens coletadas pelo sistema, que podem ser utilizados como guias para definir os pontos de controle.

O problema em estimar a função de transformação está na modelagem. Por exemplo, suponha que tenhamos um conjunto de quatro pontos de controle em uma entrada e em uma imagem de referência. Um modelo simples baseado na aproximação bilinear é dado por:

$$x = c_1 v + c_2 w + c_3 vw + c_4 \qquad (2.6\text{-}24)$$

e

$$x = c_5 v + c_6 w + c_7 vw + c_8 \qquad (2.6\text{-}25)$$

sendo que, durante a fase de estimativa, (v, w) e (x, y) são as coordenadas dos pontos de controle das imagens de entrada e de referência, respectivamente. Se tivermos quatro pares de pontos de controle correspondentes em ambas as imagens, podemos escrever oito equações utilizando as equações 2.6-24 e 2.6-25 e utilizá-las para calcular os oito coeficientes desconhecidos, $c_1, c_2, \ldots, c_8$. Esses coeficientes constituem o modelo que transforma os pixels de uma imagem nas posições dos pixels da outra imagem para realizar o registro.

Uma vez que temos os coeficientes, as equações 2.6-24 e 2.6-25 se tornam o nosso veículo para transformar todos os pixels na imagem de entrada para gerar a nova imagem desejada, que, se os pontos de controle forem selecionados corretamente, deve ser registrada com a imagem de referência. Em situações nas quais quatro pontos de controle não são suficientes para obter um registro satisfatório, um método frequentemente utilizado consiste em selecionar um número maior de pontos de controle e tratar os quadriláteros formados por grupos de quatro pontos de controle como subimagens. As subimagens são processadas

como explicado anteriormente, com todos os pixels de um quadrilátero sendo transformados, utilizando os coeficientes determinados a partir desses pontos de controle. Depois, passamos para um outro conjunto de quatro pontos de controle e repetimos o procedimento até que todas as regiões quadriláteras tenham sido processadas. Sem dúvida, é possível usar regiões que sejam mais complexas do que os quadriláteros e empregar modelos mais complexos, como a regressão polinomial pelo método dos mínimos quadrados. Em geral, o número de pontos de controle e a sofisticação do modelo necessário para solucionar um problema dependem da gravidade da distorção geométrica. Por fim, tenha em mente que a transformação definida pelas equações 2.6-24 e 2.6-25, ou por qualquer outro modelo, simplesmente mapeia as coordenadas espaciais dos pixels na imagem de entrada. Ainda precisamos realizar a interpolação de intensidade utilizando qualquer um dos métodos discutidos anteriormente para atribuir valores de intensidade a esses pixels.

■

Exemplo 2.10 Registro de imagens.

A Figura 2.37(a) mostra uma imagem de referência, e a Figura 2.37(b) mostra a mesma imagem, mas geometricamente distorcida pelo cisalhamento vertical e horizontal. Nosso objetivo é utilizar a imagem de referência para obter pontos de controle e, em seguida, utilizar os pontos de controle para registrar a imagem. Os pontos de controle selecionados (manualmente) são mostrados como pequenos quadrados brancos próximos aos cantos das imagens (só precisamos de quatro pontos de controle porque a distorção é de cisalhamento linear em ambas as direções). A Figura 2.37(c) mostra o resultado da utilização desses pontos de controle no procedimento discutido nos parágrafos anteriores para realizar o registro. Observamos que o registro não foi perfeito, como fica claro pelas bordas pretas na Figura 2.37(c). A imagem da diferença mostrada na Figura 2.37(d) mostra mais claramente um ligeiro desvio de registro entre a imagem de referência e a imagem corrigida. O motivo dessas discrepâncias é um erro na seleção manual dos pontos de controle. É difícil realizar uma relação perfeita entre os pontos de controle quando a distorção é tão acentuada.

■

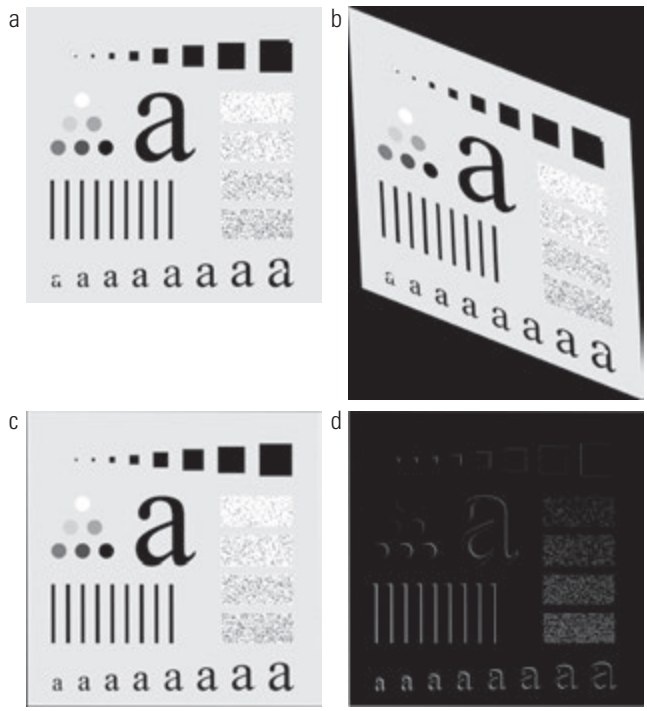


Figura 2.37 Registro de imagens. (a) Imagem de referência. (b) Entrada (imagem geometricamente distorcida). Pontos de controle correspondentes são mostrados como pequenos quadrados brancos próximos aos cantos da imagem. (c) Imagem registrada (observe os erros nas bordas externas). (d) Diferença entre (a) e (c), mostrando mais erros de registro.

2.6.6 Operações com vetores e matrizes*

O processamento de imagens multiespectrais é uma área típica na qual as operações com vetores e matrizes são utilizadas rotineiramente. Por exemplo, veremos no Capítulo 6 que as imagens coloridas são formadas no espaço de cores RGB utilizando imagens de componentes vermelhos, verdes e azuis, como ilustra a Figura 2.38. Aqui, veremos que *cada* pixel de uma imagem RGB possui três componentes, que podem ser organizados na forma de um *vetor coluna*

$$\mathbf{z} = \begin{bmatrix} z_1 \\ z_2 \\ z_3 \end{bmatrix} \tag{2.6-26}$$

sendo z_1 a intensidade de pixels na imagem vermelha e os outros dois elementos as intensidades do pixel correspondente nas imagens verde e azul, respectivamente. Dessa forma, uma imagem colorida RGB de tamanho $M \times N$ pode ser representada pelas três imagens componentes de mesmo tamanho ou por um total de MN vetores 3-D. Um caso multiespectral geral envolvendo n imagens componentes (por exemplo, veja a Figura 1.10) resultará em vetores n-dimensionais. Utilizamos esse tipo de representação vetorial em partes dos capítulos 6, 10, 11 e 12.

Uma vez que os pixels foram representados como vetores, temos à nossa disposição as ferramentas da teoria vetor-matriz. Por exemplo, a *distância euclidiana*, D, entre um pixel representado pelo vetor $\mathbf{z}$ e um ponto arbitrário $\mathbf{a}$ em um espaço n-dimensional é definida como o produto vetorial:

* Consulte os tutoriais (em inglês) no site do livro para uma breve visão sobre vetores e matrizes.

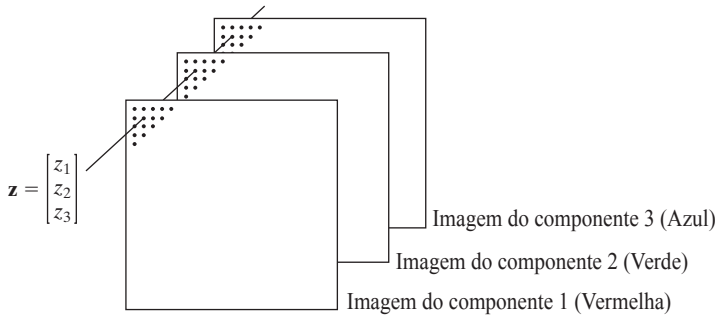


Figura 2.38 Formação de um vetor a partir de valores de pixels correspondentes em três imagens de componentes RGB.

$$D(\mathbf{z}, \mathbf{a}) = \left[(\mathbf{z} - \mathbf{a})^T(\mathbf{z} - \mathbf{a})\right]^{\frac{1}{2}}$$
$$= \left[(z_1 - a_1)^2 + (z_2 - a_2)^2 + \cdots + (z_n - a_n)^2\right]^{\frac{1}{2}} \quad (2.6\text{-}27)$$

Vemos que essa é uma generalização da distância euclidiana 2-D definida na Equação 2.5-1. A Equação 2.6-27 por vezes é chamada de *norma vetorial*, expressa por $\|\mathbf{z} - \mathbf{a}\|$. Utilizaremos cálculos de distância inúmeras vezes nos capítulos seguintes.

Outra importante vantagem dos pixels em forma de vetores está nas transformações lineares, representadas como:

$$\mathbf{w} = \mathbf{A}(\mathbf{z} - \mathbf{a}) \quad (2.6\text{-}28)$$

onde $\mathbf{A}$ é uma matriz de tamanho $m \times n$ e $\mathbf{z}$ e $\mathbf{a}$ são vetores coluna de tamanho $n \times 1$. Como veremos mais adiante, transformações desse tipo têm várias aplicações úteis no processamento de imagens.

Como observado na Equação 2.4-2, imagens inteiras podem ser tratadas como matrizes (ou, de forma equivalente, como vetores), um fato que tem importantes implicações na resolução de vários problemas de processamento de imagens. Por exemplo, podemos expressar uma imagem de tamanho $M \times N$ como um vetor de dimensão $MN \times 1$ fazendo com que a primeira linha da imagem seja composta pelos primeiros N elementos do vetor, a segunda linha pelos próximos N elementos, e assim por diante. Com imagens formadas dessa maneira, podemos expressar uma ampla variedade de processos lineares aplicados a uma imagem utilizando a notação:

$$\mathbf{g} = \mathbf{Hf} + \mathbf{n} \quad (2.6\text{-}29)$$

onde $\mathbf{f}$ é um vetor $MN \times 1$ representando uma imagem de entrada, $\mathbf{n}$ é um vetor $MN \times 1$ representando um padrão de ruído $M \times N$, $\mathbf{g}$ é um vetor $MN \times 1$ representando uma imagem processada e $\mathbf{H}$ é uma matriz $MN \times MN$ representando um processo linear aplicado à imagem de entrada (veja a Seção 2.6.2 sobre os processos lineares). É possível, por exemplo, desenvolver toda uma série de técnicas generalizadas para a restauração de imagens a partir da Equação 2.6-29, como veremos na Seção 5.9. Retomaremos a utilização de matrizes na seção a seguir e mostraremos outras utilizações de matrizes para o processamento de imagens nos capítulos 5, 8, 11 e 12.

2.6.7 Transformadas de imagens

Todas as metodologias de processamento de imagens discutidas até agora operam diretamente sobre os pixels da imagem de entrada, isto é, elas funcionam diretamente no *domínio espacial*. Em alguns casos, tarefas de processamento de imagens são mais bem formuladas transformando as imagens de entrada, transferindo a tarefa especificada para o *domínio da transformada* e aplicando a transformada inversa para retornar ao domínio espacial. Veremos uma série de transformadas diferentes à medida que avançarmos ao longo do livro. Uma classe particularmente importante de transformadas lineares bidimensionais, $T(u, v)$, pode ser expressa na forma geral

$$T(u, v) = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} f(x, y) r(x, y, u, v) \quad (2.6\text{-}30)$$

onde $f(x, y)$ é a imagem de entrada, $r(x, y, u, v)$ é chamado de *kernel de transformação direta* e a Equação 2.6-30 é calculada para $u = 0, 1, 2, \ldots, M - 1$ e $v = 0, 1, 2, \ldots, N - 1$. Como antes, x e y são variáveis espaciais, enquanto M e N são as dimensões de linha e coluna de f. As variáveis u e v são chamadas de *variáveis da transformada*. $T(u, v)$ é chamada de *transformada direta* de $f(x, y)$. Dado $T(u, v)$, podemos recuperar $f(x, y)$ utilizando a *transformada inversa* de $T(u, v)$,

$$f(x, y) = \sum_{u=0}^{M-1} \sum_{v=0}^{N-1} T(u, v) s(x, y, u, v) \quad (2.6\text{-}31)$$

para $x = 0, 1, 2, \ldots, M - 1$ e $y = 0, 1, 2, \ldots, N - 1$, onde $s(x, y, u, v)$ é chamada de *kernel de transformação inversa*.

Juntas, as equações 2.6-30 e 2.6-31 são chamadas de um *par de transformadas*.

A Figura 2.39 mostra os passos básicos para realizar o processamento de imagens no domínio da transformada linear. Em primeiro lugar, a imagem de entrada é transformada, a imagem transformada é então modificada por uma operação predefinida, e, finalmente, a imagem de saída é obtida pelo cálculo da transformada inversa. Dessa forma, vemos que o processo passa do domínio espacial ao domínio da transformada e de volta ao domínio espacial.

■

Exemplo 2.11 Processamento de imagens no domínio da transformada.

A Figura 2.40 mostra um exemplo dos passos apresentados na Figura 2.39. Neste caso, a transformada utilizada foi a de Fourier, que mencionaremos de maneira breve mais adiante nesta seção e discutiremos em detalhes no Capítulo 4. A Figura 2.40(a) é uma imagem corrompida por uma interferência senoidal e a Figura 2.40(b) é a magnitude de sua transformada de Fourier, que é a saída do primeiro estágio na Figura 2.39. Como veremos no Capítulo 4, a interferência senoidal no domínio espacial é vista como pontos brilhantes (de intensidade alta) no domínio da transformada. Neste caso, os pontos brilhantes ocorrem em um padrão circular que pode ser visto na Figura 2.40(b). A Figura 2.40(c) mostra uma imagem máscara (chamada de *filtro*) com branco e preto representando 1 e 0, respectivamente. Para esse exemplo, a operação R mostrada no segundo quadro da Figura 2.39 consiste em multiplicar a máscara pela imagem no domínio da transformada eliminando, dessa forma, os pontos brilhantes responsáveis pela interferência senoidal. A Figura 2.40(d) mostra o resultado final, obtido pelo cálculo da transformada inversa da imagem modificada. A interferência não é mais visível e os detalhes importantes estão relativamente nítidos. Na verdade, é até possível ver as *marcas fiduciais* (pequenas cruzes quase imperceptíveis) utilizadas para alinhamento de imagem.

■

Diz-se que o *kernel* de transformação direta é *separável* se

$$r(x, y, u, v) = r_1(x, u)r_2(y, v) \qquad (2.6\text{-}32)$$

Além disso, diz-se que o *kernel* é *simétrico* se $r_1(x, y)$ for funcionalmente igual a $r_2(x, y)$, de forma que

$$r(x, y, u, v) = r_1(x, u)r_1(y, v) \qquad (2.6\text{-}33)$$

Comentários idênticos se aplicam ao *kernel* inverso substituindo r por s nas equações mencionadas.

A transformada bidimensional de Fourier discutida no Exemplo 2.11 tem os seguintes *kernels* direto e inverso:

$$r(x, y, u, v) = e^{-j2\pi(ux/M + vy/N)} \qquad (2.6\text{-}34)$$

e

$$s(x, y, u, v) = \frac{1}{MN} e^{j2\pi(ux/M+vy/N)} \qquad (2.6\text{-}35)$$

respectivamente, sendo $j = \sqrt{-1}$, de forma que esses *kernels* são complexos. Substituindo tais *kernels* nas fórmulas gerais de transformada apresentadas nas equações 2.6-30 e 2.6-31, temos o *par de transformadas discretas de Fourier*:

$$T(u, v) = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} f(x, y)\, e^{-j\,2\pi\,(ux/M + vy/N)} \qquad (2.6\text{-}36)$$

e

$$f(x, y) = \frac{1}{MN} \sum_{u=0}^{M-1} \sum_{v=0}^{N-1} T(u, v)\, e^{j2\pi\,(ux/M + vy/N)} \qquad (2.6\text{-}37)$$

Essas equações são de fundamental importância no processamento de imagens digitais, e dedicamos grande parte do Capítulo 4 para deduzi-las, começando dos princípios básicos e, depois, utilizando-as em uma ampla variedade de aplicações.

Não é difícil demonstrar que os *kernels* de Fourier são separáveis e simétricos (Exercício 2.25) e que os *kernels* separáveis e simétricos permitem que transformadas bidimensionais sejam computadas utilizando transformadas unidimensionais (Exercício 2.26). Quando os *kernels* direto e inverso de um par de transformadas satisfizeram essas duas condições e $f(x, y)$ for uma imagem quadrada de tamanho $M \times M$, as equações 2.6-30 e 2.6-31 poderão ser expressas na forma matricial:

$$\mathbf{T} = \mathbf{AFA} \qquad (2.6\text{-}38)$$

onde $\mathbf{F}$ é uma matriz $M \times M$ contendo os elementos de $f(x, y)$ (veja a Equação 2.4-2), $\mathbf{A}$ é uma matriz $M \times M$ com elementos $a_{ij} = r_1(i, j)$ e $\mathbf{T}$ é a transformada $M \times M$ resultante, com valores $T(u, v)$ para $u, v = 0, 1, 2, \ldots, M - 1$.

Para obter a transformada inversa, multiplicamos antes e depois a Equação 2.6-38 por uma matriz de transformação inversa $\mathbf{B}$:

$$\mathbf{BTB} = \mathbf{BAFAB} \qquad (2.6\text{-}39)$$

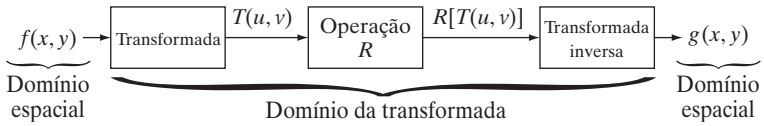


Figura 2.39 Abordagem geral para operar no domínio de uma transformada linear.

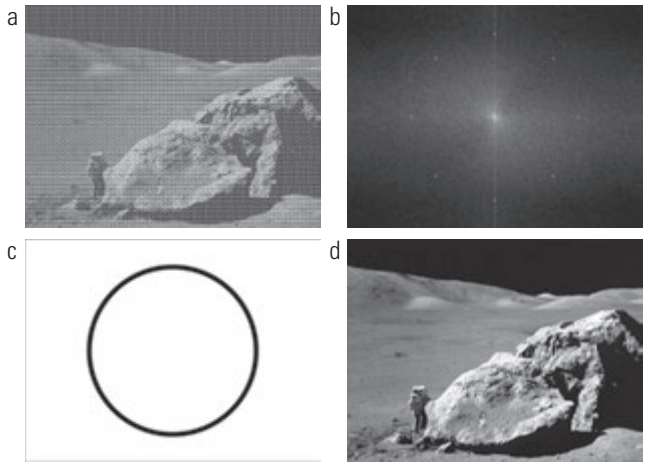


Figura 2.40 (a) Imagem corrompida por uma interferência senoidal. (b) Magnitude da transformada de Fourier mostrando pontos brilhantes de energia responsáveis pela interferência. (c) Máscara utilizada para eliminar os pontos brilhantes de energia. (d) Resultado obtido pelo cálculo da transformada da inversa de Fourier modificada. (Cortesia da Nasa).

Se $\mathbf{B} = \mathbf{A}^{-1}$,

$$\mathbf{F} = \mathbf{BTB} \tag{2.6-40}$$

indicando que **F** [cujos elementos são iguais à imagem $f(x, y)$] pode ser completamente recuperada a partir de sua transformada direta. Se **B** não for igual a $\mathbf{A}^{-1}$, o uso da Equação 2.6-40 gera uma aproximação:

$$\hat{\mathbf{F}} = \mathbf{BAFAB} \tag{2.6-41}$$

Além da transformada de Fourier, várias transformadas importantes, incluindo a de Walsh, de Hadamard, discreta de cosseno, de Haar e transformadas de slant, podem ser expressas na forma das equações 2.6-30 e 2.6-31 ou, de modo equivalente, na forma das equações 2.6-38 e 2.6-40. Discutiremos várias dessas transformadas de imagem, além de outros tipos de transformadas, em capítulos posteriores.

2.6.8 Métodos probabilísticos*

A probabilidade influencia o trabalho do processamento de imagens de várias formas. A mais simples é quando tratamos os valores de intensidade como variáveis aleatórias. Por exemplo, seja z_i, $i = 0, 1, 2, \ldots, L-1$ os valores de todas as intensidades possíveis em uma imagem digital $M \times N$. A probabilidade, $p(z_k)$, de vo nível de intensidade z_k ocorrer em uma determinada imagem é estimada como:

$$p(z_k) = \frac{n_k}{MN} \tag{2.6-42}$$

onde n_k é o número de vezes em que a intensidade z_k ocorre na imagem e MN é o número total de pixels. Naturalmente,

$$\sum_{k=0}^{L-1} p(z_k) = 1 \tag{2.6-43}$$

Calculado $p(z_k)$, podemos determinar uma série de características importantes da imagem. Por exemplo, a intensidade média é dada por

$$m = \sum_{k=0}^{L-1} z_k p(z_k) \tag{2.6-44}$$

De forma similar, a variância das intensidades é

$$\sigma^2 = \sum_{k=0}^{L-1} (z_k - m)^2 p(z_k) \tag{2.6-45}$$

A variância é uma medida de dispersão dos valores de z em relação à média, de forma que se trata de uma medida útil do contraste da imagem. Em geral, o n-ésimo momento da variável aleatória z em relação à média é definido como:

$$\mu_n(z) = \sum_{k=0}^{L-1} (z_k - m)^n p(z_k) \tag{2.6-46}$$

Vemos que $\mu_0(z) = 1$, $\mu_1(z) = 0$ e $\mu_2(z) = \sigma^2$.** Enquanto a média e a variância têm uma relação imediatamente óbvia com as propriedades visuais de uma imagem, momentos de ordem superior são mais sutis. Por exemplo, um terceiro momento positivo indica que as intensidades têm uma tendência a apresentar valores maiores do que a média; um terceiro momento negativo indicaria a condição oposta; e um terceiro momento zero indicaria que as intensidades são distribuídas de forma aproximadamente igual em ambos os lados do valor médio. Essas características são úteis para fins computacionais, mas não nos dizem muito sobre a aparência de uma imagem em geral.

* Consulte os tutoriais (em inglês) no site do livro para uma breve visão geral da teoria da probabilidade.

** As unidades de variância são em valores de intensidade elevados ao quadrado. Ao comparar valores de contraste, no entanto, normalmente utilizamos o desvio padrão, (raiz quadrada da variância), porque suas dimensões são diretamente em termos de valores de intensidade.

Exemplo 2.12 Comparação dos valores de desvio padrão como medidas de contraste da intensidade da imagem.

A Figura 2.41 apresenta três imagens de 8 bits mostrando baixo, médio e alto contraste, respectivamente. Os desvios padrão dos níveis de cinza dos pixels nas três imagens são 14,3; 31,6; e 49,2, respectivamente. Os valores de variância correspondentes são 204,3; 997,8; e 2.424,9, respectivamente. Os dois conjuntos de valores contam a mesma história, mas, considerando que o intervalo de possíveis valores de níveis de cinza nessas imagens seja [0, 255], os valores de desvio padrão se relacionam com esse intervalo de forma muito mais intuitiva do que a variância.

Como veremos ao longo deste livro, os conceitos da probabilidade exercem um papel central no desenvolvimento de algoritmos de processamento de imagens. Por exemplo, no Capítulo 3, utilizaremos a medida de probabilidade da Equação 2.6-42 para obter os algoritmos de transformação de intensidade. No Capítulo 5, utilizaremos formulações da probabilidade e de matriz para desenvolver algoritmos de restauração de imagens. No Capítulo 10, a probabilidade será utilizada para a segmentação de imagens e, no Capítulo 11, ela será utilizada para a descrição de texturas. No Capítulo 12, obteremos técnicas de reconhecimento de objetos com base em uma formulação probabilística.

Até agora, abordamos a questão da aplicação da probabilidade a uma única variável aleatória (intensidade) em uma única imagem 2-D. Se considerarmos sequências de imagens, podemos interpretar a terceira variável como sendo o tempo. As ferramentas necessárias para lidar com essa complexidade adicional são técnicas *estocásticas* de processamento de imagens (a palavra *estocástico* vem de uma palavra grega que significa, de modo genérico, "mirar em um alvo", sugerindo a aleatoriedade do resultado de um processo). Podemos ir um passo além e considerar uma imagem *inteira* (em oposição a um ponto) como o evento espacial aleatório. As ferramentas necessárias para lidar com as formulações baseadas nesse conceito são técnicas desenvolvidas a partir de *campos aleatórios*. Damos um exemplo na Seção 5.8 de como tratar imagens inteiras como eventos aleatórios, mas discussões mais aprofundadas de processos estocásticos e campos aleatórios estão além do escopo deste livro. As referências no final deste capítulo proporcionam um ponto de partida para a leitura sobre esses tópicos.

Resumo

O conteúdo deste capítulo constitui, em sua maior parte, uma base para as discussões subsequentes. Nossa abordagem do sistema visual humano, apesar de breve, dá uma ideia básica da capacidade de o olho perceber as informações visuais. A discussão sobre a luz e o espectro eletromagnético é fundamental para a compreensão da origem das várias imagens que utilizamos neste livro. De forma similar, o modelo de imagem desenvolvido na Seção 2.3.4 é utilizado no Capítulo 4 como a base para uma técnica de realce de imagem chamada de *filtragem homomórfica*.

Os conceitos de amostragem e interpolação apresentados na Seção 2.4 constituem as bases para muitos dos fenômenos de digitalização que você provavelmente encontrará na prática. Retomaremos a questão da amostragem e muitas de suas ramificações no Capítulo 4, depois de você ter dominado a transformada de Fourier e o domínio de frequência.

Os conceitos apresentados na Seção 2.5 são os elementos constitutivos básicos das técnicas de processamento baseadas nas vizinhanças de pixels. Por exemplo, como mostraremos no capítulo seguinte e no Capítulo 5, os métodos de processamento por vizinhanças estão no centro de muitos procedimentos de realce e restauração de imagens. No Capítulo 9, utilizaremos as operações por vizinhança na morfologia de imagens; no Capítulo 10, as utilizaremos para a segmentação de imagens; e, no Capítulo 11, para a descrição de imagens. Quando aplicável, o processamento por vizinhança é favorecido em usos comerciais de processamento de imagens em virtude de sua

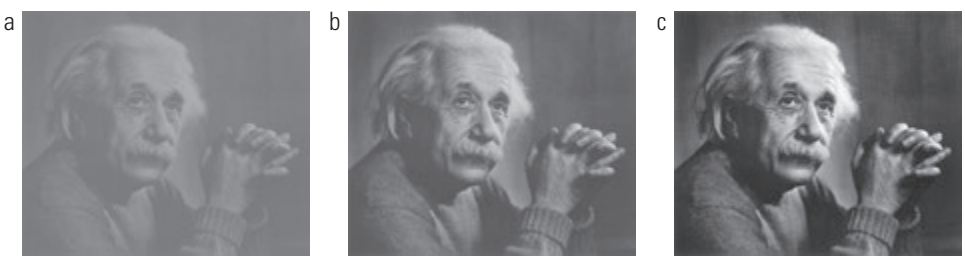


Figura 2.41 Imagens mostrando (a) baixo contraste, (b) médio contraste e (c) alto contraste.

velocidade operacional e simplicidade de implementação em hardware e/ou firmware.

O material da Seção 2.6 será útil em sua jornada ao longo deste livro. Apesar de o nível da discussão ter sido estritamente introdutório, agora você pode conceitualizar o que significa processar uma imagem digitalmente. Como mencionamos naquela seção, as ferramentas apresentadas são expandidas nos capítulos seguintes conforme necessário. Em vez de dedicar todo um capítulo ou apêndice para apresentar um tratamento abrangente dos conceitos matemáticos em um único local, fará mais sentido aprender as extensões necessárias das ferramentas matemáticas da Seção 2.6 em capítulos posteriores, no contexto de como elas são aplicadas para solucionar problemas de processamento de imagens.

Referências e leituras complementares

Leituras adicionais para o conteúdo da Seção 2.1, considerando a estrutura do olho humano, podem ser encontradas em Atchison e Smith (2000) e Oyster (1999). Para saber mais sobre a percepção visual, veja Regan (2000) e Gordon (1997). O livro de Hubel (1988) e o livro clássico de Cornsweet (1970) também são de interesse. Born e Wolf (1999) é uma referência básica que discute a luz em termos da teoria eletromagnética. A propagação da energia eletromagnética é coberta com algum detalhe em Felsen e Marcuvitz (1994).

A área de sensores de imagens é relativamente ampla e muito dinâmica. Uma excelente fonte de informações sobre sensores óticos e outros sensores de geração de imagens é a Sociedade de Engenharia Ótica (SPIE — *Society for Optical Engineering*). Sugerimos estas publicações representativas da SPIE nessa área: Blouke et al. (2001), Hoover e Doty (1996) e Freeman (1987).

O modelo de imagens apresentado na Seção 2.3.4 é de Oppenheim, Schafer e Stockham (1968). Uma referência para os valores de iluminação e refletância utilizados nesta seção é o *IESNA Lighting Handbook* (2000). Para saber mais sobre amostragem de imagens e alguns de seus efeitos, como o *aliasing*, veja Bracewell (1995). Discutiremos esse tópico em mais detalhes no Capítulo 4. Os primeiros experimentos mencionados na Seção 2.4.3 sobre a qualidade percebida da imagem como uma função da amostragem e quantização foram relatados por Huang (1965). A questão da redução do número de amostras e níveis de intensidade de uma imagem enquanto a degradação resultante é minimizada continua sendo de interesse atual, como exemplificado por Papamarkos e Atsalakis (2000). Para saber mais sobre a redução e a ampliação de imagens veja Sid-Ahmed (1995), Unser et al. (1995), Umbaugh (2005) e Lehmann et al. (1999). Para leituras adicionais sobre os tópicos cobertos na Seção 2.5, veja Rosenfeld e Kak (1982), Marchand-Maillet e Sharaiha (2000) e Ritter e Wilson (2001).

Leituras adicionais sobre sistemas lineares no contexto do processamento de imagens (Seção 2.6.2) podem ser encontradas em Castleman (1996). O método de redução de ruídos por meio da média de múltiplas imagens (Seção 2.6.3) foi proposto pela primeira vez por Kohler e Howell (1963). Veja Peebles (1993) em relação ao valor esperado da média e da variância de uma soma de variáveis aleatórias. A subtração de imagens (Seção 2.6.3) é uma ferramenta genérica de processamento de imagens utilizada em grande parte para a detecção de mudanças. Para que a subtração de imagens faça sentido, é necessário que as imagens subtraídas sejam registradas ou, de forma alternativa, que quaisquer artefatos causados pelo movimento sejam identificados. Dois artigos de Meijering et al. [1999, 2001] são representativos dos tipos de técnicas utilizadas para atingir esses objetivos.

Uma referência básica para o conteúdo apresentado na Seção 2.6.4 é Cameron (2005). Para leituras mais avançadas sobre o assunto, veja Tourlakis (2003). Para uma introdução aos conjuntos *fuzzy*, veja a Seção 3.8 e as referências correspondentes no Capítulo 3. Para mais detalhes sobre o processamento ponto a ponto e processamento por vizinhança (Seção 2.6.5), veja as seções 3.2 a 3.4 e as referências para esses tópicos no Capítulo 3. Para transformações espaciais geométricas, veja Wolberg (1990).

Noble e Daniel (1988) é uma referência básica para operações com matrizes e vetores (Seção 2.6.6). Veja o Capítulo 4 para uma discussão detalhada sobre a transformada de Fourier (Seção 2.6.7) e os capítulos 7, 8 e 11 para exemplos de outros tipos de transformadas utilizadas no processamento de imagens digitais. Peebles (1993) é uma introdução básica à probabilidade e variáveis aleatórias (Seção 2.6.8) e Papoulis (1991) apresenta uma metodologia mais avançada do tema. Para textos fundamentais sobre a utilização de áreas estocásticas e aleatórias no processamento de imagens, veja Rosenfeld e Kak (1982), Jähne (2002) e Won e Gray (2004).

Para detalhes sobre a implementação em aplicativos computacionais de muitas das técnicas ilustradas neste capítulo, veja Gonzalez, Woods e Eddins (2004).