Capítulo 3

# Transformações de intensidade e filtragem espacial

Faz toda a diferença enxergar a escuridão através da luz ou a claridade através das sombras.

*David Lindsay*

## Apresentação

A expressão *domínio espacial* se refere ao próprio plano imagem, e os métodos de processamento de imagens nessa categoria se baseiam na manipulação direta de pixels em uma imagem. Isso se contrasta com o processamento de imagens em um *domínio da transformada*, que, como vimos rapidamente na Seção 2.6.7 e discutiremos em mais detalhes no Capítulo 4, envolve primeiro transformar uma imagem no domínio da transformada, realizar o processamento nesse domínio e obter a transformada inversa para retornar os resultados ao domínio espacial. As duas principais categorias do processamento espacial são transformações de intensidade e filtragem espacial. Como veremos neste capítulo, as transformações de intensidade operam individualmente nos pixels de uma imagem, principalmente para fins de manipulação de contraste e limiarização de imagem. A filtragem espacial lida com a realização de operações como o realce de imagens, trabalhando na vizinhança de cada pixel de uma imagem. Nas seções a seguir, discutiremos várias técnicas "clássicas" de transformações de intensidade e filtragem espacial. Também veremos em alguns detalhes técnicas *fuzzy* (difusas) que nos permitem incorporar informações imprecisas, baseadas em conhecimento, na formulação de algoritmos de transformações de intensidade e filtragem espacial.

## 3.1 Fundamentos

### 3.1.1 Os fundamentos das transformações de intensidade e filtragem espacial

Todas as técnicas de processamento de imagem discutidas nesta seção são implementadas no *domínio espacial*, que, como sabemos com base na análise da Seção 2.4.2, se trata simplesmente do plano contendo os pixels de uma imagem. Como observado na Seção 2.6.7, as técnicas de domínio espacial atuam diretamente nos pixels de uma imagem em oposição, por exemplo, ao domínio de frequência (o tópico do Capítulo 4), no qual as operações são realizadas na transformada de Fourier de uma imagem, e não na própria imagem. Como veremos ao longo do livro, algumas tarefas de processamento de imagens são mais fáceis ou fazem mais sentido se implementadas no domínio espacial, ao passo que outras são mais adequadas para outras abordagens. Em geral, as técnicas no domínio espacial são computacionalmente mais eficientes e requerem menos recursos de processamento para serem realizadas.

Os processos no domínio espacial que discutiremos neste capítulo podem ser expressos por:

$$g(x, y) = T[f(x, y)] \tag{3.1-1}$$

onde $f(x, y)$ é a imagem de entrada, $g(x, y)$ é a imagem de saída, e $T$ é um operador em $f$ definido em uma vizinhança do ponto $(x, y)$. O operador pode ser aplicado a

uma única imagem (nosso principal foco neste capítulo) ou a um conjunto de imagens, como no procedimento de soma pixel por pixel de uma sequência de imagens para a redução de ruídos, como discutimos na Seção 2.6.3. A Figura 3.1 mostra a aplicação básica da Equação 3.1-1 em uma única imagem. O ponto $(x, y)$ mostrado é uma posição arbitrária na imagem, e a pequena região contendo o ponto é uma vizinhança de $(x, y)$, como explicado na Seção 2.6.5. Em geral, a vizinhança é retangular, centrada em $(x, y)$ e tem tamanho muito menor que a imagem.*

O processo ilustrado na Figura 3.1 consiste em mover a origem da vizinhança de um pixel ao outro e aplicar o operador $T$ aos pixels na vizinhança para gerar a saída nessa posição. Dessa forma, para qualquer posição específica $(x, y)$, o valor da imagem de saída $g$ nessas coordenadas é igual ao resultado da aplicação de $T$ à vizinhança com origem em $(x, y)$ na imagem $f$. Por exemplo, suponha que a vizinhança seja um quadrado de tamanho 3 × 3 e que o operador $T$ seja definido como "calcular a intensidade média da vizinhança". Considere uma posição arbitrária em uma imagem, digamos (100, 150). Supondo que a origem da vizinhança seja no seu centro, o resultado, $g(100, 150)$, nessa posição é calculado como a soma de $f(100, 150)$ e seus vizinhos-8, dividida por 9 (isto é, a intensidade média dos pixels contidos na vizinhança).

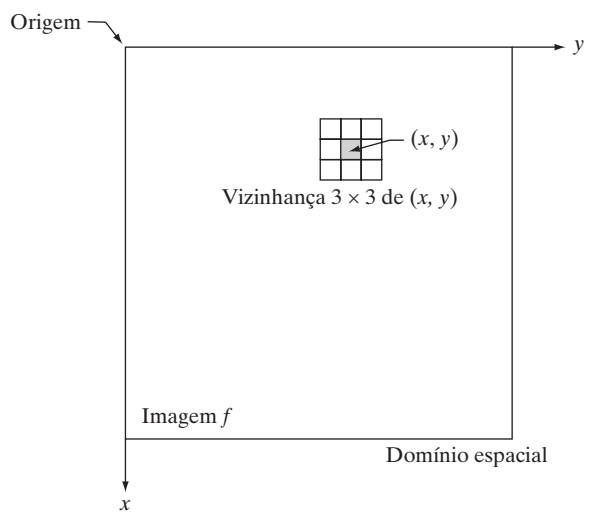



**Figura 3.1** Uma vizinhança 3 × 3 ao redor de um ponto $(x, y)$ em uma imagem no domínio espacial. A vizinhança é movida pixel a pixel na imagem para gerar uma imagem de saída.

A origem da vizinhança é, então, movida para a próxima posição e o procedimento é repetido para gerar o próximo valor da imagem de saída $g$. Normalmente, o processo tem início no canto superior esquerdo da imagem de entrada e avança pixel por pixel em uma varredura horizontal, uma linha por vez. Quando a origem da vizinhança se localizar na borda da imagem, parte da vizinhança ficará fora dela. O procedimento consiste em ignorar os vizinhos externos nos cálculos especificados por $T$ ou preencher a imagem com uma borda de 0s ou outros valores de intensidade predefinidos. A espessura da borda de preenchimento depende do tamanho da vizinhança. Retomaremos esse ponto na Seção 3.4.1.

Como discutiremos em detalhes na Seção 3.4, o procedimento que acabamos de descrever é chamado de *filtragem espacial*, no qual a vizinhança, acompanhada de uma operação predefinida, é chamada de *filtro espacial* (também denominada *máscara espacial*, *kernel*, *template* ou *janela*). O tipo de operação realizada na vizinhança determina a natureza do processo de filtragem.

A menor vizinhança possível tem tamanho 1 × 1. Nesse caso, $g$ depende apenas do valor de $f$ em um único ponto $(x, y)$, e $T$ na Equação 3.1-1 se torna uma *função de transformação de intensidade* (também chamada de *função de transformação de níveis de cinza* ou de *função de mapeamento*) da forma:

$$s = T(r) \tag{3.1-2}$$

onde, para simplificar a notação, $s$ e $r$ são variáveis que indicam, respectivamente, a intensidade de $g$ e $f$ em qualquer ponto $(x, y)$. Por exemplo, se $T(r)$ tiver a forma da Figura 3.2(a), o efeito da aplicação da transformação a cada pixel de $f$ para gerar os pixels correspondentes em $g$ seria produzir uma imagem de maior contraste do que a original, escurecendo os níveis de intensidade abaixo de $k$ e clareando os níveis acima de $k$. Nessa técnica, algumas vezes chamada de *alargamento de contraste* (veja a Seção 3.2.4), os valores de $r$ menores que $k$ são comprimidos pela função de transformação em uma faixa estreita de $s$, na direção do nível mais escuro. O oposto se aplica a valores de $r$ maiores que $k$. Observe como um valor de intensidade $r_0$ é mapeado para obter o valor correspondente $s_0$. No caso limite mostrado na Figura 3.2(b), $T(r)$ produz uma imagem de dois níveis (binária). Um mapeamento dessa forma é chamado de função de *limiarização* (*thresholding*). Algumas metodologias de processamento relativamente simples, ainda que poderosas, podem ser formuladas com base nas funções de transformação de intensidade. Neste capítulo, utilizaremos as transforma-

* Outros formatos de vizinhança, com aproximações digitais de círculos, por vezes são utilizados, mas os formatos retangulares são os mais comuns por serem muito mais fáceis de serem implementados computacionalmente.

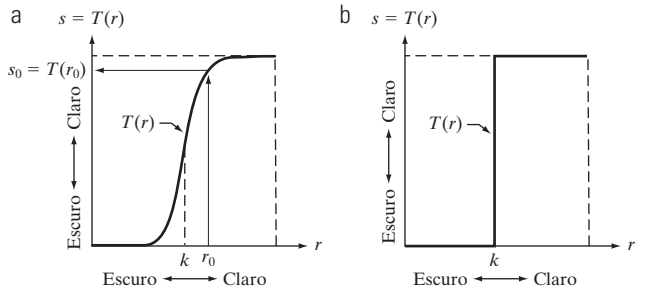



**Figura 3.2** Funções de transformação de intensidade. (a) Função de alargamento de contraste. (b) Função de limiarização.

ções de intensidade principalmente para o realce de imagens. No Capítulo 10, elas são utilizadas na segmentação de imagens. Procedimentos cujos resultados dependem somente da intensidade em um ponto são, por vezes, chamadas de técnicas de *processamento ponto a ponto*, em oposição a técnicas de *processamento por vizinhança*, discutidas anteriormente nesta seção.

### 3.1.2 Sobre os exemplos deste capítulo

Apesar de as transformações de intensidade e filtragem espacial cobrirem uma ampla variedade de aplicações, a maioria dos exemplos apresentados neste capítulo é de aplicações para o realce de imagens. *Realce* é o processo de manipular uma imagem de forma que o resultado seja mais adequado do que o original para uma aplicação específica. A palavra *específica* é importante neste contexto, porque reconhece desde o início que as técnicas de realce são orientadas ao problema. Dessa forma, por exemplo, um método bastante útil para realçar imagens de raios X pode não ser a melhor técnica para realçar imagens de satélite capturadas na banda infravermelha do espectro eletromagnético. Não existe uma "teoria" geral para o realce de imagens. Quando uma imagem é processada para a interpretação visual, o observador é o juiz em relação ao desempenho de um método particular. Ao lidar com a percepção por máquina, é mais fácil quantificar uma determinada técnica. Por exemplo, em um sistema de reconhecimento automático de caracteres, o método de realce mais apropriado é aquele que resulta na melhor taxa de reconhecimento, desconsiderando outros fatores, como os requisitos computacionais de um método em relação a outro.

Independentemente da aplicação ou do método utilizado, contudo, o realce de imagens é uma das áreas mais visualmente interessantes do processamento de imagens. Por sua própria natureza, os iniciantes no processamento de imagens costumam considerar as aplicações de realce interessantes e de compreensão relativamente simples. Dessa forma, utilizar exemplos de realce de imagens para ilustrar os métodos de processamento espacial abordados neste capítulo, não apenas evita termos um capítulo adicional no livro dedicado exclusivamente ao realce de imagens, como também, e o mais importante, constitui um método eficaz para apresentar aos iniciantes os detalhes das técnicas de processamento no domínio espacial. Como você verá ao longo do livro, o material básico explicado neste capítulo se aplica a um escopo muito mais amplo do que somente o realce de imagens.

## 3.2 Algumas funções básicas de transformação de intensidade

As transformações de intensidade estão entre as mais simples de todas as técnicas de processamento de imagens. Os valores dos pixels antes e depois do processamento serão representados por $r$ e $s$, respectivamente. Como indicado na seção anterior, esses valores estão relacionados por uma expressão da forma $s = T(r)$, onde $T$ é uma transformação que mapeia um valor de pixel $r$ em um valor de pixel $s$. Como estamos lidando com variáveis digitais, os valores de uma função de transformação normalmente são armazenados em um arranjo unidimensional e os mapeamentos de $r$ em $s$ são implementados por meio de buscas em tabelas indexadas (*table lookups*). Para um ambiente de 8 bits, uma tabela indexada contendo os valores de $T$ terá 256 entradas.

Como uma introdução às transformações de intensidade, vejamos a Figura 3.3, que mostra três tipos básicos de funções frequentemente utilizadas para o realce de imagens: linear (transformações de negativo e de identidade), logarítmica (transformações de log e log inverso) e de potência (transformações de $n$-ésima potência e $n$-ésima raiz). A função identidade é o caso trivial no qual as intensidades de saída são idênticas às intensidades de entrada. Ela foi incluída no gráfico só para uma abrangência completa.

### 3.2.1 Negativos de imagem

O negativo de uma imagem com níveis de intensidade na faixa $[0, L - 1]$ é obtido utilizando a transformação de negativo mostrada na Figura 3.3, dada pela expressão:

$$s = L - 1 - r \tag{3.2-1}$$

Reverter os níveis de intensidade de uma imagem dessa maneira produz o equivalente a um negativo fotográfico. Esse tipo de processamento é particularmente adequado para realçar detalhes brancos ou cinza incorporados a regiões escuras de uma imagem, especialmente

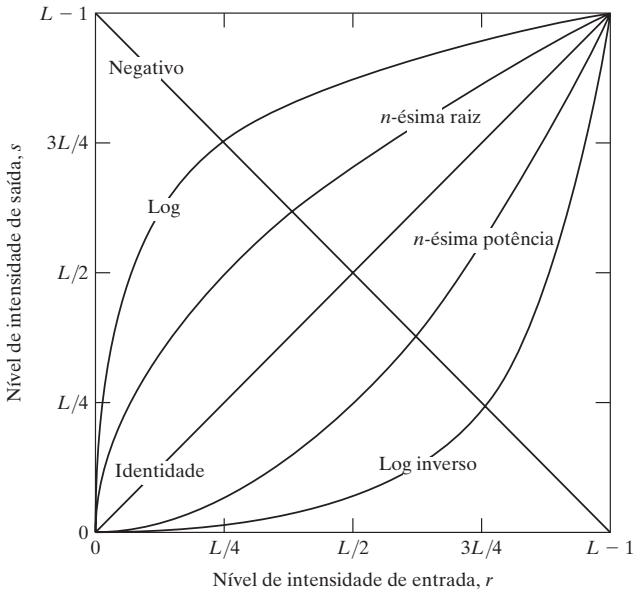



**Figura 3.3** Algumas funções básicas de transformação de intensidade. Todas as curvas foram ajustadas para o intervalo mostrado.

quando as áreas escuras são dominantes em termos de tamanho. A Figura 3.4 mostra um exemplo. A imagem original é uma mamografia digital mostrando uma pequena lesão. Apesar de o conteúdo visual ser o mesmo nas duas imagens, observe como é mais fácil analisar o tecido mamário no negativo da imagem neste caso particular.

### 3.2.2 Transformações logarítmicas

A forma geral da transformação logarítmica na Figura 3.3 é:

$$s = c \log (1 + r) \tag{3.2-2}$$

onde $c$ é uma constante e considera-se que r ≥ 0. O formato da curva logarítmica na Figura 3.3 mostra que essa transformação mapeia uma faixa estreita de baixos valores de intensidade de entrada em uma faixa mais ampla

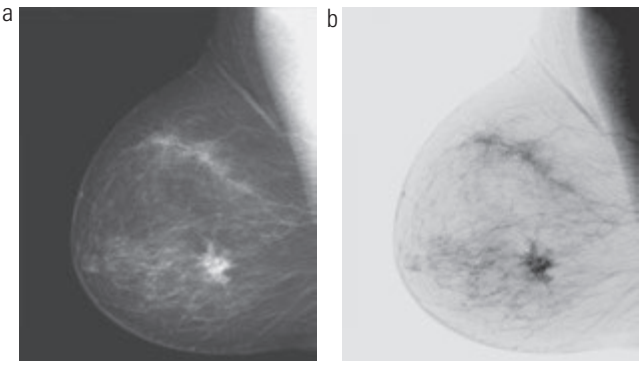



**Figura 3.4** (a) Mamografia digital original. (b) Negativo da imagem obtido utilizando a função de transformação da Equação 3.2-1. (Cortesia da G.E. Medical Systems.)

de níveis de saída. O oposto se aplica aos valores mais altos de níveis de intensidade de entrada. Utilizamos uma transformação desse tipo para expandir os valores de pixels mais escuros em uma imagem ao mesmo tempo em que comprimimos os valores de nível mais alto. O oposto se aplica à transformação logarítmica inversa.

Qualquer curva que tenha o formato geral das funções logarítmicas mostradas na Figura 3.3 realizaria essa expansão/compressão dos níveis de intensidade em uma imagem, mas as transformações de potência discutidas na próxima seção são muito mais versáteis para esse propósito. A função logarítmica tem a importante característica de comprimir a faixa dinâmica das imagens com grandes variações de valores de pixels. Uma ilustração clássica de uma aplicação na qual os valores de pixels têm uma grande faixa dinâmica é o espectro de Fourier, que discutiremos no Capítulo 4. Por ora, nos concentraremos apenas nas características das imagens dos espectros. Não é incomum encontrarmos valores de espectro variando de 0 a $10^6$ ou mais. Apesar de o processamento de números como esses não apresentar problemas para o computador, os sistemas de exibição de imagens geralmente não são capazes de reproduzir com fidelidade uma variedade tão ampla de valores de intensidade. O efeito final é que um grau significativo de detalhes de intensidade pode se perder na exibição de um espectro de Fourier típico.

Como uma ilustração das transformações logarítmicas, a Figura 3.5(a) mostra um espectro de Fourier com valores variando de 0 a $1{,}5 \times 10^6$. Quando esses valores são linearmente ajustados para serem exibidos em um sistema de 8 bits, os pixels mais claros dominam a exibição em detrimento dos valores mais baixos (e tão importantes quanto) do espectro. O efeito dessa dominância é ilustrado pela área relativamente pequena da imagem na Figura 3.5(a) que não é percebida como preta. Se, em vez de exibir os valores dessa maneira, aplicarmos inicialmente a Equação 3.2-2 (com $c$ = 1 neste caso) aos valores do espectro, a faixa de valores do resultado passa a ser de 0 a 6,2, que é a mais apropriada. A Figura 3.5(b) mostra o resultado de ajustar linearmente essa nova faixa e exibir o espectro no mesmo monitor de 8 bits. A riqueza de detalhes visíveis nessa imagem em comparação com uma exibição não modificada do espectro fica clara nessas imagens. A maior parte dos espectros de Fourier vistos em publicações de processamento de imagens foi ajustada dessa forma.

### 3.2.3 Transformações de potência (gama)

As transformações de potência apresentam a forma básica:

$$s = cr^{\gamma} \tag{3.2-3}$$

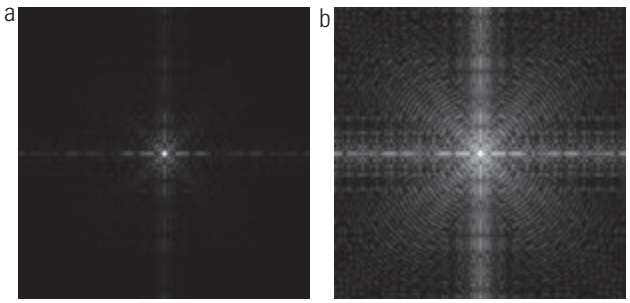



**Figura 3.5** (a) Espectro de Fourier. (b) Resultado da aplicação da transformação logarítmica da Equação 3.2-2 com $c = 1$.

sendo $c$ e $\gamma$ constantes positivas. Algumas vezes a Equação 3.2-3 é escrita como $s = c\,(r + \varepsilon)^{\gamma}$ para incluir uma compensação ou *offset* (isto é, uma saída mensurável quando a entrada for zero). No entanto, as compensações costumam ser um problema na calibração de monitores e, como resultado, costumam ser ignoradas na Equação 3.2-3. Plotagens de $s$ *versus* $r$ para vários valores de $\gamma$ são mostradas na Figura 3.6. Como no caso da transformação logarítmica, curvas de transformação de potência com valores de $\gamma$ menores que 1 (fração) mapeiam uma faixa estreita de valores escuros de entradas em uma faixa mais ampla de valores de saída, com o oposto se aplicando a valores mais altos de níveis de entrada. Diferentemente da função logarítmica, contudo, notamos aqui toda uma classe de curvas de transformação possíveis obtidas simplesmente por meio da variação de $\gamma$. Como esperávamos, vemos na Figura 3.6 que essas curvas geradas com valores de $\gamma > 1$ têm o efeito exatamente oposto que as geradas com valores de $\gamma < 1$. Por fim, notamos que a Equação 3.2-3 é reduzida à transformação de identidade quando $c = \gamma = 1$.

Uma série de dispositivos utilizados para a captura, impressão e exibição de imagens funciona de acordo com uma lei de potência. Por convenção, o expoente na equação de potência é chamado de *gama* (daí a utilização desse símbolo na Equação 3.2-3). O processo utilizado para corrigir esses fenômenos de resposta à lei de potência é chamado de *correção gama*. Por exemplo, dispositivos de tubo de raios catódicos (CRT, de *cathode ray tube*) apresentam uma resposta de intensidade em relação à tensão que é uma função de potência, com expoentes variando de aproximadamente 1,8 a 2,5. No que se refere à curva para $\gamma = 2{,}5$ na Figura 3.6, vemos que sistemas de exibição de imagens como esses tenderiam a produzir imagens mais escuras que o pretendido. Esse efeito é ilustrado na Figura 3.7. A Figura 3.7(a) mostra uma imagem de variação gradativa de intensidade (gradiente) exibida em um monitor. Como esperado, a imagem de

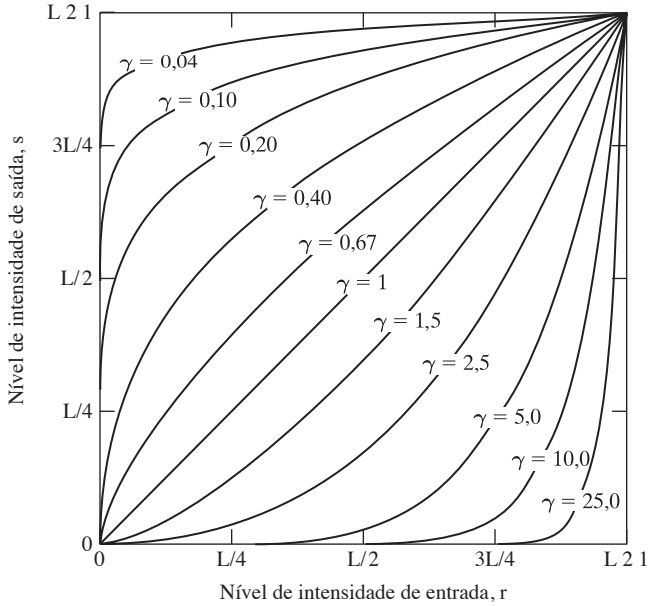



**Figura 3.6** Plotagens da equação $s = cr^{\gamma}$ para vários valores de $\gamma$ ($c = 1$ em todos os casos). Todas as curvas foram ajustadas para se adequar à faixa mostrada.

saída no monitor parece mais escura que a imagem original de entrada, como mostra a Figura 3.7(b). A correção gama nesse caso é direta. Tudo o que precisamos fazer é pré-processar a imagem de entrada antes de exibi-la no monitor, realizando a transformação $s = r^{1/2,5} = r^{0,4}$. O resultado é mostrado na Figura 3.7(c). Quando exibida no mesmo monitor, a entrada transformada pela corre-

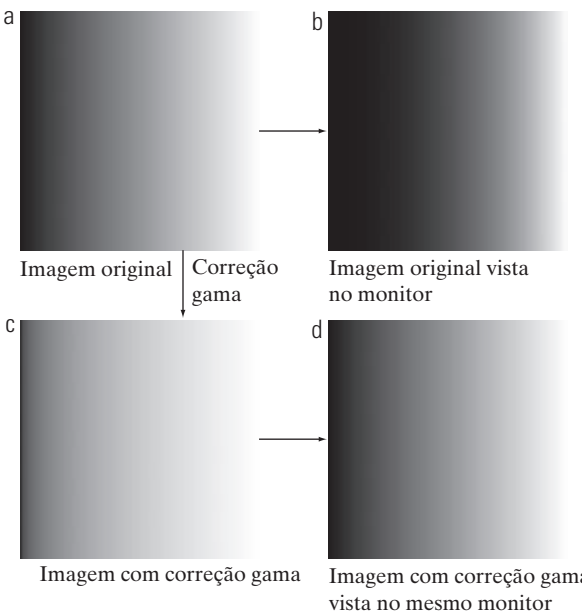



**Figura 3.7** (a) Imagem com variação gradativa de intensidade (gradiente). (b) Imagem vista em um monitor simulado com gama igual a 2,5. (c) Imagem com correção gama. (d) Imagem corrigida vista no mesmo monitor. Compare (d) e (a).

ção gama produz uma saída mais parecida com a imagem original, como mostra a Figura. 3.7(d). Uma análise similar pode ser aplicada a outros dispositivos de geração de imagens, como digitalizadores e impressoras. A única diferença seria o valor de gama, que depende do dispositivo (Poynton, 1996).

A correção gama é importante quando uma imagem precisa ser exibida na tela de um computador como exatidão. Imagens que não são adequadamente corrigidas podem ter uma aparência desbotada ou, o que é mais provável, escura demais. Tentar reproduzir as cores com exatidão também requer algum conhecimento da correção gama porque a variação do valor de gama altera não apenas a intensidade como também as proporções de vermelho, verde e azul em uma imagem colorida. A correção gama tem se tornado cada vez mais relevante nos últimos anos, à medida que o uso de imagens digitais para fins comerciais na Internet tem aumentado. Não é incomum que imagens criadas para um site popular da rede sejam vistas por milhões de pessoas, a maioria das quais com diferentes monitores e/ou configurações de monitor. Alguns sistemas de computador chegam a incorporar correção gama parcial. Além disso, padrões atuais de imagens não contêm o valor de gama com o qual uma imagem foi criada, complicando ainda mais a questão. Dadas essas limitações, uma metodologia razoável para armazenar imagens em um site na Internet é pré-processar as imagens com um valor gama que represente uma "média" dos tipos de monitores e sistemas computacionais disponíveis comercialmente naquele determinado momento.

■

### Exemplo 3.1 Realce de contraste utilizando transformações de potência.

Além da correção gama, as transformações de potência são úteis para a manipulação de contraste para uso geral. A Figura 3.8(a) mostra uma imagem de ressonância magnética (MRI) de uma coluna vertebral humana na região torácica superior com uma fratura-luxação e pinçamento medular. A fratura é visível perto do centro vertical da medula, aproximadamente um quarto para baixo em relação à borda superior da imagem. Como a imagem é predominantemente escura, uma expansão dos níveis de intensidade é desejável. Isso pode ser feito com uma transformação de potência utilizando um expoente fracionário ($\gamma < 1$). As outras imagens mostradas na figura foram obtidas por meio do processamento da Figura 3.8(a) com a função de transformação de potência da Equação 3.2-3. Os valores de gama correspondentes às imagens (b) a (d) são 0,6, 0,4 e 0,3, respectivamente (o valor de $c$ é 1 em todos os casos). Notamos que, à medida que gama foi reduzido de 0,6 a 0,4, mais detalhes se tornaram visíveis. Uma redução adicional de gama para 0,3

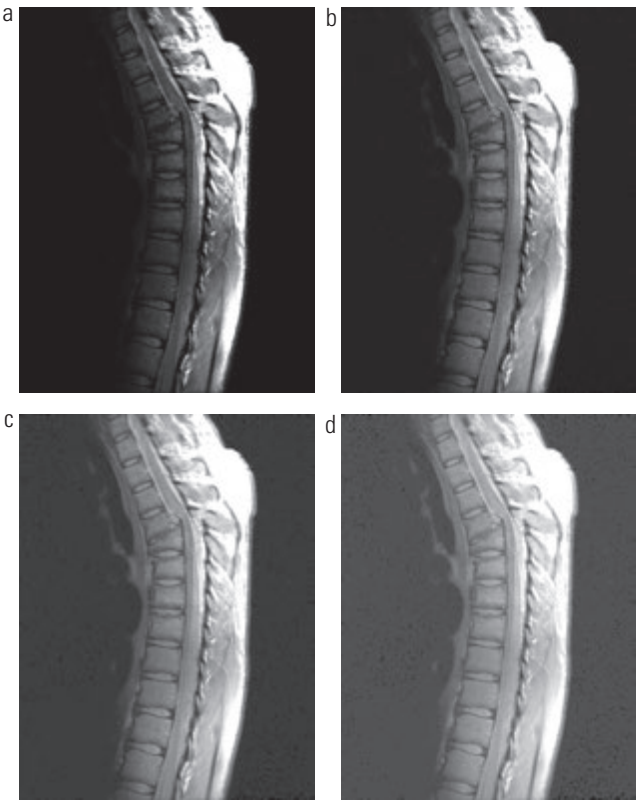



**Figura 3.8** (a) Imagem de ressonância magnética (MRI) de uma coluna vertebral humana fraturada. (b) a (d) Resultados da aplicação da transformação na Equação 3.2-3 com $c = 1$ e $\gamma = 0{,}6$, 0,4 e 0,3, respectivamente. (Imagem original: cortesia do Dr. David R. Pickens, Departamento de Radiologia e Ciências Radiológicas, Centro Médico da Universidade de Vanderbilt.)

aumentou um pouco mais os detalhes do fundo da imagem, mas já começou a reduzir o contraste, de modo que a imagem passou a ter uma aparência ligeiramente "desbotada", sem brilho, especialmente no fundo. Ao comparar todos os resultados, vemos que o maior realce em termos de contraste e detalhes discerníveis foi obtido com $\gamma = 0{,}4$. Um valor de $\gamma = 0{,}3$ é um limite aproximado abaixo do qual o contraste para essa imagem especificamente seria reduzido a um nível inaceitável.

■

■

### Exemplo 3.2 Uma outra ilustração das transformações de potência.

A Figura 3.9(a) mostra o problema oposto ao da Figura 3.8(a). A imagem a ser processada agora tem uma aparência desbotada, indicando que a compressão dos níveis de intensidade é desejável. Isso pode ser realizado com a Equação 3.2-3 utilizando valores de $\gamma$ maiores do que 1. Os resultados do processamento da Figura 3.9(a) com $\gamma = 3{,}0$, 4,0 e 5,0 são mostrados nas figuras 3.9(b) a (d). Resultados adequados foram obtidos com valores de gama iguais a 3,0 e 4,0, e o último apresentou uma aparência ligeiramente

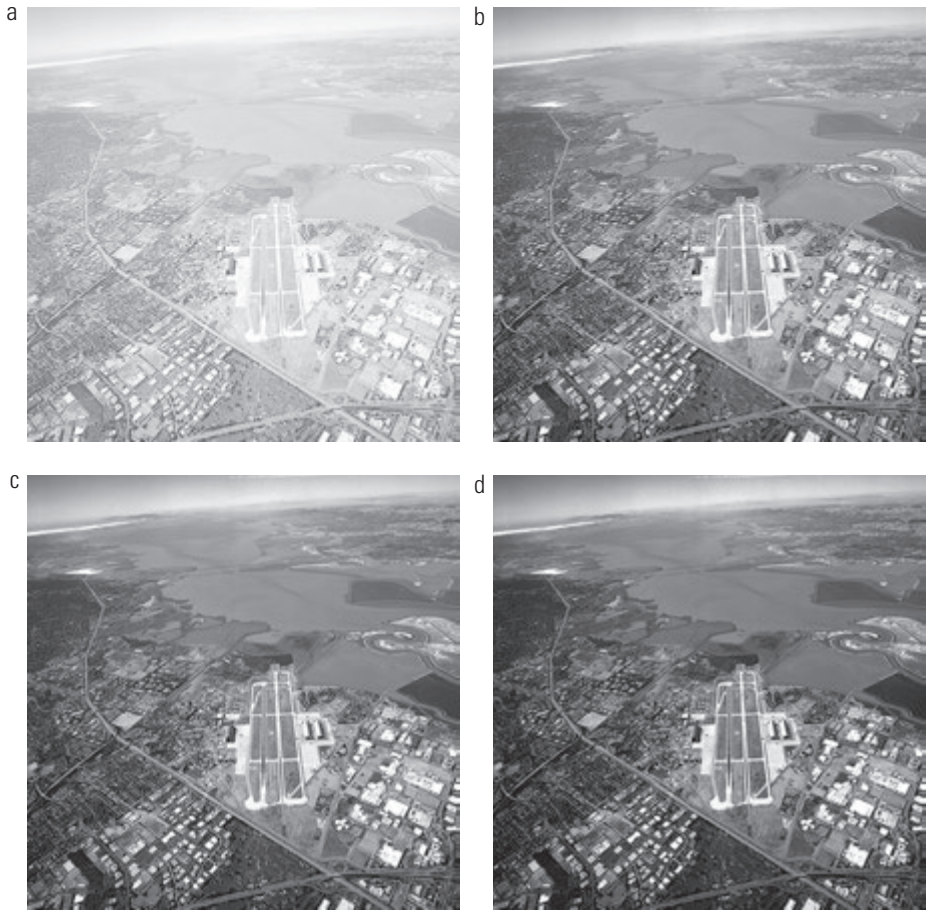



**Figura 3.9** (a) Imagem aérea. (b) a (d) Resultados da aplicação da transformação na Equação 3.2-3 com $c = 1$ e $\gamma = 3{,}0$, 4,0 e 5,0, respectivamente. (Imagem original: cortesia da Nasa.)

melhor graças ao maior contraste. O resultado obtido com $\gamma = 5{,}0$ apresenta áreas muito escuras, nas quais alguns detalhes são perdidos. A região escura à esquerda da estrada principal no quadrante superior esquerdo é um exemplo de uma área assim.

■

### 3.2.4 Funções de transformação linear definidas por partes

Uma abordagem complementar aos métodos discutidos nas três seções anteriores consiste na utilização de funções lineares definidas por partes. A principal vantagem das funções lineares por partes sobre os tipos de funções que discutimos até agora é que a forma das funções por partes pode ser arbitrariamente complexa. De fato, como veremos em breve, a implementação prática de algumas transformações importantes só pode ser formulada como funções por partes. A principal desvantagem das funções por partes consiste no fato de sua especificação requerer consideravelmente mais dados de entrada do usuário.

**Alargamento de contraste**

Uma das mais simples funções lineares definidas por partes é a transformação de alargamento de contraste. Imagens de baixo contraste podem resultar de uma iluminação ruim, de uma faixa dinâmica insuficiente no sensor de imagem ou até mesmo de uma configuração errada da abertura de uma lente no momento da aquisição da imagem. O *alargamento de contraste* é um processo que expande a faixa de níveis de intensidade de uma imagem de modo a incluir todo o intervalo de intensidades do meio de gravação ou do dispositivo de exibição.

A Figura 3.10(a) mostra uma transformação típica utilizada para o alargamento de contraste. As posições dos pontos $(r_1, s_1)$ e $(r_2, s_2)$ controlam o formato da função de transformação. Se $r_1 = s_1$ e $r_2 = s_2$, a transformação é uma função linear que não produz nenhuma alteração nos níveis de intensidade. Se $r_1 = r_2$, $s_1 = 0$ e $s_2 = L - 1$, a transformação se torna uma *função de limiarização* que cria uma imagem binária, como ilustrado na Figura 3.2(b). Os valores intermediários de $(r_1, s_1)$ e $(r_2, s_2)$ produzem vários

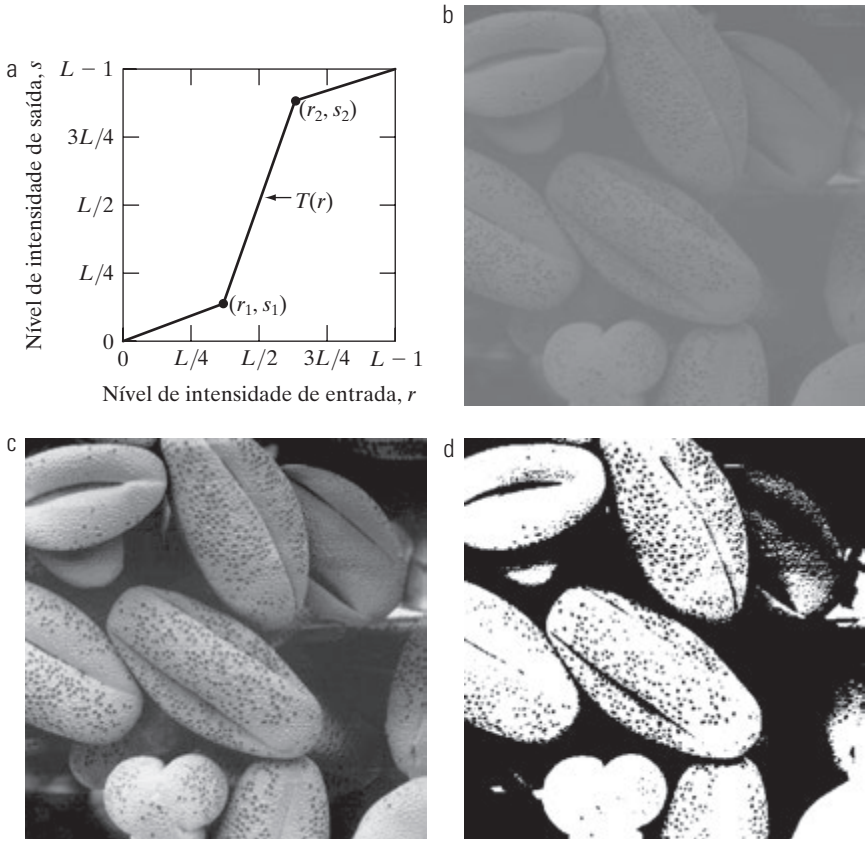



**Figura 3.10** Alargamento de contraste. (a) Forma da função de transformação. (b) Uma imagem de baixo contraste. (c) Resultado do alargamento de contraste. (d) Resultado da limiarização. (Imagem original: cortesia do Dr. Roger Heady, Faculdade de Pesquisas em Ciências Biológicas, Universidade Nacional Australiana, Camberra, Austrália.)

graus de expansão dos níveis de intensidade da imagem de saída, afetando, assim, seu contraste. Em geral, pressupõe-se que $r_1 \leq r_2$ e $s_1 \leq s_2$, de forma que a função tenha um valor único e seja monotonicamente crescente. Essa condição mantém a ordem dos níveis de intensidade, prevenindo, assim a criação de artefatos de intensidade na imagem processada.

A Figura 3.10(b) mostra uma imagem de 8 bits com baixo contraste. A Figura 3.10(c) mostra o resultado do alargamento de contraste, obtido definindo $(r_1, s_1) = (r_{\text{mín}}, 0)$ e $(r_2, s_2) = (r_{\text{máx}}, L - 1)$, onde $r_{\text{mín}}$ e $r_{\text{máx}}$ são os níveis mínimo e máximo de intensidade da imagem, respectivamente. Dessa forma, a função de transformação alargou linearmente os níveis de seu intervalo original para o intervalo completo $[0, L - 1]$. Por fim, a Figura 3.10(d) mostra o resultado da aplicação da função de limiarização definida anteriormente, com $(r_1, s_1) = (m, 0)$ e $(r_2, s_2) = (m, L - 1)$, sendo $m$ o nível médio de intensidade da imagem. A imagem original na qual esses resultados se baseiam é uma imagem de grãos de pólen, gerada por microscópio eletrônico de varredura e ampliada aproximadamente 700 vezes.

### Fatiamento de níveis de intensidade

Frequentemente, pode ser interessante enfatizar um intervalo específico de intensidades em uma imagem. As aplicações incluem realce de características como massas de água em imagens de satélite e realce de falhas em imagens de raios X. O processo, muitas vezes chamado de *fatiamento de níveis de intensidade*, pode ser implementado de várias formas, mas a maioria constitui uma variação de dois temas básicos. Uma metodologia consiste em exibir em um valor (digamos, o branco), todos os valores na faixa de interesse e, em outro (digamos, o preto), todas as outras intensidades. Essa transformação, mostrada na Figura 3.11(a), produz uma imagem binária. A segunda metodologia, baseada na transformação da Figura 3.11(b), clareia (ou escurece) a faixa desejada de intensidades, mas mantém inalterados todos os outros níveis de intensidade da imagem.

■ **Exemplo 3.3** Fatiamento de níveis de intensidade.

A Figura 3.12(a) é um angiograma da aorta próximo da região dos rins (veja a Seção 1.3.2 para uma explicação mais detalhada dessa imagem). O objetivo desse exemplo é

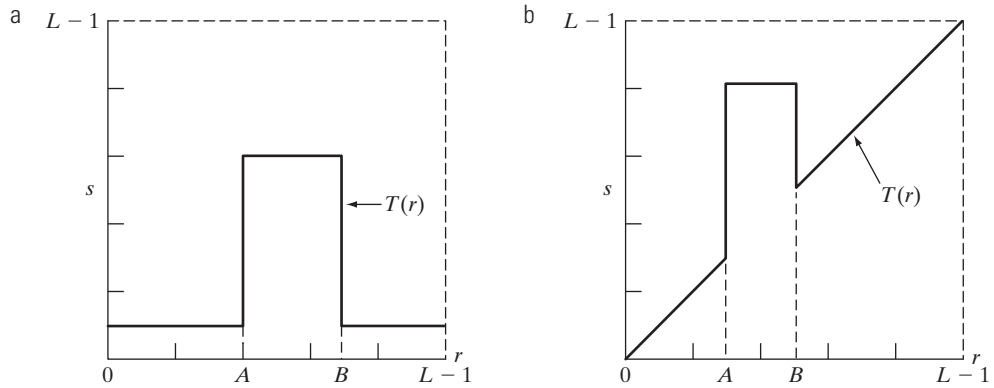



**Figura 3.11** (a) Essa transformação enfatiza a faixa de intensidades [*A*, *B*] e reduz todas as outras intensidades a um nível mais baixo. (b) Essa transformação enfatiza a faixa [*A*, *B*] e preserva todos os outros níveis de intensidade.

utilizar o fatiamento de níveis de intensidade para enfatizar os principais vasos sanguíneos que parecem mais claros como resultado de uma substância de contraste que foi injetada. A Figura 3.12(b) mostra o resultado da utilização de uma transformação da forma da Figura 3.11(a), com a faixa selecionada próxima ao topo da escala, já que a faixa de interesse é mais clara que o fundo. O resultado final dessa transformação é que o vaso sanguíneo e partes dos rins parecem brancos, ao passo que todas as outras intensidades são pretas. Esse tipo de realce produz uma imagem binária e é útil para estudar a *forma* do fluxo da substância de contraste (para detectar, por exemplo, pontos de obstrução).

Se, por outro lado, quisermos nos concentrar nos valores reais de intensidade da região de interesse, podemos utilizar a transformação da Figura 3.11(b). A Figura 3.12(c) mostra o resultado da utilização de uma transformação como essa, na qual uma faixa de intensidades na região do cinza médio em torno da intensidade média da imagem foi definida como preto, ao passo que todas as outras intensidades foram mantidas inalteradas. Neste exemplo, vemos que a tonalidade do nível de cinza dos principais vasos sanguíneos e parte da área do rim foram mantidas intactas. Um resultado assim pode ser útil quando o interesse é medir o fluxo real da substância de contraste em função do tempo em uma série de imagens.

■

### Fatiamento por planos de bits

Os pixels são números digitais compostos de bits. Por exemplo, a intensidade de cada pixel em uma imagem em escala de cinza de 256 níveis é composta de 8 bits (isto é, um byte). Em vez de enfatizar faixas de intensidade, poderíamos enfatizar a contribuição feita à aparência final da imagem por bits específicos. Como ilustra a Figura 3.13, uma imagem de 8 bits pode ser considerada composta de oito planos de 1 bit, com o plano 1 contendo o bit menos significativo de todos os pixels da imagem, e o plano 8, todos os bits mais significativos.

A Figura 3.14(a) mostra uma imagem em escala de cinza de 8 bits, e as figuras 3.14(b) a (i) são seus oito pla-

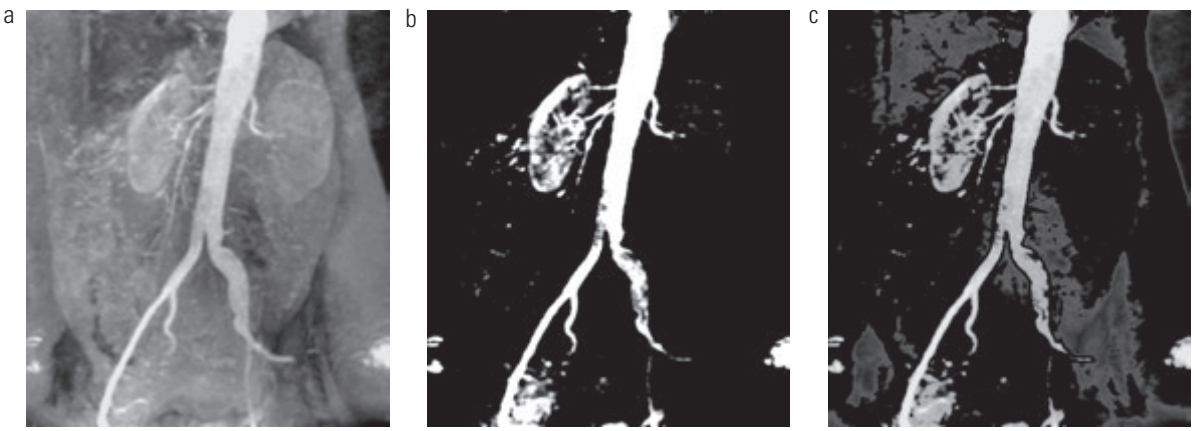



**Figura 3.12** (a) Angiograma da aorta. (b) Resultado da utilização da transformação de fatiamento do tipo ilustrado na Figura 3.11(a) com a faixa de intensidades de interesse selecionada no extremo superior da escala de cinza. (c) Resultado da utilização da transformação na Figura 3.11(b) com a área selecionada ajustada para o preto, de forma que os níveis de cinza na área dos vasos sanguíneos e rins foram preservados. (Imagem original: cortesia do Dr. Thomas R. Gest, Faculdade de Medicina da Universidade de Michigan.)

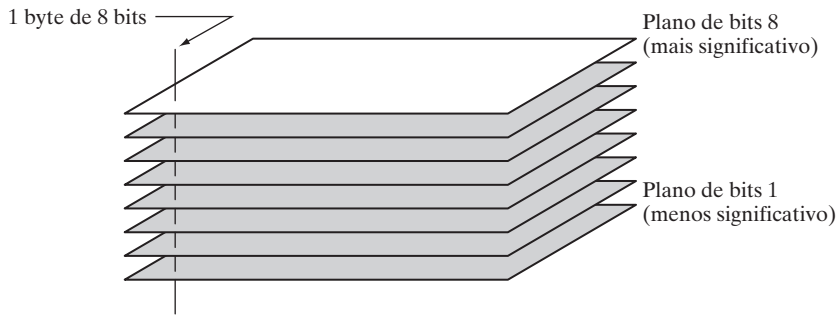



**Figura 3.13** Representação em planos de bits de uma imagem de 8 bits.

nos de 1 bit, com a Figura 3.14(b) correspondendo ao bit menos significativo. Observe que os quatro planos de bits mais significativos, especialmente os dois últimos, contêm uma boa quantidade dos dados visualmente significativos. Os planos menos significativos contribuem com detalhes de intensidades mais sutis na imagem. A imagem original tem uma borda cinza cuja intensidade é 194. Observe que essa mesma borda é preta (0) em alguns dos planos de bits, ao passo que é branca (1) em outros. Para entender por que, considere um pixel, digamos, no meio da borda inferior da Figura 3.14(a). Os pixels correspondentes nos planos de bits, começando com o plano mais significativo, têm valores 1 1 0 0 0 0 1 0, que correspondem à representação binária do decimal 194. O valor de qualquer pixel na imagem original pode ser reconstruído de forma similar a partir de seus pixels correspondentes de valor binário nos planos de bits.

Em termos de funções de transformação de intensidade, não é difícil demonstrar que a imagem binária do oitavo plano de bits de uma imagem de 8 bits pode ser obtida pelo processamento da imagem de entrada com uma função de limiarização que mapeia todas as intensidades entre 0 e 127 em 0 e todas as intensidades entre 128 e 255 em 1. A imagem binária da Figura 3.14(i) foi obtida exatamente dessa forma. Deixamos como um exercício (Exercício 3.4) a obtenção das funções de transformação de intensidade para gerar outros planos de bits.

Costuma ser útil decompor uma imagem em planos de bits para analisar a importância relativa de cada bit na imagem, um processo que ajuda a determinar a adequação do número de bits utilizados para quantizar a imagem. Além disso, esse tipo de decomposição é útil para a compressão de imagens (o tópico do Capítulo 8), no qual não são utilizados todos os planos na reconstrução de uma imagem. Por exemplo, a Figura 3.15(a) mostra uma imagem reconstruída utilizando os planos de bits 8 e 7. A reconstrução é realizada multiplicando os pixels do $n$-ésimo plano pela constante $2^{n-1}$. Isso representa apenas converter o $n$-ésimo bit significativo em um decimal. Cada plano utilizado é multiplicado pela constante correspondente, e todos os planos utilizados são somados para obter a imagem em escala de cinza. Dessa forma,

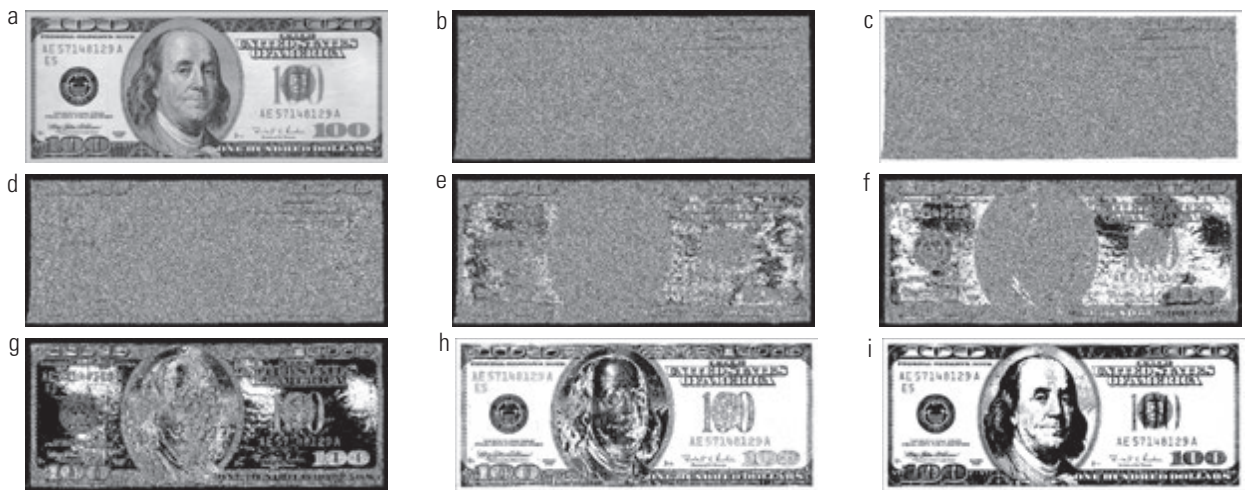



**Figura 3.14** (a) Uma imagem em escala de cinza de 8 bits com dimensões 500 × 1.192 pixels. (b) a (i) Planos de bits 1 a 8, com o plano de bits 1 correspondendo ao bit menos significativo. Cada plano de bits é uma imagem binária.



**Figura 3.15** Imagens reconstruídas utilizando (a) planos de bits 8 e 7; (b) planos de bits 8, 7 e 6; e (c) planos de bits 8, 7, 6 e 5. Compare (c) com a Figura 3.14(a).

para obter a Figura 3.15(a), multiplicamos o plano de bits 8 por 128, o plano de bits 7 por 64, e somamos os dois planos. Apesar de as principais características da imagem original serem restauradas, a imagem reconstruída parece ter pouco contraste, especialmente no fundo. Isso não é de surpreender, já que dois planos podem produzir apenas quatro níveis de intensidade distintos. Adicionar o plano 6 à reconstrução melhorou a situação, como mostra a Figura 3.15(b). Observe que o fundo dessa imagem tem um falso contorno perceptível. Esse efeito é significativamente reduzido acrescentando o quinto plano à reconstrução, como ilustra a Figura 3.15(c). Utilizar mais planos na reconstrução não contribuiria de maneira importante para a aparência dessa imagem. Dessa forma, concluímos que armazenar os quatro planos de bits mais relevantes nos permitiria reconstruir a imagem original em detalhes aceitáveis. Armazenar esses quatro planos em vez da imagem original requer 50% menos espaço de armazenamento (ignorando considerações sobre arquitetura de memória).

## 3.3 Processamento de histograma

O *histograma* de uma imagem digital com níveis de intensidade no intervalo $[0, L-1]$ é uma função discreta $h(r_k) = n_k$, onde $r_k$ é o $k$-ésimo valor de intensidade e $n_k$ é o número de pixels da imagem com intensidade $r_k$. Costuma-se normalizar um histograma dividindo cada um desses componentes pelo número total de pixels da imagem, expresso pelo produto $MN$, onde, geralmente, $M$ e $N$ são as dimensões de linha e coluna da imagem. Dessa forma, um histograma normalizado é dado por $p(r_k) = r_k/MN$ para $k = 0, 1, 2, \ldots, L-1$. De modo geral, $p(r_k)$ é uma estimativa da probabilidade de ocorrência do nível de intensidade $r_k$ em uma imagem. A soma de todos os componentes de um histograma normalizado é igual 1.*

Histogramas são a base para várias técnicas de processamento no domínio espacial. A manipulação de histogramas pode ser utilizada para o realce de imagens, como mostrado nesta seção. Além de fornecer estatísticas úteis da imagem, veremos em capítulos subsequentes que as informações inerentes a histogramas também são bastante úteis em outras aplicações de processamento de imagens, como compressão e segmentação. Histogramas são fáceis de serem calculados utilizando-se um aplicativo computacional, e eles também podem ser calculados em implementações econômicas de hardware, sendo, dessa forma, uma ferramenta popular para o processamento de imagens em tempo real.

Como uma introdução ao processamento de histogramas para transformações de intensidade, observe a Figura 3.16, que é a imagem dos grãos de pólen da Figura 3.10 mostrada em quatro características básicas em relação à intensidade da imagem: escura, clara, baixo contraste e alto contraste. O lado direito da figura mostra os histogramas correspondentes a essas imagens. O eixo horizontal de cada histograma corresponde a valores de intensidade, $r_k$. O eixo vertical corresponde a valores de $h(r_k) = n_k$ ou $p(r_k) = n_k/MN$ se os valores forem normalizados. Dessa forma, os histogramas podem ser vistos como gráficos de $h(r_k) = n_k$ *versus* $r_k$ ou $p(r_k) = n_k/MN$ *versus* $r_k$.

Notamos na imagem escura que os componentes do histograma estão concentrados no lado inferior (escuro) da escala de intensidades. De forma similar, os componentes do histograma da imagem clara tendem à direção do lado superior da escala. Uma imagem com baixo contraste tem um histograma estreito normalmente localizado no meio da escala de intensidades. Para uma imagem monocromática, isso implica uma aparência cinza, desbotada e sem brilho. Finalmente, vemos que os componentes do histograma na imagem de alto contraste cobrem uma faixa bem ampla da escala de intensidades e, também, que a distribuição de pixels não está muito longe de ser uniforme, com poucas linhas verticais sendo muito mais altas do que as outras. Intuitivamente, é razoável concluir que uma imagem cujos pixels tendem a ocupar todo o intervalo de níveis possíveis de intensidade e, além disso, tendem a ser distribuídos uniformemente terá uma aparência de alto contraste e exibirá uma grande variedade de tons de cinza. O resultado final será uma imagem que mostra boa correspondência em relação aos detalhes de nível de cinza e tem uma ampla faixa dinâmica. Em breve veremos que é possível desenvolver uma função

* Consulte o site do livro para uma revisão da teoria elementar das probabilidades.

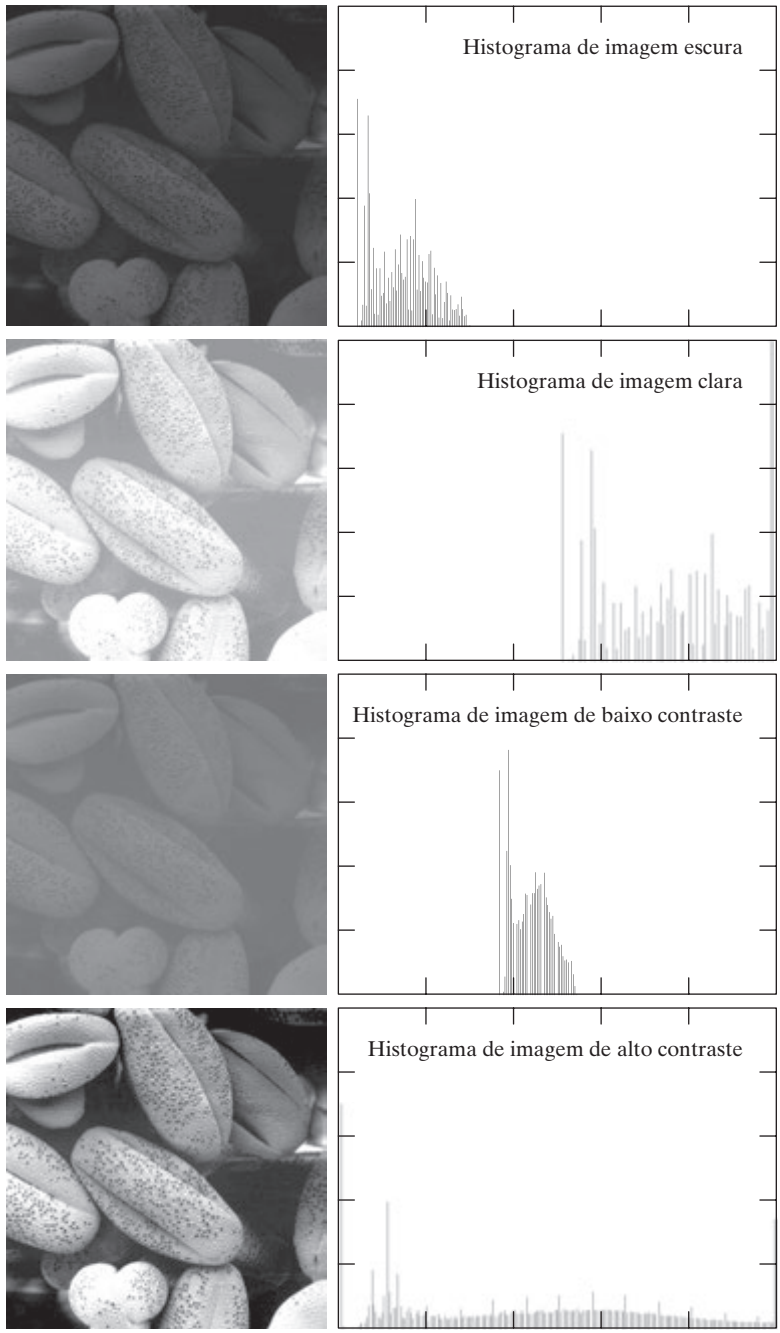



**Figura 3.16** Quatro tipos básicos de imagem: escura, clara, baixo contraste, alto contraste e seus histogramas correspondentes.

de transformação que pode automaticamente atingir esse efeito, com base apenas em informações disponíveis no histograma da imagem de entrada.

### 3.3.1 Equalização de histograma

Considere por um momento valores contínuos de intensidade, com a variável $r$ expressando as intensidades de uma imagem a ser processada. Como de costume, consideramos que $r$ esteja no intervalo $[0, L-1]$, com $r = 0$ representando o preto, e $r = L - 1$ representando o branco. Para que $r$ satisfaça essas condições, nos concentraremos nas transformações (mapeamentos de intensidade) da fórmula:

$$s = T(r) \quad 0 \le r \le L-1 \tag{3.3-1}$$

que produz um nível de intensidade de saída $s$ para todos os pixels da imagem de entrada que têm intensidade $r$. Consideramos que:

**(a)** $T(r)$ é uma função monotonicamente* crescente no intervalo $0 \le r \le L-1$; e

**(b)** $0 \le T(r) \le L-1$ para $0 \le r \le L-1$.

Em algumas formulações que discutiremos mais adiante, utilizamos o inverso:

$$r = T^{-1}(s) \quad 0 \le s \le L-1 \tag{3.3-2}$$

neste caso, alteramos a condição (a) para

**(a')** $T(r)$ é uma função estritamente monotonicamente crescente no intervalo $0 \le r \le L-1$.

O requisito da condição (a), de que $T(r)$ deve ser monotonicamente crescente, assegura que os valores de intensidade da saída nunca serão invertidos em relação aos valores correspondentes de entrada, impedindo, dessa forma, a criação de artefatos por reversões de intensidade. A condição (b) assegura que o intervalo de intensidades da saída seja o mesmo que o da entrada. Por fim, a condição (a') assegura que o mapeamento inverso de $s$ em $r$ será um para um, impedindo, dessa forma, ambiguidades. A Figura 3.17(a) mostra uma função que satisfaz as condições (a) e (b). No caso, vemos que é possível que múltiplos valores sejam mapeados em um valor único e, mesmo assim, satisfaçam essas duas condições. Isto é, uma função de transformação monotônica executa um mapeamento um para um ou muitos para um. Não há problema algum no mapeamento de $r$ em $s$. No entanto, a Figura 3.17(a) apresenta um problema se quisermos recuperar os valores de $r$ unicamente a partir dos valores mapeados (o mapeamento inverso pode ser visualizado invertendo o sentido das setas). Isso seria possível para o mapeamento inverso de $s_k$ na Figura 3.17(a), mas o mapeamento inverso de $s_q$ é um *intervalo* de valores, o que, é claro, em geral nos impede de recuperar o valor original de $r$ que resultou em $s_q$. Como mostra a Figura 3.17(b), requerer que $T(r)$ seja estritamente monotônico assegura que os mapeamentos inversos tenham um *valor único* (isto é, o mapeamento é um para um nas duas direções). Esse é um requisito teórico que nos permitirá deduzir algumas técnicas importantes de processamento de histogramas mais adiante neste capítulo. Como na prática lidamos com valores inteiros de intensidade, somos forçados a arredondar todos os resultados a seus valores inteiros mais próximos. Dessa forma, quando a condição de "estritamente monotônico" não for satisfeita, lidaremos com o problema de uma transformação inversa não única procurando as correspondências inteiras mais próximas. O Exemplo 3.8 apresenta uma ilustração acerca do assunto.

Os níveis de intensidade em uma imagem podem ser vistos como variáveis aleatórias no intervalo $[0, L-1]$. Um descritor fundamental de uma variável aleatória é sua função densidade de probabilidade (PDF, de *probability density function*). Sejam $p_r(r)$ e $p_s(s)$ as PDFs de $r$ e $s$, respectivamente, onde os subscritos em $p$ são utilizados para indicar que, em geral, $p_r$ e $p_s$ são funções diferentes. Um resultado fundamental da teoria elementar das probabilidades é que, se $p_r(r)$ e $T(r)$ são conhecidas e $T(r)$ é contínua e diferenciável ao longo do intervalo de valores

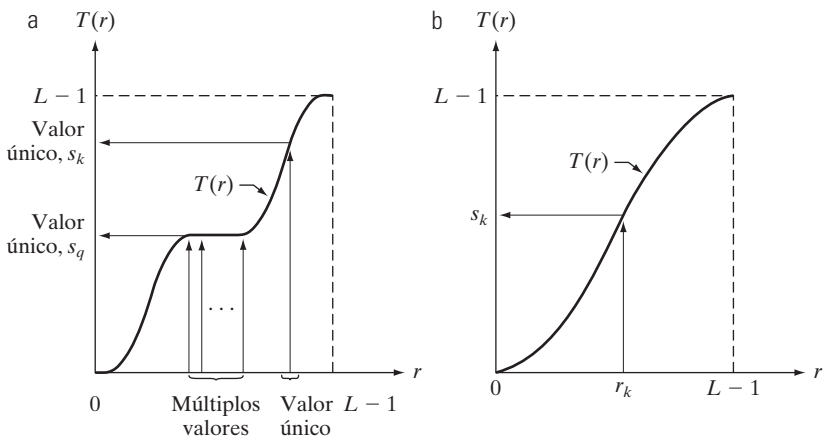



**Figura 3.17** (a) Função monotonicamente crescente, mostrando como múltiplos valores podem ser mapeados em um único valor. (b) Função estritamente monotonicamente crescente. Esse é um mapeamento um para um, em ambas as direções.

* Lembre-se de que uma função $T(r)$ é monotonicamente crescente se $T(r_2) \ge T(r_1)$ para $r_2 > r_1$. $T(r)$ é uma função estritamente monotonicamente crescente se $T(r_2) > T(r_1)$ para $r_2 > r_1$. Deninições similares se aplicam a funções monotonicamente decrescentes.

de interesse, então a PDF da variável transformada (mapeada) $s$ pode ser obtida utilizando a simples fórmula :

$$p_s(s) = p_r(r)\left|\frac{dr}{ds}\right| \tag{3.3-3}$$

Dessa forma, vemos que a PDF da variável de intensidade da saída $s$ é determinada pela PDF das intensidades da entrada e pela função de transformação utilizada [lembre-se de que $r$ e $s$ se relacionam por meio de $T(r)$].

Uma função de transformação de especial importância no processamento de imagens tem a forma:

$$s = T(r) = (L-1)\int_0^r p_r(w)\,dw \tag{3.3-4}$$

sendo $w$ uma variável local da integração. O lado direito dessa equação é reconhecido como a função de distribuição acumulada (CDF, de *cumulative distribution function*) da variável aleatória $r$. Como as PDFs são sempre positivas, e lembrando que a integral de uma função corresponde à área sob a função, segue-se que a função de transformação da Equação 3.3-4 satisfaz a condição (a) porque a área sob a função não pode diminuir à medida que $r$ aumenta. Quando o limite superior dessa equação for $r = (L - 1)$, a integral será calculada como 1 (a área sob uma curva PDF é sempre 1), de forma que o valor máximo de $s$ é $(L - 1)$ e a condição (b) também é satisfeita.

Para encontrar a $p_s(s)$ correspondente à transformação que acabamos de analisar, utilizamos a Equação 3.3-3. Sabemos, com base na regra de Leibniz do cálculo elementar, que a derivada de uma integral definida em relação a seu limite superior é o integrando calculado nesse limite. Isto é:

$$\begin{aligned}\frac{ds}{dr} &= \frac{dT(r)}{dr} \\ &= (L-1)\frac{d}{dr}\left[\int_0^r p_r(w)\,dw\right] \\ &= (L-1)p_r(r)\end{aligned} \tag{3.3-5}$$

Substituindo esse resultado por $dr/ds$ na Equação 3.3-3 e tendo em mente que todos os valores de probabilidade são positivos, temos

$$\begin{aligned}p_s(s) &= p_r(r)\left|\frac{dr}{ds}\right| \\ &= p_r(r)\left|\frac{1}{(L-1)p_r(r)}\right| \\ &= \frac{1}{L-1} \qquad 0 \le s \le L-1\end{aligned} \tag{3.3-6}$$

Reconhecemos a forma de $p_s(s)$ na última linha dessa equação como uma função densidade de probabilidade *uniforme*. Em resumo, demonstramos que realizar a transformação de intensidade na Equação 3.3-4 gera uma variável aleatória, $s$, caracterizada por uma PDF uniforme. É importante notar, a partir dessa equação, que $T(r)$ depende de $p_r(r)$, mas, como mostra a Equação 3.3-6, a $p_s(s)$ resultante é *sempre* uniforme, *independentemente* da forma de $p_r(r)$. A Figura 3.18 ilustra esses conceitos.

■

**Exemplo 3.4** Ilustração das equações 3.3-4 e 3.3-6.

Para explicar os conceitos, vejamos o exemplo simples a seguir. Suponha que os valores de intensidade (contínuos) em uma imagem tenham a PDF

$$p_r(r) = \begin{cases} \dfrac{2r}{(L-1)^2} & \text{para } 0 \le r \le L-1 \\ 0 & \text{para todos os outros intervalos} \end{cases}$$

Da Equação 3.3-4:

$$\begin{aligned}s = T(r) &= (L-1)\int_0^r p_r(w)\,dw \\ &= \frac{2}{L-1}\int_0^r w\,dw = \frac{r^2}{L-1}\end{aligned}$$

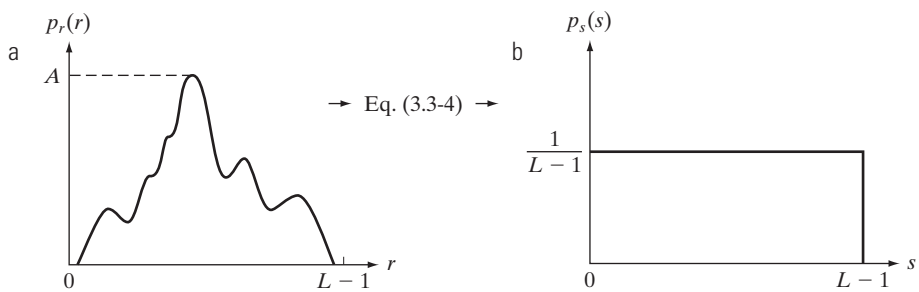



**Figura 3.18** (a) Uma PDF arbitrária. (b) Resultado da aplicação da transformação na Equação 3.3-4 a todos os níveis de intensidade, $r$. As intensidades resultantes, $s$, têm uma PDF uniforme, independentemente da forma da PDF das intensidades $r$.

Suponha em seguida que formemos uma nova imagem com intensidades, $s$, obtida utilizando essa transformação; isto é, os valores de $s$ são formados elevando ao quadrado os valores de intensidade correspondentes da imagem de entrada e dividindo-os por $(L-1)$. Por exemplo, considere uma imagem na qual $L = 10$ e suponha que um pixel em uma posição arbitrária $(x, y)$ na imagem de entrada tenha intensidade $r = 3$. Então, o pixel nessa posição da nova imagem é $s = T(r) = r^2/9 = 1$. Podemos verificar que a PDF das intensidades na nova imagem é uniforme simplesmente substituindo $p_r(r)$ na Equação 3.3-6 e utilizando o fato de que $s = r^2/(L-1)$; isto é:

$$p_s(s) = p_r(r)\left|\frac{dr}{ds}\right| = \frac{2r}{(L-1)^2}\left|\left[\frac{ds}{dr}\right]^{-1}\right|$$
$$= \frac{2r}{(L-1)^2}\left|\left[\frac{d}{dr}\frac{r^2}{L-1}\right]^{-1}\right|$$
$$= \frac{2r}{(L-1)^2}\left|\frac{(L-1)}{2r}\right| = \frac{1}{L-1}$$

sendo que o último passo resulta do fato de $r$ ser não negativo e considerarmos $L > 1$. Como era esperado, o resultado é uma PDF uniforme.

■

Para valores discretos, lidamos com probabilidades (valores de histograma) e somatórios em vez de funções densidade de probabilidade e integrais*. Como mencionado anteriormente, a probabilidade de ocorrência do nível de intensidade $r_k$ em uma imagem digital é calculada por:

$$p_r(r_k) = \frac{n_k}{MN} \qquad K - 0,1,2,3..., L-1 \qquad (3.3\text{-}7)$$

onde $MN$ é o número total de pixels da imagem, $n_k$ é o número de pixels com intensidade $r_k$, e $L$ é o número de níveis de intensidade possíveis na imagem (por exemplo, 256 para uma imagem de 8 bits). Como observamos no início dessa seção, um gráfico de $p_r(r_k)$ *versus* $r_k$ costuma ser chamado de *histograma*.

A forma discreta da transformação na Equação 3.3-4 é:

$$s_k = T(r_k) = (L-1)\sum_{j=0}^{k} p_r(r_j) = \frac{(L-1)}{MN}\sum_{j=0}^{k} n_j \qquad (3.3\text{-}8)$$
$$k = 0, 1, 2, \ldots, L-1$$

Dessa forma, uma imagem processada (de saída) é obtida mapeando cada pixel da imagem de entrada com intensidade $r_k$ em um pixel correspondente com nível $s_k$ na imagem de saída, utilizando a Equação 3.3-8. A transformação (mapeamento) $T(r_k)$ nessa equação é chamada de *equalização de histograma* ou *linearização de histograma*. Não é difícil demonstrar (Exercício 3.10) que essa transformação satisfaz as condições (a) e (b) definidas anteriormente nesta seção.

■

**Exemplo 3.5** Uma ilustração simples da equalização de histograma.

Antes de prosseguirmos, será útil analisarmos um exemplo simples. Suponha que uma imagem de 3 bits ($L = 8$) de dimensões $64 \times 64$ pixels ($MN = 4096$) tenha a distribuição de intensidade mostrada na Tabela 3.1, na qual os níveis de intensidade são números inteiros no intervalo $[0, L-1] = [0, 7]$.

O histograma de nossa imagem hipotética é esboçado na Figura 3.19(a). Os valores da função de transformação de equalização de histograma são obtidos utilizando a Equação 3.3-8. Por exemplo:

$$s_0 = T(r_0) = 7\sum_{j=0}^{0} p_r(r_j) = 7p_r(r_0) = 1,33$$

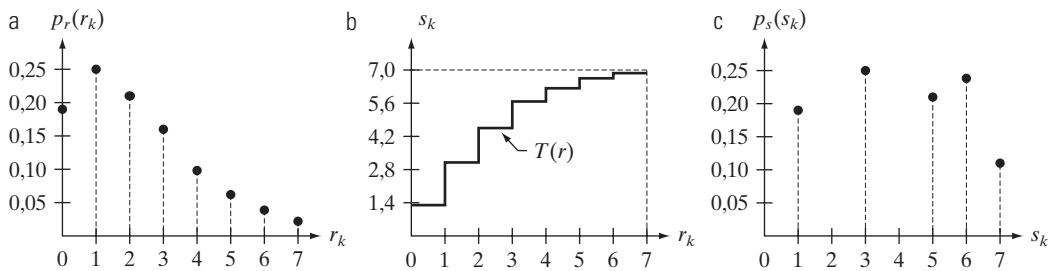



**Figura 3.19** Ilustração da equalização de histograma de uma imagem de 3 bits (8 níveis de intensidade). (a) Histograma original. (b) Função de transformação. (c) Histograma equalizado.

* As condições de monotonicidade definidas anteriormente também se aplicam no caso discreto. Nós simplesmente restringimos os valores das variáveis para que elas sejam discretas.

**Tabela 3.1** Distribuição de intensidades e valores de histograma para uma imagem digital de 3 bits, 64 × 64 pixels.

| $r_k$ | $n_k$ | $p_r(r_k) = n_k/MN$ |
|---|---|---|
| $r_0 = 0$ | 790 | 0,19 |
| $r_1 = 1$ | 1.023 | 0,25 |
| $r_2 = 2$ | 850 | 0,21 |
| $r_3 = 3$ | 656 | 0,16 |
| $r_4 = 4$ | 329 | 0,08 |
| $r_5 = 5$ | 245 | 0,06 |
| $r_6 = 6$ | 122 | 0,03 |
| $r_7 = 7$ | 81 | 0,02 |

De forma similar:

$$s_1 = T(r_1) = 7\sum_{j=0}^{1} p_r(r_j) = 7p_r(r_0) + 7p_r(r_1) = 3{,}08$$

e $s_2 = 4{,}55$; $s_3 = 5{,}67$; $s_4 = 6{,}23$; $s_5 = 6{,}65$; $s_6 = 6{,}86$; $s_7 = 7{,}00$. Essa função de transformação tem o formato de uma escada, como mostra a Figura 3.19(b).

Nesse ponto, os valores de $s$ ainda terão frações porque foram gerados pela soma de valores de probabilidade, de forma que os arredondamos para o número inteiro mais próximo:

$$S_0 = 1{,}33 \rightarrow 1 \qquad S_4 = 6{,}23 \rightarrow 6$$
$$S_1 = 3{,}08 \rightarrow 3 \qquad S_5 = 6{,}65 \rightarrow 7$$
$$S_2 = 4{,}55 \rightarrow 5 \qquad S_6 = 6{,}86 \rightarrow 7$$
$$S_3 = 5{,}67 \rightarrow 6 \qquad S_7 = 7{,}00 \rightarrow 7$$

Esses são os valores do histograma equalizado. Observe que há apenas cinco níveis de intensidade distintos. Como $r_0 = 0$ foi mapeado em $s_0 = 1$, há 790 pixels na imagem equalizada do histograma com esse valor (Tabela 3.1). Além disso, há nessa imagem 1.023 pixels com um valor de $s_1 = 3$ e 850 pixels com um valor de $s_2 = 5$. Contudo, tanto $r_3$ quanto $r_4$ foram mapeados no mesmo valor, 6, de forma que há (656 + 329) = 985 pixels na imagem equalizada com esse valor. De forma similar, há (245 + 122 + 81) = 448 pixels com valor 7 no histograma da imagem equalizada. Dividir esses números por $MN$ = 4.096 gerou o histograma equalizado da Figura 3.19(c).

Como um histograma é uma aproximação de uma PDF, e nenhum novo nível de intensidade é criado no processo, histogramas perfeitamente uniformes são raros em aplicações práticas da equalização de histograma. Assim, diferentemente de seu equivalente contínuo, não pode ser provado (em geral) que a equalização de um histograma discreto resulta em um histograma uniforme. No entanto, como veremos em breve, utilizar a Equação 3.3-8 tende a espalhar o histograma da imagem de entrada, de forma que os níveis de intensidade da imagem equalizada cubram um intervalo maior da escala de intensidade. O resultado final é o realce do contraste.

■

Discutimos anteriormente nesta seção as várias vantagens de ter valores de intensidade que cubrem toda a escala de cinza. Além de produzir intensidades que tenham essa tendência, o método que acabamos de definir tem a vantagem adicional de ser totalmente "automático". Em outras palavras, dada uma imagem, o processo de equalização de histograma consiste simplesmente na implementação da Equação 3.3-8, que se baseia em informações que podem ser extraídas diretamente da imagem em questão, sem a necessidade da especificação de outros parâmetros. Também notamos a simplicidade dos cálculos necessários para implementar a técnica.

A *transformação inversa* de $s$ de volta a $r$ é expressa por:

$$r_k = T^{-1}(s_k) \qquad k = 0, 1, 2, \ldots, L-1 \qquad (3.3\text{-}9)$$

Pode ser demonstrado (Exercício 3.10) que essa transformação inversa satisfaz as condições (a') e (b) somente se nenhum dos níveis, $r_k$, $k = 0, 1, 2, \ldots, L-1$, estiver faltando da imagem de entrada, o que, por sua vez, significa que nenhum dos componentes do histograma da imagem é zero. Apesar de a transformação inversa não ser utilizada na equalização de histograma, ela exerce um papel central no processo de especificação de histograma que será desenvolvido na próxima seção.

■

### Exemplo 3.6 Equalização de histograma.

A coluna da esquerda na Figura 3.20 mostra as quatro imagens da Figura 3.16, e a coluna central mostra o resultado da aplicação da equalização de histograma em cada uma dessas imagens. Os três primeiros resultados de cima para baixo mostram uma melhora significativa. Como esperado, a equalização de histograma não teve muito efeito na quarta imagem porque as intensidades dessa imagem já cobriam toda a escala de intensidade. A Figura 3.21 mostra as funções de transformação utilizadas para gerar as imagens equalizadas da Figura 3.20. Essas funções foram geradas utilizando a Equação 3.3-8. Observe que a transformação (4) tem um formato praticamente linear, indicando que as entradas foram mapeadas em saídas praticamente iguais.

A terceira coluna da Figura 3.20 mostra os histogramas das imagens equalizadas. É interessante notar que, apesar de todos esses histogramas serem diferentes, as imagens do histograma equalizado são visualmente muito similares. Isso não surpreende porque a diferença básica entre as imagens da coluna da esquerda se dá em termos de contraste, não de conteúdo. Em outras palavras, como as imagens têm o mesmo conteúdo, o aumento de contraste resultante da equalização de histograma foi o suficiente para fazer com que quaisquer diferenças de intensidade nas imagens

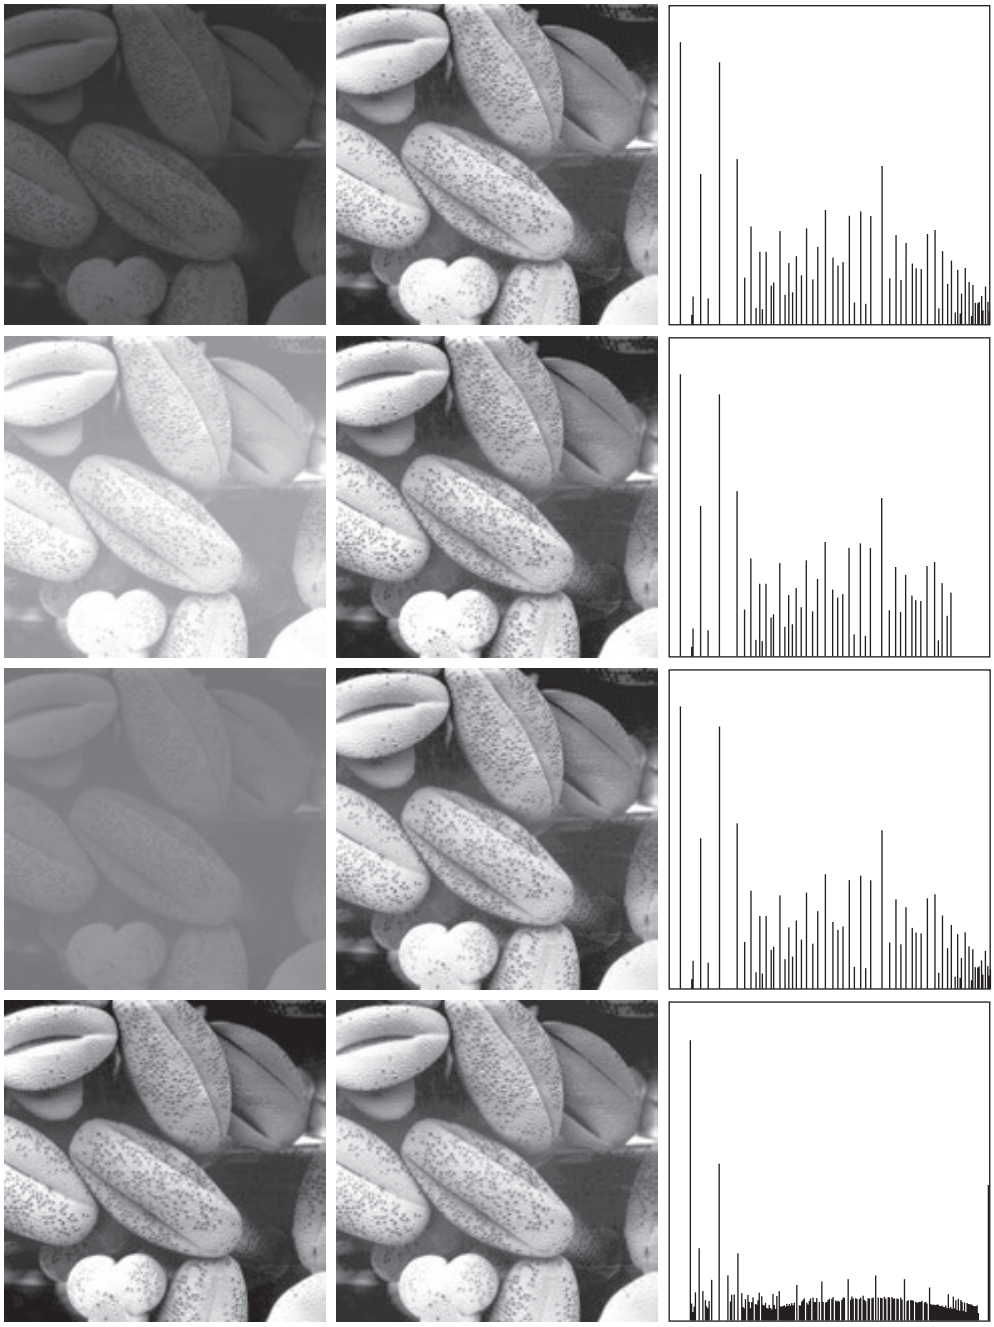


**Figura 3.20** Coluna da esquerda: imagens da Figura 3.16. Coluna central: imagens que correspondem aos histogramas equalizados. Coluna da direita: histogramas das imagens da coluna central.

equalizadas fossem visualmente imperceptíveis. Considerando as significativas diferenças de contraste entre as imagens originais, esse exemplo ilustra o poder da equalização de histograma como uma ferramenta adaptável de realce de contraste.

■

### 3.3.2 Especificação de histograma

Como sugerido na análise anterior, a equalização de histograma automaticamente determina uma função de transformação que busca produzir uma imagem de saída que tenha um histograma uniforme. Quando um realce automático é desejado, essa é uma boa abordagem porque os resultados dessa técnica são previsíveis, e sua implementação é fácil. Mostraremos, nesta seção, que há aplicações nas quais o realce baseado em um histograma uniforme não é a melhor metodologia. Em particular, algumas vezes é útil poder especificar o formato do histograma que desejamos que a imagem processada tenha.

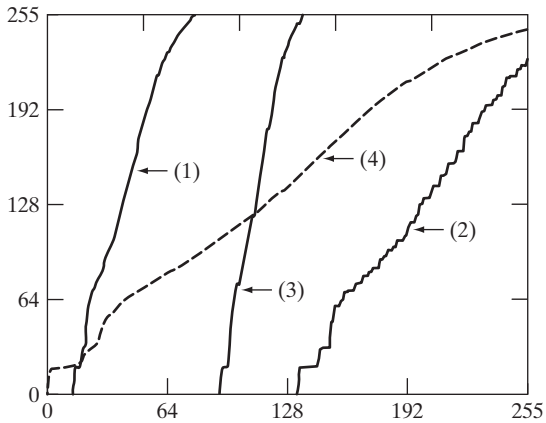



**Figura 3.21** Funções de transformação para a equalização de histograma. As transformações de (1) a (4) foram obtidas a partir dos histogramas das imagens (de cima para baixo) na coluna esquerda da Figura 3.20 utilizando a Equação 3.3-8.

O método utilizado para gerar uma imagem processada que tenha um histograma específico é chamado de *casamento de histogramas* ou *especificação de histograma*.

Vamos retomar por um momento as intensidades contínuas $r$ e $z$ (consideradas variáveis aleatórias contínuas), com $p_r(r)$ e $p_z(z)$ expressando suas funções densidade de probabilidade contínua correspondentes. Nessa notação, $r$ e $z$ expressam os níveis de intensidade das imagens de entrada e saída (processada), respectivamente. Podemos estimar $p_r(r)$ a partir da imagem de entrada, ao passo que $p_z(z)$ é a função densidade de probabilidade *especificada* que desejamos que a imagem de saída tenha.

Seja $s$ uma variável aleatória com a propriedade

$$s = T(r) = (L-1)\int_0^r p_r(w)\,dw \qquad (3.3\text{-}10)$$

onde, como antes, $w$ é uma variável local de integração. Reconhecemos essa expressão como a versão contínua da equalização de histograma dada na Equação 3.3-4.

Suponha, em seguida, que definamos uma variável aleatória $z$ com a propriedade:

$$G(z) = (L-1)\int_0^z p_z(t)\,dt = s \qquad (3.3\text{-}11)$$

onde $t$ é uma variável local de integração. Segue, dessas duas equações, que $G(z) = T(r)$ e, portanto, $z$ deve satisfazer a condição:

$$z = G^{-1}\left[T(r)\right] = G^{-1}(s) \qquad (3.3\text{-}12)$$

A transformação $T(r)$ pode ser obtida com a Equação 3.3-10, uma vez que $p_r(r)$ foi estimada a partir da imagem de entrada. De forma similar, a função de transformação $G(z)$ pode ser obtida utilizando a Equação 3.3-11, já que $p_z(z)$ é dada.

As equações 3.3-10 a 3.3-12 mostram que uma imagem, cujos níveis de intensidade têm uma função densidade de probabilidade especificada, pode ser obtida a partir de uma dada imagem utilizando o seguinte procedimento:

1. Obtenha $p_r(r)$ a partir da imagem de entrada e aplique a Equação 3.3-10 para obter os valores de $s$.
2. Utilize a PDF especificada na Equação 3.3-11 para obter a função de transformação $G(z)$.
3. Obtenha a transformação inversa $z = G^{-1}(s)$; pelo fato de $z$ ser obtida de $s$, esse processo é um *mapeamento* de $s$ em $z$, sendo $z$ os valores desejados.
4. Obtenha a imagem de saída equalizando, inicialmente, a imagem de entrada por meio da Equação 3.3-10; os valores dos pixels dessa imagem são os valores $s$. Para cada pixel com valor $s$ na imagem equalizada, realize o mapeamento inverso $z = G^{-1}(s)$ para obter o pixel correspondente na imagem de saída. Quando todos os pixels forem processados dessa forma, a PDF da imagem de saída será igual à PDF especificada.

■

**Exemplo 3.7** Especificação de histograma.

Considerando valores contínuos de intensidade, suponha que a intensidade de uma imagem tenha uma PDF $p_r(r) = 2r/(L-1)^2$ para $0 \le r \le (L-1)$ e $p_r(r) = 0$ para outros valores de $r$. Encontre a função de transformação que produzirá uma imagem cuja PDF da intensidade seja $p_z(z) = 3z^2/(L-1)^3$ para $0 \le z \le (L-1)$ e $p_z(z) = 0$ para outros valores de $z$.

Inicialmente, calculamos a transformação de equalização de histograma para o intervalo $[0, L-1]$:

$$s = T(r) = (L-1)\int_0^r p_r(w)\,dw$$
$$= \frac{2}{(L-1)}\int_0^r w\,dw = \frac{r^2}{(L-1)}$$

Por definição, essa transformação é 0 para valores fora do intervalo $[0, L-1]$. Elevar ao quadrado os valores das intensidades de entrada e dividi-los por $(L-1)^2$ produzirá uma imagem cujas intensidades, $s$, têm uma PDF uniforme, porque se trata de uma transformação de equalização de histograma, como discutido anteriormente.

Estamos interessados em uma imagem com um histograma especificado, de forma que calculamos:

$$G(z) = (L-1)\int_0^z p_z(w)\,dw$$
$$= \frac{3}{(L-1)^2}\int_0^z w^2\,dw = \frac{z^3}{(L-1)^2}$$

ao longo do intervalo [0, $L-1$]; essa função, por definição, é 0 em todos os outros pontos. Por fim, é necessário que $G(z) = s$, mas $G(z) = z^3/(L-1)^2$; então $z^3/(L-1)^2 = s$, e temos:

$$z = \left[(L-1)^2 s\right]^{1/3}$$

Assim, se multiplicarmos todo pixel do histograma equalizado por $(L-1)^2$ e elevarmos o produto à potência 1/3, o resultado será uma imagem cujas intensidades, $z$, têm a PDF $p_z(z) = 3z^2/(L-1)^3$ no intervalo [0, $L-1$], como desejado.

Como $s = r^2/(L-1)$, podemos gerar as intensidades, $z$, diretamente das intensidades, $r$, da imagem de entrada:

$$z = \left[(L-1)^2 s\right]^{1/3} = \left[(L-1)^2 \frac{r^2}{(L-1)}\right]^{1/3} = \left[(L-1) r^2\right]^{1/3}$$

Dessa forma, elevar ao quadrado o valor de cada pixel da imagem original, multiplicar o resultado por $(L-1)$ e elevar o produto à potência 1/3 resultará em uma imagem cujos níveis de intensidade, $z$, têm a PDF especificada. Vemos que o passo intermediário de equalizar a imagem de entrada pode ser pulado; tudo o que precisamos é obter a função de transformação $T(r)$ que mapeia $r$ em $s$. Então, os dois passos podem ser combinados em uma única transformação de $r$ para $z$.

■

Como mostrou o exemplo anterior, a especificação de histograma em princípio é direta. Na prática, uma dificuldade comum é encontrar expressões analíticas significativas para $T(r)$ e $G^{-1}$. Felizmente, o problema é bastante simplificado quando lidamos com quantidades discretas. O trabalho é o mesmo que na equalização de histograma, na qual somente uma aproximação para o histograma desejado é obtida. Apesar disso, contudo, alguns resultados muito úteis podem ser obtidos, mesmo com aproximações grosseiras.

A fórmula discreta da Equação 3.3-10 é a transformação da equalização de histograma da Equação 3.3-8, que repetiremos aqui por conveniência:

$$s_k = T(r_k) = (L-1)\sum_{j=0}^{k} p_r(r_j) = \frac{(L-1)}{MN}\sum_{j=0}^{k} n_j \qquad k = 0, 1, 2, \ldots, L-1 \qquad (3.3\text{-}13)$$

onde, como antes, $MN$ é o número total de pixels da imagem, $n_j$ é o número de pixels com intensidade $r_j$ e $L$ é o número total de níveis de intensidade possíveis na imagem. De forma similar, dado um valor específico de $s_k$, a formulação discreta da Equação 3.3-11 envolve o cálculo da função de transformação:

$$G(z_q) = (L-1)\sum_{i=0}^{q} p_z(z_i) \qquad (3.3\text{-}14)$$

para um valor de $q$, de forma que:

$$G(z_q) = s_k \qquad (3.3\text{-}15)$$

sendo $p_z(z_i)$ o $i$-ésimo valor do histograma especificado. Como antes, calculamos o valor desejado de $z_q$ obtendo a transformação inversa:

$$z_q = G^{-1}(s_k) \qquad (3.3\text{-}16)$$

Em outras palavras, essa operação nos dá um valor de $z$ para cada valor de $s$; assim, ela realiza um *mapeamento* de $s$ em $z$.

Na prática, não precisamos calcular o inverso de $G$. Como lidamos com níveis de intensidade que são números inteiros (por exemplo, de 0 a 255 para uma imagem de 8 bits), basta calcular todos os valores possíveis de $G$ utilizando a Equação 3.3-14 para $q = 0, 1, 2, \ldots, L-1$. Esses valores são ajustados e arredondados para os valores inteiros mais próximos cobrindo o intervalo [0, $L-1$]. Os valores são organizados em uma tabela. Então, dado um determinado valor de $s_k$, procuramos a melhor correspondência nos valores armazenados na tabela. Se, por exemplo, a 64ª entrada da tabela for a mais próxima de $s_k$, então $q = 63$ (lembre-se que começamos a contagem a partir de 0), e $z_{63}$ é a melhor solução para a Equação 3.3-15. Dessa forma, o determinado valor $s_k$ seria associado a $z_{63}$ (isto é, aquele valor específico de $s_k$ seria *mapeado* em $z_{63}$). Como $z$ representa as intensidades utilizadas como base para especificar o histograma $p_z(z)$, segue-se que $z_0 = 0$, $z_1 = 1, \ldots, z_{L-1} = L-1$, de forma que $z_{63}$ teria o valor de intensidade 63. Repetindo esse procedimento, podemos calcular o mapeamento de cada valor de $s_k$ no valor de $z_q$, que é a solução mais próxima para a Equação 3.3-15. Esses mapeamentos são a solução para o problema de especificação de histograma.

Lembrando que $s_k$ são os valores da imagem do histograma equalizado, podemos resumir o procedimento de especificação de histograma como se segue:

1. Calcule o histograma $p_r(r)$ da imagem em questão e utilize-o para calcular a transformação de equalização de histograma na Equação 3.3-13. Arredonde os valores resultantes, $s_k$, para o intervalo de números inteiros [0, $L-1$].
2. Calcule todos os valores da função de transformação $G$ utilizando a Equação (3.3-14) para $q = 0, 1, 2, \ldots, L-1$, onde $p_z(z_i)$ são os valores do histograma es-

pecificado. Arredonde os valores de $G$ para números inteiros no intervalo $[0, L-1]$. Anote os valores de $G$ em uma tabela.

3. Para cada valor de $s_k = 0, 1, 2, \ldots, L-1$, utilize os valores de $G$ obtidos no passo 2 para encontrar o valor correspondente de $z_q$, de forma que $G(z_q)$ seja o mais próximo de $s_k$ e grave esses mapeamentos de $s$ em $z$. Quando mais de um valor de $z_q$ satisfizer um determinado $s_k$ (isto é, o mapeamento não é único), escolha o menor valor por convenção.
4. Forme a imagem especificada primeiro equalizando o histograma da imagem de entrada e depois mapeando todos os valores dos pixels equalizados, $s_k$, dessa imagem no valor correspondente $z_q$ na imagem especificada utilizando os mapeamentos do passo 3. Como no caso contínuo, o passo intermediário de equalizar a imagem de entrada é conceitual. Esse passo pode ser pulado combinando as duas funções de transformação, $T$ e $G^{-1}$, como demonstra o Exemplo 3.8.

Como mencionamos anteriormente, para que $G^{-1}$ satisfaça as condições (a') e (b), $G$ deve ser estritamente monotônica, o que, de acordo com a Equação 3.3-14, significa que nenhum dos valores $p_z(z_i)$ do histograma especificado pode ser zero (Exercício 3.10). Ao trabalhar com quantidades discretas, o fato de essa condição não poder ser satisfeita não representa um problema sério de implementação, como sugere o passo 3. O exemplo a seguir ilustra numericamente esse ponto.

■

**Exemplo 3.8** Um exemplo simples da especificação de histograma.

Vejamos novamente a imagem hipotética 64 × 64 do Exemplo 3.5, cujo histograma é repetido na Figura 3.22(a). Deseja-se transformar esse histograma de forma que ele tenha os valores especificados na segunda coluna da Tabela 3.2. A Figura 3.22(b) mostra um esboço desse histograma.

O primeiro passo do procedimento é obter os valores ajustados do histograma equalizado, o que fizemos no Exemplo 3.5:

$$s_0 = 1 \quad s_2 = 5 \quad s_4 = 6 \quad s_6 = 7$$
$$s_1 = 3 \quad s_3 = 6 \quad s_5 = 7 \quad s_7 = 7$$

No próximo passo, calculamos todos os valores da função de transformação, $G$, utilizando a Equação 3.3-14:

$$G(z_0) = 7\sum_{j=0}^{0} p_z(z_j) = 0,00$$

De forma similar:

$$G(z_1) = 7\sum_{j=0}^{1} p_z(z_j) = 7\left[p(z_0) + p(z_1)\right] = 0,00$$

e

$$G(z_2) = 0,00 \quad G(z_4) = 2,45 \quad G(z_6) = 5,95$$
$$G(z_3) = 1,05 \quad G(z_5) = 4,55 \quad G(z_7) = 7,00$$

Como no Exemplo 3.5, esses valores fracionários são convertidos em números inteiros no nosso intervalo válido, [0, 7]. Os resultados são:

$$G(z_0) = 0,00 \rightarrow 0 \qquad G(z_4) = 2,45 \rightarrow 2$$
$$G(z_1) = 0,00 \rightarrow 0 \qquad G(z_5) = 4,55 \rightarrow 5$$
$$G(z_2) = 0,00 \rightarrow 0 \qquad G(z_6) = 5,95 \rightarrow 6$$
$$G(z_3) = 1,05 \rightarrow 1 \qquad G(z_7) = 7,00 \rightarrow 7$$

Esses resultados são resumidos na Tabela 3.3 e a função de transformação é esboçada na Figura 3.22(c). Observe que $G$ não é estritamente monotônica, de forma que a condição (a') é violada. Assim, utilizamos a abordagem descrita no passo 3 do algoritmo para lidar com essa situação.

No terceiro passo do procedimento, calculamos o menor valor de $z_q$, de modo que o valor $G(z_q)$ seja o mais próximo possível de $s_k$. Fazemos isso para todos os valores de $s_k$ para criar os mapeamentos necessários de $s$ em $z$. Por exemplo, $s_0 = 1$, e vemos que $G(z_3) = 1$, o que representa uma associação perfeita nesse caso, de forma que temos a correspondência $s_0 \rightarrow z_3$. Em outras palavras, cada pixel cujo valor é 1 na imagem equalizada do histograma seria mapeado em um pixel com valor igual a 3 (na posição correspondente) na imagem do histograma especificado. Prosseguindo dessa forma, chegamos aos mapeamentos da Tabela 3.4.

No passo final do procedimento, utilizamos os mapeamentos da Tabela 3.4 para mapear cada pixel na imagem do histograma equalizado em um pixel correspondente na imagem do histograma especificado recém-criado. Os valores do

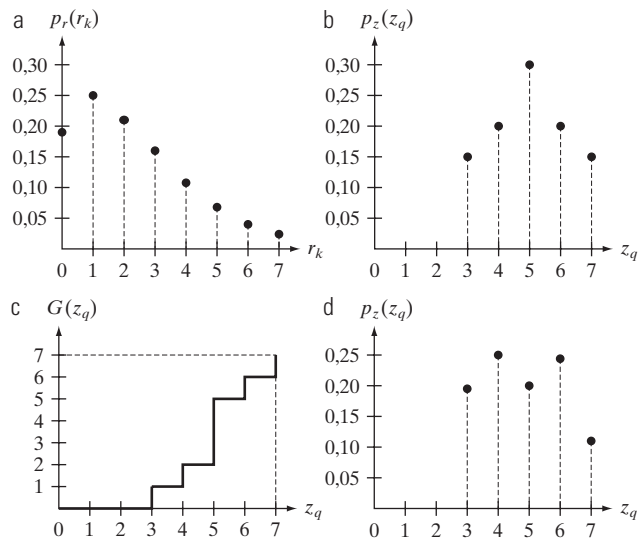



**Figura 3.22** (a) Histograma de uma imagem de 3 bits. (b) Histograma especificado desejado. (c) Função de transformação obtida a partir do histograma especificado desejado. (d) Resultado da especificação do histograma. Compare (b) e (d).

**Tabela 3.2** Histograma especificado e histograma real (os valores da terceira coluna são provenientes dos cálculos realizados no Exemplo 3.8).

| $z_q$ | Especificado $p_z(z_q)$ | Real $p_z(z_q)$ |
|---|---|---|
| $z_0 = 0$ | 0,00 | 0,00 |
| $z_1 = 1$ | 0,00 | 0,00 |
| $z_2 = 2$ | 0,00 | 0,00 |
| $z_3 = 3$ | 0,15 | 0,19 |
| $z_4 = 4$ | 0,20 | 0,25 |
| $z_5 = 5$ | 0,30 | 0,21 |
| $z_6 = 6$ | 0,20 | 0,24 |
| $z_7 = 7$ | 0,15 | 0,11 |

histograma resultante são relacionados na terceira coluna da Tabela 3.2, e o histograma é esboçado na Figura 3.22(d). Os valores de $p_z(z_q)$ foram obtidos utilizando o mesmo procedimento do Exemplo 3.5. Por exemplo, vemos na Tabela 3.4 que $s = 1$ é mapeado em $z = 3$, e que há 790 pixels na imagem do histograma equalizado com o valor de 1. Dessa forma, $p_z(z_3) = 790/4.096 = 0{,}19$.

Apesar de o resultado final mostrado na Figura 3.22(d) não corresponder exatamente ao histograma especificado, a tendência geral de mover as intensidades da imagem para a extremidade superior da escala de intensidade do histograma definitivamente se concretizou. Como mencionamos anteriormente, obter a imagem do histograma equalizado como um passo intermediário é útil para explicar o procedimento, mas não necessário. Em vez disso, poderíamos relacionar os mapeamentos dos valores de $r$ em $s$ e de $s$ em $z$ em uma tabela de três colunas. Então, poderíamos utilizar esses mapeamentos para mapear diretamente os pixels originais nos pixels da imagem do histograma especificado.

■

**Tabela 3.3** Todos os valores possíveis da função de transformação $G$ ajustados, arredondados e ordenados em relação a $z$.

| $z_q$ | $G(z_q)$ |
|---|---|
| $z_0 = 0$ | 0 |
| $z_1 = 1$ | 0 |
| $z_2 = 2$ | 0 |
| $z_3 = 3$ | 1 |
| $z_4 = 4$ | 2 |
| $z_5 = 5$ | 5 |
| $z_6 = 6$ | 6 |
| $z_7 = 7$ | 7 |

■

### Exemplo 3.9 Comparação entre a equalização de histograma e a especificação de histograma.

A Figura 3.23(a) mostra uma imagem da lua de Marte, Fobos, obtida pelo *Mars Global Surveyor*, da Nasa. A Figura 3.23(b) mostra o histograma da Figura 3.23(a). A imagem é dominada por áreas extensas e escuras, resultando em um histograma caracterizado por uma grande concentração de pixels na extremidade mais escura da escala de cinza. À primeira vista, seria possível concluir que a equalização de histograma seria uma boa abordagem para melhorar essa imagem, de forma que os detalhes nas áreas escuras se tornariam mais visíveis. Demonstraremos na análise a seguir que isso não ocorre neste caso.

A Figura 3.24(a) mostra a função de transformação da equalização de histograma (Equação 3.3-8 ou 3.3-13) obtida a partir do histograma da Figura 3.23(b). A característica mais relevante dessa função de transformação é a rapidez na qual ela sobe do nível de intensidade 0 a um nível próximo de 190. Isso é causado pela grande concentração de pixels no histograma de entrada com níveis próximos de 0. Quan-

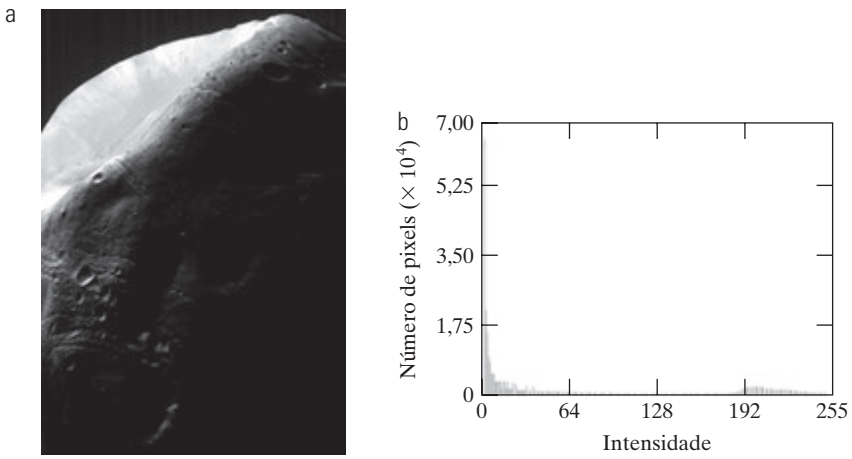



**Figura 3.23** (a) Imagem da lua de Marte, Fobos, obtida pelo *Mars Global Surveyor*, da Nasa. (b) Histograma. (Imagem original: cortesia da Nasa.)

**Tabela 3.4** Mapeamentos de todos os valores de $s_k$ nos valores correspondentes de $z_q$.

| $s_k$ | → | $z_q$ |
|---|---|---|
| 1 | → | 3 |
| 3 | → | 4 |
| 5 | → | 5 |
| 6 | → | 6 |
| 7 | → | 7 |

do essa transformação é aplicada aos níveis da imagem de entrada para obter o resultado do histograma equalizado, o efeito final é o mapeamento de um intervalo muito estreito de pixels escuros na extremidade superior da escala de cinza da imagem de saída. Como vários pixels da imagem de entrada apresentam níveis justamente nesse intervalo, esperaríamos que o resultado fosse uma imagem com uma aparência clara e desbotada. Como mostra a Figura 3.24(b), de fato é o que acontece. O histograma dessa imagem é mostrado na Figura 3.24(c). Observe como todos os níveis de intensidade tendem para a metade superior da escala de cinza.

Como o problema com a função de transformação da Figura 3.24(a) foi causado por uma grande concentração de pixels na imagem original com níveis próximos de 0, uma metodologia razoável consiste em modificar o histograma dessa imagem de forma que ela não apresente essa propriedade. A Figura 3.25(a) mostra uma função *manualmente especificada* que preserva o formato geral do histograma original, mas apresenta uma transição mais suave para os níveis da região escura da escala de cinza. A amostragem dessa função em 256 valores discretos igualmente espaçados produziu o histograma especificado desejado. A função de transformação $G(z)$, obtida a partir desse histograma utilizando a Equação 3.3-14, é indicada como a transformação (1) na Figura 3.25(b). De forma similar, a transformação inversa $G^{-1}(s)$ da Equação 3.3-16 (obtida utilizando o procedimento passo a passo discutido anteriormente) é indicada como a transformação (2) na Figura 3.25(b). A imagem realçada da Figura 3.25(c) foi obtida aplicando a transformação (2) aos pixels da imagem do histograma equalizado na Figura 3.24(b). A melhora na imagem do histograma especificado em relação ao resultado obtido pela equalização de histograma se evidencia na comparação dessas duas imagens. É interessante notar que bastou uma alteração relativamente pequena no histograma original para se obter uma melhora significativa na aparência. A Figura 3.25(d) mostra o histograma da Figura 3.25(c). A característica mais perceptível desse histograma é o fato de que sua extremidade inferior se deslocou para a direita na direção da região mais clara da escala de cinza (mas não excessivamente), como desejado.

■

Apesar de provavelmente já estar claro, salientamos, antes de concluir esta seção, que a especificação de histo-

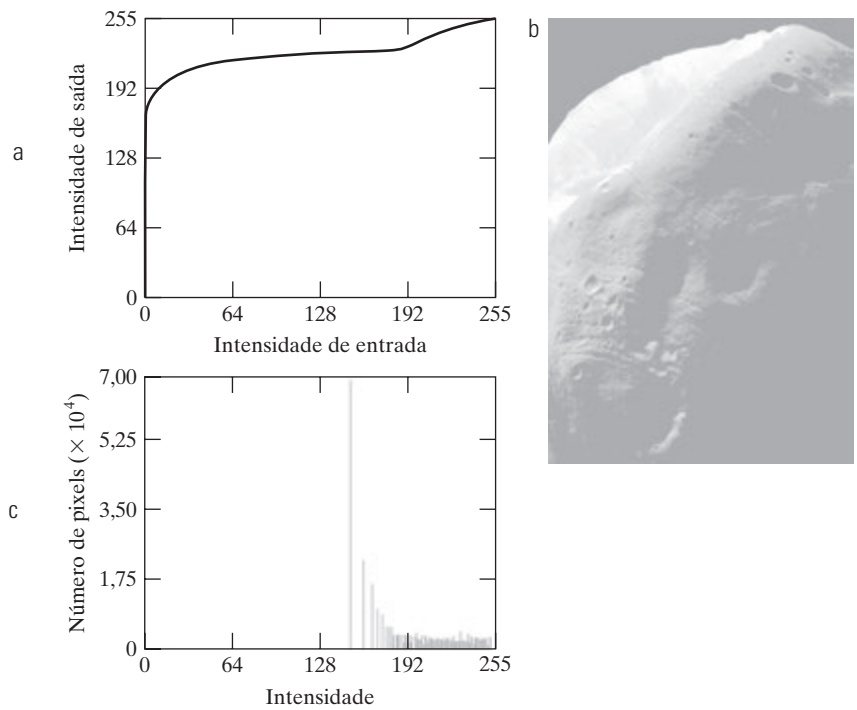



**Figura 3.24** (a) Função de transformação para a equalização de histograma. (b) Imagem do histograma equalizado (observe a aparência desbotada e sem brilho). (c) Histograma de (b).

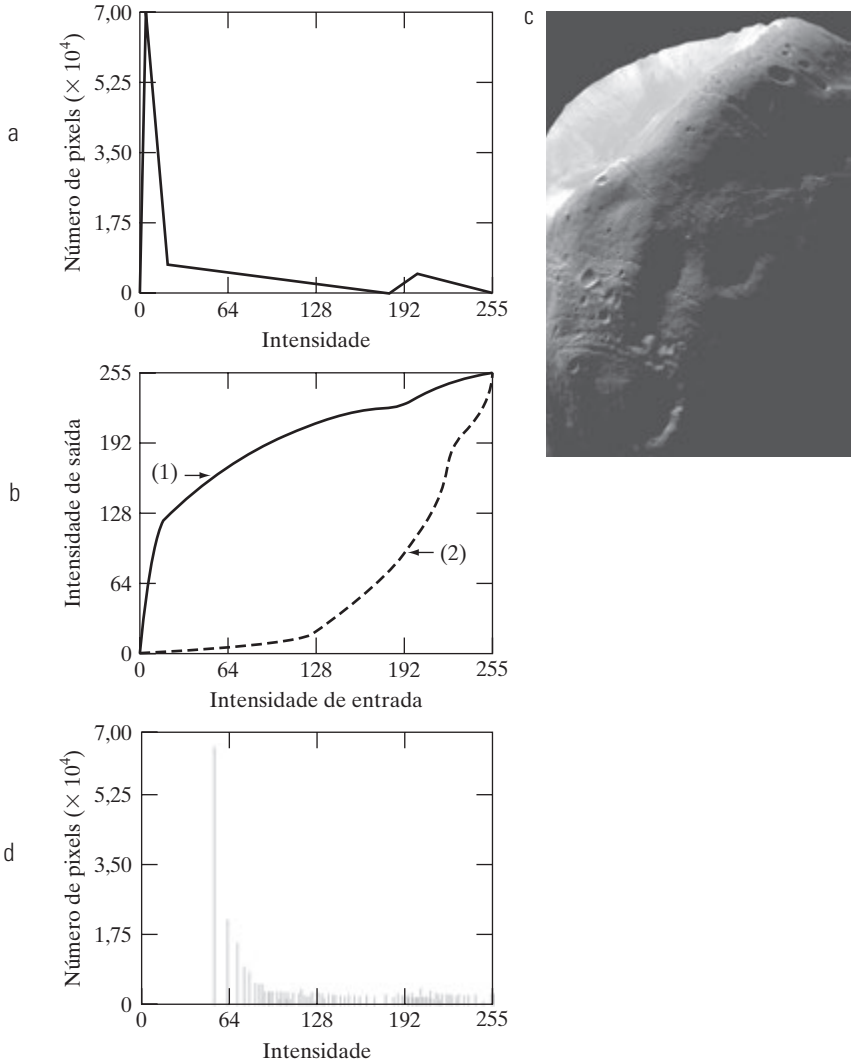



**Figura 3.25** (a) Histograma especificado desejado. (b) Transformações. (c) Imagem realçada utilizando os mapeamentos da curva (2). (d) Histograma de (c).

grama é, em grande parte, um processo de tentativa e erro. É possível utilizar as orientações aprendidas no exercício em questão, com fizemos no exemplo anterior. Pode haver casos nos quais é possível determinar como um histograma "aproximado" deve parecer e usar isso como o histograma especificado. Em casos como esses, a especificação de histograma passa a ser um processo direto. Em geral, contudo, não há regras para especificar histogramas, e deve-se recorrer à análise caso a caso para qualquer tarefa de realce dada.

### 3.3.3 Processamento local de histograma

Os métodos de processamento de histograma discutidos nas duas seções anteriores são *globais*, no sentido de que os pixels são modificados por uma função de transformação com base na distribuição de intensidade de toda uma imagem. Apesar de esse método global ser apropriado para o realce geral da imagem, há casos nos quais é necessário realçar detalhes em pequenas áreas de uma imagem. O número de pixels dessas áreas pode ter uma influência desprezível sobre o cálculo de uma transformação global cujo formato não necessariamente garante o realce local desejado. A solução é elaborar funções de transformação com base na distribuição de intensidade em uma vizinhança de cada pixel da imagem.

As técnicas de processamento de histograma previamente descritas são facilmente adaptadas ao realce local. O procedimento consiste em definir uma vizinhança e mover seu centro de um pixel ao outro. Em cada posição, o histograma dos pontos da vizinhança é calculado e uma função de equalização de histograma ou de especificação de histograma é obtida. Depois disso, essa função é utilizada para mapear a intensidade do pixel central da vizinhança. O centro da região da vizinhança é, então,

movido para a posição do pixel adjacente e o procedimento é repetido. Como apenas uma linha ou coluna da vizinhança muda durante uma translação pixel a pixel da vizinhança, é possível atualizar o histograma obtido na posição anterior com os novos dados em cada passo do movimento (Exercício 3.12). Esse método tem claras vantagens em relação ao cálculo repetido do histograma para todos os pixels da região da vizinhança a cada vez que a região é movida uma posição. Outro método geralmente usado para reduzir os cálculos é o de utilizar regiões que não se sobreponham, mas esse método normalmente produz um efeito "xadrez" não desejado.

■

**Exemplo 3.10** Equalização local de histograma.

A Figura 3.26(a) mostra uma imagem de 8 bits, 512 × 512, que à primeira vista parece conter cinco quadrados pretos sobre um fundo cinza. A imagem apresenta um ligeiro ruído, que é imperceptível. A Figura 3.26(b) mostra o resultado da equalização global de histograma. Como costuma ser o caso da equalização de histograma de regiões suaves e com ruído, essa imagem mostra um realce significativo do ruído. Além do ruído, contudo, a Figura 3.26(b) não revela quaisquer novos detalhes relevantes em relação à original, além de uma leve indicação de que o quadrado superior esquerdo e o inferior direito contêm um objeto. A Figura 3.26(c) foi obtida utilizando a equalização local de histograma com uma vizinhança de dimensões 3 × 3. No caso, vemos detalhes significativos contidos nos quadrados escuros. Os valores de intensidade desses objetos eram muito próximos da intensidade dos quadrados grandes, e suas dimensões eram pequenas demais para influenciar a equalização global de histograma o suficiente para mostrar esse detalhe.

■

### 3.3.4 Utilizando estatísticas de histograma para o realce da imagem

Estatísticas obtidas diretamente do histograma de uma imagem podem ser utilizadas para o realce da imagem. Seja $r$ uma variável aleatória discreta representando os valores de intensidade no intervalo $[0, L-1]$ e $p(r_i)$ indicando o componente do histograma normalizado correspondente ao valor $r_i$. Como indicado anteriormente, podemos considerar $p(r_i)$ uma estimativa da probabilidade de a intensidade $r_i$ ocorrer na imagem da qual o histograma foi obtido.

Como discutimos na Seção 2.6.8, o $n$-ésimo momento de $r$ em relação à sua média é definido como:

$$\mu_n(r) = \sum_{i=0}^{L-1} (r_i - m)^n \, p(r_i) \qquad (3.3\text{-}17)$$

onde $m$ é o valor médio (intensidade média) de $r$ (isto é, a intensidade média dos pixels da imagem):*

$$m = \sum_{i=0}^{L-1} r_i p(r_i) \qquad (3.3\text{-}18)$$

O segundo momento é particularmente importante:

$$\mu_2(r) = \sum_{i=0}^{L-1} (r_i - m)^2 \, p(r_i) \qquad (3.3\text{-}19)$$

Reconhecemos essa expressão como a variância da intensidade, normalmente expressa por $\sigma^2$ (lembre que o desvio padrão é a raiz quadrada da variância). Enquanto a média é uma medida da intensidade média, a variância (ou desvio padrão) é uma medida do contraste de uma imagem. Observe que todos os momentos são facilmen-

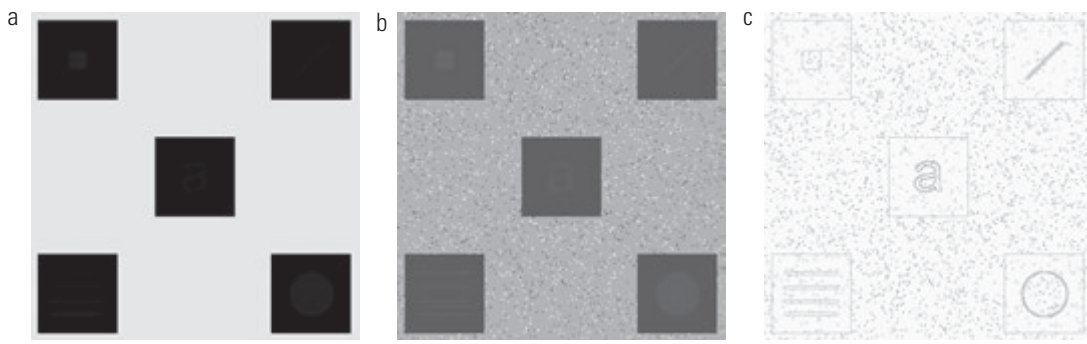



**Figura 3.26** (a) Imagem original. (b) Resultado da equalização global de histograma. (c) Resultado da equalização local de histograma aplicada em (a), utilizando uma vizinhança de dimensões 3 × 3.

* Seguimos a convenção na utilização de $m$ para o valor médio. Não confunda com o mesmo símbolo utilizado para expressar o número de linhas em uma vizinhança $m \times n$, na qual também utilizamos a convenção notacional.

te calculados utilizando as expressões apresentadas, uma vez que o histograma tenha sido obtido a partir de uma determinada imagem.

Ao trabalhar apenas com a média e a variância, costuma-se estimá-las diretamente dos valores amostrados, sem considerar o histograma. Apropriadamente, essas estimativas são chamadas de *média da amostra* e *variância da amostra*. Elas são dadas pelas expressões a seguir, conhecidas do campo da estatística básica:

$$m = \frac{1}{MN}\sum_{x=0}^{M-1}\sum_{y=0}^{N-1} f(x,y) \qquad (3.3\text{-}20)$$

e

$$\sigma^2 = \frac{1}{MN}\sum_{x=0}^{M-1}\sum_{y=0}^{N-1}\left[f(x,y)-m\right]^2 \qquad (3.3\text{-}21)$$

para $x = 0, 1, 2, \ldots, M-1$ e $y = 0, 1, 2, \ldots, N-1$*. Em outras palavras, como já sabemos, a intensidade média de uma imagem pode ser obtida pela simples soma dos valores de todos os seus pixels, dividindo a soma pelo número total de pixels na imagem. Uma interpretação similar se aplica à Equação 3.3-21. Como ilustramos no exemplo a seguir, os resultados obtidos utilizando essas duas equações são idênticos aos resultados obtidos utilizando as equações 3.3-18 e 3.3-19, contanto que o histograma utilizado nessas equações seja calculado a partir da mesma imagem utilizada para as equações 3.3-20 e 3.3-21.

■

**Exemplo 3.11** Calculando estatísticas de histograma.

Antes de prosseguir, será útil analisar um simples exemplo numérico para consolidar os conceitos. Considere a imagem a seguir, de 2 bits e tamanho 5 × 5:

$$\begin{array}{ccccc} 0 & 0 & 1 & 1 & 2 \\ 1 & 2 & 3 & 0 & 1 \\ 3 & 3 & 2 & 2 & 0 \\ 2 & 3 & 1 & 0 & 0 \\ 1 & 1 & 3 & 2 & 2 \end{array}$$

os pixels são representados por 2 bits; dessa forma, $L = 4$ e os níveis de intensidade estão no intervalo [0, 3]. O número total de pixels é 25, de forma que o histograma tem os componentes:

$$p(r_0) = \frac{6}{25} = 0,24;\ p(r_1) = \frac{7}{25} = 0,28;$$

$$p(r_2) = \frac{7}{25} = 0,28;\ p(r_3) = \frac{5}{25} = 0,20$$

onde o numerador em $p(r_i)$ é o número de pixels na imagem com nível de intensidade $r_i$. Podemos calcular o valor médio das intensidades da imagem utilizando a Equação 3.3-18:

$$\begin{aligned} m &= \sum_{i=0}^{3} r_i p(r_i) \\ &= (0)(0,24)+(1)(0,28)+(2)(0,28)+(3)(0,20) \\ &= 1,44 \end{aligned}$$

Sendo $f(x, y)$ o arranjo matricial anterior 5 × 5 e utilizando a Equação 3.3-20, obtemos:

$$\begin{aligned} m &= \frac{1}{25}\sum_{x=0}^{4}\sum_{y=0}^{4} f(x,y) \\ &= 1,44 \end{aligned}$$

Como esperado, os resultados conferem. Do mesmo modo, o resultado para a variância é o mesmo (1,1264) utilizando a Equação 3.3-19 ou a Equação 3.3-21.

■

Consideramos dois usos da média e da variância para fins de realce de imagens. A média e a variância *globais* são calculadas ao longo de toda a imagem e são úteis para ajustes mais gerais em termos de intensidade e contraste. Uma utilização mais poderosa desses parâmetros está no realce local, no qual a média e a variância *locais* são utilizadas como a base para fazer alterações que dependem das características da vizinhança ao redor de cada pixel de uma imagem.

Sejam $(x, y)$ as coordenadas de qualquer pixel de uma determinada imagem e $S_{xy}$ uma vizinhança (subimagem) de tamanho especificado, centrada em $(x, y)$. O valor médio dos pixels dessa vizinhança é dado pela expressão:

$$ms_{xy} = \sum_{i=0}^{L-1} r_i p_{S_{xy}}(r_i) \qquad (3.3\text{-}22)$$

onde $S_{xy}$ é o histograma dos pixels na região $S_{xy}$. Esse histograma tem $L$ componentes, correspondendo aos $L$ valores de intensidade possíveis na imagem de entrada. Contudo, muitos dos componentes são 0, dependendo do tamanho de $S_{xy}$. Por exemplo, se a vizinhança tiver dimensões 3 × 3 e $L = 256$, apenas entre 1 e 9 dos 256 componentes do histograma da vizinhança serão diferentes de zero. Esses valores diferentes de zero corresponderão ao número

* O denominador da Equação 3.3-21 algumas vezes é escrito como $MN - 1$ em vez de $MN$. Isso é feito para obter uma estimativa imparcial da variância. No entanto, estamos mais interessados que as equações 3.3-21 e 3.3-19 se correspondam quando o histograma da Equação 3.3-19 é calculado a partir da mesma imagem utilizada na Equação 3.3-21. Para isso, precisamos do termo $MN$. A diferença é desprezível para qualquer imagem de dimensões práticas.

de diferentes intensidades em $S_{xy}$ (o número máximo de diferentes intensidades possíveis em uma região 3 × 3 é 9, e o mínimo é 1).

De forma similar, a variância dos pixels na vizinhança é dada por:

$$\sigma^2_{S_{xy}} = \sum_{i=0}^{L-1} \left(r_i - m_{S_{xy}}\right)^2 p_{S_{xy}}(r_i) \qquad (3.3\text{-}23)$$

Como antes, a média local é uma medida de intensidade média na vizinhança $S_{xy}$, e a variância local (ou o desvio padrão) é uma medida de contraste de intensidade nessa vizinhança. Expressões análogas às equações 3.3-20 e 3.3-21 podem ser escritas para vizinhanças. Simplesmente utilizamos os valores dos pixels das vizinhanças nos somatórios e o número de pixels da vizinhança no denominador.

Como o exemplo a seguir ilustra, um aspecto importante do processamento de imagens utilizando a média e a variância locais consiste na flexibilidade proporcionada para o desenvolvimento de técnicas simples, porém poderosas, de realce com base em medidas estatísticas que têm relação próxima e previsível com a aparência da imagem.

■

### Exemplo 3.12 Realce local utilizando estatísticas de histograma.

A Figura 3.27(a) mostra uma imagem gerada por um microscópio eletrônico de varredura de um filamento de tungstênio enrolado em um suporte. O filamento está no centro da imagem e seu suporte está bastante claro e fácil de analisar. Há uma outra estrutura de filamento no lado direito e escuro da imagem, mas é quase imperceptível, e seu tamanho e outras características não são facilmente discerníveis. O realce local pela manipulação do contraste é uma abordagem ideal para problemas como este, no qual partes de uma imagem podem conter elementos ocultos.

Neste caso específico, o problema é realçar as áreas escuras ao mesmo tempo em que se deixa a área clara o mais inalterada possível, já que não precisa de realce. Podemos utilizar os conceitos apresentados nesta seção para formular um método de realce capaz de distinguir a diferença entre escuro e claro e, ao mesmo tempo, capaz de realçar somente as áreas escuras. Uma medida para saber se uma área é relativamente clara ou escura em um ponto $(x, y)$ é comparar a intensidade média local, $M_{S_{xy}}$ com a intensidade média da imagem, chamada de *média global* e expressa por $m_G$. Este valor é obtido com a Equação 3.3-18 ou com a Equação 3.3-20, utilizando a imagem inteira. Dessa forma, temos o primeiro elemento do nosso esquema de realce: consideraremos o pixel em um ponto $(x, y)$ como um candidato para o processamento se $M_{S_{xy}} \leq k_0 m_G$, onde $k_0$ é uma constante positiva com valor menor que 1,0.

Como estamos interessados em realçar áreas com baixo contraste, também precisamos de uma medida para definir se o contraste de uma área faz com que ela seja uma candidata ao realce. Consideraremos o pixel em um ponto $(x, y)$ como um candidato para o realce se $\sigma_{S_{xy}} \leq k_2 \sigma_G$ sendo $\sigma_G$ o *desvio padrão global* obtido utilizando as equações 3.3-19 ou 3.3-21 e $k_2$ uma constante positiva. O valor dessa constante será maior que 1,0 se estivermos interessados em realçar as áreas claras e menor que 1,0 para as áreas escuras.

Por fim, precisamos definir os menores valores de contraste que estamos dispostos a aceitar; caso contrário, o procedimento tentaria realçar áreas constantes, cujo desvio padrão é zero. Dessa forma, também definimos um limite inferior para o desvio padrão local exigindo que $k_1 \sigma_G \leq \sigma_{S_{xy}}$, com $k_1 < k_2$. Um pixel em $(x, y)$ que satisfaça todas as condições para o realce local é processado simplesmente multiplicando-o por uma constante especificada, $E$, para aumentar (ou diminuir) o valor de seu nível de intensidade relativo ao restante da imagem. Os pixels que não satisfazem as condições de realce não são alterados.

Resumimos a metodologia anterior como se segue. Temos $f(x, y)$ representando o valor de uma imagem de quais-

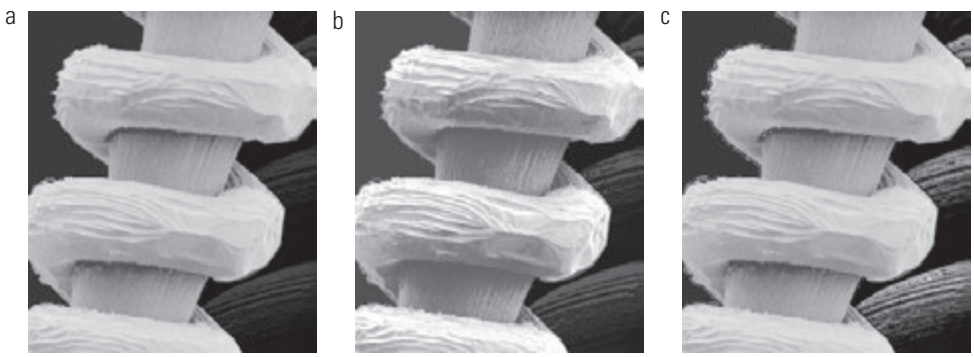



**Figura 3.27** (a) Imagem gerada por um microscópio eletrônico de varredura de um filamento de tungstênio ampliado aproximadamente 130× (b) Resultado da equalização global do histograma. (c) Imagem realçada utilizando estatísticas locais de histograma. (Imagem original: cortesia do Dr. Michael Shaffer, Departamento de Ciências Geológicas, Universidade de Oregon, Eugene.)

quer coordenadas $(x, y)$ da imagem e $g(x, y)$ representando o valor realçado correspondente dessas coordenadas. Então:

$$g(x,y) = \begin{cases} E \cdot f(x,y) & \text{se } m_{S_{xy}} \leq k_0 m_G \\ & \text{e } k_1\sigma_G \leq \sigma_{S_{xy}} \leq k_2\sigma_G \\ f(x,y) & \text{para todos os outros intervalos} \end{cases} \tag{3.3-24}$$

para $x = 0, 1, 2, \ldots, M-1$ e $y = 0, 1, 2, \ldots, N-1$, sendo que, como indicado acima, $E$, $k_0$, $k_1$ e $k_2$ são parâmetros especificados, $m_G$ é a média global da imagem de entrada e $\sigma_G$ é seu desvio padrão. Os parâmetros $M_{S_{xy}}$ e $\sigma_{S_{xy}}$ são a média e o desvio padrão locais, respectivamente. $M$ e $N$ são as dimensões da imagem em termos de linhas e colunas.

Escolher os parâmetros na Equação 3.3-24 geralmente requer alguma experimentação para se familiarizar com uma determinada imagem ou categoria de imagens. Nesse caso, os valores a seguir foram selecionados: $E = 4{,}0$, $k_0 = 0{,}4$, $k_1 = 0{,}02$ e $k_2 = 0{,}4$. O valor relativamente baixo de 4,0 para $E$ foi escolhido de forma que, ao ser multiplicado pelos níveis nas áreas que serão realçadas (que são escuras), o resultado ainda tenderia ao extremo mais escuro da escala e, dessa forma, preservaria o equilíbrio visual da imagem. O valor de $k_0$ foi escolhido como menos da metade da média global porque podemos ver na imagem que as áreas que requerem realce definitivamente são escuras o suficiente para estarem abaixo da metade do valor da média global. Uma análise similar levou à escolha dos valores para $k_1$ e $k_2$. A escolha dessas constantes em geral não é difícil, mas deve ser orientada por uma análise lógica do problema de realce em questão. Por fim, o tamanho da área local $S_{xy}$ deve ser o menor possível para preservar detalhes e manter o custo computacional o menor possível. Escolhemos uma região de tamanho 3 × 3.

Como uma base para a comparação, realçamos a imagem utilizando a equalização global de histograma. A Figura 3.27(b) mostra o resultado. A área escura foi melhorada, mas ainda é difícil perceber detalhes, e as áreas claras foram alteradas, o que não queríamos fazer. A Figura 3.27(c) mostra o resultado da utilização do método de estatísticas locais explicado nesta seção. Ao comparar essa imagem com a original na Figura 3.27(a) ou com o resultado da equalização de histograma na Figura 3.27(b), observamos os detalhes que passaram a ser perceptíveis no lado direito da Figura 3.27(c). Observe, por exemplo, a nitidez dos contornos dos filamentos escuros. Cabe notar que as áreas de intensidade mais clara à esquerda foram mantidas intactas, um dos nossos objetivos iniciais.

■

## 3.4 Fundamentos da filtragem espacial

Nesta seção, apresentaremos vários conceitos básicos que fundamentam a utilização de filtros espaciais para o processamento de imagens. A filtragem espacial é uma das principais ferramentas utilizadas na área para uma ampla gama de aplicações, de forma que recomendamos fortemente que você desenvolva uma sólida compreensão desses conceitos. Como mencionamos no início deste capítulo, os exemplos desta seção lidam, em grande parte, com a utilização de filtros espaciais para o realce de imagem. Outras aplicações da filtragem espacial serão discutidas em capítulos posteriores.

O termo *filtro* foi emprestado do processamento no domínio da frequência, que é o tópico do próximo capítulo, no qual "filtragem" se refere a aceitar (passar) ou rejeitar certos componentes de frequência. Por exemplo, um filtro que aceita baixas frequências é chamado de filtro *passa-baixa*. O efeito final produzido por um filtro passa-baixa é borrar (suavizar) uma imagem. Podemos obter uma suavização similar diretamente na própria imagem utilizando filtros espaciais (também chamados de *máscaras*, *kernels*, *templates* e *janelas*). De fato, como mostraremos no Capítulo 4, existe uma correspondência um a um entre os filtros espaciais lineares e filtros no domínio da frequência.* No entanto, os filtros espaciais oferecem consideravelmente mais versatilidade porque, como veremos posteriormente, eles também podem ser utilizados para a filtragem não linear, algo que não é possível fazer no domínio da frequência.

### 3.4.1 O funcionamento da filtragem espacial

Na Figura 3.1, explicamos brevemente que um filtro espacial consiste em (1) uma *vizinhança* (normalmente um pequeno retângulo), (2) uma *operação predefinida* realizada sobre os pixels da imagem incluídos na vizinhança. A filtragem cria um novo pixel com coordenadas iguais às coordenadas do centro da vizinhança, e cujo valor é o resultado da operação de filtragem.** Uma imagem processada (filtrada) é gerada à medida que o centro do filtro percorre cada pixel na imagem de entrada. Se a operação realizada sobre os pixels da imagem for linear, o filtro é chamado de *filtro espacial linear*. Caso contrário, o filtro é *não linear*. Concentraremos a nossa atenção primeiro em filtros lineares e depois ilustraremos alguns filtros não lineares simples. A Seção 5.3 apresenta uma lista mais abrangente de filtros não lineares e suas aplicações.

A Figura 3.28 ilustra o funcionamento da filtragem espacial linear utilizando uma vizinhança 3 × 3. Em qual-

* Veja a Seção 2.6.2, sobre linearidade.

** O valor do pixel filtrado normalmente é atribuído a uma posição correspondente em uma nova imagem criada para receber os resultados da filtragem. Raramente ocorre de os pixels filtrados substituírem os valores da posição correspondente na imagem original, já que isso alteraria o conteúdo da imagem enquanto a filtragem ainda continua sendo realizada.

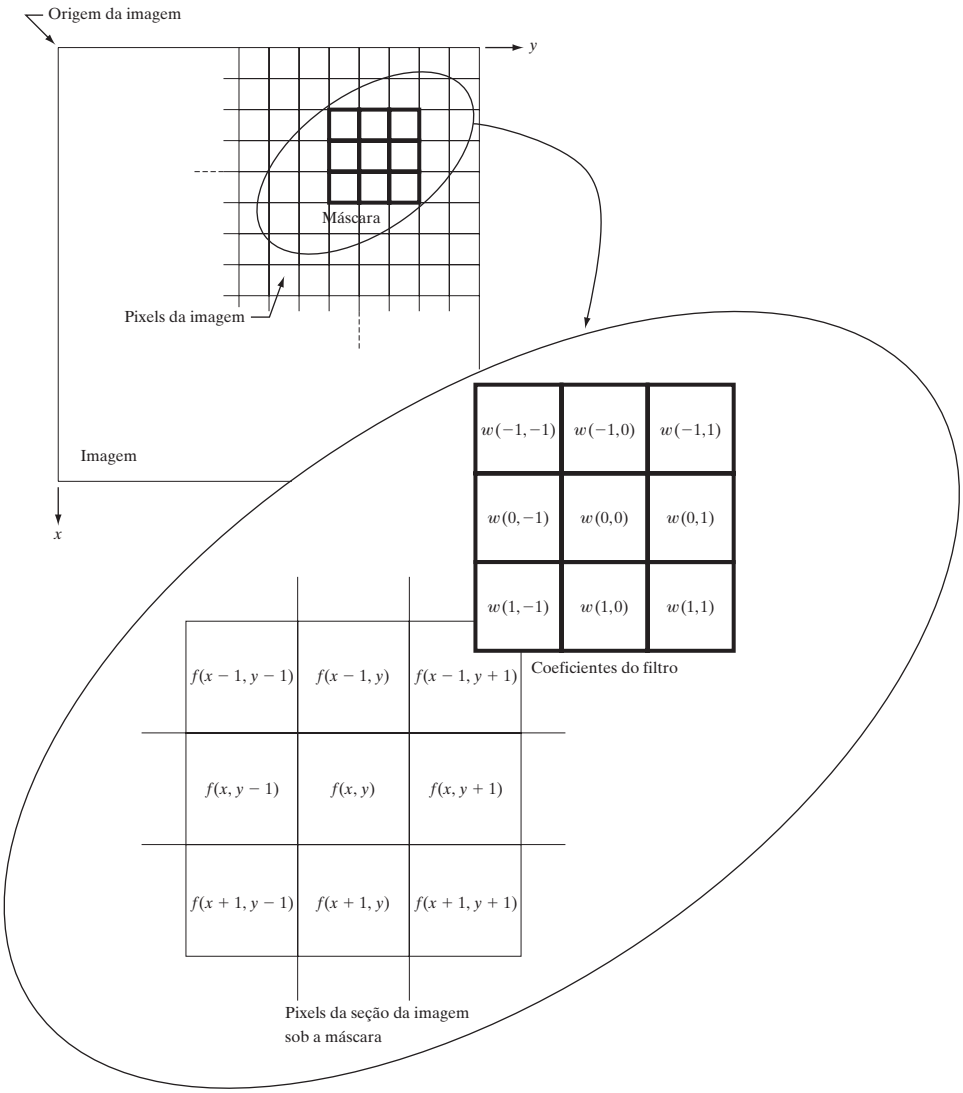



**Figura 3.28** O funcionamento da filtragem espacial linear utilizando uma máscara 3 × 3. A forma escolhida para expressar as coordenadas dos coeficientes da máscara simplifica a escrita de expressões para a filtragem linear.

quer ponto $(x, y)$ da imagem, a resposta, $g(x, y)$, do filtro é a soma dos produtos dos coeficientes do filtro com os pixels da imagem englobados pelo filtro:

$$g(x,y) = w(-1,-1)f(x-1,y-1) + w(-1,0)f(x-1,y) + \ldots + w(0,0)f(x,y) + \ldots + w(1,1)f(x+1,y+1)$$

Observe que o coeficiente central do filtro, $w(0, 0)$, se alinha com o pixel da posição $(x, y)$. Para um tamanho de máscara $m \times n$, consideramos que $m = 2a + 1$ e $n = 2b + 1$, sendo $a$ e $b$ números inteiros positivos. Isso significa que nosso foco na discussão a seguir será em filtros de tamanho ímpar, e o menor é de tamanho $3 \times 3$*. Em geral, a filtragem espacial linear de uma imagem de dimensões $M \times N$ com um filtro de dimensões $m \times n$ é dada pela expressão:

$$g(x,y) = \sum_{s=-a}^{a} \sum_{t=-b}^{b} w(s,t) f(x+s, y+t)$$

onde $x$ e $y$ variam de forma que cada pixel em $w$ percorre todos os pixels em $f$.

* Certamente é possível trabalhar com filtros de tamanho misto (par e ímpar). No entanto, trabalhar com tamanhos ímpares simplifica a indexação e também é mais intuitivo, porque os filtros têm centros que encontram valores inteiros.

### 3.4.2 Convolução e correlação espacial

Há dois conceitos estreitamente relacionados que devem ser bem compreendidos ao realizar a filtragem espacial linear. Um consiste na *correlação*, e o outro na *convolução*. A correlação é o processo de mover uma máscara pela imagem e calcular a soma dos produtos em cada posição, exatamente como explicado na seção anterior. O funcionamento da convolução é o mesmo, exceto o fato de o primeiro filtro ser rotacionado a 180°. A melhor forma de explicar as diferenças entre os dois conceitos é pelo exemplo. Começamos com uma ilustração unidimensional.

A Figura 3.29(a) mostra uma função unidimensional, $f$, e um filtro, $w$, e a Figura 3.29(b) mostra a posição inicial para realizar a correlação. A primeira coisa que observamos é que há partes das funções que não se sobrepõem. A solução para esse problema é preencher $f$ em cada lado com 0s suficientes para permitir que cada pixel de $w$ percorra todos os pixels de $f$.* Se o filtro for de tamanho $m$, precisamos de $m - 1$ 0s em cada lado de $f$. A Figura 3.29(c) mostra uma função preenchida com 0s de modo apropriado. O primeiro valor da correlação é a soma dos produtos de $f$ com $w$ para a posição inicial mostrada na Figura 3.29(c) (a soma dos produtos é 0). Isso corresponde à primeira posição, ou seja, ao deslocamento $x = 0$. Para obter o segundo valor da correlação, deslocamos $w$ uma posição de pixel para a direita (deslocamento $x = 1$) e calculamos a soma dos produtos. O resultado, mais uma vez, é 0. Na verdade, o primeiro resultado di-

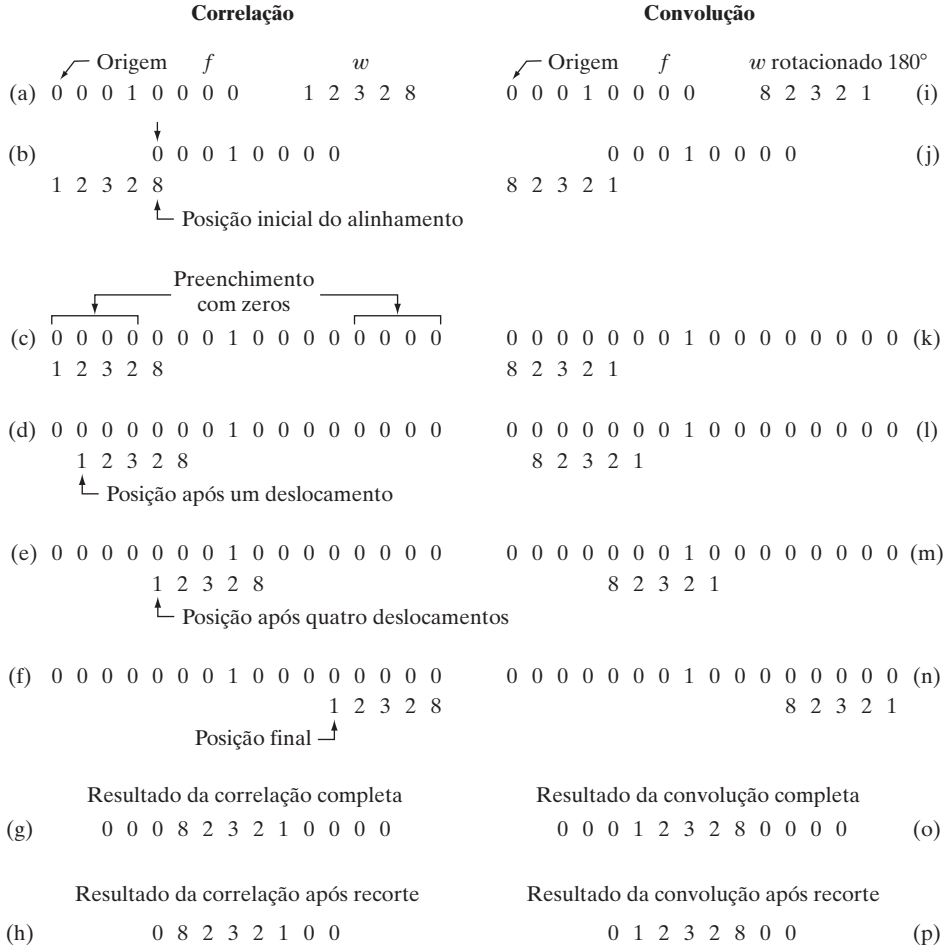



**Figura 3.29** Ilustração de convolução e correlação unidimensional de um filtro com impulso unitário discreto. Observe que a correlação e a convolução são funções de *deslocamento*.

* Preencher a imagem com zeros não é a única opção. Por exemplo, poderíamos duplicar o valor do primeiro e do último elemento $m - 1$ vezes em cada lado de $f$, ou espelhar o primeiro e o último elemento $m - 1$ e utilizar os valores espelhados para fazer o preenchimento.

ferente de zero se dá quando $x = 3$, que é o caso no qual o valor 8 de $w$ se sobrepõe ao valor 1 de $f$ e o resultado da correlação é 8. Procedendo dessa forma, obtemos todo o resultado da correlação na Figura 3.29(g). Observe que foram necessários 12 valores de $x$ (isto é, $x = 0, 1, 2, \ldots, 11$) para deslocar totalmente $w$ através de $f$, de forma que cada pixel de $w$ percorresse cada pixel de $f$. Em muitas ocasiões, gostamos de trabalhar com arranjos de correlação do mesmo tamanho que $f$, caso no qual recortamos a correlação completa para corresponder ao tamanho da função original, como mostra a Figura 3.29(h).

Devemos observar dois pontos importantes na discussão do parágrafo anterior. Em primeiro lugar, a correlação é uma função de *deslocamento* do filtro. Em outras palavras, o primeiro valor da correlação corresponde ao deslocamento zero do filtro, o segundo corresponde ao deslocamento de uma unidade, e assim por diante. O segundo ponto a ser observado é que correlacionar um filtro $w$ com uma função que contenha apenas 0s e um único 1 resulta em uma cópia de $w$, mas *rotacionada* a 180°. Chamamos uma função que contém um único 1, e o restante é composto de 0s de um *impulso unitário discreto*. Dessa forma, concluímos que a correlação de uma função com um impulso unitário discreto gera uma versão rotacionada da função exatamente na posição que estava o impulso.

O conceito da convolução é fundamental na teoria dos sistemas lineares. Como veremos no Capítulo 4, uma propriedade fundamental da convolução é que realizar a convolução de uma função com um impulso unitário gera uma cópia da função na posição do impulso. Vimos no parágrafo anterior que a correlação também gera uma cópia da função, mas rotacionada a 180°.* Dessa forma, se *pré-rotacionarmos* o filtro e realizarmos a mesma operação de soma dos produtos de cada deslocamento, devemos ser capazes de obter o resultado desejado. Como mostra a coluna da direita da Figura 3.29, isso é de fato o que acontece. Assim, vemos que, para realizar a convolução, tudo o que fazemos é rotacionar a 180° uma função e realizar as mesmas operações que na correlação. Na verdade, não faz diferença qual das duas funções rotacionamos.

Os conceitos anteriores se estendem facilmente a imagens, como mostra a Figura 3.30. Para um filtro de dimensões $m \times n$, preenchemos com zeros a imagem com um mínimo de $m - 1$ linhas acima e abaixo e $n - 1$ colunas à esquerda e à direita. Neste caso, $m$ e $n$ são iguais a 3, de forma que preenchemos $f$ com duas linhas de 0s acima e abaixo e duas colunas de 0s à esquerda e direita, como mostra a Figura 3.30(b). A Figura 3.30(c) mostra a posição inicial da máscara para realizar a correlação, e a Figura 3.30(d) mostra o resultado da correlação completa. A Figura 3.30(e) mostra o resultado correspondente após o recorte. Observe mais uma vez que o resultado é rotacionado a 180°**. Para a convolução, pré-rotacionamos a máscara como antes e repetimos a operação de soma dos produtos de cada deslocamento como acabamos de explicar. As figuras 3.30(f) a (h) mostram o resultado. Vemos novamente que a convolução de uma função com um impulso copia a função na posição do impulso. Deve ficar claro que, se a máscara for simétrica, a correlação e a convolução geram o mesmo resultado.

Se, em vez de conter apenas um 1, a imagem $f$ da Figura 3.30 contivesse uma região idêntica a $w$, o valor da função de correlação (após a normalização) teria sido máximo quando $w$ estivesse centrado nessa região de $f$. Dessa forma, como veremos no Capítulo 12, a correlação também pode ser utilizada para encontrar *correspondências* entre imagens.

Resumindo a discussão anterior na forma de equação, temos que a correlação de um filtro $w(x, y)$ de tamanho $m \times n$ com uma imagem $f(x, y)$, expressa como $w(x, y) \star f(x, y)$, é dada pela equação mostrada no final da última seção, que repetimos aqui por conveniência:

$$w(x,y) \star f(x,y) = \sum_{s=-a}^{a} \sum_{t=-b}^{b} w(s,t) f(x+s, y+t) \quad (3.4\text{-}1)$$

Essa equação é calculada para todos os valores das variáveis de deslocamento $x$ e $y$, de forma que todos os elementos de $w$ percorram cada um dos pixels de $f$, onde presumimos que $f$ foi apropriadamente preenchida. Como explicamos anteriormente, $a = (m - 1)/2$, $b = (n - 1)/2$, e consideramos, para praticidade de notação, que $m$ e $n$ são números inteiros ímpares.

De forma similar, a convolução de $w(x, y)$ e $f(x, y)$, expressa por $w(x, y) \star f(x, y)$***, é dada pela expressão:****

* Observe que a rotação de 180º equivale a inverter horizontalmente a função.

** Em imagens 2-D, a rotação a 180º equivale a inverter a máscara em relação a um eixo e, depois, em relação ao outro.

*** Como a convolução é comutativa, temos que $w(x, y) \star f(x, y) = f(x, y) \star w(x, y)$. Isso não é verdade para a correlação, como pode ser visto, por exemplo, invertendo a ordem das funções na Figura 3.29(a).

**** Muitas vezes, quando o significado é claro, expressamos o resultado de uma correlação ou convolução por uma função $g(x, y)$, em vez de escrever $w(x, y) \star f(x, y)$ ou $w(x, y) \star f(x, y)$. Por exemplo, veja a equação no final da seção anterior e a Equação (3.5-1).

$$w(x,y) \quad f(x,y) = \sum_{s=-a}^{a} \sum_{t=-b}^{b} w(s,t) f(x-s, y-t) \quad (3.4\text{-}2)$$

onde o sinal de menos à direita inverte $f$ (isto é, a rotaciona a 180°). Inverter e deslocar $f$ em vez de $w$ são processos realizados para fins de simplicidade de notação e também para seguir a forma convencional. O resultado é o mesmo. Como no caso da correlação, essa equação é calculada para todos os valores das variáveis de deslocamento $x$ e $y$, de forma que todos os elementos de $w$ percorram cada um dos os pixels de $f$, que presumimos ter sido apropriadamente preenchidos. Podemos expandir a Equação 3.4-2 para uma máscara 3 × 3 e nos convencermos de que o resultado de utilizar essa equação é idêntico ao exemplo da Figura 3.30. Na prática, costuma-se trabalhar com um algoritmo que implementa a Equação 3.4-1. Se quisermos realizar a correlação, incluímos $w$ no algoritmo; para a convolução, incluímos $w$ rotacionado em 180°. O oposto se aplica caso, em vez disso, um algoritmo que implementa a Equação 3.4-2 esteja disponível.

Como mencionamos anteriormente, a convolução é fundamental na teoria dos sistemas lineares. Como veremos no Capítulo 4, a propriedade de que a convolução de uma função com um impulso unitário copia a função na posição do impulso tem um papel central em uma série de importantes derivações. Retomaremos a convolução no Capítulo 4 no contexto da transformada de Fourier e do teorema da convolução. Diferentemente da Equação 3.4-2, contudo, estaremos lidando com a convolução de funções que são do mesmo tamanho. A forma da equação é a mesma, mas os limites do somatório são diferentes.

Utilizar a correlação ou a convolução para realizar a filtragem espacial é uma questão de preferência. Na verdade, como tanto a Equação 3.4-1 quanto a Equação 3.4-2 são capazes de realizar a função uma da outra por uma simples rotação do filtro, o importante é que a máscara do filtro utilizada em uma dada tarefa de filtragem seja especificada de forma a corresponder com a operação pretendida. Todos os resultados da filtragem espacial linear deste capítulo se baseiam na Equação 3.4-1.

Finalmente, é importante dizer que você provavelmente encontrará os termos *filtro de convolução*, *máscara de convolução* ou *kernel de convolução* na literatura sobre

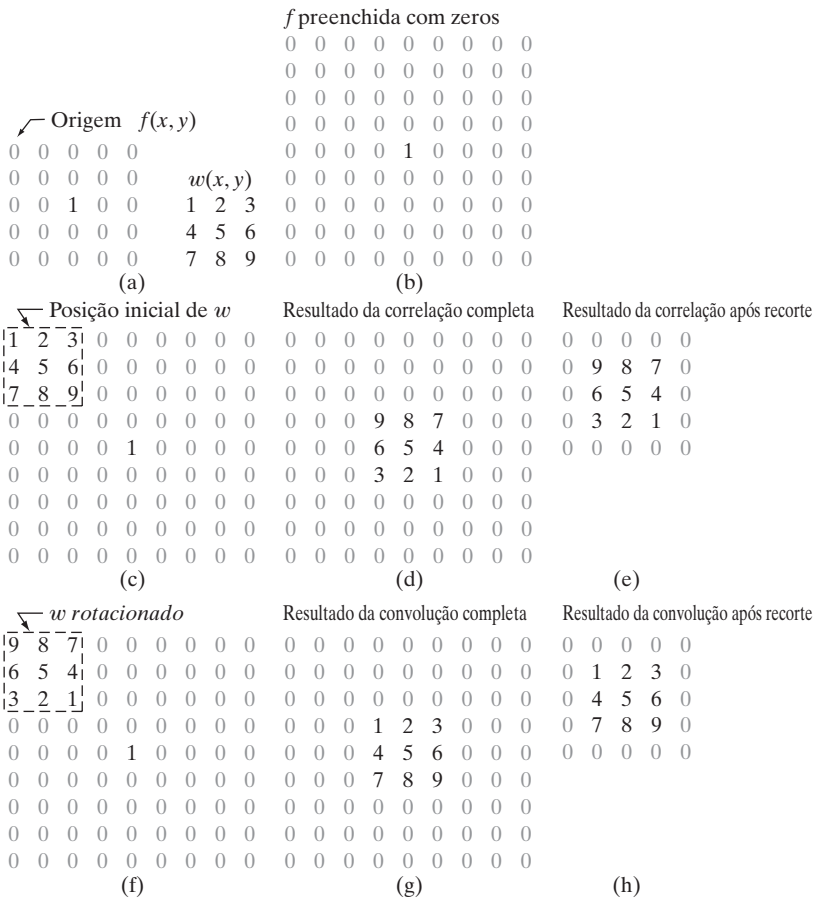



**Figura 3.30** Correlação (linha do meio) e convolução (última linha) de um filtro 2-D com um impulso unitário discreto 2-D. Os zeros são mostrados em cinza para simplificar a análise visual.

| | | |
|---|---|---|
| $w_1$ | $w_2$ | $w_3$ |
| $w_4$ | $w_5$ | $w_6$ |
| $w_7$ | $w_8$ | $w_9$ |

**Figura 3.31** Outra representação de uma máscara 3 × 3.

processamento de imagens. Como regra, esses termos são utilizados para expressar um filtro espacial, e não necessariamente o filtro será utilizado verdadeiramente para uma convolução. De forma similar, a expressão "realizar a convolução de uma máscara com uma imagem" costuma ser utilizada para expressar o processo de deslocamento e soma dos produtos que acabamos de explicar, e não necessariamente diferencia entre a correlação e a convolução. Em vez disso, ela é utilizada de forma genérica para expressar uma dessas duas operações. Essa terminologia imprecisa costuma ser fonte de confusão.

### 3.4.3 Representação vetorial da filtragem linear

Quando o interesse for a resposta característica, $R$, de uma máscara para a correlação ou a convolução, algumas vezes pode ser útil expressar a soma dos produtos como:*

$$\begin{aligned} R &= w_1 z_1 + w_2 z_2 + \cdots + w_{mn} z_{mn} \\ &= \sum_{k=1}^{mn} w_k z_k \\ &= \mathbf{w}^T \mathbf{z} \end{aligned} \tag{3.4-3}$$

onde os valores de $w$ são os coeficientes de um filtro $m \times n$ e os valores de $z$ são as intensidades correspondentes da imagem que estão cobertas pelo filtro. Se estivermos interessados em utilizar a Equação 3.4-3 para a correlação, devemos utilizar a máscara sem alterações. Para utilizar a mesma equação para a convolução, basta rotacionar a máscara em 180°, como explicamos na seção anterior. Está implícito que a Equação 3.4-3 se aplica a um par específico de coordenadas $(x, y)$. Você verá na próxima seção por que esta notação é útil para explicar as características de um dado filtro linear.

A título de exemplo, a Figura 3.31 mostra uma máscara genérica 3 × 3 com os coeficientes definidos. Neste caso, a Equação 3.4-3 passa a ser:

$$\begin{aligned} R &= w_1 z_1 + w_2 z_2 + \cdots + w_9 z_9 \\ &= \sum_{k=1}^{9} w_k z_k \\ &= \mathbf{w}^T \mathbf{z} \end{aligned} \tag{3.4-4}$$

* Consulte a seção Tutoriais no site do livro para uma breve revisão sobre vetores e matrizes.

onde $\mathbf{w}$ e $\mathbf{z}$ são vetores 9-dimensionais formados a partir dos coeficientes da máscara e das intensidades de imagem cobertas pela máscara, respectivamente.

### 3.4.4 Gerando máscaras de filtragem espacial

Para gerar um filtro espacial *linear* $m \times n$, devemos especificar os coeficientes da máscara $mn$. Esses coeficientes, por sua vez, são selecionados com base no que o filtro deve fazer, tendo em mente que tudo o que podemos fazer com a filtragem linear é implementar uma soma de produtos. Por exemplo, suponha que queiramos substituir os pixels de uma imagem pela intensidade média de uma vizinhança 3 × 3 centrada nesses pixels. O valor médio de qualquer posição $(x, y)$ na imagem é a soma dos nove valores de intensidade da vizinhança 3 × 3 centrada em $(x, y)$ dividida por 9. Com $z_i$, $i = 1, 2, \ldots, 9$, indicando essas intensidades, a média é:

$$R = \frac{1}{9}\sum_{i=1}^{9} z_i$$

Mas isso é o mesmo que a Equação 3.4-4 com valores de coeficiente $w_i = 1/9$. Em outras palavras, uma operação de filtragem linear com uma máscara 3 × 3 cujos coeficientes são 1/9 implementa o cálculo desejado da média. Como discutiremos na próxima seção, essa operação resulta na suavização de imagens. Analisaremos nas seções a seguir uma série de outras máscaras de filtragem com base nessa abordagem.

Em algumas aplicações, temos uma função contínua de duas variáveis, e o objetivo é obter uma máscara de filtragem espacial com base nessa função. Por exemplo, uma função gaussiana de duas variáveis tem a forma básica:

$$h(x, y) = e^{-\frac{x^2+y^2}{2\sigma^2}}$$

onde $\sigma$ é o desvio padrão e, como sempre, consideramos que as coordenadas $x$ e $y$ sejam números inteiros. Para gerar, digamos, uma máscara 3 × 3 a partir dessa função, fazemos uma amostragem ao redor de seu centro. Assim, $w_1 = h(-1, -1)$, $w_2 = h(-1, 0)$, ..., $w_9 = h(1, 1)$. Uma máscara $m \times n$ é gerada de forma similar. Lembre-se que uma função gaussiana bidimensional tem o formato de um sino e que o desvio padrão controla o quanto o sino é "aberto".

Gerar um filtro *não linear* requer especificar as dimensões de uma vizinhança e a(s) operação(ões) a ser(em) executada(s) nos pixels da imagem contidos na vizinhança. Por exemplo, lembrando que a operação *máx* é não linear (veja a Seção 2.6.2), um filtro *máx* 5 × 5 centrado em um ponto arbitrário $(x, y)$ de uma imagem obtém o máximo valor de intensidade dos 25 pixels e atribui

esse valor à posição $(x, y)$ na imagem processada. Filtros não lineares são bastante poderosos e, em algumas aplicações, podem realizar funções que estão além das possibilidades dos filtros lineares, como veremos mais adiante neste capítulo e também no Capítulo 5.

## 3.5 Filtros espaciais de suavização

Os filtros de suavização são utilizados para borramento e redução de ruído. O borramento é aplicado em tarefas de pré-processamento, como remoção de pequenos detalhes da imagem antes da extração de objetos (grandes) e conexão de pequenas descontinuidades em linhas ou curvas. A redução de ruído pode ser obtida pelo borramento com um filtro linear e também pela filtragem não linear.

### 3.5.1 Filtros lineares de suavização

A saída (resposta) de um filtro espacial linear de suavização é simplesmente a média dos pixels contidos na vizinhança da máscara de filtragem. Esses filtros por vezes são chamados de *filtros de média*. Como mencionado na seção anterior, eles também podem ser chamados de *filtros passa-baixa*.

A ideia por trás dos filtros de suavização é direta. Ao substituir o valor de cada pixel de uma imagem pela média dos níveis de intensidade da vizinhança definida pela máscara, o processo resulta em uma imagem com perda da nitidez, ou seja, com redução das transições "abruptas" nas intensidades. Pelo fato de o ruído aleatório normalmente consistir em transições abruptas nos níveis de intensidade, a aplicação mais evidente da suavização é a redução de ruído. No entanto, as bordas (que quase sempre são características desejáveis de uma imagem) também são caracterizadas por transições abruptas de intensidade, de forma que os filtros de média apresentam o efeito colateral indesejável de borrar as bordas. Uma outra aplicação desse tipo de processo inclui a suavização de falsos contornos resultantes da utilização de um número insuficiente de níveis de intensidade, como discutido na Seção 2.4.3. Uma importante utilização dos filtros de média é a redução de detalhes "irrelevantes" em uma imagem. Por "irrelevantes" queremos dizer regiões da imagem que são menores que o tamanho da máscara utilizada na filtragem. Esta última aplicação é ilustrada mais adiante nesta seção.

A Figura 3.32 mostra dois filtros de suavização 3 × 3. A utilização do primeiro filtro gera a média aritmética simples dos pixels cobertos pela máscara. Isso pode ser visto com mais facilidade substituindo os coeficientes da máscara na Equação 3.4-4:

$$R = \frac{1}{9}\sum_{i=1}^{9} z_i$$

que é a média dos níveis de intensidade dos pixels na vizinhança 3 × 3 definida pela máscara, como discutimos anteriormente. Observe que, em vez de 1/9, os coeficientes do filtro são todos 1s. A ideia aqui é que é computacionalmente mais eficiente ter coeficientes com valor 1. Ao final do processo de filtragem, toda a imagem é dividida por 9. Uma máscara $m \times n$ teria uma constante de normalização igual a $1/mn$. Um filtro espacial de média no qual todos os coeficientes são iguais é chamado, algumas vezes, de filtro retangular (*box filter*).

A segunda máscara da Figura 3.32 é um pouco mais interessante. Essa máscara gera a chamada *média ponderada*, terminologia utilizada para indicar que os pixels são multiplicados por diferentes coeficientes, atribuindo, dessa forma, mais importância (peso) a alguns pixels à custa de outros. Na máscara mostrada na Figura 3.32(b), o pixel no centro da máscara é multiplicado por um valor mais alto do que qualquer outro, atribuindo, assim, mais importância a esse pixel no cálculo da média. Os outros pixels são inversamente ponderados em função de sua distância ao centro da máscara. Os termos diagonais estão mais distantes do centro do que os vizinhos ortogonais (por um fator de $\sqrt{2}$) e, portanto, têm um peso menor do que os vizinhos imediatos do pixel central. A estratégia básica por trás do processo de atribuir o maior peso ao ponto central e, depois, reduzir o valor dos coeficientes em função do aumento da distância da origem, é simplesmente uma tentativa de reduzir o borramento no processo de suavização. Poderíamos ter escolhido outros pesos para atingir o mesmo objetivo geral. No entanto, a soma de todos os coeficientes da máscara da Figura 3.32(b) é igual a 16, o que é uma característica interessante para a implementação computacional por ser um número inteiro e potência de 2. Na prática, em geral é difícil ver as diferenças entre as imagens suavizadas utilizando uma das máscaras mostradas na Figura 3.32, ou arranjos similares, porque a área coberta por essas máscaras em qualquer posição de uma imagem é muito pequena.

No que se refere à Equação 3.4-1, a implementação geral para a filtragem de uma imagem $M \times N$ com um filtro de média ponderada de tamanho $m \times n$ ($m$ e $n$ ímpares) é dada pela expressão:

$$g(x,y) = \frac{\sum_{s=-a}^{a}\sum_{t=-b}^{b} w(s,t)\, f(x+s,\, y+t)}{\sum_{s=-a}^{a}\sum_{t=-b}^{b} w(s,t)} \qquad (3.5\text{-}1)$$

Os parâmetros nessa equação são iguais aos definidos na Equação 3.4-1. Como antes, considera-se que a imagem completamente filtrada seja obtida aplicando a Equação 3.5-1 para $x = 0, 1, 2, \ldots, M - 1$ e $y = 0, 1, 2, \ldots, N - 1$. O denominador da Equação 3.5-1 é simplesmente a soma dos coeficientes da máscara; logo, é uma constante que só precisa ser calculada uma vez.

■

**Exemplo 3.13** Suavização de imagens com máscaras de vários tamanhos.

Os efeitos da suavização como uma função do tamanho do filtro são ilustrados na Figura 3.33, que apresenta uma imagem original e os resultados suavizados correspondentes obtidos com a utilização de filtros de média quadrados de tamanhos $m$ = 3, 5, 9, 15 e 35 pixels, respectivamente. As principais características desses resultados são: para $m$ = 3, observamos um ligeiro borramento em toda a imagem, mas, como esperado, os detalhes que são aproximadamente do mesmo tamanho que a máscara são consideravelmente mais afetados. Por exemplo, os quadrados pretos 3 × 3 e 5 × 5 na parte superior da imagem, a pequena letra "a" e o ruído granulado fino mostram um borramento significativo em comparação com o restante da imagem. Observe que o ruído é menos acentuado e os contornos irregulares dos caracteres foram agradavelmente suavizados.

O resultado para $m$ = 5 é de certa forma similar, com um ligeiro aumento do borramento. Para $m$ = 9, vemos consideravelmente mais borramento, e o círculo 20% preto não é tão distinguível do fundo da imagem quanto nas três imagens anteriores, ilustrando o efeito de mesclagem que o borramento tem sobre objetos cujas intensidades se aproximam das intensidades dos pixels vizinhos. Observe a significativa suavização adicional dos retângulos com ruído. Os resultados para $m$ = 15 e 35 são extremos no que diz respeito às dimensões dos objetos da imagem. Esse tipo de borramento agressivo geralmente é utilizado para eliminar pequenos objetos de uma imagem. Por exemplo, os três quadrados pequenos, dois dos círculos e a maioria das áreas retangulares com ruído foram mesclados ao fundo da imagem na Figura 3.33(f). Observe também nessa figura a borda preta acentuada. Esse é um resultado do preenchimento da borda da imagem original com 0s (preto) e o recorte da área preenchida após a filtragem. Parte do preto foi misturada em todas as imagens filtradas, mas o efeito só ficou realmente inaceitável nas imagens suavizadas com os filtros maiores.

■

a

$$\frac{1}{9} \times \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

b

$$\frac{1}{16} \times \begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{bmatrix}$$

**Figura 3.32** Duas máscaras 3 × 3 (de média) para suavização. A constante de multiplicação diante de cada máscara é igual a 1 dividido pela soma dos valores de seus coeficientes, o que é necessário para calcular uma média.

Como já mencionamos, uma importante aplicação da média espacial consiste em borrar uma imagem para obter uma representação mais geral dos objetos de interesse, já que a intensidade dos objetos menores se mistura ao fundo, e os objetos maiores se tornam "borrões", que são mais fáceis de serem detectados. O tamanho da máscara define o tamanho relativo dos objetos que serão mesclados ao fundo. A título de exemplo, vejamos a Figura 3.34(a), que é uma imagem gerada pelo telescópio Hubble em órbita ao redor da Terra. A Figura 3.34(b) mostra o resultado da aplicação de um filtro de média 15 × 15 a essa imagem. Vemos que vários objetos foram mesclados ao fundo ou tiveram a intensidade consideravelmente reduzida. É comum uma operação como essa ser seguida da limiarização para eliminar objetos com base em sua intensidade. O resultado da utilização da função de limiarização da Figura 3.2(b) com um valor de limiar igual a 25% da maior intensidade da imagem borrada é mostrado na Figura 3.34(c). Comparando esse resultado à imagem original, vemos que ele é uma representação razoável do que consideraríamos os maiores e mais claros objetos da imagem.

### 3.5.2 Filtros de estatística de ordem (não lineares)

Os filtros de estatística de ordem são filtros espaciais não lineares cuja resposta se baseia na ordenação (classificação) dos pixels contidos na área da imagem coberta pelo filtro e substituindo o valor do pixel central pelo valor determinado pelo resultado da classificação. O filtro mais conhecido dessa categoria é o *filtro de mediana*, o qual, como o nome sugere, substitui o valor de um pixel pela mediana dos valores de intensidade na vizinhança desse pixel (o valor original do pixel é incluído no cálculo da mediana). Os filtros de mediana são bastante populares, porque, para certos tipos de ruído aleatório, proporcionam excelentes resultados na redução de ruído, com borramento consideravelmente menor do que filtros lineares de suavização de tamanho similar. Os filtros de mediana são particularmente eficazes na presença de ruído implusivo, também chamado de *ruído sal e pimenta*, em razão de sua aparência, como pontos brancos e pretos sobrepostos em uma imagem.

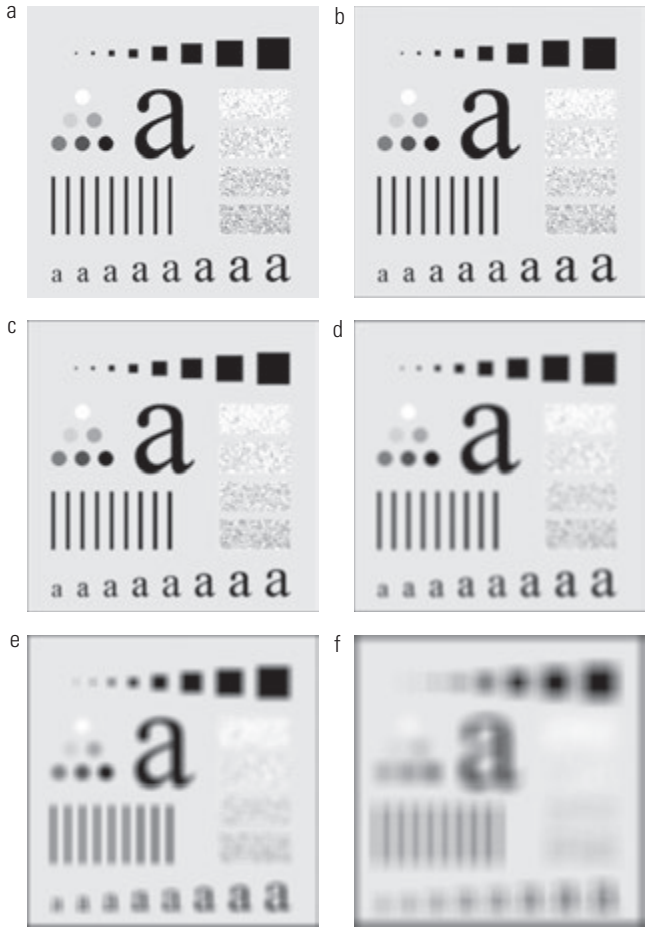



**Figura 3.33** (a) Imagem original de 500 × 500 pixels. (b) a (f) Resultados da suavização com filtros de média, quadrados, de tamanhos $m$ = 3, 5, 9, 15 e 35, respectivamente. Os quadrados pretos no alto das imagens têm tamanhos 3, 5, 9, 15, 25, 35, 45 e 55 pixels, respectivamente; suas bordas estão distantes 25 pixels umas das outras. O tamanho das letras na parte inferior varia de 10 a 24 pontos, em incrementos de 2 pontos; a letra maior na parte superior tem 60 pontos. As barras verticais têm 5 pixels de largura e 100 pixels de altura; sua separação é de 20 pixels. O diâmetro dos círculos é de 25 pixels e suas bordas estão distantes 15 pixels; seus níveis de intensidade variam de 0% a 100% de preto em incrementos de 20%. O fundo da imagem é 10% preto. Os retângulos com ruído têm 50 × 120 pixels.

A mediana, $\xi$, de um conjunto de valores é tal que metade dos valores do conjunto é menor ou igual a $\xi$, e a outra metade é maior ou igual a $\xi$. Para realizar a filtragem por mediana em um ponto de uma imagem, primeiro ordenamos os valores dos pixels da vizinhança, calculamos sua mediana e atribuímos esse valor ao pixel correspondente na imagem filtrada. Por exemplo, em uma vizinhança 3 × 3, a mediana é o quinto maior valor, em uma vizinhança 5 × 5, é o 13º valor, e assim por diante. Quando vários valores de uma vizinhança são iguais, todos os valores iguais são agrupados. Por exemplo, suponha que uma vizinhança 3 × 3 tenha valores (10, 20, 20, 20, 15, 20, 20, 25, 100). Esses valores são ordenados como (10, 15, 20, 20, 20, 20, 20, 25, 100), o que resulta em uma mediana igual a 20. Dessa forma, a principal função dos filtros de mediana é forçar pontos com níveis de intensidade distintos para serem mais semelhantes aos seus vizinhos. De fato, agrupamentos isolados de pixels que são claros ou escuros em relação aos seus vizinhos, e cuja área é menor que $m^2/2$ (metade da área do filtro), são eliminados por um filtro de mediana $m \times m$. Neste caso, "eliminado" significa forçado a receber a intensidade mediana dos vizinhos. Grandes agrupamentos são consideravelmente menos afetados.

Apesar de o filtro de mediana definitivamente ser o filtro de estatística de ordem mais útil no processamento de imagens, ele não é o único. A mediana representa o 50º percentil de um conjunto de valores ordenados, mas devemos lembrar, com base nos fundamentos da estatística, que a ordenação tem muitas outras possibilidades.* Por exemplo, utilizar o 100º percentil resulta no chamado *filtro máx*, útil para identificar os pontos mais claros de uma imagem. A resposta de um filtro máx 3 × 3 é dada por $R = \text{máx}\{z_k | k = 1, 2, ..., 9\}$ O filtro de 0º percentil é o *filtro mín*, utilizado para fazer o oposto. Os filtros de mediana, *máx*, *mín* e vários outros filtros não lineares serão analisados em mais detalhes na Seção 5.3.

■

**Exemplo 3.14** Utilização da filtragem de mediana para a redução de ruído.

A Figura 3.35(a) mostra uma imagem de raios X de uma placa de circuito fortemente corrompida pelo ruído sal e pimenta. Para ilustrar a questão da superioridade da filtragem de mediana sobre a filtragem de média em situações como essas, mostraremos, na Figura 3.35(b), o resultado do processamento da imagem com ruído pelo filtro de média 3 × 3 e, na Figura 3.35(c), o resultado da utilização de um filtro de mediana 3 × 3. O filtro de média borrou a imagem e seu desempenho na redução do ruído foi baixo. A superioridade da filtragem de mediana sobre a filtragem de média é evidente em todos os aspectos. Em geral, a filtragem de mediana é muito mais adequada do que a filtragem de média para a remoção do ruído sal e pimenta.

■

## 3.6 Filtros espaciais de aguçamento

O principal objetivo do aguçamento é salientar transições de intensidade para o aumento da nitidez de uma imagem. As utilizações do aguçamento de imagens são

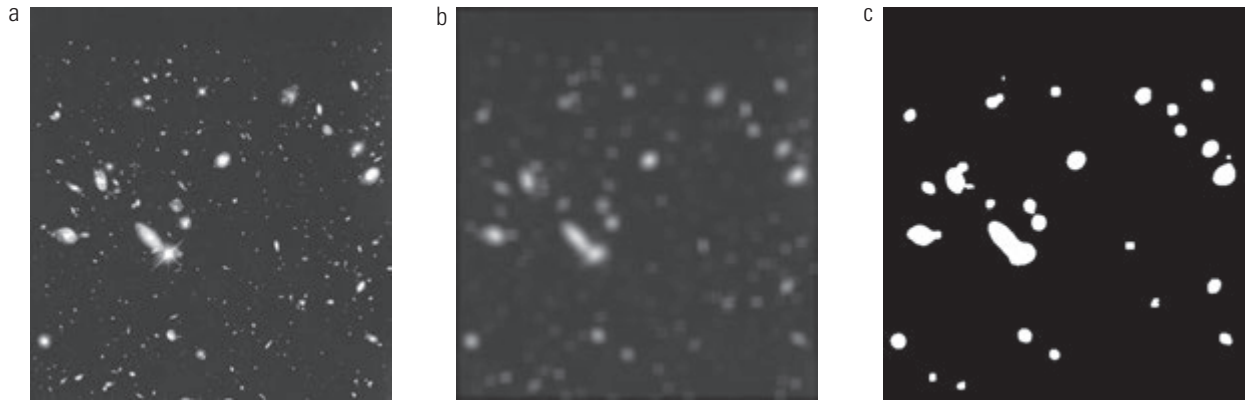



**Figura 3.34** (a) Imagem de 528 × 485 pixels obtida com o telescópio espacial Hubble. (b) Imagem filtrada com um filtro de média de tamanho 15 × 15. (c) Resultado da limiarização de (b). (Imagem original: cortesia da Nasa.)

variadas e incluem aplicações como impressão eletrônica, imagens médicas, inspeção industrial e navegação autônoma em sistemas militares. Na última seção, vimos que o borramento de imagens poderia ser realizado no domínio do espaço pela média dos pixels em uma vizinhança. Como o cálculo da média é análogo à integração, é lógico concluir que o aguçamento pode ser realizado pela diferenciação no domínio do espaço. Este de fato é o caso, e a análise desta seção lida com as várias formas de definir e implementar operadores para o aguçamento por diferenciação digital. Fundamentalmente, a força da resposta de um operador derivativo é proporcional ao nível de descontinuidade da intensidade da imagem no ponto no qual o operador é aplicado. Dessa forma, a diferenciação de uma imagem realça as bordas e outras descontinuidades (como o ruído) e atenua as áreas com intensidades de variação mais suave.

### 3.6.1 Fundamentos

Nas duas seções seguintes, analisaremos em detalhes os filtros de aguçamento baseados em derivadas de primeira e segunda ordem, respectivamente. Antes de prosseguir com esta discussão, contudo, vamos parar para examinar algumas propriedades fundamentais dessas derivadas no contexto digital. Para simplificar a explicação, nos concentraremos inicialmente nas derivadas unidimensionais. Em particular, estamos interessados no comportamento dessas derivadas nas áreas de intensidade constante, no início e no final de descontinuidades (descontinuidades de degrau e rampa) e ao longo de rampas de intensidade. Como veremos no Capítulo 10, esses tipos de descontinuidades podem ser utilizados para modelar pontos de ruído, linhas e bordas em uma imagem. O comportamento das derivadas durante transições para essas características de imagem e a partir dessas características também é de interesse.

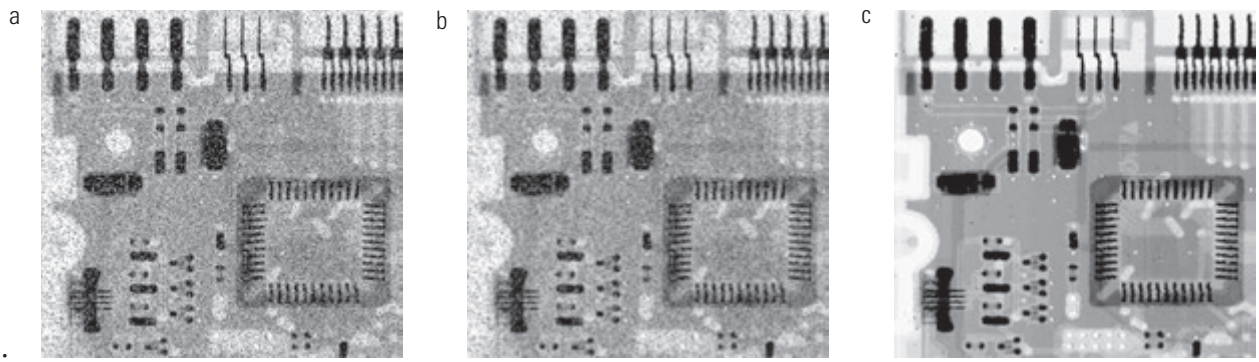



**Figura 3.35** (a) Imagem de raios X de uma placa de circuito corrompida pelo ruído sal e pimenta. (b) Redução de ruído com um filtro de média 3 × 3. (c) Redução de ruído com um filtro de mediana 3 × 3. (Imagem original: cortesia do Sr. Joseph E. Pascente, Lixi, Inc.)

* Veja a Seção 10.3.5 sobre os percentis.

As derivadas de uma função digital são definidas em termos de diferenças. Há várias maneiras de defini-las. No entanto, é preciso que qualquer definição utilizada para a *primeira derivada* (1) seja zero em áreas de intensidade constante; (2) seja diferente de zero no início de um degrau ou rampa de intensidade; e (3) seja diferente de zero ao longo das rampas. De forma similar, qualquer definição de uma *segunda derivada* (1) deve ser zero em áreas constantes; (2) deve ser diferente de zero no início *e* no final de um degrau ou rampa de intensidade; e (3) deve ser zero ao longo de rampas de inclinação constante. Como estamos lidando com quantidades digitais cujos valores são finitos, a máxima variação possível de intensidade também é finita e a distância mais curta na qual essa mudança pode ocorrer é a distância entre pixels adjacentes.

Uma definição básica da derivada de primeira ordem de uma função unidimensional $f(x)$ é a diferença:*

$$\frac{\partial f}{\partial x} = f\left(x+1\right) - f\left(x\right) \qquad (3.6\text{-}1)$$

Utilizamos uma derivada parcial para manter a mesma notação quando considerarmos uma imagem como uma função de duas variáveis, $f(x, y)$, ocasião na qual estaremos lidando com derivadas parciais ao longo dos dois eixos espaciais. A utilização de uma derivada parcial na presente discussão não afeta de forma alguma a natureza do nosso objetivo. Certamente, $\partial f / \partial x = df / dx$ quando houver apenas uma variável na função; o mesmo se aplica à segunda derivada.

Definimos a derivada de segunda ordem de $f(x)$ como a diferença:

$$\frac{\partial^2 f}{\partial x^2} = f\left(x+1\right) + f\left(x-1\right) - 2f\left(x\right) \qquad (3.6\text{-}2)$$

É fácil verificar que essas duas definições satisfazem as condições mencionadas. Para ilustrar isso, e para analisar as semelhanças e diferenças entre as derivadas de primeira e segunda ordem de uma função digital, vejamos o exemplo da Figura 3.36.

A Figura 3.36(b) (centro da figura) mostra uma seção de uma linha de varredura (perfil de intensidade). Os valores dentro dos pequenos quadrados são de intensidade na linha de varredura, que são plotados acima deles como pontos pretos na Figura 3.36(a). A linha tracejada que liga os pontos foi incluída para facilitar a visualização. Como mostra a figura, a linha de varredura contém uma rampa de intensidade, três seções de intensidade constante e um degrau de intensidade. Os círculos indicam o início ou o fim de transições de intensidade. As derivadas de primeira e segunda ordem calculadas com a utilização das duas definições anteriores são incluídas abaixo da linha de varredura na Figura 3.36(b), e são plotadas na Figura 3.36(c). Ao calcular a primeira derivada na posição $x$, subtraímos o valor da função nessa posição do valor do próximo ponto. Dessa maneira, trata-se de uma operação de "olhar adiante". De maneira similar, para calcular a segunda derivada em $x$, utilizamos os pontos anterior e seguinte no cálculo. Para evitar uma situação na qual o ponto anterior ou seguinte estejam fora do alcance da linha de varredura, mostraremos os cálculos de derivadas na Figura 3.36 a partir do segundo até o penúltimo ponto na sequência.

Vamos considerar as propriedades da primeira e da segunda derivada à medida que percorremos o perfil da esquerda para a direita. Em primeiro lugar, encontramos uma área de intensidade constante e, como mostram as Figuras 3.36(b) e (c), as duas derivadas são zero, de modo que a condição (1) é satisfeita para ambas. Em seguida, encontramos uma rampa de intensidade seguida de um degrau e notamos que a derivada de primeira ordem é diferente de zero no início da rampa e no início do degrau; de forma similar, a segunda derivada é diferente de zero no início *e* no final, tanto da rampa quanto do degrau; assim, a propriedade (2) é satisfeita para as duas derivadas. Por fim, verificamos que a propriedade (3) também é satisfeita para as duas derivadas porque a primeira derivada é diferente de zero, e a segunda é zero ao longo da rampa. Observe que o sinal da segunda derivada muda no início e no final de um degrau ou de uma rampa. Com efeito, vemos na Figura 3.36(c) que, em uma transição de degrau, uma linha ligando esses dois valores cruza o eixo horizontal na metade do caminho entre os dois extremos. Essa propriedade de *cruzamento por zero* é bastante útil para localizar bordas, como veremos no Capítulo 10.

As bordas nas imagens digitais, muitas vezes, são transições parecidas com rampas em termos de intensidade, caso no qual a primeira derivada da imagem resultaria em bordas espessas pelo fato de a derivada ser diferente de zero ao longo de uma rampa. Por outro lado, a segunda derivada produziria uma dupla borda, com espessura de um pixel, separada por zeros. Com isso, concluímos que a segunda derivada realça muito mais os detalhes finos do que a primeira derivada, uma propriedade que é muito adequada para o aguçamento de imagens. Além disso,

* Retomaremos a Equação 3.6-1 na Seção 10.2.1 e mostraremos como ela resulta de uma expansão da série de Taylor. Por enquanto, essa será a definição aceita.

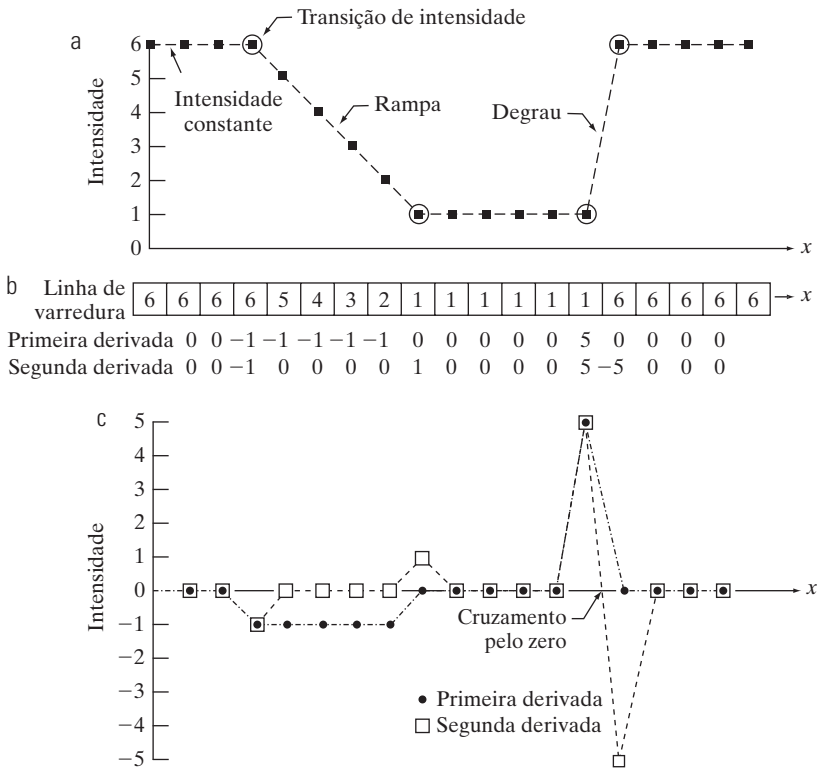



**Figura 3.36** Ilustração do primeiro e do segundo derivativo de uma função digital unidimensional representando uma seção de um perfil de intensidade horizontal de uma imagem. Em (a) e (c), os pontos de dados são ligados por linhas tracejadas para facilitar a visualização.

como veremos mais adiante nesta seção, os segundas derivadas são muito mais fáceis de implementar do que as primeiras derivadas, de forma que nos concentraremos inicialmente nas segundas derivadas.

### 3.6.2 Utilizando a segunda derivada para o aguçamento de imagens – o laplaciano

Nesta seção, analisaremos a implementação de derivadas bidimensionais de segunda ordem e sua utilização para o aguçamento de imagens. Retomaremos essa derivada no Capítulo 10, onde a utilizaremos extensivamente para a segmentação de imagens. A metodologia consiste basicamente em definir uma fórmula discreta da derivada de segunda ordem e construir uma máscara de filtragem com base nessa formulação. Estamos interessados em filtros *isotrópicos*, cuja resposta independe da direção das descontinuidades da imagem à qual o filtro é aplicado. Em outras palavras, os filtros isotrópicos são *invariantes em rotação*, no sentido de que rotacionar a imagem e depois aplicar o filtro fornece o mesmo resultado que aplicar o filtro à imagem primeiro e depois rotacionar o resultado.

Pode ser demonstrado (Rosenfeld e Kak, 1982) que o operador derivativo isotrópico mais simples é o laplaciano, que, para uma função (imagem) $f(x, y)$ de duas variáveis, é definido como:

$$\nabla^2 f = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2} \tag{3.6-3}$$

Como as derivadas de qualquer ordem são operações lineares, o laplaciano é um operador linear. Para expressar essa equação na forma discreta, utilizamos a definição da Equação 3.6-2, tendo em mente que precisamos considerar uma segunda variável. Na direção $x$, temos

$$\frac{\partial^2 f}{\partial x^2} = f(x+1, y) + f(x-1, y) - 2f(x, y) \tag{3.6-4}$$

e, de forma similar, na direção $y$, temos:

$$\frac{\partial^2 f}{\partial y^2} = f(x, y+1) + f(x, y-1) - 2f(x, y) \tag{3.6-5}$$

Dessa forma, segue-se, a partir das três equações anteriores, que o laplaciano discreto de duas variáveis é:

$$\nabla^2 f = f(x+1, y) + f(x-1, y) + f(x, y+1) + f(x, y-1) - 4f(x, y) \tag{3.6-6}$$

Essa equação pode ser implementada utilizando a máscara de filtragem da Figura 3.37(a), a qual gera um resultado isotrópico para rotações em incrementos de 90°.

a

| | | |
|---|---|---|
| 0 | 1 | 0 |
| 1 | −4 | 1 |
| 0 | 1 | 0 |

b

| | | |
|---|---|---|
| 1 | 1 | 1 |
| 1 | −8 | 1 |
| 1 | 1 | 1 |

c

| | | |
|---|---|---|
| 0 | −1 | 0 |
| −1 | 4 | −1 |
| 0 | −1 | 0 |

d

| | | |
|---|---|---|
| −1 | −1 | −1 |
| −1 | 8 | −1 |
| −1 | −1 | −1 |

**Figura 3.37** (a) Máscara de filtragem utilizada para implementar a Equação 3.6-6. (b) Máscara utilizada para implementar uma extensão dessa equação que inclui os termos diagonais. (c) e (d) Duas outras implementações do laplaciano frequentemente encontradas na prática.

O funcionamento da implementação é similar ao da Seção 3.5.1 para filtros lineares de suavização. Nós simplesmente estamos utilizando coeficientes diferentes aqui.

As direções diagonais podem ser incorporadas à definição do laplaciano digital com o acréscimo de mais dois termos à Equação 3.6-6, um para cada direção diagonal. A forma de cada novo termo é a mesma que a Equação 3.6-4 ou a Equação 3.6-5, mas as coordenadas estão ao longo das diagonais. Como cada termo de diagonal também contém um termo $-2f(x, y)$, o total subtraído dos termos da diferença agora seria $-8f(x, y)$. A Figura 3.37(b) mostra a máscara utilizada para implementar essa nova definição. Essa máscara gera resultados isotrópicos em incrementos de 45°. Você provavelmente verá na prática as máscaras laplacianas mostradas nas figuras 3.37(c) e (d). Elas são obtidas a partir das definições das segundas derivadas que são os negativos das derivadas utilizadas nas equações 3.6-4 e 3.6-5. Dessa forma, eles geram resultados equivalentes, mas a diferença do sinal deve ser levada em consideração ao combinar (pela soma ou subtração) uma imagem filtrada pelo laplaciano com outra imagem.

Como o laplaciano é um operador diferencial, sua utilização realça as descontinuidades de intensidade em uma imagem e atenua as regiões com níveis de intensidade de variação mais suave. Isso tenderá a produzir imagens nas quais as linhas de borda e outras descontinuidades aparecerão em tons de cinza sobrepostos a um fundo escuro e uniforme. As características do fundo podem ser "recuperadas" enquanto se preserva o efeito de aguçamento do laplaciano simplesmente adicionando a imagem laplaciana à original. Como observamos no parágrafo anterior, é importante levar em consideração qual definição de laplaciano está sendo utilizada. Se a definição em uso tiver um coeficiente de centro negativo, então *subtraímos*, em vez de adicionar, a imagem laplaciana para obter o resultado de aguçamento. Assim, a forma básica na qual utilizamos o laplaciano para o aguçamento de imagens é

$$g(x, y) = f(x, y) + c\left[\nabla^2 f(x, y)\right] \qquad (3.6\text{-}7)$$

onde $f(x, y)$ e $g(x, y)$ são as imagens de entrada e aguçada, respectivamente. A constante é $c = -1$ se os filtros laplacianos na Figura 3.37(a) ou (b) forem utilizados e $c = 1$ se qualquer um dos outros filtros for utilizado.

■

**Exemplo 3.15** Aguçamento de imagens utilizando o laplaciano.

A Figura 3.38(a) mostra uma imagem ligeiramente borrada do polo norte da Lua. A Figura 3.38(b) mostra o resultado da filtragem dessa imagem com a máscara laplaciana da Figura 3.37(a). Várias regiões dessa imagem são pretas porque o laplaciano contém valores tanto positivos quanto negativos, e todos os valores negativos são ajustados para 0 pelo sistema de exibição.

Uma forma típica de ajustar a escala de uma imagem laplaciana é somar seu valor mínimo a ela para levar o novo mínimo a zero e ajustar o resultado para o intervalo total de intensidade $[0, L - 1]$, como explicamos nas equações (2.6-10) e (2.6-11). A imagem da Figura 3.38(c) foi ajustada dessa forma. Observe que as características dominantes da imagem são as bordas e as descontinuidades acentuadas de intensidade. O fundo, antes preto, agora é cinza em razão do ajuste. A aparência acinzentada é típica de imagens laplacianas que foram adequadamente ajustadas. A Figura 3.38(d) mostra o resultado obtido utilizando a Equação 3.6-7 com $c = -1$. Os detalhes dessa imagem são evidentemente mais claros e nítidos do que na imagem original. Adicionar a imagem original à laplaciana restaurou as variações globais de intensidade da imagem, com o laplaciano aumentando o contraste nos pontos de descontinuidade de intensidade. O resultado final é uma imagem na qual pequenos detalhes foram realçados e a tonalidade do fundo foi razoavelmente preservada. Por fim, a Figura 3.38(e) mostra o resultado da repetição do procedimento anterior com o filtro na Figura 3.37(b). Aqui, notamos uma melhoria significativa em termos de aguçamento em relação à Figura 3.38(d). Isso não é inesperado porque utilizar o filtro da Figura 3.37(b) proporciona uma diferenciação adicional (aguçamento) nas

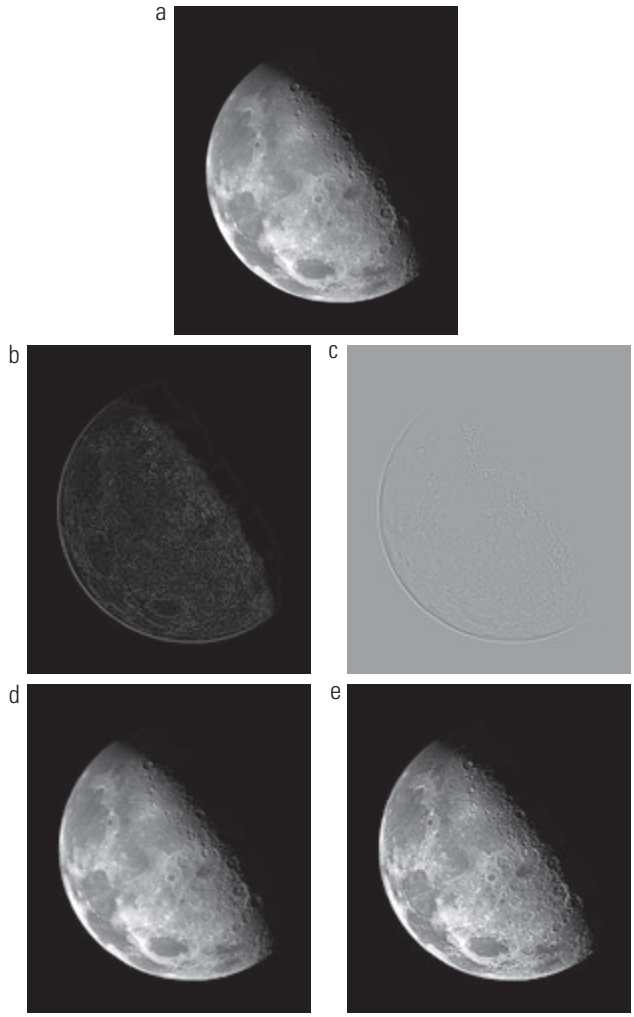



**Figura 3.38** (a) Imagem borrada do polo norte da Lua. (b) Laplaciano sem ajuste. (c) Laplaciano com ajuste. (d) Imagem aguçada utilizando a máscara da Figura 3.37(a). (e) Resultado da utilização da máscara da Figura 3.37(b). (Imagem original: cortesia da Nasa.)

direções diagonais. Resultados como os das figuras 3.38(d) e (e) têm feito do laplaciano uma das ferramentas preferidas para o aguçamento de imagens digitais.

■

### 3.6.3 Máscara de nitidez e filtragem *high-boost*

Um processo que tem sido utilizado por muitos anos pela indústria gráfica e de publicações para aumentar a nitidez de imagens (aguçamento) consiste em subtrair uma versão não nítida (suavizada) de uma imagem da imagem original. Esse processo, chamado de *máscara de nitidez* (*unsharp masking*), consiste nos seguintes passos:

1. Borrar a imagem original.
2. Subtrair a imagem borrada da original (a diferença resultante é chamada de *máscara*.)
3. Adicionar a máscara à imagem original.

Com $\overline{f}(x, y)$ denotando a imagem borrada, a máscara de nitidez é expressa na forma de equação como segue. Em primeiro lugar, obtemos a máscara:

$$g_{\text{máscara}}(x,y) = f(x,y) - \overline{f}(x,y) \qquad (3.6\text{-}8)$$

Depois, adicionamos uma porção ponderada da máscara de volta à imagem original:

$$g(x,y) = f(x,y) + k * g_{\text{máscara}}(x,y) \qquad (3.6\text{-}9)$$

onde incluímos um peso, $k (k \geq 0)$, para generalização. Quando $k = 1$, temos a máscara de nitidez, como definido anteriormente. Quando $k > 1$, o processo é chamado de *filtragem high-boost* (ou filtragem "alto-reforço"). Escolher $k < 1$ atenua a contribuição da máscara de nitidez.

A Figura 3.39 explica como a máscara de nitidez funciona. O perfil de intensidade da Figura 3.39(a) pode ser interpretado como uma linha de varredura horizontal que atravessa uma borda vertical que faz a transição de uma região escura a uma clara em uma imagem. A Figura 3.39(b) mostra o resultado da suavização, sobreposta ao sinal original (tracejado). A Figura 3.39(c) é a máscara de nitidez, obtida subtraindo o sinal borrado do original. Ao comparar esse resultado com a seção da Figura 3.36(c) que corresponde à rampa da Figura 3.36(a), observamos que a máscara de nitidez da Figura 3.39(c) é muito similar à que obteríamos utilizando uma derivada de segunda ordem. A Figura 3.39(d) é o resultado final realçado pelo

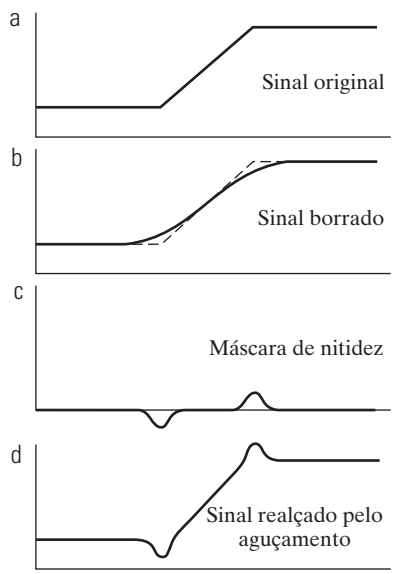



**Figura 3.39** Ilustração unidimensional do funcionamento da máscara de nitidez. (a) Sinal original. (b) Sinal borrado com o original tracejado para referência. (c) Máscara de nitidez. (d) Sinal realçado pelo aguçamento obtido pelo acréscimo de (c) a (a).

aguçamento, que foi obtido somando-se a máscara ao sinal original. Os pontos nos quais ocorrem uma mudança de inclinação da intensidade no sinal agora são enfatizados (aguçados). Observe que valores negativos foram adicionados ao sinal original. Assim, é possível que o resultado final tenha intensidades negativas se a imagem original tiver valores zero ou se o valor escolhido de $k$ for muito alto, o suficiente para que os picos da máscara sejam enfatizados a um nível mais alto que o valor mínimo da imagem original. Os valores negativos podem gerar uma auréola (halo) escura ao redor das bordas, o que, se $k$ for suficientemente alto, pode produzir resultados indesejáveis.

■

**Exemplo 3.16** Aguçamento de imagens utilizando a máscara de nitidez.

A Figura 3.40(a) mostra uma imagem ligeiramente borrada de um texto branco sobre um fundo cinza-escuro. A Figura 3.40(b) foi obtida utilizando um filtro de suavização do tipo gaussiano (veja a Seção 3.4.4) de dimensões 5 × 5 com $\sigma = 3$. A Figura 3.40(c) é a máscara de nitidez, obtida com a Equação 3.6-8. A Figura 3.40(d) foi obtida utilizando a máscara de nitidez (Equação 3.6-9 com $k = 1$). Essa imagem apresenta uma ligeira melhora em relação à original, mas é possível melhorar ainda mais. A Figura 3.40(e) mostra o resultado da utilização da Equação (3.6-9) com $k = 4{,}5$, o maior valor possível que poderíamos utilizar para manter todos os valores no resultado final positivos. A melhora dessa imagem em relação à original é significativa.

■

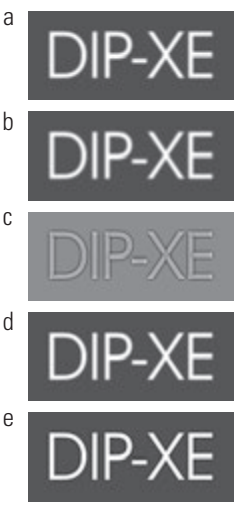



**Figura 3.40** (a) Imagem original. (b) Resultado do borramento com um filtro gaussiano. (c) Máscara de nitidez. (d) Resultado da utilização de uma máscara de nitidez. (e) Resultado da filtragem *high-boost*.

### 3.6.4 Utilização de derivadas de primeira ordem para o aguçamento (não linear) de imagens – o gradiente

As derivadas de primeira ordem em processamento de imagens são implementadas utilizando a magnitude do gradiente. Para uma função $f(x, y)$, o gradiente de $f$ nas coordenadas $(x, y)$ é definido como o *vetor* coluna bidimensional:*

$$\nabla f \equiv \text{grad}(f) \equiv \begin{bmatrix} g_x \\ g_y \end{bmatrix} = \begin{bmatrix} \dfrac{\partial f}{\partial x} \\ \dfrac{\partial f}{\partial y} \end{bmatrix} \tag{3.6-10}$$

Esse vetor tem a importante propriedade geométrica de apontar na direção da maior taxa de variação de $f$ na posição $(x, y)$.

O *módulo* ou *magnitude* (*tamanho*) do vetor $\nabla f$ é expresso como $M(x, y)$, sendo que:

$$M(x, y) = \text{mag}(\nabla f) = \sqrt{g_x^2 + g_y^2} \tag{3.6-11}$$

é o *valor* em $(x, y)$ da taxa de variação na direção do vetor gradiente. Observe que $M(x, y)$ é uma imagem do mesmo tamanho que a original, criada quando $x$ e $y$ podem variar ao longo de todas as posições de pixels em $f$. É comum referir-se a essa imagem como a *imagem gradiente* (ou apenas *gradiente* quando o significado é claro).

Como os componentes do vetor gradiente são derivadas, eles são operadores lineares. No entanto, a magnitude desse vetor não é linear, em virtude das operações de potência e raiz quadrada. Por outro lado, as derivadas parciais da Equação 3.6-10 não são invariantes em rotação (isotrópicas), mas a magnitude do vetor gradiente é. Em algumas implementações, é mais adequado computacionalmente aproximar as operações de potência e raiz quadrada para valores absolutos:

$$M(x, y) \approx |g_x| + |g_y| \tag{3.6-12}$$

Essa expressão ainda preserva as mudanças relativas na intensidade, mas a propriedade isotrópica é, em geral, perdida. No entanto, como no caso do laplaciano, as propriedades isotrópicas do gradiente discreto definido no próximo parágrafo são preservadas somente para um número limitado de incrementos de rotação que dependem das máscaras de filtragem aplicadas para aproximar as derivadas. As máscaras mais populares utilizadas como uma aproximação do gradiente são isotrópicas em múlti-

* Discutiremos o gradiente com mais detalhes na Seção 10.2.5. Aqui, estamos interessados apenas na utilização da magnitude do gradiente para o aguçamento de imagens.

plos de 90°. Esses resultados independem de utilizarmos a Equação 3.6-11 ou a Equação 3.6-12, de forma que nada significativo é perdido utilizando a última equação se optarmos por isso.

Como no caso do laplaciano, agora definiremos aproximações discretas para as equações anteriores e, a partir daí, formularemos as máscaras de filtragem apropriadas. Para simplificar a discussão que se segue, utilizaremos a notação da Figura 3.41(a) para indicar as intensidades dos pontos da imagem em uma região 3 × 3. Por exemplo, o ponto central, $z_5$, expressa $f(x, y)$ em uma posição arbitrária, $(x, y)$; $z_1$ expressa $f(x - 1, y - 1)$ e assim por diante, utilizando a notação apresentada na Figura 3.28. Como mostrado na Seção 3.6.1, as aproximações mais simples de uma derivada de primeira ordem que satisfaz as condições definidas nessa seção são $g_x = (z_8 - z_5)$ e $g_y = (z_6 - z_5)$. Duas outras definições propostas por Roberts (1965) no início do desenvolvimento do processamento digital de imagens utilizam diferenças diagonais:

$$g_x = (z_9 - z_5) \quad \text{e} \quad g_y = (z_8 - z_6) \tag{3.6-13}$$

Se utilizarmos as equações 3.6-11 e 3.6-13, calcularemos a imagem gradiente como:

$$M(x, y) = \left[(z_9 - z_5)^2 + (z_8 - z_6)^2\right]^{1/2} \tag{3.6-14}$$

Se utilizarmos as equações (3.6-12) e (3.6-13), então:

$$M(x, y) \approx |z_9 - z_5| + |z_8 - z_6| \tag{3.6-15}$$

onde se entende que $x$ e $y$ variam ao longo da imagem, como já descrito anteriormente. Os termos das derivadas parciais necessários na Equação 3.6-13 podem ser implementados utilizando as duas máscaras lineares das figuras 3.41(b) e (c). Essas máscaras são chamadas de *operadores gradientes diagonais de Roberts*.

As máscaras de tamanhos pares são mais difíceis de implementar por não terem um centro de simetria. As menores máscaras nas quais estamos interessados são de dimensões 3 × 3. As aproximações para $g_x$ e $g_y$ utilizando uma vizinhança 3 × 3 centrada em $z_5$ são:

$$g_x = \frac{\partial f}{\partial x} = (z_7 + 2z_8 + z_9) - (z_1 + 2z_2 + z_3) \tag{3.6-16}$$

e

$$g_y = \frac{\partial f}{\partial y} = (z_3 + 2z_6 + z_9) - (z_1 + 2z_4 + z_7) \tag{3.6-17}$$

Essas equações podem ser implementadas utilizando as máscaras das figuras 3.41(d) e (e). A diferença entre a terceira e a primeira linha da região da imagem 3 × 3 implementada pela máscara da Figura 3.41(d) aproxima a derivada parcial na direção $x$, e a diferença entre a terceira e a primeira coluna na outra máscara aproxima a derivada na direção $y$. Depois de calcular as derivadas parciais com essas máscaras, obtemos a magnitude do gradiente como antes. Por exemplo, substituir $g_x$ e $g_y$ na Equação 3.6-12 resulta em

$$M(x, y) \approx |(z_7 + 2z_8 + z_9) - (z_1 + 2z_2 + z_3)| + |(z_3 + 2z_6 + z_9) - (z_1 + 2z_4 + z_7)| \tag{3.6-18}$$

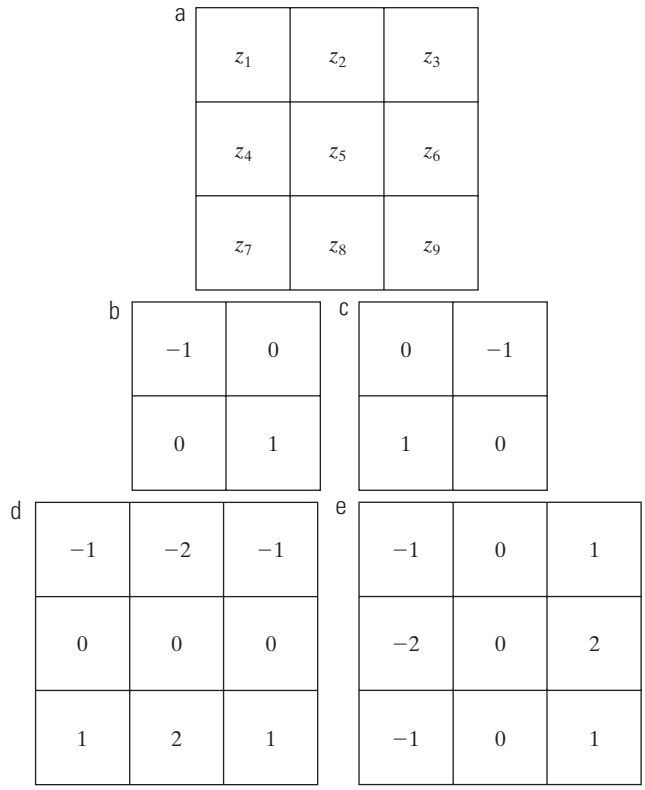



**Figura 3.41** (a) Região 3 × 3 de uma imagem ($z$ são valores de intensidade). (b) a (c) Operadores gradientes diagonais de Roberts. (d) a (e) Operadores de Sobel. Somando todos os coeficientes da máscara o resultado é zero, como se espera de um operador derivativo.

As máscaras das figuras 3.41(d) e (e) são chamadas de *operadores de Sobel*. O objetivo da utilização do valor 2 no coeficiente central é atingir alguma suavização atribuindo mais importância ao ponto central (discutiremos esse conceito em mais detalhes no Capítulo 10). Observe que a soma dos coeficientes de todas as máscaras mostradas na Figura 3.41 resulta em 0, indicando que eles geram uma resposta 0 em áreas de intensidade constante, como esperado para um operador derivativo.

Como mencionamos anteriormente, os cálculos de $g_x$ e $g_y$ são operações lineares pois envolvem derivadas e, dessa forma, podem ser implementadas como uma soma de produtos utilizando as máscaras espaciais da Figura 3.41. O aspecto não linear do aguçamento com o gradiente é o cálculo de $M(x, y)$ envolvendo operações de potência e de raiz quadrada, ou a utilização de valores absolutos, todas operações não lineares. Essas operações são realizadas *depois* do processo linear que calcula $g_x$ e $g_y$.

■

**Exemplo 3.17** Utilização de gradiente para realce de borda.

O gradiente é frequentemente utilizado em processos de inspeção industrial, para ajudar as pessoas na detecção de defeitos ou, o mais comum, como uma etapa de pré-processamento na inspeção automatizada. Teremos mais a dizer a respeito nos capítulos 10 e 11. No entanto, será útil neste ponto analisaremos um exemplo simples para mostrar como o gradiente pode ser utilizado para realçar defeitos e eliminar características de fundo com transição suave. Neste exemplo, o realce é utilizado como uma etapa de pré-processamento para a inspeção automatizada, e não para a análise humana.

A Figura 3.42(a) mostra uma imagem ótica de uma lente de contato, iluminada por um arranjo de luz elaborado para salientar imperfeições, como os dois defeitos de borda no contorno da lente vistos nas posições de 4 e 5 horas. A Figura 3.42(b) mostra o gradiente obtido utilizando a Equação 3.6-12 com as duas máscaras de Sobel das figuras 3.41(d) e (e). Os defeitos da borda também são bastante visíveis nessa imagem, mas com a vantagem adicional de os tons de cinza constantes ou com transição suave terem sido eliminados, simplificando consideravelmente os cálculos necessários para a inspeção automatizada. O gradiente também pode ser utilizado para enfatizar pequenos espículos que podem não ser imediatamente visíveis em uma imagem na escala de cinza (esses pontos podem representar elementos estranhos, bolsas de ar em uma solução líquida ou minúsculas imperfeições da lente). A capacidade de realçar pequenas descontinuidades em uma área cinza uniforme representa outra importante característica do gradiente.

■

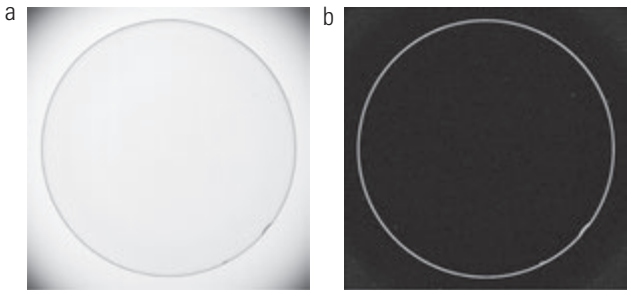



**Figura 3.42** (a) Imagem ótica de uma lente de contato (observe os defeitos de contorno nas posições de 4 e 5 horas). (b) Gradiente de Sobel. (Imagem original: cortesia de Pete Sites, Perceptics Corporation.)

## 3.7 Combinando métodos de realce espacial

Com algumas poucas exceções, como a combinação de suavização com limiarização (Figura 3.34), nos concentramos até agora em métodos individuais. Frequentemente, uma dada tarefa demandará a aplicação de várias técnicas complementares para atingir um resultado aceitável. Nesta seção, ilustraremos um exemplo de como a combinação de várias metodologias desenvolvidas até agora neste capítulo pode realizar uma difícil tarefa de realce de imagem.

A imagem da Figura 3.43(a) mostra uma varredura nuclear óssea de corpo inteiro, utilizada para detectar doenças como infecções ósseas e tumores. Nosso objetivo é realçar essa imagem aumentando sua nitidez (aguçamento) e salientando os detalhes do esqueleto. A faixa dinâmica estreita dos níveis de intensidade e o grande conteúdo de ruído fazem com que essa imagem seja difícil de ser realçada. A estratégia que seguiremos consiste em utilizar o laplaciano para salientar os detalhes finos e o gradiente para realçar as bordas proeminentes. Por razões que explicaremos em breve, uma versão suavizada da imagem do gradiente será aplicada para mascarar a imagem laplaciana (veja a Figura 2.30 em relação ao mascaramento). Por fim, tentaremos ampliar a faixa dinâmica dos níveis de intensidade utilizando uma transformação de intensidade.

A Figura 3.43(b) mostra o laplaciano da imagem original obtido com a utilização do filtro da Figura 3.37(d). Essa imagem foi ajustada (somente para a exibição) utilizando a mesma técnica que na Figura 3.38(c). Podemos obter uma imagem realçada, em um primeiro momento, simplesmente adicionando as figuras 3.43(a) e (b), de acordo com a Equação 3.6-7. Só de olhar o nível de ruído da Figura 3.43(b), esperaríamos uma imagem realçada com bastante ruído adicionando as figuras 3.43(a) e (b), um fato confirmado pelo resultado na Figura 3.43(c). Uma ideia que imediatamente nos ocorre para reduzir o ruído é utilizar um filtro de mediana. No entanto, a filtragem de mediana é um processo não linear que pode eliminar caraterísticas importantes da imagem, o que é inaceitável no processamento de imagens médicas.

Uma abordagem alternativa baseia-se em utilizar uma máscara formada a partir de uma versão suavizada do gradiente da imagem original. A razão por trás dessa escolha é direta e está calcada nas propriedades das derivadas de primeira e segunda ordem explicadas na Seção

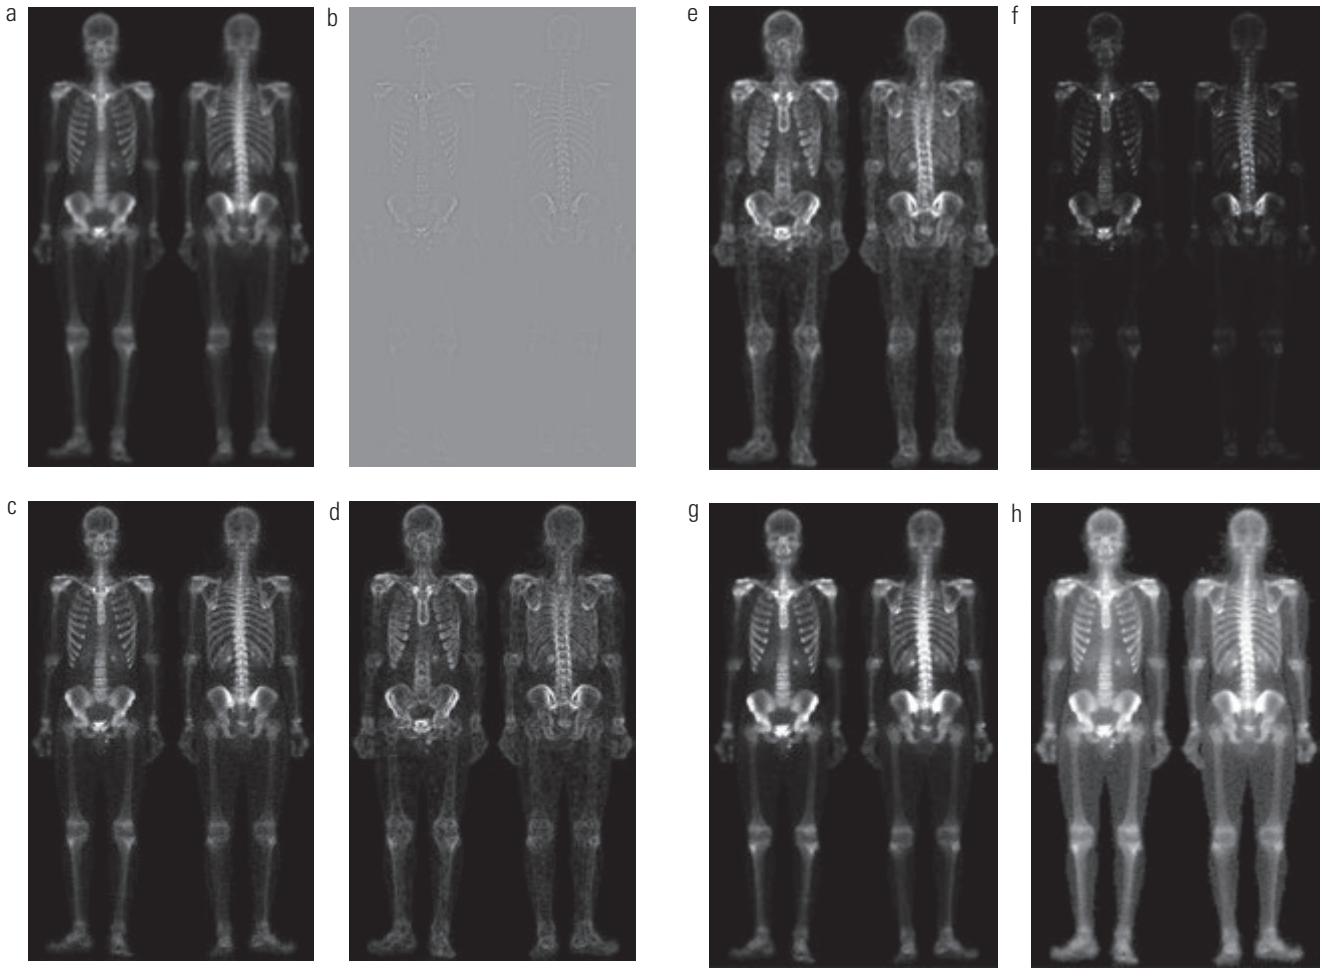



**Figura 3.43** (a) Imagem de varredura óssea de corpo inteiro. (b) Laplaciano de (a). (c) Imagem após o aguçamento, obtida adicionando (a) e (b). (d) Gradiente de Sobel de (a). (e) Imagem de Sobel suavizada com um filtro de média 5 × 5. (f) Imagem de máscara formada pelo produto de (c) e (e). (g) Imagem realçada, obtida pela soma de (a) e (f). (h) Resultado final obtido pela aplicação da transformação de potência em (g). Compare (g) e (h) com (a). (Imagem original: cortesia da G.E. Medical Systems.)

3.6.1. O laplaciano, por ser um operador de derivada de segunda ordem, tem a grande vantagem de ser mais eficaz para realçar detalhes finos. Contudo, isso faz com que produza resultados com mais ruído do que o gradiente. O ruído é mais indesejado em áreas suaves, onde tende a ser mais visível. O gradiente tem uma resposta média mais poderosa em áreas de transições significativas de intensidade (rampas e degraus) em comparação ao laplaciano. A resposta do gradiente ao ruído e detalhes finos é mais baixa do que a do laplaciano e pode ser reduzida ainda mais pela suavização do gradiente com um filtro de média. A ideia, então, é suavizar o gradiente e multiplicá-lo pela imagem laplaciana. Nesse contexto, podemos considerar o gradiente suavizado como uma imagem de máscara. O produto preservará os detalhes nas áreas de transição acentuada enquanto reduzirá o ruído nas áreas relativamente uniformes. Esse processo pode ser interpretado de forma generalizada como a combinação dos melhores recursos do laplaciano e do gradiente. O resultado é adicionado à imagem original para obter uma imagem final realçada.

A Figura 3.43(d) mostra o gradiente de Sobel da imagem original, calculado com a Equação 3.6-12. Os componentes $g_x$ e $g_y$ foram obtidos utilizando as máscaras das figuras 3.41(d) e (e), respectivamente. Como esperávamos, as bordas são muito mais acentuadas nessa imagem do que na imagem laplaciana. A imagem suavizada do gradiente na Figura 3.43(e) foi obtida utilizando um filtro de média 5 × 5. As duas imagens gradiente foram ajustadas para exibição da mesma forma como a imagem laplaciana. Pelo fato de que o menor valor possível em uma imagem gradiente é 0, o fundo nas imagens ajustadas do gradiente é preto, em vez de cinza, como no laplaciano ajustado. O fato de as figuras 3.43(d) e (e) serem muito mais claras do que a Figura 3.43(b) comprova,

mais uma vez, que o gradiente de uma imagem com um conteúdo de borda significativo tem valores mais altos em geral do que uma imagem laplaciana.

O produto da imagem laplaciana com a imagem gradiente suavizada é mostrado na Figura 3.43(f). Observe a dominância das bordas mais acentuadas e a relativa falta de ruído visível, o que representa o principal objetivo do mascaramento do laplaciano com uma imagem gradiente suavizada. Adicionar a imagem resultante à original levou à imagem realçada mostrada na Figura 3.43(g). O aumento significativo na nitidez dos detalhes nessa imagem em relação à original fica claro na maior parte da imagem, incluindo costelas, medula espinhal, pelve e crânio. Esse tipo de realce não teria sido possível utilizando exclusivamente o laplaciano ou o gradiente.

O procedimento de aguçamento que acabamos de discutir não afeta, de forma significativa, a faixa dinâmica dos níveis de intensidade de uma imagem. Assim, o último passo de nossa tarefa de realce é alargar a faixa dinâmica da imagem realçada. Como discutimos com relativo detalhamento nas seções 3.2 e 3.3, existem várias funções de transformação de intensidade capazes de atingir esse objetivo. Sabemos, com base nos resultados da Seção 3.3.2, que a equalização de histogramas provavelmente não funcionará bem com imagens com distribuições de intensidade na faixa mais escura da escala, como as nossas imagens neste caso. A especificação de histogramas poderia ser uma solução, mas a característica das imagens com as quais estamos lidando, ser mais escura, adequa-se muito melhor a uma transformação de potência. Como desejamos distribuir os níveis de intensidade ao longo de toda a escala, o valor de $\gamma$ na Equação 3.2-3 deve ser menor do que 1. Após algumas tentativas com essa equação, chegamos ao resultado da Figura 3.43(h), obtido com $\gamma = 0{,}5$ e $c = 1$. Comparando essa imagem com a Figura 3.43(g), vemos que detalhes significativos passam a ser visíveis na Figura 3.43(h). As áreas na região dos pulsos, mãos, tornozelos e pés são bons exemplos disso. A estrutura óssea também está muito mais acentuada, incluindo os ossos dos braços e pernas. Observe também a suave definição do contorno do corpo e do tecido corporal. Realçar detalhes dessa natureza por meio da expansão da faixa dinâmica dos níveis de intensidade também realçou o ruído, mas a Figura 3.43(h) representa uma melhora visual significativa em relação à imagem original.

A abordagem que acabamos de discutir é representativa dos tipos de processos que podem ser combinados para atingir resultados que seriam impossíveis com uma técnica isolada. A forma na qual os resultados são utilizados depende da aplicação. O usuário final do tipo de imagem mostrada neste exemplo provavelmente seria um radiologista. Por uma série de razões que estão além do escopo da nossa discussão, os médicos têm um certo receio de se basear em resultados realçados para chegar a um diagnóstico. No entanto, imagens realçadas são bastante úteis para salientar detalhes que podem servir como indicativos para análises posteriores da imagem original ou da sequência de imagens. Em outras áreas, o resultado realçado pode ser o produto final. Exemplos são encontrados na indústria gráfica, na inspeção de produtos baseada em imagens, em investigações criminais, na microscopia, na área de segurança e em uma série de outras áreas nas quais o principal objetivo do realce é obter uma imagem com um maior conteúdo de detalhes visuais.

## 3.8 Utilização de técnicas *fuzzy* para transformações de intensidade e filtragem espacial

Concluiremos este capítulo com uma introdução aos conjuntos *fuzzy* (difusos) e sua aplicação para as transformações de intensidade e filtragem espacial, que são os principais tópicos de discussão nas seções anteriores. Essas duas aplicações estão entre as áreas mais frequentes nas quais as técnicas *fuzzy* são aplicadas para o processamento de imagens. As referências no final deste capítulo fornecem um ponto de partida para a literatura sobre conjuntos *fuzzy* e outras aplicações de técnicas *fuzzy* no processamento de imagens. Como veremos nas discussões a seguir, os conjuntos *fuzzy* proporcionam suporte para a incorporação do conhecimento humano à resolução de problemas cuja formulação se baseia em conceitos imprecisos.

### 3.8.1 Introdução

Como observamos na Seção 2.6.4, um *conjunto* é uma coletânea de objetos (elementos), e a *teoria dos conjuntos* representa a série de ferramentas que lidam com operações envolvendo conjuntos. A teoria dos conjuntos, combinada à lógica matemática, é um dos axiomas fundamentais da matemática clássica. No centro da teoria dos conjuntos, encontramos a noção de pertinência do conjunto. Estamos acostumados a lidar com os chamados conjuntos *crisp* (rígidos), cuja pertinência só pode ser verdadeira ou falsa no sentido tradicional da lógica booleana de dois valores, com 1 normalmente indicando verdadeiro e 0 indicando falso. Por exemplo, suponha que tenhamos $Z$ expressando o conjunto de todas as pessoas e que queiramos

definir um subconjunto, $A$, de $Z$, chamado de "conjunto de pessoas jovens". Para formar esse subconjunto, precisamos definir uma *função de pertinência*[*] que atribua um valor 1 ou 0 a cada elemento, $z$, de $Z$. Como estamos lidando com uma lógica de dois valores, a função de pertinência simplesmente define um limiar no qual ou abaixo do qual uma pessoa é considerada jovem, e acima do qual uma pessoa é considerada não jovem. A Figura 3.44(a) resume esse conceito utilizando um limiar de idade de 20 anos e com $\mu_A(z)$ expressando a função de pertinência que acabamos de discutir.

Vemos uma dificuldade imediata com essa formulação: uma pessoa de 20 anos de idade é considerada jovem, mas uma pessoa cuja idade é 20 anos e 1 segundo não pertence ao conjunto de pessoas jovens. Esse é um problema fundamental dos conjuntos *crisp* que limita a utilização da teoria clássica dos conjuntos em várias aplicações práticas. O que precisamos é de mais flexibilidade no que queremos dizer com "jovem", isto é, precisamos de uma transição *gradual* de jovem para não jovem. A Figura 3.44(b) mostra uma possibilidade. A principal característica dessa função é que ela possui um número infinito de valores, permitindo, assim, uma transição contínua entre jovem e não jovem. Isso possibilita ter *graus* de "juventude". Agora podemos afirmar, por exemplo, que uma pessoa é jovem (extremidade plana superior da curva), relativamente jovem (mais para o começo da rampa), 50% jovem (no meio da rampa), não tão jovem (mais para o final da rampa) e assim por diante (observe que a inclinação descendente da curva na Figura 3.44(b)

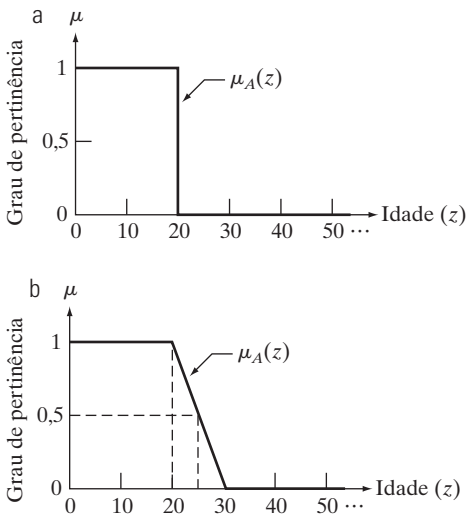



**Figura 3.44** Funções de pertinência utilizadas para gerar (a) um conjunto *crisp* (rígido) e (b) um conjunto *fuzzy* (difuso).

faz com que nosso conceito de "jovem" seja menos preciso). Esses tipos de afirmações vagas (*fuzzy*) estão mais de acordo com o que as pessoas utilizam quando falam de forma imprecisa sobre a idade. Dessa maneira, podemos interpretar infinitos valores das funções de pertinência como o fundamento de uma *lógica fuzzy*, e os conjuntos gerados utilizando essas funções podem ser considerados *conjuntos fuzzy*. Esses conceitos serão formalizados na próxima seção.

### 3.8.2 Princípios da teoria dos conjuntos *fuzzy*

A teoria dos conjuntos *fuzzy* foi apresentada por L. A. Zadeh em um artigo há mais de quatro décadas (Zadeh, 1965). Como a discussão a seguir demonstra, os conjuntos *fuzzy* proporcionam uma forma de lidar com informações imprecisas.

#### Definições

Seja $Z$ um conjunto de elementos (objetos) e $z$ um elemento genérico de $Z$; isto é, $Z = \{z\}$.[**] Esse conjunto é chamado de *universo de discurso*. Um *conjunto fuzzy*[***] $A$ em $Z$ é caracterizado por uma *função de pertinência*, $\mu_A(z)$, que associa a cada elemento de $Z$ um número real no intervalo $[0, 1]$. O valor de $\mu_A(z)$ em $z$ representa o *grau de pertinência* de $z$ em $A$. Quanto mais próximo de 1 for o valor de $\mu_A(z)$, maior é o grau de pertinência de $z$ em $A$, e o contrário ocorre quando o valor de $\mu_A(z)$ for mais próximo de 0. O conceito de "pertence a", tão utilizado em conjuntos comuns, não tem o mesmo significado na teoria dos conjuntos *fuzzy*. Com conjuntos comuns, dizemos que um elemento pertence ou não pertence a um conjunto. Com os conjuntos *fuzzy*, dizemos que todos os valores de $z$ para os quais $\mu_A(z) = 1$ são membros *totais* do conjunto, todos os valores de $z$ para os quais $\mu_A(z) = 0$ *não* são membros do conjunto, e todos os valores de $z$ para os quais $\mu_A(z)$ estão entre 0 e 1 são membros *parciais* do conjunto. Dessa forma, um conjunto *fuzzy* é um *par ordenado* consistindo de valores de $z$ e uma função de pertinência correspondente que atribui um grau de pertinência a cada $z$. Isto é:

$$A = \left\{ z, \mu_A(z) \middle| z \in Z \right\} \tag{3.8-1}$$

Quando as variáveis são contínuas, o conjunto $A$ nessa equação pode ter um número infinito de elementos. Quando os valores de $z$ são discretos, podemos mostrar

[*] As funções de pertinência também são chamadas de *funções características*.

[**] Seguimos a notação convencional dos conjuntos *fuzzy* utilizando $Z$, em vez da notação de conjuntos mais tradicional $U$, para indicar o conjunto universo de uma dada aplicação.

[***] A expressão subconjunto *fuzzy* também é utilizada na literatura, indicando que $A$ é um subconjunto de $Z$. No entanto, a expressão conjunto *fuzzy* é utilizada com mais frequência.

os elementos de $A$ explicitamente. Por exemplo, se os incrementos de idade da Figura 3.44 fossem limitados a anos inteiros, teríamos:

$$A = \{(1,1),(2,1),(3,1),\ldots,(20,1),(21,0.9),$$
$$(22,0,8),\ldots,(25,0,5)\ (24,0,4),\ldots\ (29,0,1)\}$$

onde, por exemplo, o elemento (22, 0,8) indica que a idade 22 tem um grau de pertinência 0,8 no conjunto. Todos os elementos com idades de 20 ou menos são membros totais do conjunto e aqueles com idades de 30 ou mais não são membros do conjunto. Observe que um gráfico desse conjunto seria simplesmente um conjunto de pontos discretos sobre a curva da Figura 3.44(b), de forma que $\mu_A(z)$ definiria $A$ completamente. Considerado de outra forma, vemos que um conjunto *fuzzy* discreto não é nada mais do que o conjunto de pontos de uma função que mapeia cada elemento do domínio do problema (universo de discurso) em um número maior que 0 e menor ou igual a 1. Dessa forma, geralmente encontramos os termos *conjunto fuzzy* e *função de pertinência* sendo utilizados como sinônimos.

Quando $\mu_A(z)$ pode ter somente dois valores, digamos, 0 e 1, a função de pertinência se reduz à função característica conhecida de um conjunto comum (*crisp*) $A$. Assim, conjuntos comuns podem ser considerados um caso especial de conjuntos *fuzzy*. Em seguida, analisaremos várias definições envolvendo conjuntos *fuzzy* que são extensões das definições correspondentes dos conjuntos comuns.

- *Conjunto vazio:* um conjunto *fuzzy* é *vazio* se, e somente se, sua função de pertinência for exatamente igual a 0 em $Z$.
- *Igualdade:* dois conjuntos *fuzzy* $A$ e $B$ são *iguais*, indicados por $A = B$, se, e somente se, $\mu_A(z) = \mu_B(z)$ para todo $z \in Z$.*
- *Complemento:* o *complemento* (NÃO) de um conjunto *fuzzy* $A$, indicado por $\overline{A}$ ou NÃO($A$), é definido como o conjunto cuja função de pertinência é:

$$\mu_{\bar{A}}(z) = 1 - \mu_A(z) \tag{3.8-2}$$

para todo $z \in Z$.

- *Subconjunto:* um conjunto *fuzzy* $A$ é um *subconjunto* de um conjunto *fuzzy* $B$ se, e somente se:

$$\mu_A(z) \leq \mu_B(z) \tag{3.8-3}$$

para todo $z \in Z$.

- *União:* a *união* (OU) de dois conjuntos *fuzzy* $A$ e $B$, indicada por A ∪ B, ou $A$ OU $B$, é um conjunto *fuzzy* $U$ com função de pertinência:

$$\mu_U(z) = \max\left[\mu_A(z), \mu_B(z)\right] \tag{3.8-4}$$

para todo $z \in Z$.

- *Interseção:* a interseção (E) de dois conjuntos *fuzzy* $A$ e $B$, indicada por $A \cap B$, ou $A$ E $B$, é um conjunto *fuzzy* $I$ com função de pertinência:

$$\mu_I(z) = \min\left[\mu_A(z), \mu_B(z)\right] \tag{3.8-5}$$

para todo $z \in Z$.

Observe que os termos NÃO, OU e E são utilizados de forma equivalente ao trabalhar com os conjuntos *fuzzy* para indicar complementação, união e interseção, respectivamente.

■

**Exemplo 3.18** Ilustração das definições de conjuntos *fuzzy*.

A Figura 3.45 ilustra algumas das definições citadas anteriormente. A Figura 3.45(a) mostra as funções de pertinência de dois conjuntos, $A$ e $B$, e a Figura 3.45(b) mostra a função de pertinência do complemento de $A$. A Figura 3.45(c) mostra a função de pertinência da união de $A$ e $B$, e a Figura 3.45(d) mostra o resultado correspondente da interseção desses dois conjuntos. Observe que essas figuras são compatíveis com a nossa noção habitual de complemento, união e interseção dos conjuntos *crisp*.**

■

Apesar de a probabilidade e a lógica *fuzzy* operarem ao longo do mesmo intervalo [0, 1], uma distinção significativa deve ser feita entre as duas. Vejamos o exemplo da Figura 3.44. Uma afirmação probabilística poderia ser formulada como: "Existe 50% de chances de uma pessoa ser jovem", ao passo que uma afirmação *fuzzy* seria "O grau de pertinência de uma pessoa dentro do conjunto de pessoas jovens é 0,5". É importante notar a diferença entre essas duas afirmações. Na primeira afirmação, uma pessoa é considerada como parte do conjunto de pessoas jovens ou do conjunto de pessoas não

* A notação "para todo $z \in$ Z" significa: "para todos os valores de $z$ que pertencem a $Z$".

** Você provavelmente encontrará exemplos na literatura nos quais a área sob a curva da função de pertinência de, digamos, a interseção de dois conjuntos *fuzzy*, é sombreada para indicar o resultado da operação. Isso representa uma influência negativa das operações de conjuntos comuns e é incorreto. Somente os pontos ao longo da própria função de pertinência são aplicáveis quando lidamos com conjuntos *fuzzy*.

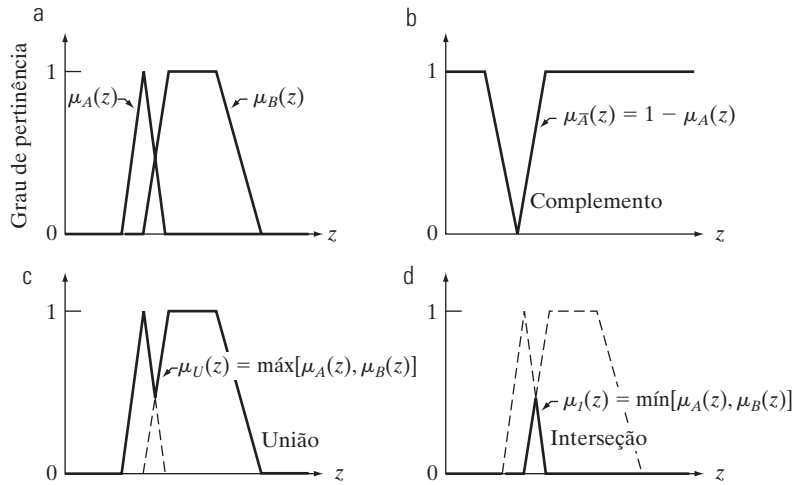



**Figura 3.45** (a) Função de pertinência de dois conjuntos, *A* e *B*. (b) Função de pertinência do complemento de *A*. (c) e (d) funções de pertinência da união e interseção dos dois conjuntos.

jovens; temos apenas 50% de chances de saber a qual conjunto a pessoa pertence. A segunda afirmação pressupõe que a pessoa é jovem em algum nível – no caso, esse nível é de 0,5. Uma outra interpretação é dizer que se trata de uma pessoa "meio" jovem: não realmente jovem, mas longe de ser não jovem. Em outras palavras, a lógica *fuzzy* não é probabilística; ela só lida com graus de pertinência em um conjunto. Nesse sentido, vemos que os conceitos da lógica difusa encontram aplicação em situações caracterizadas pela imprecisão e incerteza, e não pela aleatoriedade.

### Algumas funções de pertinência comuns

Os tipos de funções de pertinência utilizadas na prática incluem os seguintes.

*Triangular:*

$$\mu(z) = \begin{cases} 1-(a-z)/b & a-b \le z < a \\ 1-(z-a)/c & a \le z \le a+c \\ 0 & \text{caso contrário} \end{cases} \quad (3.8\text{-}6)$$

*Trapezoidal:*

$$\mu(z) = \begin{cases} 1-(a-z)/c & a-c \le z < a \\ 1 & a \le z < b \\ 1-(z-b)/d & b \le z \le b+d \\ 0 & \text{caso contrário} \end{cases} \quad (3.8\text{-}7)$$

*Sigma:*

$$\mu(z) = \begin{cases} 1-(a-z)/b & a-b \le z \le a \\ 1 & z > a \\ 0 & \text{caso contrário} \end{cases} \quad (3.8\text{-}8)$$

*Formato de S:*

$$S(z;a,b,c) = \begin{cases} 0 & z < a \\ 2\left(\dfrac{z-a}{c-a}\right)^2 & a \le z \le b \\ 1-2\left(\dfrac{z-c}{c-a}\right)^2 & b < z \le c \\ 1 & z > c \end{cases} \quad (3.8\text{-}9)$$

*Formato de sino:*[*]

$$\mu(z) = \begin{cases} S(z;c-b,c-b/2,c) & z \le c \\ 1-S(z;c,c+b/2,c+b) & z > c \end{cases} \quad (3.8\text{-}10)$$

A função formato de sino algumas vezes é chamada de função $\Pi$ (ou $\pi$).

*Gaussiana truncada:*

$$\mu(z) = \begin{cases} e^{-\frac{(z-a)^2}{2b^2}} & a-c \le z \le a+c \\ 0 & \text{caso contrário} \end{cases} \quad (3.8\text{-}11)$$

[*] A função formato de sino algumas vezes é chamada de função $\Pi$ (ou $\pi$).

Normalmente, só a variável independente, $z$, é incluída na expressão $\mu(z)$ para simplificar as equações. Abrimos uma exceção na Equação 3.8-9 para utilizar sua forma na Equação 3.8-10. A Figura 3.46 mostra exemplos das funções de pertinência que acabamos de discutir. As três primeiras funções são lineares por partes em relação a um conjunto de variáveis, as duas funções seguintes são suaves e a última função é uma função gaussiana truncada. A Equação 3.8-9 descreve uma importante função em formato de S utilizada frequentemente ao trabalhar com conjuntos *fuzzy*. O valor de $z = b$ no qual $S = 0{,}5$, nessa equação é chamado de *ponto de inflexão*. Como mostra a Figura 3.46(d), esse é o ponto no qual a curva muda de direção. Não é difícil demonstrar (Exercício 3.31) que $b = (a + c)/2$. Na curva em formato de sino da Figura 3.46(e), o valor de $b$ define a *largura de banda* da curva.

### 3.8.3 Utilização dos conjuntos *fuzzy*

Nesta seção, definimos as bases da utilização dos conjuntos *fuzzy* e ilustramos os conceitos resultantes com exemplos de situações simples e bem conhecidas. Depois aplicaremos os resultados ao processamento de imagens nas seções 3.8.4 e 3.8.5. Abordar a apresentação dessa forma facilita a compreensão do material, especialmente para leitores não familiarizados com a área.

Suponha que estejamos interessados em utilizar cores para categorizar um determinado tipo de fruta em três grupos: não madura, meio madura e madura. Vamos supor que observações de frutas em vários estágios de maturidade levaram à conclusão de que a fruta não madura é verde, a meio madura é amarela e a madura é vermelha. Os indicativos *verde*, *amarelo* e *vermelho* são descrições vagas da sensação de cor. Como um ponto de partida, essas indicações devem ser expressas em um formato *fuzzy*. Isto é, elas precisam ser *fuzzificadas*. Isso é feito definindo a pertinência como uma função da cor (comprimento de onda da luz), como mostra a Figura 3.47(a). Nesse contexto, a *cor* é uma *variável linguística* e uma cor específica (por exemplo, *vermelho* em um comprimento de onda fixo) é um *valor linguístico*. Um valor linguístico, $z_0$, é fuzzificado utilizando funções de pertinência para mapeá-lo no intervalo [0, 1], como mostra a Figura 3.47(b).

O *conhecimento* específico do problema que acabamos de explicar pode ser formalizado na forma das *regras fuzzy SE-ENTÃO* (*IF-THEN*) a seguir:*

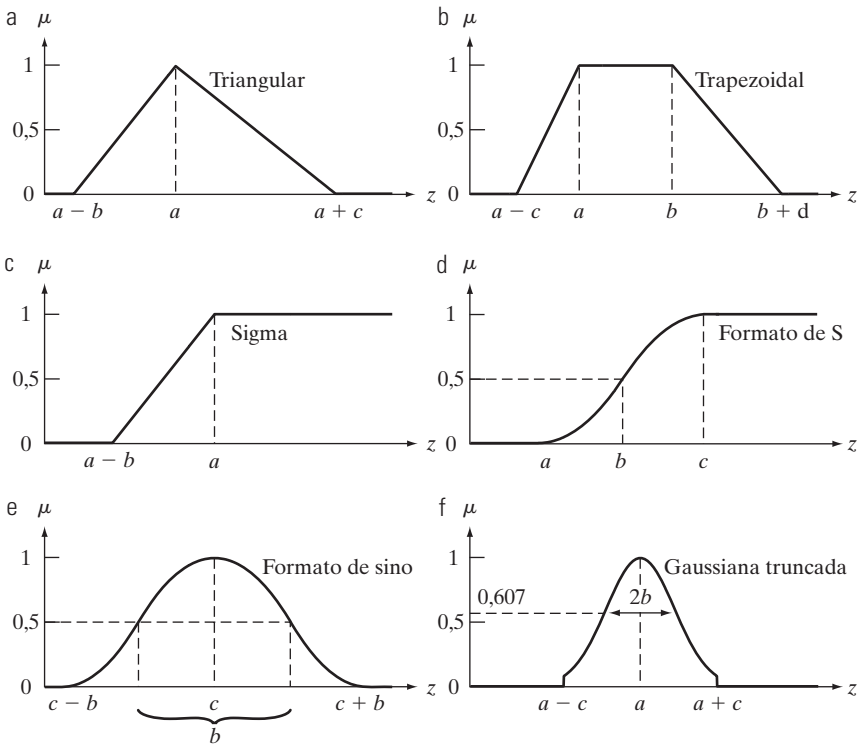



**Figura 3.46** Funções de pertinência correspondentes às equações 3.8-6 a 3.8-11.

* A parte de uma regra SE-ENTÃO à esquerda de ENTÃO costuma ser chamada de *antecedente* (ou *premissa*). A parte à direita é chamada de consequente (ou *conclusão*).

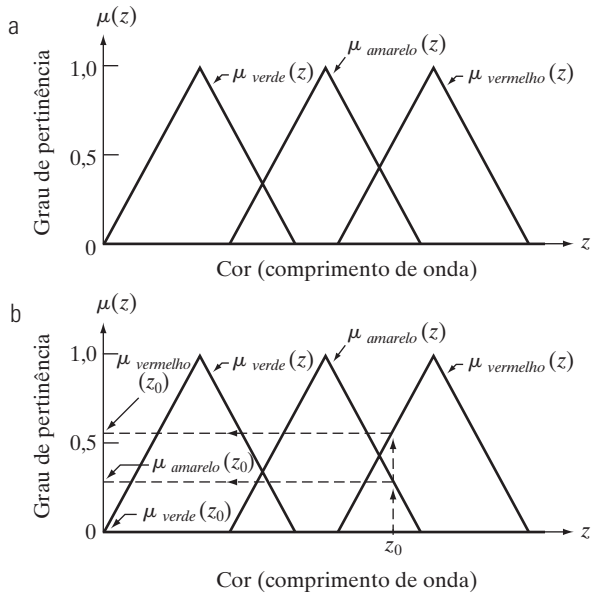



**Figura 3.47** (a) Funções de pertinência utilizadas para fuzzificar a cor. (b) Fuzzificação de uma cor específica (curvas descrevendo a sensação de cor têm formato de sino; veja um exemplo na Seção 6.1. Entretanto, costuma-se utilizar formatos triangulares como uma aproximação ao trabalhar com conjuntos *fuzzy*).

$R_1$: SE a cor for *verde*, ENTÃO a fruta está *não madura*.

OU

$R_2$: SE a cor for *amarela*, ENTÃO a fruta está *meio madura*.

OU

$R_3$: SE a cor for *vermelha*, ENTÃO a fruta está *madura*.

Essas regras representam a soma total do nosso conhecimento sobre o problema; elas nada mais são do que um formalismo para um processo de pensamento.

O próximo passo do procedimento consiste em encontrar uma forma de utilizar as informações de entrada (cores) e a base de conhecimento representada pelas regras SE-ENTÃO para gerar o resultado de saída do sistema *fuzzy*. Esse processo é conhecido como *implicação* ou *inferência*. No entanto, antes de a implicação poder ser aplicada, o antecedente de cada regra precisa ser processado para resultar em um *único* valor. Como mostraremos no final desta seção, várias partes de um antecedente estão ligadas por Es e OUs. Com base nas definições da Seção 3.8.2, isso significa realizar operações *mín* e *máx*. Para simplificar a explicação, lidamos inicialmente com regras cujos antecedentes contêm apenas uma parte.

Como estamos lidando com informações *fuzzy*, os resultados também serão *fuzzy*, de forma que funções de pertinência também precisam ser definidas para os resultados. A Figura 3.48 mostra as funções de pertinência dos resultados *fuzzy* que utilizaremos neste exemplo. Observe que a variável independente dos resultados é a *maturidade*, que é diferente da variável independente dos dados de entrada.

As figuras 3.47 e 3.48, junto com a base de regras, contêm todas as informações necessárias para relacionar os dados de entrada com os de saída. Por exemplo, observamos que a expressão *vermelho* E *maduro* nada mais é do que a operação de interseção (E) definida anteriormente. Neste caso, as variáveis independentes das funções de pertinência de entrada e de saída são diferentes, de forma que o resultado será bidimensional. Por exemplo, as figuras 3.49(a) e (b) mostram as funções de pertinência de *vermelho* e *maduro*, e a Figura 3.49(c) mostra como elas se relacionam nas duas dimensões. Para encontrar o resultado da operação E entre essas duas funções, lembre, com base na Equação 3.8-5, que E é definido como o mínimo das duas funções de pertinência, isto é:

$$\mu_3(z,v) = \text{mín}\ \{\mu_{verm}(z),\ \mu_{mad}(v)\} \qquad (3.8\text{-}12)$$

sendo que o 3 subscrito denota que esse é o resultado da regra $R_3$ da base de conhecimento. A Figura 3.49(d) mostra o resultado da operação E.*

A Equação 3.8-12 é um resultado geral envolvendo duas funções de pertinência. Na prática, estamos interessados na saída resultante de uma entrada *específica*. Seja $z_0$ um valor específico de *vermelho*. O grau de pertinência do componente da cor vermelha em resposta a esse dado de entrada é simplesmente um valor escalar, $\mu_{\text{verm}}$

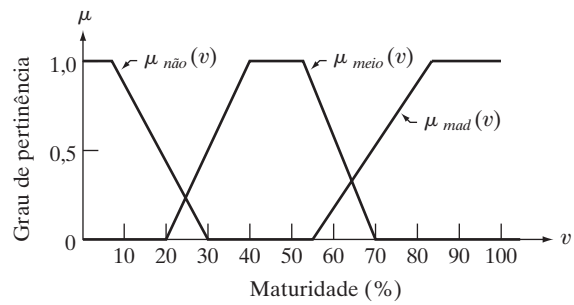



**Figura 3.48** Funções de pertinência caracterizando os resultados de saída *não maduro*, *meio maduro* e *maduro*.

* Observe que a Equação 3.8-12 é formada de pares ordenados de valores $\{\mu_{verm}(z),\ \mu_{mad}(v)\}$ e lembre que um conjunto de pares ordenados normalmente é chamado de um produto *cartesiano*, indicado por $X \times V$, sendo $X$ um conjunto de valores $\{\mu_{verm}(z_1), \mu_{verm}(z_2),..., \mu_{verm}(z_n)\}$ gerados a partir de $\mu_{\text{vermelho}}(z)$ pela variação de $z$, e $V$ é um conjunto similar de $n$ valores gerados a partir de $\mu_{meio}(v)$ por meio da variação de v. Dessa forma, $X \times V = \{(\mu_{verm}(z_1), \mu_{meio}(v_1)),..., (\mu_{verm}(z_n), \mu_{meio}(v_1))\}$, e vimos na Figura 3.49(d) que a operação E envolvendo duas variáveis pode ser expressa como um mapeamento de $X \times V$ no limite [0, 1], indicado por $X \times V \rightarrow [0,1]$ . Apesar de não utilizarmos essa notação nesta discussão, a mencionamos aqui porque você provavelmente irá encontrá-la na literatura sobre conjuntos *fuzzy*.

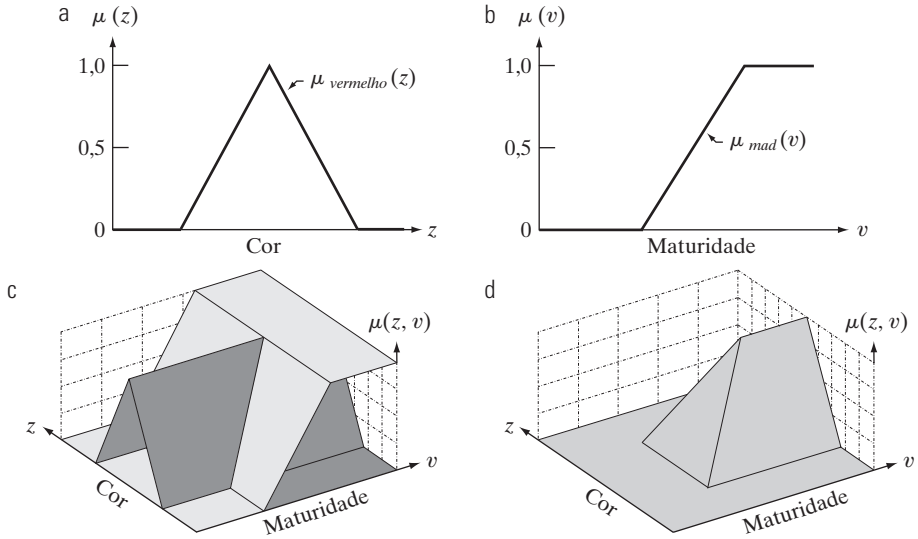



**Figura 3.49** (a) Formato da função de pertinência associada à cor vermelha e (b) função de pertinência da função de saída. Essas duas funções são associadas pela regra $R_3$. (c) Representação combinada das duas funções. A representação é 2-D porque as variáveis independentes em (a) e (b) são diferentes. (d) A operação E de (a) e (b), como definida na Equação 3.8-5.

($z_0$). Encontramos o resultado correspondente à regra $R_3$ para esse dado específico realizando a operação E entre $\mu_{\text{verm}}(z_0)$ e o resultado geral, $\mu_3(z,v)$, calculado também em $z_0$. Como observamos antes, a operação E é implementada utilizando a operação mínima:

$$Q_3(v) = \text{mín}\,\{\mu_{verm}(z_o), \mu_3(z_o\, v)\} \qquad (3.8\text{-}13)$$

onde $Q_3(v)$ indica o resultado *fuzzy* em razão da regra $R_3$ e uma entrada específica. A única variável em $Q_3$ é a variável de saída, $v$, como esperado.

Para interpretar graficamente a Equação 3.8-13, vamos retomar a Figura 3.49(d), que mostra a função geral $\mu_3(z,v)$. Realizar a operação mínima de uma constante positiva, $c$, com essa função recortaria todos os valores de $\mu_3(z,v)$ acima dessa constante, como mostra a Figura 3.50(a). Contudo, estamos interessados apenas em um valor ($z_0$) ao longo do eixo da cor, de forma que o resultado relevante é uma seção transversal da função truncada ao longo do eixo da maturidade, com a seção transversal posicionada em $z_0$, como mostra a Figura 3.50(b) [como a Figura 3.50(a) corresponde à regra $R_3$, segue-se que $c = \mu_{\text{verm}}(z_0)$]. A Equação 3.8-13 é a expressão para essa seção transversal.

Utilizando a mesma linha de raciocínio, obtemos as respostas *fuzzy* em razão das outras duas regras e da entrada específica $z_0$, como segue:

$$Q_2(v) = \text{mín}\,\{\mu_{amar}(z_o), \mu_3(z_o, v)\} \qquad (3.8\text{-}14)$$

e

$$Q_1(v) = \text{mín}\,\{\mu_{verde}(z_o), \mu_1(z_o, v)\} \qquad (3.8\text{-}15)$$

Cada uma dessas equações corresponde ao resultado de saída associado a uma regra particular e a um dado de entrada específico. Em outras palavras, elas representam o resultado do processo de implicação mencionado alguns parágrafos atrás. Tenha em mente que cada uma dessas três respostas é um conjunto *fuzzy*, apesar de a entrada ser um valor escalar.

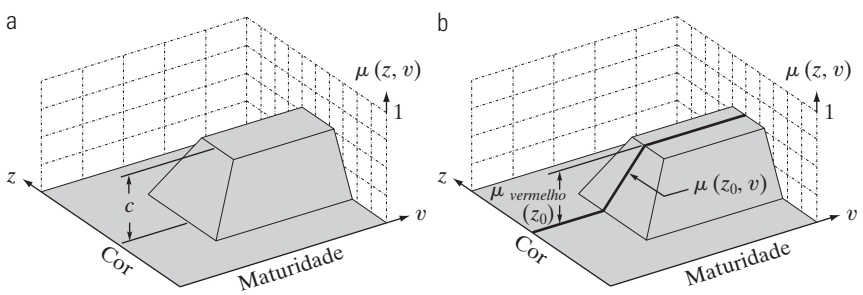



**Figura 3.50** (a) Resultado do cálculo da operação de mínimo entre uma constante arbitrária, $c$, e a função $\mu_3(z, v)$ a partir da Equação 3.8-12. O mínimo equivale a uma operação E. (b) Seção transversal (linha escura) em uma cor específica, $z_0$.

Para obter a resposta geral, *agregamos* as respostas individuais. No conjunto de regras definido no início desta seção, as três regras estão associadas pela operação OU. Dessa forma, o resultado *fuzzy* completo (agregado) é dado por:

$$Q = Q_1 \text{ OR } Q_2 \text{ OR } Q_3 \tag{3.8-16}$$

e vemos que a resposta geral é a união de três conjuntos *fuzzy* individuais. Como OU é definido como uma operação *máx*, podemos escrever esse resultado como:

$$Q(v) = \max_r \{\min_s \{\mu_s(z_o), \mu_r(z_o, v)\}\} \tag{3.8-17}$$

para $r = \{1, 2, 3\}$ e $s = \{verde, amarelo, vermelho\}$. Apesar de ter sido desenvolvida no contexto de um exemplo, essa expressão é perfeitamente genérica; para estendê-la a $n$ regras, simplesmente fazemos com que $r = \{1, 2, \ldots, n\}$; de forma similar, podemos expandir $s$ para incluir qualquer número finito de funções de pertinência. As equações 3.8-16 e 3.8-17 afirmam a mesma coisa: a resposta, $Q$, do nosso sistema *fuzzy*, é a união de conjuntos *fuzzy* individuais resultantes de cada regra por meio do processo de implicação.

A Figura 3.51 resume graficamente a discussão até este ponto. A Figura 3.51(a) mostra as três funções de pertinência de entrada calculadas em $z_0$, e a Figura 3.51(b) mostra as saídas em resposta à entrada $z_0$. Esses conjuntos *fuzzy* correspondem às seções transversais recortadas discutidas em relação à Figura 3.50(b). Observe que, numericamente, $Q_1$ consiste só em 0s porque $\mu_{\text{verde}}(z_0) = 0$; isto é, $Q_1$ é *vazio*, de acordo com a definição da Seção 3.8.2. A Figura 3.51(c) mostra o resultado final, $Q$, que também é um conjunto *fuzzy*, formado a partir da união de $Q_1$, $Q_2$ e $Q_3$.

Conseguimos obter com sucesso a saída completa correspondente a uma entrada específica, mas ainda estamos lidando com um conjunto *fuzzy*. O último passo é obter um resultado *crisp*, $v_0$, a partir do conjunto *fuzzy* $Q$ utilizando um processo chamado de *defuzzificação*. Há várias maneiras de defuzzificar $Q$ para obter um resultado *crisp*. Uma das metodologias utilizadas com mais frequência consiste em calcular o centro de gravidade desse conjunto (as referências citadas no final deste capítulo mencionam outras). Dessa forma, se $Q(v)$ na Equação 3.8-17 pode ter $K$ valores possíveis, $Q(1)$, $Q(2)$, … $Q(K)$, seu centro de gravidade é dado por

$$v_0 = \frac{\sum_{v=1}^{K} vQ(v)}{\sum_{v=1}^{K} Q(v)} \tag{3.8-18}$$

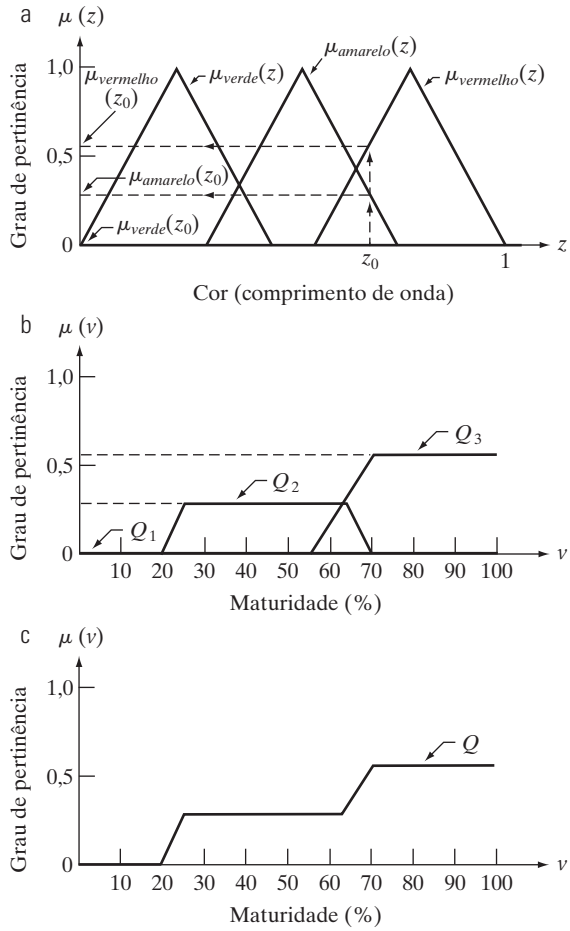



**Figura 3.51** (a) Funções de pertinência com uma cor específica, $z_0$, selecionada. (b) Conjuntos *fuzzy* individuais obtidos a partir das equações 3.8-13 a 3.8-15. (c) Conjunto *fuzzy* final obtido com a utilização da Equação 3.8-16 ou 3.8-17.

Calcular essa equação com os valores (discretos)* de $Q$ na Figura 3.51(c) resulta em $v_0 = 72{,}3$, indicando que a determinada cor $z_0$ implica uma maturidade de aproximadamente 72%.

Até este ponto, consideramos regras SE-ENTÃO cujos antecedentes têm apenas uma parte, como "SE a cor for *vermelha*". Regras contendo mais de uma parte devem ser combinadas para resultar em um *único* número representando todos os antecedentes para essa regra. Por exemplo, suponha que temos a regra: SE a cor for *vermelha* OU a consistência for *macia*, ENTÃO a fruta está *madura*. Uma função de pertinência teria de ser definida

* O conjunto *fuzzy* Q da Figura 3.51(c) é mostrado como uma curva sólida para facilitar a visualização, mas tenha em mente que estamos lidando com valores digitais neste livro, de forma que $Q$ é uma função digital.

para a variável linguística *macia*. Então, para obter um único número para essa regra que leve em consideração as duas partes do antecedente, primeiro avaliamos um determinado valor de cor de entrada para o *vermelho*, utilizando a função de pertinência *vermelho* e um determinado valor de *consistência* utilizando a função de pertinência *macio*. Como as duas partes estão vinculadas por OU, utilizamos o máximo dos dois valores resultantes*. Esse valor é então utilizado no processo de implicação para "recortar" a função de pertinência de saída *maduro*, que é a função associada a essa regra. O restante do procedimento é igual ao descrito anteriormente, como mostra o resumo a seguir.

A Figura 3.52 mostra o exemplo da fruta utilizando duas entradas: *cor* e *consistência*. Podemos utilizar essa figura e as informações anteriores para resumir os principais passos a serem seguidos na aplicação da lógica *fuzzy* baseada em regras:

1. *Fuzzificar a entrada:* para cada entrada escalar, encontre os valores *fuzzy* correspondentes mapeando essa entrada no intervalo [0, 1], utilizando as funções de pertinência aplicáveis em cada regra, como mostram as duas primeiras colunas da Figura 3.52.
2. *Realizar quaisquer operações de lógica* fuzzy *necessárias:* as saídas de todas as partes de um antecedente devem ser combinadas para gerar um *único* valor utilizando a operação *máx* ou *mín*, dependendo de as partes estarem conectadas por OUs ou por Es.

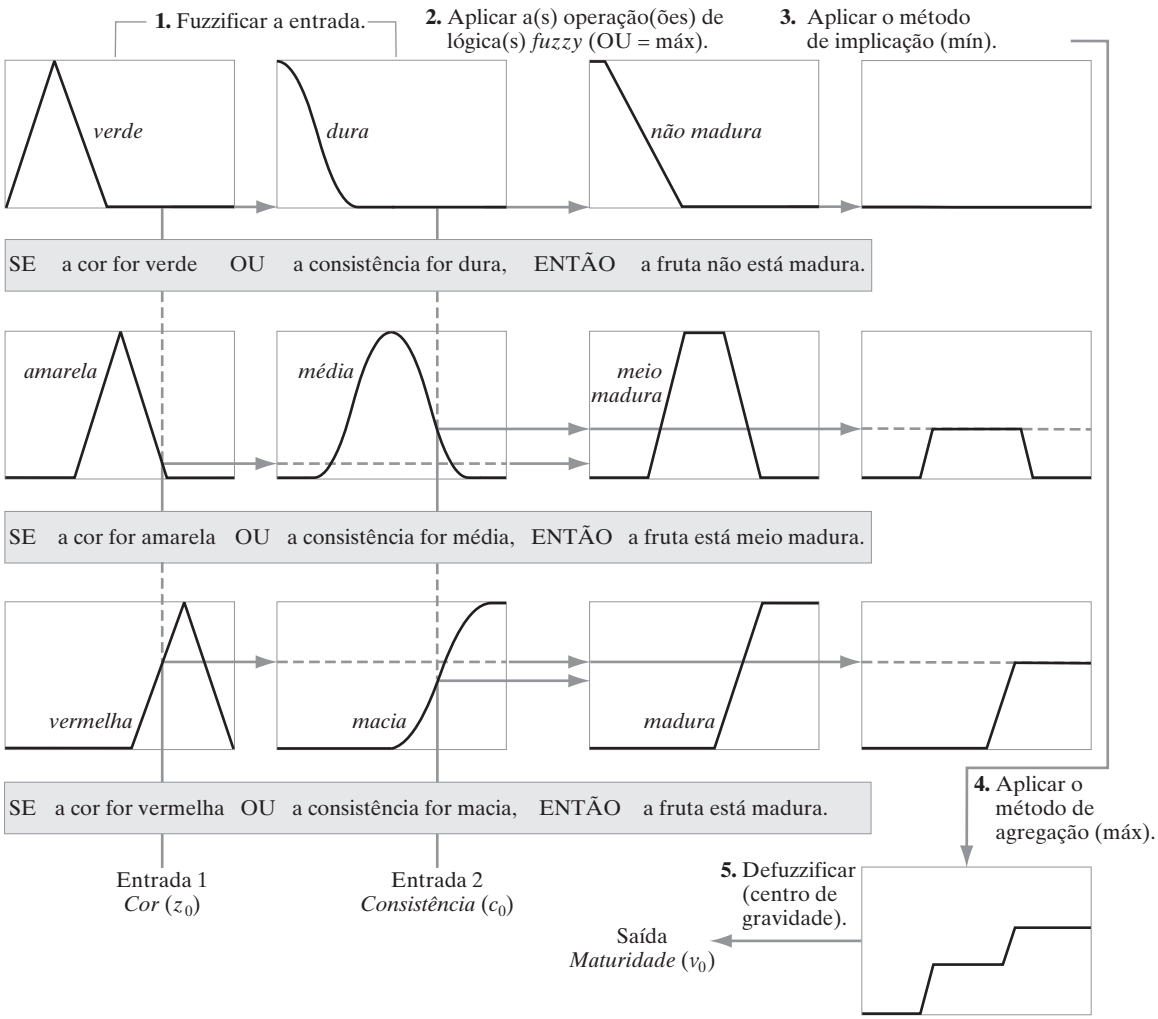



**Figura 3.52** Exemplo ilustrando os cinco passos básicos normalmente utilizados para implementar um sistema *fuzzy* baseado em regras: (1) fuzzificação, (2) operações lógicas (somente OU foi utilizado neste exemplo), (3) implicação, (4) agregação e (5) defuzzificação.

* Antecedentes cujas partes são conectadas por Es são calculados de forma similar utilizando a operação mín.

Na Figura 3.52, todas as partes dos antecedentes são conectadas por OUs, de forma que utilizamos a operação *máx*. O número de partes de um antecedente e o tipo de operador lógico utilizado para conectá-los difere de uma regra a outra.

3. *Aplicar um método de implicação:* uma única saída do antecedente de cada regra é utilizada para proporcionar a saída correspondente a essa regra. Utilizamos E para a implicação, que é definida como a operação *mín*. Isso recorta a função de pertinência correspondente de saída no valor fornecido pelo antecedente, como mostram a terceira e a quarta colunas da Figura 3.52.
4. *Aplicar um método de agregação aos conjuntos* fuzzy *do passo 3:* como mostra a última coluna da Figura 3.52, o resultado de cada regra é um conjunto *fuzzy*. Eles devem ser combinados para levar a um único conjunto *fuzzy* de saída. A metodologia utilizada aqui consiste em aplicar o OU para as saídas individuais, para que a operação *máx* seja empregada.
5. *Defuzzificar o conjunto* fuzzy *de saída final:* neste passo final, obtemos uma saída escalar *crisp*. Isso é feito calculando o centro de gravidade do conjunto *fuzzy* agregado do passo 4.

Quando o número de variáveis for grande, costuma-se utilizar a notação resumida (variável, conjunto *fuzzy*) para relacionar a variável à sua função de pertinência correspondente. Por exemplo, a regra "SE a cor for *verde*, ENTÃO a fruta está *não madura*" seria escrita como "SE (*z*, *verde*) ENTÃO (*v*, *não madura*)", sendo que, como antes, as variáveis *z* e *v* representam cor e grau de maturidade, respectivamente, ao passo que *verde* e *não maduro* são os dois conjuntos *fuzzy* definidos pelas funções de pertinência $\mu_{\text{verde}}(z)$ e $\mu_{\text{não}}(v)$, respectivamente.

Em geral, ao lidar com $M$ regras SE-ENTÃO, $N$ variáveis de entrada, $z_1, z_2, \ldots z_N$, e uma variável de saída, $v$, o tipo de formulação de regra *fuzzy* utilizado com mais frequência no processamento de imagens tem a forma

$$\begin{aligned}&\text{SE } (z_1, A_{11}) \text{ E } (z_2, A_{12}) \text{ E } \ldots \text{ E } (z_N, A_{1N}), \text{ ENTÃO } (v, B_1)\\ &\text{SE } (z_1, A_{21}) \text{ E } (z_2, A_{22}) \text{ E } \ldots \text{ E } (z_N, A_{2N}), \text{ ENTÃO } (v, B_2)\\ &\ldots\ \ldots\\ &\text{SE } (z_1, A_{M1}) \text{ E } (z_2, A_{M2}) \text{ E } \ldots \text{ E } (z_N, A_{MN}), \text{ ENTÃO } (v, B_M)\\ &\qquad\qquad\qquad\qquad\qquad\qquad\qquad\qquad\qquad\qquad \text{SENÃO } (v, B_E)\end{aligned} \tag{3.8-19}$$

onde $A_{ij}$ é o conjunto *fuzzy* associado à *i*-ésima regra e à *j*-ésima variável de entrada, $B_i$ é o conjunto *fuzzy* associado à saída da *i*-ésima regra e consideramos que os componentes dos antecedentes da regra sejam conectados por Es. Observe que introduzimos uma regra SENÃO (*ELSE*), associada ao conjunto *fuzzy* $B_E$. Essa regra é executada quando nenhuma das regras anteriores for completamente satisfeita; sua saída é explicada a seguir.

Como indicado anteriormente, todos os elementos do antecedente de cada regra devem ser calculados para gerar um único valor escalar. Na Figura 3.52, utilizamos a operação *máx* porque as regras se baseavam em OUs *fuzzy*. A formulação da Equação 3.8-19 utiliza Es, de forma que precisamos utilizar o operador *mín*.* Calcular os antecedentes da *i*-ésima regra na Equação 3.8-19 produz uma saída escalar, $\lambda_i$, dada por:

$$\lambda_i = \text{mín}\{\mu_{A_{ij}}(z_j); \quad j = 1, 2, ..., N\} \tag{3.8-20}$$

para $i = 1, 2, \ldots, M$, sendo $\mu_{A_{ij}}(z_j)$ a função de pertinência do conjunto *fuzzy* $A_{ij}$ calculada no valor da *j*-ésima entrada. Muitas vezes, $\lambda$ é chamado de *nível de força* (ou *nível de ativação*) da *i*-ésima regra. No que se refere à discussão anterior, $\lambda$ é simplesmente o valor utilizado para recortar a função de saída da *i*-ésima regra.

A regra SENÃO é executada quando as condições das regras ENTÃO são satisfeitas de forma fraca (damos um exemplo detalhado de como as regras SENÃO são utilizadas na Seção 3.8.5). Sua resposta deve ser forte quando todas as outras são fracas. Em certo sentido, é possível considerar uma regra SENÃO como uma operação NÃO sobre os resultados das outras regras. Sabemos, a partir da Seção 3.8.2, que $\mu_{\text{não}(A)} = \mu_{\bar{A}}(z) = 1 - \mu_A(z)$. Dessa forma, aplicar essa ideia de combinar (efetuar as operações E) todos os níveis das regras ENTÃO leva ao seguinte nível de ativação para a regra SENÃO:

$$\lambda_E = \text{mín}\{1 - \lambda_i; \quad i = 1, 2, ..., M\} \tag{3.8-21}$$

Vemos que, se todas as regras ENTÃO forem ativadas em "força máxima" (todas as suas respostas forem 1), a resposta da regra SENÃO é 0, como o esperado. À medida que as respostas das regras ENTÃO tornam-se mais fracas, a força da regra SENÃO aumenta. Esse é o equivalente *fuzzy* das regras SE-ENTÃO-SENÃO, muito utilizadas em linguagem de programação de computadores.

Ao lidar com OUs nos antecedentes, simplesmente substituímos os Es na Equação 3.8-19 por OUs e a *mín* na Equação 3.8-20 por uma *máx*; a Equação 3.8-21 permanece inalterada. Apesar de ser possível formular antece-

* A utilização de OU ou E no conjunto de regras depende de como as regras são formuladas, o que, por sua vez, depende do problema em questão. Utilizamos OUs na Figura 3.52 e Es na Equação 3.8-19 para que você se familiarize com as duas formulações.

dentes e consequentes mais complexos do que os discutidos aqui, as formulações que desenvolvemos utilizando apenas Es e OUs são bastante genéricas e utilizadas em uma ampla variedade de aplicações de processamento de imagens. As referências no final deste capítulo contêm definições adicionais (mas menos utilizadas) de operadores de lógica *fuzzy* e abordam outros métodos para a implicação (incluindo saídas múltiplas) e defuzzificação. A introdução apresentada nesta seção é fundamental e serve como uma base sólida para leituras mais avançadas sobre assunto. Nas duas seções seguintes, mostraremos como aplicar os conceitos *fuzzy* ao processamento de imagens.

### 3.8.4 Utilização de conjuntos *fuzzy* para transformações de intensidade

Vamos analisar o problema geral de realce de contraste, uma das principais aplicações das transformações de intensidade. Podemos expressar o processo de realce de contraste de uma imagem em escala de cinza utilizando as seguintes regras:

SE um pixel for *escuro*, ENTÃO faça com que ele fique *mais escuro*.

SE um pixel for *cinza*, ENTÃO faça com que ele fique *cinza*.

SE um pixel for *claro*, ENTÃO faça com que ele fique *mais claro*.

Tendo em mente que esses são termos *fuzzy*, podemos expressar os conceitos de *escuro*, *cinza* e *claro* por meio das funções de pertinência da Figura 3.53(a).

Em termos da saída, podemos considerar *mais escuro* como sendo graus de um valor de intensidade escura (100% preto sendo o tom limitador de escuro), *mais claro* como graus de um tom mais claro (100% branco sendo o valor limitador) e *cinza* como sendo graus de uma intensidade no meio da escala de cinza. Neste caso, por "graus" nos referimos à quantidade de uma intensidade específica. Por exemplo, 80% preto é um cinza muito escuro. Quando interpretadas como intensidades *constantes* cuja força é modificada, as funções de pertinência de saída são *singulares* (funções de pertinência constantes), como mostra a Figura 3.53(b). Os vários níveis de uma intensidade no intervalo [0, 1] ocorrem quando as funções singulares são recortadas pela força da resposta de suas regras correspondentes, como mostra a quarta coluna da Figura 3.52 (mas mantenha em mente que estamos trabalhando aqui apenas com uma entrada, não duas, como na figura). Como estamos lidando com constantes nas funções de pertinência de saída, segue-se, da Equação 3.8-18, que a saída, $v_0$, para qualquer entrada, $z_0$, é dada por

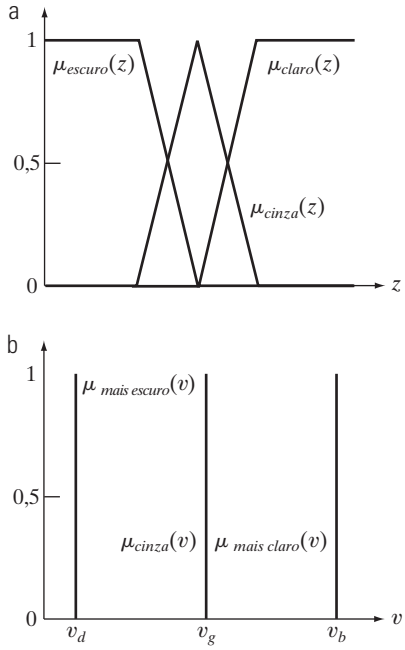



**Figura 3.53** (a) Entrada e (b) funções de pertinência de saída para realce de contraste *fuzzy*, baseado em regras.

$$v_0 = \frac{\mu_{escuro}(Z_0)\times v_d + \mu_{cinza}(Z_0)\times v_g + \mu_{claro}(Z_0)\times v_b}{\mu_{escuro}(Z_0)+\mu_{cinza}(Z_0)+\mu_{claro}(Z_0)} \quad (3.8\text{-}22)$$

Os somatórios do numerador e do denominador dessas expressões são mais simples do que na Equação 3.8-18 porque as funções de pertinência de saída são constantes modificadas (recortadas) pelos valores fuzzificados.

O processamento de imagens por lógica *fuzzy* é computacionalmente intensivo porque todo o processo de fuzzificação, processando os antecedentes de todas as regras, implicação, agregação e defuzzificação, deve ser aplicado a *cada* pixel da imagem de entrada. Dessa forma, utilizar funções singulares como na Equação 3.8-22 reduz significativamente os requisitos de processamento computacional, simplificando a implicação, a agregação e a defuzzificação. Essa redução pode ser significativa em aplicações nas quais a velocidade do processamento é um requisito importante.

■

**Exemplo 3.19** Ilustração do realce de imagens utilizando modificação de contraste por lógica *fuzzy* baseada em regras.

A Figura 3.54(a) mostra uma imagem cujas intensidades cobrem uma faixa estreita da escala de cinza (veja o histograma da imagem na Figura 3.55(a)), dando à imagem uma aparência de baixo contraste. Como uma base para comparação, a Figura 3.54(b) mostra o resultado da equalização de histograma. Como mostra o histograma da imagem

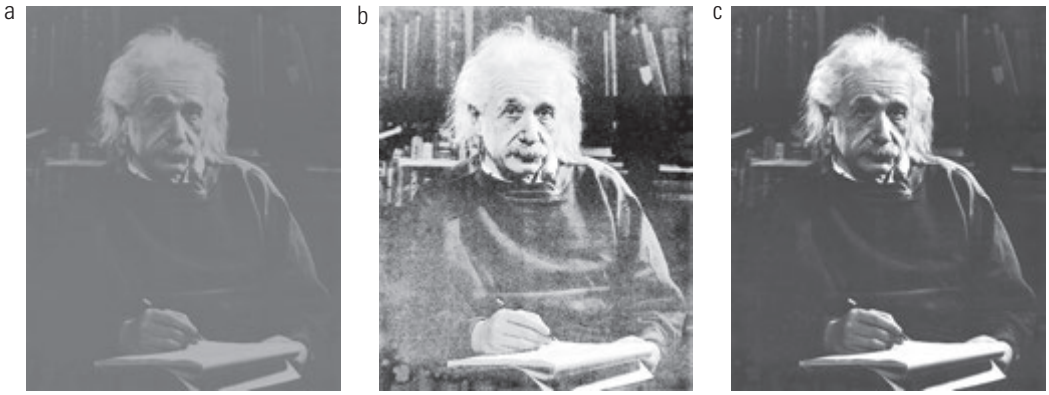



**Figura 3.54** (a) Uma imagem de baixo contraste. (b) Resultado da equalização de histograma. (c) Resultado da utilização do realce de contraste por lógica *fuzzy* baseada em regras.

equalizada (Figura 3.55(b)), expandir toda a escala de cinza de fato aumenta o contraste, mas acrescenta intensidades na extremidade superior e inferior que dão à imagem uma aparência de "superexposição". Por exemplo, os detalhes da testa e dos cabelos do professor Einstein são, na maior parte, perdidos. A Figura 3.54(c) mostra o resultado da utilização da metodologia de modificação de contraste baseada em regras discutidas nos parágrafos anteriores. A Figura 3.55(c) mostra as funções de pertinência de entrada utilizadas, sobrepostas no histograma da imagem original. As saídas singulares foram selecionadas em $v_d = 0$ (preto), $v_g = 127$ (cinza médio) e $v_b = 255$ (branco).

Comparando as figuras 3.54(b) e 3.54(c), nesta última vemos uma considerável melhora da tonalidade. Observe, por exemplo, o nível de detalhes na testa e nos cabelos, em comparação com as mesmas regiões na Figura 3.54(b). A razão para a melhora pode ser facilmente explicada analisando o histograma da Figura 3.54(c), mostrada na Figura 3.55(d). Diferentemente do histograma da imagem equalizada, esse histograma manteve as mesmas características básicas do histograma da imagem original. Entretanto, é evidente que os níveis escuros (os picos na extremidade baixa do histograma) foram movidos para a esquerda, escurecendo os níveis. O oposto aplica-se aos níveis claros. Os tons de cinza médios foram ligeiramente espalhados, muito menos do que na equalização do histograma.

O preço dessa melhora do desempenho é uma complexidade de processamento consideravelmente maior. Uma

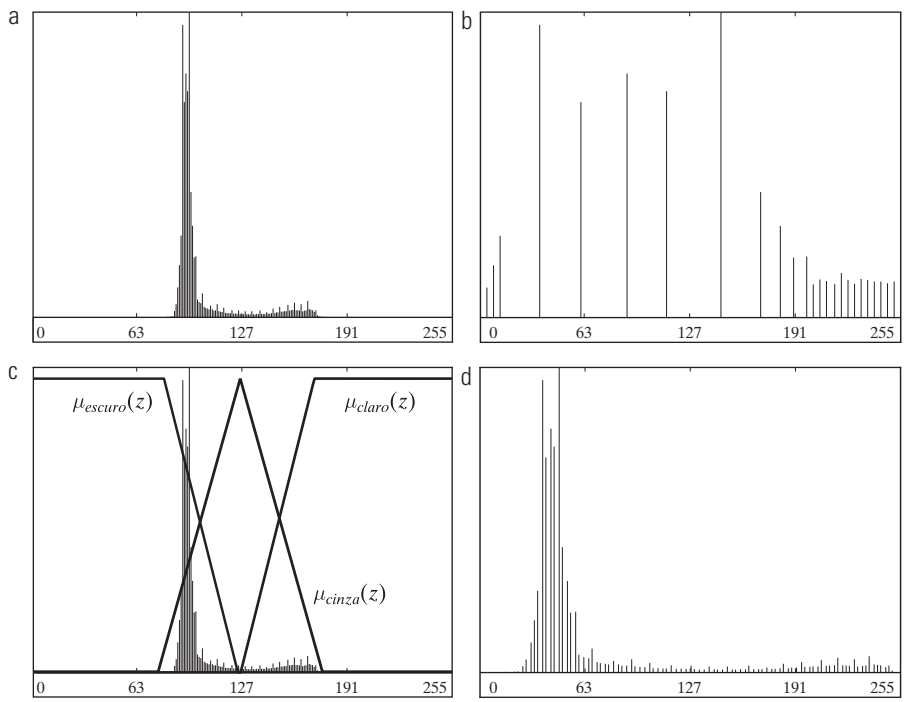



**Figura 3.55** (a) e (b) Histograma das figuras 3.54(a) e (b). (c) Funções de pertinência de entradas sobrepostas em (a). (d) Histograma da Figura 3.54(c).

abordagem prática a ser seguida quando a velocidade de processamento e o resultado final da imagem forem fatores importantes consiste em utilizar técnicas *fuzzy* para definir como deveria ser a aparência dos histogramas de imagens bem equilibradas. Então, técnicas mais rápidas, como a especificação de histograma, podem ser utilizadas para atingir resultados similares mapeando os histogramas das imagens de entrada em um ou mais histogramas "ideais" determinados com a utilização da metodologia *fuzzy*.

■

### 3.8.5 Utilização de conjuntos *fuzzy* para filtragem espacial

Ao aplicar conjuntos *fuzzy* à filtragem espacial, a metodologia básica é definir propriedades de vizinhança que "capturem" a essência do que os filtros devem detectar. Por exemplo, vamos analisar o problema da detecção de fronteiras entre regiões de uma imagem. Isso é importante em várias aplicações de processamento de imagens, como o aguçamento, que discutimos anteriormente nesta seção, e na segmentação de imagens, que discutiremos no Capítulo 10.

Podemos desenvolver um algoritmo de extração de fronteiras com base em um simples conceito *fuzzy*: *Se um pixel pertencer a uma região uniforme, faça com que ele seja branco; senão, faça com que ele seja preto*, onde *preto* e *branco* são conjuntos *fuzzy*. Para expressar o conceito de uma "região uniforme" em termos *fuzzy*, podemos levar em consideração as diferenças de intensidade entre o pixel central de uma vizinhança e seus vizinhos. Para a vizinhança 3 × 3 da Figura 3.56(a), as diferenças entre o pixel central (definido como $z_5$) e cada um dos vizinhos formam a subimagem de tamanho 3 × 3 na Figura 3.56(b), sendo que $d_i$ indica a diferença de intensidade entre o $i$-ésimo vizinho e o ponto central (isto é, $d_i = z_i - z_5$, onde os valores de $z$ correspondem à intensidade). Um conjunto simples de quatro regras SE-ENTÃO e uma

a

| | | |
|---|---|---|
| $z_1$ | $z_2$ | $z_3$ |
| $z_4$ | $z_5$ | $z_6$ |
| $z_7$ | $z_8$ | $z_9$ |

Vizinhança de pixel

b

| | | |
|---|---|---|
| $d_1$ | $d_2$ | $d_3$ |
| $d_4$ | 0 | $d_6$ |
| $d_7$ | $d_8$ | $d_9$ |

Diferenças de intensidade

**Figura 3.56** (a) Vizinhança de pixel 3 × 3. (b) Diferenças de intensidade correspondentes entre o pixel central e seus vizinhos. Somente $d_2$, $d_4$, $d_6$ e $d_8$ foram utilizados na presente aplicação para simplificar a análise.

regra SENÃO implementa a essência do conceito *fuzzy* mencionado no início deste parágrafo:*

SE $d_2$ for *zero* E $d_6$ for *zero*, ENTÃO $z_5$ é *branco*
SE $d_6$ for *zero* E $d_8$ for *zero*, ENTÃO $z_5$ é *branco*
SE $d_8$ for *zero* E $d_4$ for *zero*, ENTÃO $z_5$ é *branco*
SE $d_4$ for *zero* E $d_2$ for *zero*, ENTÃO $z_5$ é *branco*
SENÃO $z_5$ é *preto*

onde *zero* também é um conjunto *fuzzy*. A consequente de cada regra define os valores nos quais a intensidade do pixel central ($z_5$) é mapeada. Isto é, a afirmação "ENTÃO $z_5$ é branco" significa que a intensidade do pixel localizado no centro da máscara é mapeada em branco. Essas regras simplesmente afirmam que o pixel central é considerado parte de uma região uniforme se as diferenças de intensidade que acabamos de mencionar forem zero (em um sentido *fuzzy*); de outra forma, ele é considerado como um pixel de fronteira.

A Figura 3.57 mostra possíveis funções de pertinência para os conjuntos *fuzzy zero*, *preto* e *branco*, respectivamente, onde utilizamos *ZE*, *PR* e *BR* para simplificar a notação. Observe que o intervalo da variável independentemente do conjunto *fuzzy ZE* para uma imagem com $L$ possíveis

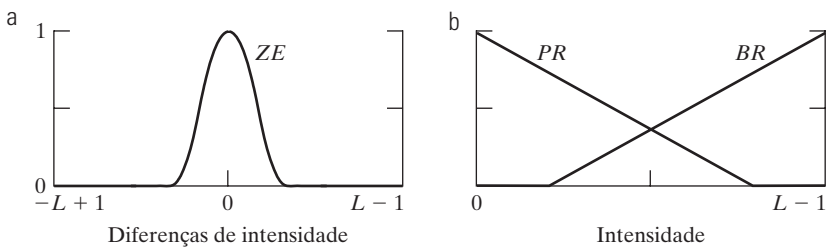



**Figura 3.57** (a) Função de pertinência do conjunto *fuzzy zero*. (b) Funções de pertinência dos conjuntos *fuzzy preto* e *branco*.

* Utilizamos apenas as diferenças de intensidade entre os vizinhos-4 e o ponto central para simplificar o exemplo. A utilização dos vizinhos-8 seria uma extensão direta da abordagem demonstrada aqui.

níveis de intensidade é $[-L + 1, L - 1]$ porque as diferenças de intensidade podem variar entre $-(L - 1)$ e $(L - 1)$. Por outro lado, o intervalo das intensidades de saída é $[0, L - 1]$, como na imagem original. A Figura 3.58 mostra graficamente as regras citadas, onde o quadro indicado por $z_5$ mostra que a intensidade do pixel central é mapeada no valor de saída *BR* ou *PR*.

■

**Exemplo 3.20** Ilustração do realce de fronteira utilizando a filtragem espacial *fuzzy* baseada em regras.

A Figura 3.59(a) mostra uma imagem 512 × 512 de uma cabeça humana, gerada por tomografia computadorizada, e a Figura 3.59(b) é o resultado da aplicação da metodologia de filtragem espacial *fuzzy* que acabamos de discutir. Observe a eficácia do método na extração das fronteiras entre as regiões, inclusive o contorno do cérebro (região cinza interna). As regiões constantes na imagem aparecem como cinza porque, quando as diferenças de intensidade discutidas anteriormente são próximas de zero, as regras ENTÃO têm uma resposta mais forte. Essas respostas, por sua vez, recortam a função *BR*. A saída (o centro de gravidade das regiões triangulares recortadas) é uma constante entre $(L - 1)/2$ e $(L - 1)$ produzindo, dessa forma, o tom acinzentado visto na imagem. O contraste dessa imagem pode ser significativamente melhorado por meio da expansão da escala de cinza. Por exemplo, a Figura 3.59(c) foi obtida por meio do ajuste de intensidade definido nas equações 2.6-10 e 2.6-11, com $K = L - 1$. O resultado final é que os valores de intensidade da Figura 3.59(c) cobrem toda a escala de cinza de 0 a $(L - 1)$.

■

## Resumo

O material que acabamos de analisar é representativo das técnicas atuais utilizadas para as transformações de intensidade e filtragem espacial. Os tópicos incluídos neste capítulo foram selecionados por seu valor como material fundamental que deve servir de base para uma área em constante evolução. Apesar de a maioria dos exemplos utilizados neste capítulo estar relacionada ao realce de imagens, as técnicas apresentadas são perfeitamente genéricas e serão retomadas ao longo dos capítulos seguintes em contextos não relacionados ao realce. No capítulo seguinte, voltaremos a analisar o processo de filtragem, mas utilizando conceitos do domínio da frequência. Veremos uma correspondência um a um entre os filtros espaciais lineares estudados aqui e os filtros no domínio da frequência.

## Referências e leituras complementares

O material apresentado na Seção 3.1 é proveniente de Gonzalez (1986). Leituras adicionais para o material da Seção 3.2 podem ser encontradas em Schowengerdt (1983), Poyton (1996) e Russ (1999). Veja também o artigo de Tsujii et al. (1998) sobre as otimização de monitores de imagens. Algumas referências sobre o pro-

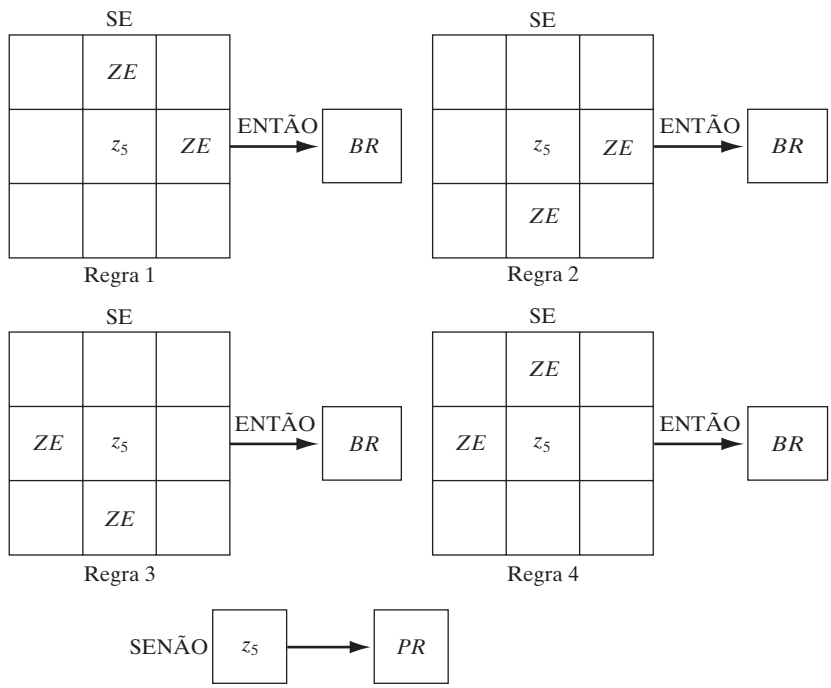



**Figura 3.58** Regras *fuzzy* para a detecção de fronteiras.

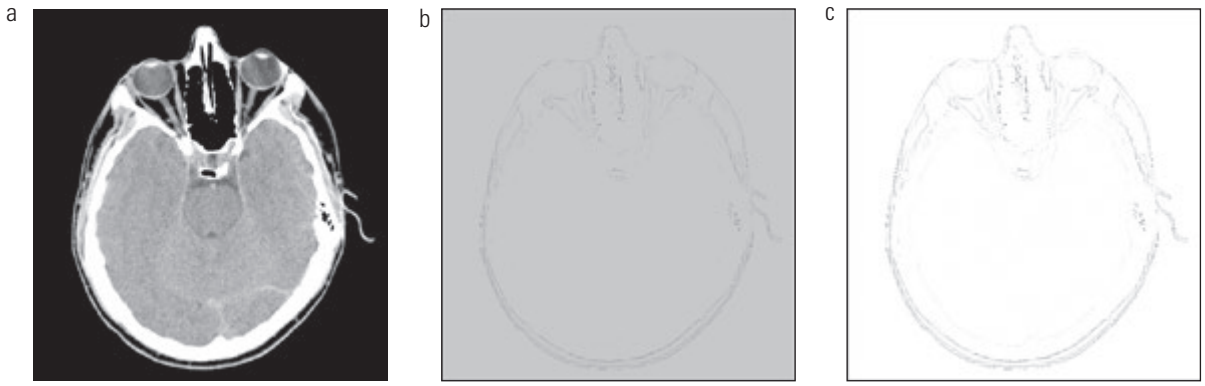



**Figura 3.59** (a) Tomografia computadorizada de uma cabeça humana. (b) Resultado da filtragem espacial *fuzzy* utilizando as funções de pertinência da Figura 3.57 e as regras da Figura 3.58. (c) Resultado após o ajuste de intensidade. Os quadros pretos delimitando a imagem em (b) e (c) foram acrescentados para facilitar a visualização e não fazem parte dos dados. (Imagem original: cortesia do Dr. David R. Pickens, Universidade de Vanderbilt.)

cessamento de histogramas são Hummel (1974), Gonzalez e Fittes (1977) e Woods e Gonzalez (1981). Stark (2000) apresenta generalizações interessantes da equalização de histogramas para realce de contraste adaptativo. Outras abordagens para o realce de contraste são exemplificadas por Centeno e Haertel (1997) e Cheng e Xu (2000). Para leituras adicionais sobre a especificação exata de histogramas, veja Coltuc, Bolon e Chassery (2006). Para extensões do método de equalização local de histograma, veja Caselles et al. (1999) e Zhu et al. (1999). Veja Narendra e Fitch (1981) sobre a utilização e implementação de estatísticas locais para o processamento de imagens. Kim et al. (1997) apresentam uma abordagem interessante combinando o gradiente com estatísticas locais para realce de imagens.

Para leituras adicionais sobre filtros espaciais lineares e sua implementação, veja Umbaugh (2005), Jain (1989) e Rosenfeld e Kak (1982). Filtros de ordenação (classificação) também são discutidos nessas referências. Wilburn (1998) analisa generalizações dos filtros de ordenação. O livro de Pitas e Venetsanopoulos (1990) também lida com o filtro de mediana e outros filtros espaciais não lineares. Uma edição especial de *IEEE Transactions in Image Processing* (1996) é dedicada ao processamento não linear de imagens. O material sobre filtragem *high-boost* é de Schowengerdt (1983). Retomaremos muitos dos filtros espaciais apresentados neste capítulo em discussões sobre a restauração de imagens (Capítulo 5) e detecção de bordas (Capítulo 10).

Referências fundamentais para a Seção 3.8 são três artigos sobre a lógica *fuzzy* de L. A. Zadeh (Zadeh, 1965, 1973, 1976). Esses artigos são muito bem escritos e vale a pena estudá-los em detalhes, já que estabeleceram os fundamentos para a lógica *fuzzy* e algumas de suas aplicações. Uma visão geral de uma ampla variedade de aplicações da lógica *fuzzy* no processamento de imagens pode ser encontrada no livro de Kerre e Nachtegael (2000). O exemplo da Seção 3.8.4 baseia-se em uma aplicação similar descrita por Tizhoosh (2000). O exemplo da Seção 3.8.5 é basicamente de Russo e Ramponi (1994). Para exemplos adicionais de aplicações dos conjuntos *fuzzy* às transformações de intensidade e filtragem de imagens, veja Patrascu (2004) e Nie e Barner (2006), respectivamente. Essas referências, que variam de 1965 a 2006, representam um bom ponto de partida para um estudo mais detalhado das várias formas nas quais os conjuntos *fuzzy* podem ser utilizados no processamento de imagens. A implementação computacional da maioria dos métodos discutidos neste capítulo pode ser encontrada em Gonzalez, Woods e Eddins (2004).

## Exercícios*

*3.1 Elabore uma função de transformação de intensidade para distribuir (expandir) as intensidades de uma imagem de forma que a menor intensidade seja 0, e a maior seja $L - 1$.

3.2 Exponenciais na forma $e^{-\alpha r^2}$, sendo $\alpha$ uma constante positiva, são úteis para construir funções de transformação de intensidade suaves. Comece com essa função básica e construa funções de transformação que tenham os formatos gerais mostrados nas figuras a seguir. As constantes mostradas são parâmetros de *entrada*, e suas transformações propostas devem incluí-las na especificação. (Para simplificar suas respostas, $L_0$ não é um parâmetro necessário na terceira curva.)

* Soluções detalhadas dos exercícios marcados com um asterisco podem ser encontradas no site do livro. O site também inclui projetos sugeridos com base no conteúdo deste capítulo.