Capítulo 5

Restauração e reconstrução de imagens

O que vemos não é necessariamente o que vemos…
É uma total incógnita para nós o que os objetos podem ser por si só e distantes da receptividade dos nossos sentidos. Não sabemos de nada além da nossa forma de percebê-los.
Immanuel Kant

Apresentação

Como no realce de imagens, o principal objetivo das técnicas de restauração é melhorar uma imagem em algum sentido predefinido. Apesar de haver áreas de sobreposição, o realce de imagens é principalmente um processo subjetivo, enquanto a restauração de imagens é, em grande parte, um processo objetivo. A restauração procura recuperar uma imagem corrompida com base em um conhecimento *a priori* do fenômeno de degradação. Dessa forma, as técnicas de restauração se orientam na direção da definição da degradação e da aplicação do processo inverso para recuperar a imagem original.

Essa abordagem normalmente envolve o desenvolvimento de critérios para definir o que seria uma imagem boa para estabelecer uma estimativa do resultado desejado. Por outro lado, as técnicas de realce basicamente consistem na elaboração de procedimentos heurísticos elaborados para manipular uma imagem beneficiando-se dos aspectos psicofísicos do sistema visual humano. Por exemplo, o alargamento do contraste é considerado uma técnica de realce por se basear principalmente nos aspectos agradáveis que pode apresentar ao observador, ao passo que a remoção do borramento de uma imagem ao aplicar uma função de redução de borramento (*deblurring*) é considerada uma técnica de restauração.

O material desenvolvido neste capítulo é estritamente introdutório. Analisamos o problema da restauração somente em relação a uma imagem digital degradada; dessa forma, abordaremos apenas superficialmente temas referentes à degradação de sensores, digitalizadores e monitores. Esses tópicos, apesar de serem importantes nas aplicações de restauração de imagens em geral, estão fora do escopo da presente análise.

Como vimos nos capítulos 3 e 4, algumas técnicas de restauração são mais bem formuladas no domínio espacial, ao passo que outras são mais adequadas ao domínio da frequência. Por exemplo, o processamento espacial é aplicável quando a única degradação é o ruído aditivo. Por outro lado, degradações como borramento de imagens são difíceis de solucionar no domínio espacial utilizando pequenas máscaras de filtragem. Nesse caso, os filtros no domínio da frequência baseados em vários critérios de otimização são as abordagens preferenciais. Esses filtros também levam em consideração a presença de ruído. Como visto no Capítulo 4, um filtro de restauração que soluciona uma determinada aplicação no domínio da frequência, muitas vezes, é utilizado como a base para desenvolver um filtro digital que será mais adequado para a operação de rotina utilizando uma implementação de hardware/firmware.

A Seção 5.1 apresenta um modelo linear do processo de degradação/restauração de imagens. A Seção 5.2 trata de vários modelos de ruído encontrados na prática. Na Seção 5.3, desenvolvemos várias técnicas de filtragem espacial para reduzir o conteúdo de ruído de uma imagem, um processo muitas vezes chamado de *denoising* de imagens. A Seção 5.4 é dedicada a métodos de redução de ruído utilizando técnicas do domínio da frequência. A Seção 5.5 apresenta modelos de degradação de imagens que são lineares e invariantes no espaço, e a Seção 5.6 apresenta métodos de estimativa de funções de degradação. As seções 5.7 a 5.10 incluem o desenvolvimento de metodologias fundamentais de restauração de imagens. Concluíremos o capítulo (Seção 5.11) com uma introdução à reconstrução de imagens a partir de projeções. A principal aplicação desse conceito é a tomografia computadorizada (CT), uma das mais importantes aplicações comerciais do processamento de imagens, especialmente na área da saúde.

5.1 Modelo de processo de degradação/restauração de imagens

Como mostra a Figura 5.1, o processo de degradação é formulado neste capítulo como uma função de degradação $f(x, y)$ que, com um termo de ruído aditivo, atua sobre uma imagem de entrada para produzir uma imagem degradada $g(x, y)$. Dado $g(x, y)$, algum conhecimento sobre a função de degradação H e algum conhecimento sobre o termo de ruído aditivo $\eta(x, y)$, o objetivo da restauração é obter uma estimativa $\hat{f}(x, y)$ da imagem original. Queremos que a estimativa esteja o mais próximo possível da imagem de entrada original, e, em geral, quanto mais sabemos sobre H e η, mais próximo $\hat{f}(x, y)$ estará de $f(x, y)$. A abordagem de restauração utilizada na maior parte deste capítulo se baseia em vários tipos de filtros de restauração de imagens.

Demonstraremos, na Seção 5.5, que, se H for um processo linear e invariante no espaço, a imagem degradada será determinada no *domínio espacial* por

$$g(x, y) = h(x, y) \star f(x, y) + \eta(x, y) \qquad (5.1\text{-}1)$$

na qual $h(x, y)$ é a representação espacial da função de degradação e, como no Capítulo 4, o símbolo $\star$ indica convolução. Sabemos, com base na análise da Seção 4.6.6, que a convolução no domínio espacial é análoga à multiplicação no domínio da frequência, então podemos expressar o modelo na Equação 5.1-1 em uma representação equivalente no *domínio da frequência*:

$$G(u, v) = H(u, v)F(u, v) + N(u, v) \qquad (5.1\text{-}2)$$

na qual os termos em letras maiúsculas representam as transformadas de Fourier dos termos correspondentes na Equação 5.1-1. Essas duas equações constituem as bases para a maior parte do conteúdo relativo à restauração desenvolvido neste capítulo.

Nas três seções seguintes, vamos considerar que H seja o operador identidade e que lidamos apenas com degradações em razão do ruído. A partir da Seção 5.6, analisaremos uma série de importantes funções de degradação de imagens e analisaremos vários métodos de restauração de imagens tanto na presença de H quanto na de η.

5.2 Modelos de ruído

As principais fontes de ruído em imagens digitais surgem durante a aquisição e/ou transmissão das imagens. O desempenho dos sensores de aquisição de imagens é afetado por uma série de fatores, como condições ambientais durante a aquisição da imagem e a qualidade dos elementos sensores em si. Por exemplo, na aquisição de imagens com uma câmera CCD, a iluminação e a temperatura do sensor são fatores importantes que afetam a quantidade de ruído da imagem resultante. As imagens são corrompidas durante a transmissão, principalmente em virtude de interferências no canal utilizado para a transmissão. Por exemplo, uma imagem transmitida utilizando uma rede sem fio (*wireless*) pode ser corrompida como resultado de relâmpagos ou outros distúrbios atmosféricos.

5.2.1 Propriedades espaciais e de frequência do ruído

Os parâmetros relevantes na nossa discussão são os que definem as características espaciais do ruído e se o ruído se correlaciona com a imagem. As propriedades de frequência se referem ao conteúdo de frequência do ruído no domínio de Fourier (isto é, em oposição à frequências do espectro eletromagnético). Por exemplo, quando o espectro de Fourier do ruído é constante, o ruído normalmente é chamado de *ruído branco*. Essa terminologia provém das propriedades físicas da luz branca, que contém aproximadamente todas as frequências no espectro visível nas mesmas proporções. Com base na discussão do Capítulo 4, não é difícil demonstrar que o espectro de Fourier de uma função cujas frequências tenham as mesmas proporções é uma constante.

Com a exceção do ruído periódico no domínio do espaço (Seção 5.2.3), presumimos, neste capítulo, que o ruído é independente das coordenadas espaciais e

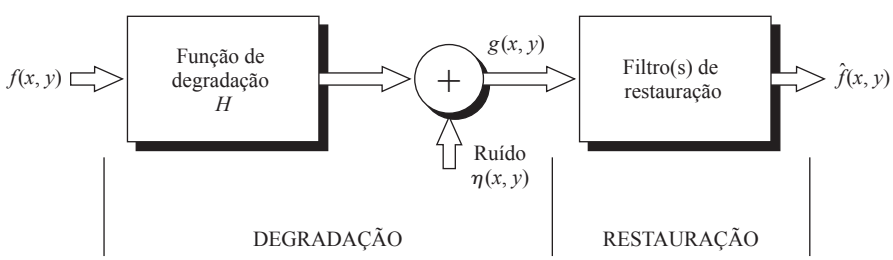


Figura 5.1 Modelo do processo de degradação/restauração de imagens.

que ele não se correlaciona com a imagem em si (isto é, não há correlação entre os valores de pixel e os valores dos componentes do ruído). Apesar de esses pressupostos serem pelo menos parcialmente inválidos em algumas aplicações (a aquisição de imagens com limitação quântica, como nos raios X e na medicina nuclear, é um bom exemplo disso), a complexidade de lidar com ruído correlacionado e espacialmente dependente não se inclui no escopo da nossa discussão.

5.2.2 Algumas importantes funções densidade de probabilidade de ruído

Com base nas premissas da seção anterior, o descritor de ruído *espacial* no qual nos concentraremos é o comportamento estatístico dos valores de intensidade no componente de ruído do modelo da Figura 5.1. Eles podem ser considerados variáveis aleatórias, caracterizados por uma função densidade de probabilidade (PDF, de *probability density function*). Apresentaremos a seguir as PDFs mais comuns encontradas em aplicações de processamento de imagens.*

Ruído gaussiano

Em função da possibilidade de manipulação matemática tanto no domínio do espaço quanto no da frequência, os modelos de ruído gaussiano (também chamados de *normais*) são bastante utilizados na prática. Na verdade, essa capacidade de manipulação é tão conveniente que muitas vezes resulta em modelos gaussianos que são utilizados em situações nas quais eles são, na melhor das hipóteses, marginalmente aplicáveis.

A PDF de uma variável aleatória gaussiana, z, é dada por

$$p(z) = \frac{1}{\sqrt{2\pi}\sigma} e^{-(z-\overline{z})^2/2\sigma^2} \tag{5.2-1}$$

na qual z representa intensidade, $\overline{z}$ é o valor médio** de z e σ é seu desvio padrão. O desvio padrão elevado ao quadrado, σ^2, é chamado de *variância* de z. A Figura 5.2(a) mostra um gráfico dessa função. Quando z é descrito pela Equação 5.2-1, aproximadamente 70% de seus valores estarão no intervalo $[(\overline{z} - \sigma), (\overline{z} + \sigma)]$. Cerca de 95% estarão no intervalo $[(\overline{z} - 2\sigma), (\overline{z} + 2\sigma)]$.

Ruído de Rayleigh

A PDF do ruído de Rayleigh é dada por

$$p(z) = \begin{cases} \dfrac{2}{b}(z-a)e^{-(z-a)^2/b} & \text{para } z \geq a \\ 0 & \text{para } z < a \end{cases} \tag{5.2-2}$$

A média e a variância dessa densidade são dadas por

$$\overline{z} = a + \sqrt{\pi b / 4} \tag{5.2-3}$$

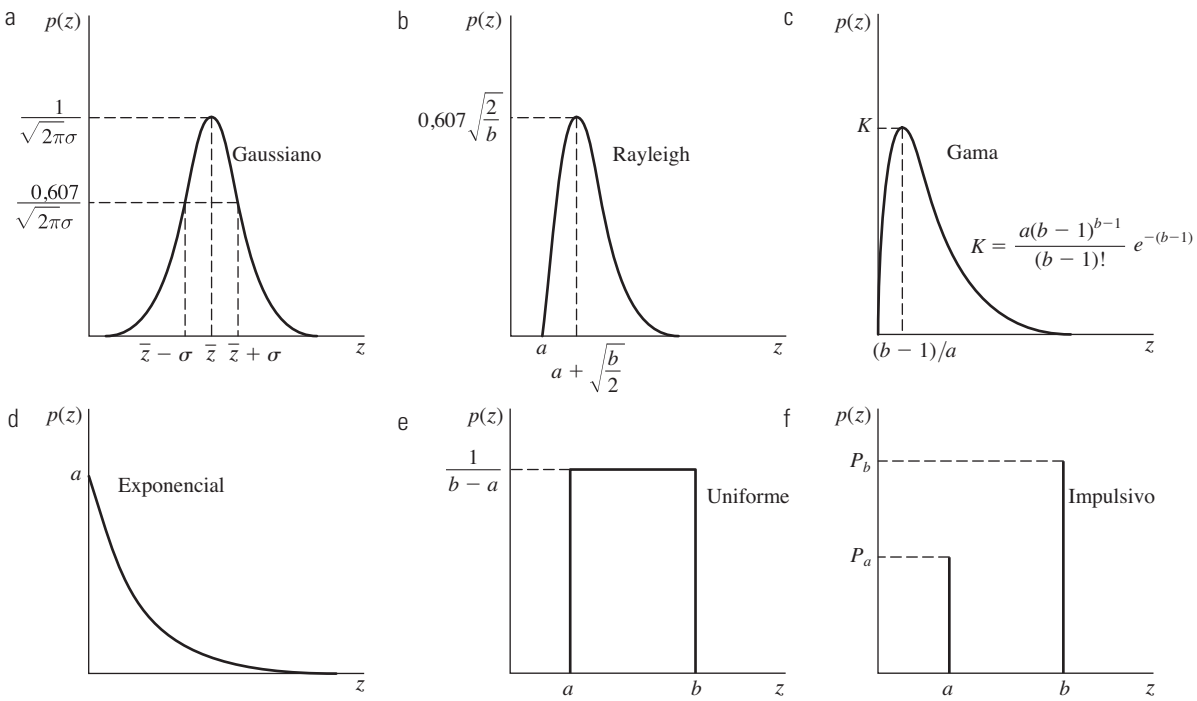


Figura 5.2 Algumas importantes funções densidade de probabilidade.

* Consulte o site do livro para uma breve revisão da teoria da probabilidade.

** Nesta seção, utilizamos $\overline{z}$ no lugar de m para expressar a média, visando evitar confusão quando utilizamos, mais adiante, m e n para expressar o tamanho da vizinhança.

e

$$\sigma^2 = \frac{b(4-\pi)}{4} \tag{5.2-4}$$

A Figura 5.2(b) mostra um gráfico da densidade de Rayleigh. Observe o deslocamento a partir da origem e o fato de que o formato básico dessa densidade é inclinado para a direita. A densidade de Rayleigh pode ser bastante útil para a aproximação de histogramas inclinados.

Ruído de Erlang (gama)

A PDF do ruído de Erlang é dada por

$$p(z) = \begin{cases} \dfrac{a^b z^{b-1}}{(b-1)!} e^{-az} & \text{para } z \geq 0 \\ 0 & \text{para } z < 0 \end{cases} \tag{5.2-5}$$

na qual os parâmetros são tais que $a > 0$, b é um inteiro positivo e "!" indica fatorial. A média e a variância dessa densidade são dadas por

$$\overline{z} = \frac{b}{a} \tag{5.2-6}$$

e

$$\sigma^2 = \frac{b}{a^2} \tag{5.2-7}$$

A Figura 5.2(c) mostra um gráfico dessa densidade. Apesar de a Equação 5.2-5 muitas vezes ser chamada de *densidade gama*, estritamente falando isso só é correto quando o denominador for a função gama, $\Gamma(b)$. Quando o denominador for como mostrado, é mais apropriado se referir à densidade como *densidade de Erlang*.

Ruído exponencial

A PDF do ruído *exponencial* é dada por

$$p(z) = \begin{cases} ae^{-az} & \text{para } z \geq 0 \\ 0 & \text{para } z < 0 \end{cases} \tag{5.2-8}$$

sendo $a > 0$. A média e a variância dessa função densidade são

$$\overline{z} = \frac{1}{a} \tag{5.2-9}$$

e

$$\sigma^2 = \frac{1}{a^2} \tag{5.2-10}$$

Observe que essa PDF é um caso especial da PDF de Erlang, com $b = 1$. A Figura 5.2(d) mostra um gráfico dessa função densidade.

Ruído uniforme

A PDF do ruído *uniforme* é dada por

$$p(z) = \begin{cases} \dfrac{1}{b-a} & \text{se a} \leq z \leq b \\ 0 & \text{se não} \end{cases} \tag{5.2-11}$$

A média dessa função densidade é dada por

$$\overline{z} = \frac{a+b}{2} \tag{5.2-12}$$

e sua variância, por

$$\sigma^2 = \frac{(b-a)^2}{12} \tag{5.2-13}$$

A Figura 5.2(e) mostra um gráfico da densidade uniforme.

Ruído impulsivo (sal e pimenta)

A PDF do ruído de *impulsivo* (*bipolar*) é dada por

$$p(z) = \begin{cases} P_a & \text{para } z = a \\ P_b & \text{para } z = b \\ 0 & \text{se não} \end{cases} \tag{5.2-14}$$

Se $b > a$, a intensidade b aparecerá como um ponto claro na imagem. Por outro lado, o nível a aparecerá como um ponto escuro. Se P_a ou P_b for zero, o ruído impulsivo é chamado de *unipolar*. Se nenhuma probabilidade for zero, e especialmente se elas foram aproximadamente iguais, os valores do ruído impulsivo se assemelharão a grãos de sal e pimenta aleatoriamente distribuídos pela imagem. Por essa razão, o ruído impulsivo bipolar também é chamado de ruído *sal e pimenta*. Ruído *data-drop-out* e ruído *spike* também são termos utilizados para se referir a esse tipo de ruído. Utilizaremos os termos ruído *impulsivo* ou *sal e pimenta* de forma intercambiável.

Os impulsos de ruído podem ser negativos ou positivos. Geralmente, o processo de digitalização inclui um ajuste de intensidades na imagem. Como a corrupção gerada pelo ruído impulsivo normalmente é grande em comparação com a intensidade do sinal da imagem, o ruído impulsivo normalmente é digitalizado como valores extremos de intensidade (preto ou branco puros) em uma imagem. Dessa forma, costuma-se presumir que a e b são valores "saturados", no sentido de serem iguais aos valores mínimo e máximo permitidos na imagem digitalizada. Como resultado, impulsos negativos aparecem como pontos pretos (pimenta) em uma imagem. Pela mesma razão, impulsos positivos aparecem como pontos brancos (sal). Para uma imagem de 8 bits, isso normal-

mente significa que $a = 0$ (preto) e $b = 225$ (branco). A Figura 5.2(f) mostra a PDF do ruído impulsivo.

Como um grupo, as PDFs apresentadas anteriormente proporcionam ferramentas úteis para formular uma ampla variedade de situações de corrupção por ruído encontradas na prática. Por exemplo, o ruído gaussiano surge em uma imagem em decorrência de fatores como, por exemplo, o ruído de circuitos eletrônicos e o ruído dos sensores de imagem em virtude de iluminação insuficiente e/ou alta temperatura. A densidade de Rayleigh é útil na caracterização dos fenômenos de ruído na aquisição de imagens de profundidade (*range imaging*). As densidades exponencial e gama encontram aplicação na aquisição de imagens por laser. O ruído impulsivo é encontrado em situações nas quais transientes rápidos, como problemas de chaveamento, ocorrem durante a aquisição da imagem, como mencionamos no parágrafo anterior. A densidade uniforme é talvez a que menos descreve as situações práticas. No entanto, a densidade uniforme é bastante útil como base para vários geradores de números aleatórios utilizados em simulações [Peebles (1993) e Gonzalez, Woods e Eddins (2004)].

■

Exemplo 5.1 Imagens com ruído e seus histogramas.

A Figura 5.3 mostra um padrão de teste bastante apropriado para ilustrar os modelos de ruído que acabamos de discutir. Trata-se de um padrão apropriado para utilização por ser composto de áreas simples e constantes que abrangem toda a escala de cinza, do preto ao quase branco em apenas três incrementos. Isso facilita a análise visual das características dos vários componentes de ruído adicionados à imagem.

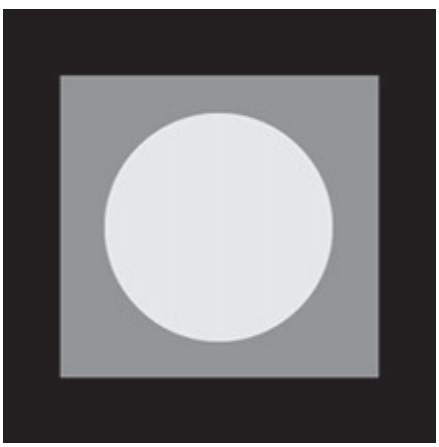


Figura 5.3 Padrão de teste utilizado para ilustrar as características das PDFs de ruído mostradas na Figura 5.2.

A Figura 5.4 mostra o padrão de teste após o acréscimo dos seis tipos de ruído discutidos até agora nesta seção. Mostrado sob cada imagem está o histograma calculado diretamente a partir dessa imagem. Os parâmetros do ruído foram escolhidos em cada caso, de forma que o histograma correspondente aos três níveis de intensidade no padrão de teste começaria a se mesclar. Isso fez com que o ruído fosse bastante visível, sem obscurecer a estrutura básica da imagem original.

Observamos uma estreita correspondência na comparação dos histogramas da Figura 5.4 com as PDFs da Figura 5.2. O histograma para o exemplo de sal e pimenta tem um pico extra na extremidade branca da escala de intensidade porque os componentes de ruído são preto e branco puros, e o componente mais claro do padrão de teste (o círculo) é cinza-claro. Com a exceção de uma intensidade geral ligeiramente diferente, é difícil diferenciar visualmente entre as primeiras cinco imagens da Figura 5.4, apesar de seus histogramas serem significativamente diferentes. A aparência sal e pimenta da imagem corrompida pelo ruído impulsivo é a única que é visualmente indicativa do tipo de ruído que causa a degradação.

■

5.2.3 Ruído periódico

O ruído periódico em uma imagem normalmente resulta de interferência elétrica ou eletromecânica durante a aquisição da imagem. Esse é o único tipo de ruído espacialmente dependente que será considerado neste capítulo. Como veremos na Seção 5.4, o ruído periódico pode ser reduzido significativamente por meio da filtragem no domínio da frequência. Vejamos, por exemplo, imagem da Figura 5.5(a). Essa imagem é gravemente corrompida pelo ruído senoidal (espacial) de várias frequências. A transformada de Fourier de uma senoide pura é um par de impulsos* conjugados, localizados nas frequências conjugadas da onda senoidal (Tabela 4.3). Dessa forma, se a amplitude de uma onda senoidal no domínio do espaço for suficientemente alta, poderíamos ver, no espectro da imagem, um par de impulsos para cada onda senoidal presente na imagem. Como mostra a Figura 5.5(b), de fato é o que acontece com os impulsos aparecendo aproximadamente como um círculo porque os valores de frequência neste caso particular estão dispostos dessa forma. Teremos muito mais a dizer na Seção 5.4 sobre este e outros exemplos de ruído periódico.

* Tome cuidado para não confundir o termo impulso da frequência com a utilização do mesmo termo no contexto do ruído de impulso.

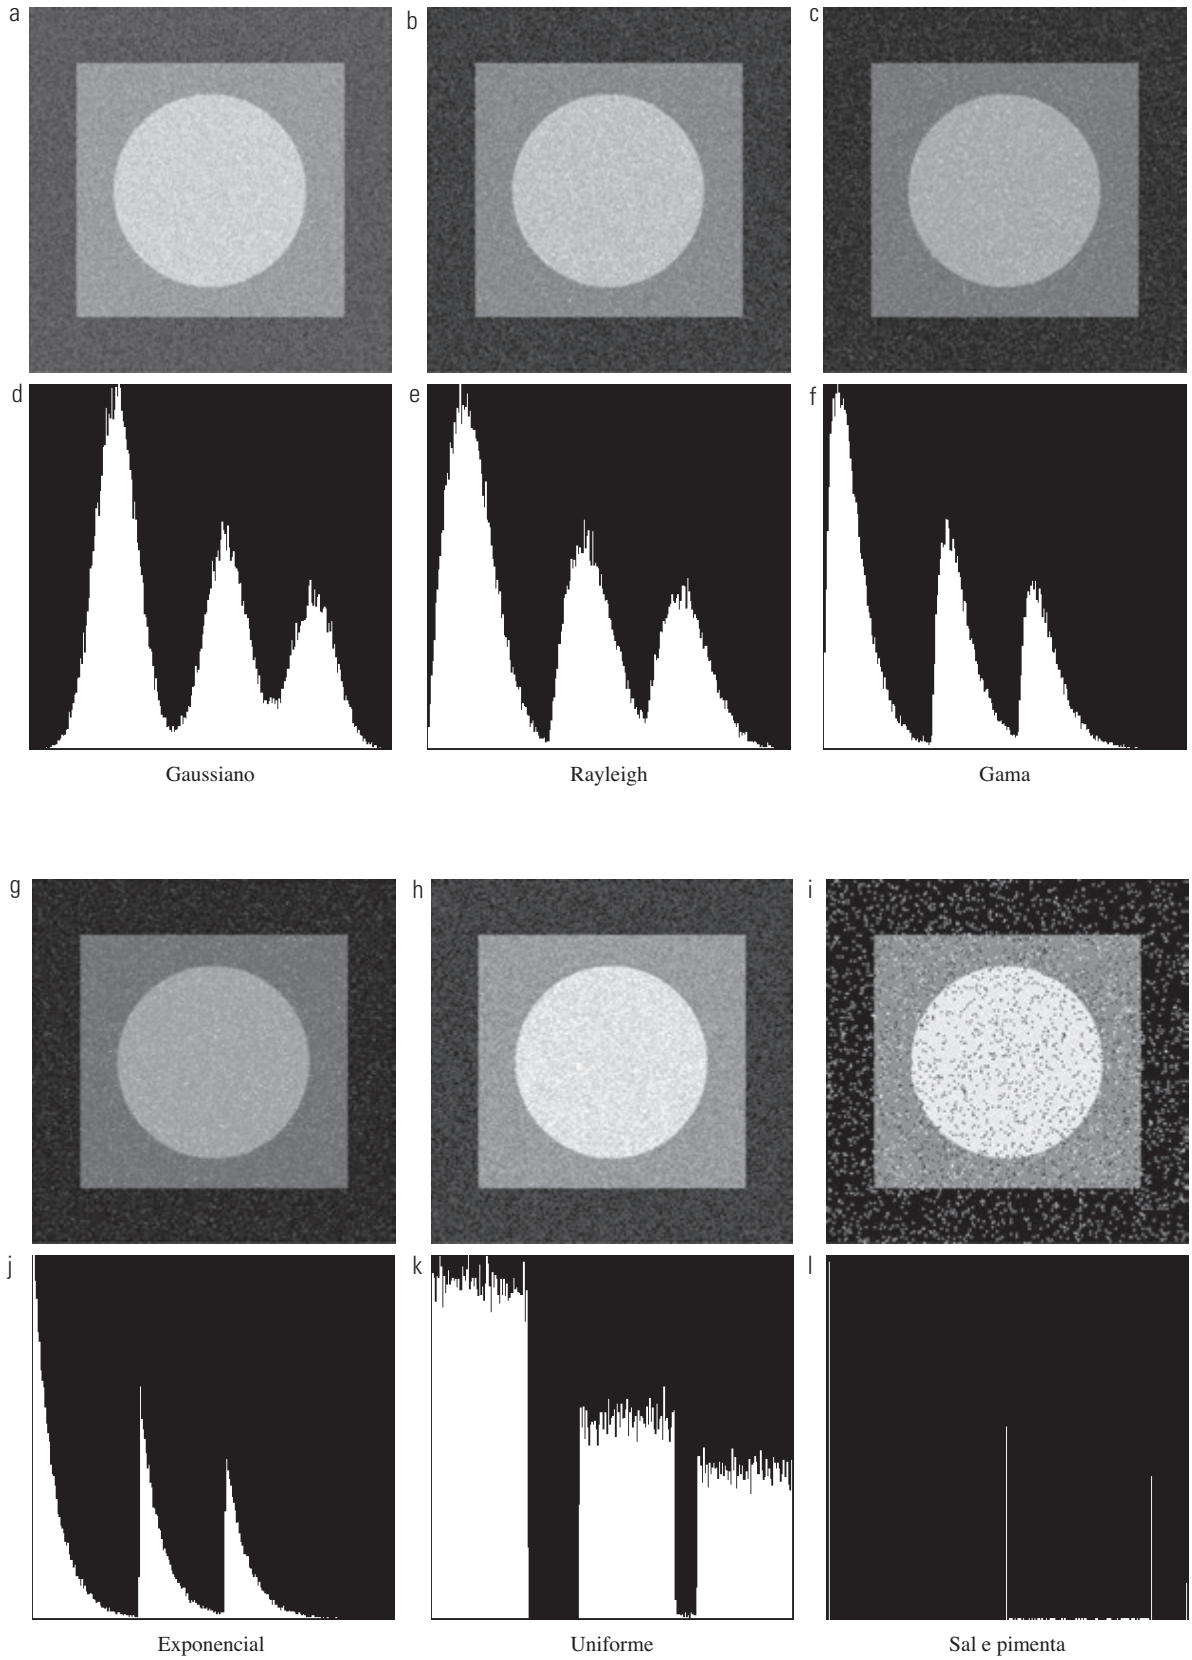


Figura 5.4 (a) a (f) Imagens e histogramas resultantes do acréscimo do ruído gaussiano, de Rayleigh e gama à imagem da Figura 5.3. (g) a (l) Imagens e histogramas resultantes do acréscimo do ruído exponencial, uniforme e sal e pimenta à imagem da Figura 5.3.

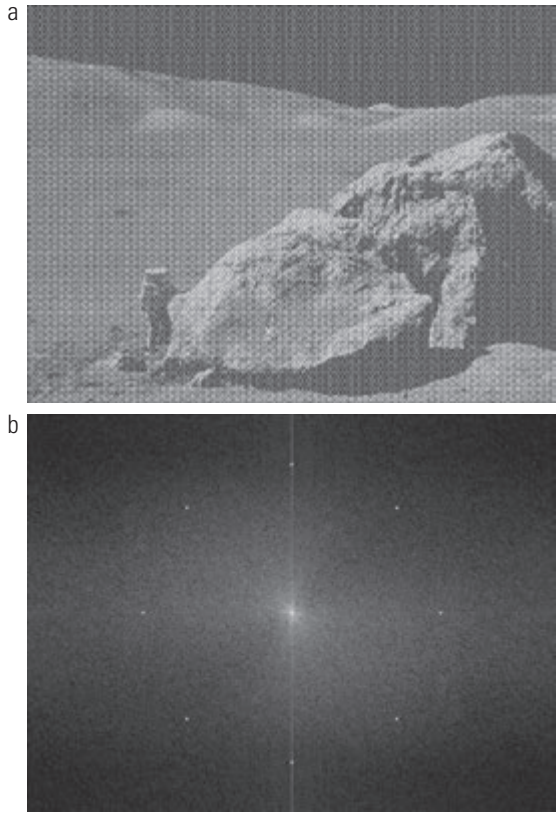


Figura 5.5 (a) Imagem corrompida pelo ruído senoidal. (b) Espectro (cada par de impulsos conjugados corresponde a uma onda senoidal). (Imagem original: cortesia da Nasa.)

5.2.4 Estimativa de parâmetros de ruído

Os parâmetros do ruído periódico normalmente são estimados por meio da inspeção do espectro de Fourier da imagem. Como observamos na seção anterior, o ruído periódico tende a produzir picos de frequência que muitas vezes podem ser detectados até por análise visual. Uma outra abordagem é tentar inferir a periodicidade dos componentes do ruído diretamente a partir da imagem, mas isso só é possível em casos mais simples.

A análise automatizada é possível em situações nas quais os picos de ruído são excepcionalmente acentuados ou quando se tem conhecimento da localização dos componentes de frequência da interferência.

Os parâmetros das PDFs de ruído podem ser parcialmente conhecidos a partir de especificações do sensor, mas costuma ser necessário estimá-los para um arranjo particular de aquisição de imagens. Se o sistema de aquisição de imagens estiver disponível, um modo simples de estudar as características do ruído do sistema é coletando um conjunto de imagens em ambientes "uniformes". Por exemplo, no caso de um sensor ótico, isso é tão simples quanto adquirir a imagem de um painel cinza sólido uniformemente iluminado. As imagens resultantes costumam ser bons indicativos do ruído do sistema.

Quando somente imagens que já foram geradas por um sensor estiverem disponíveis, costuma ser possível estimar os parâmetros da PDF a partir de pequenas áreas de intensidade razoavelmente constante do fundo da imagem. Por exemplo, as faixas verticais (de 150 × 20 pixels) mostradas na Figura 5.6 foram recortadas das imagens gaussiana, de Rayleigh e uniforme da Figura 5.4. Os histogramas mostrados foram calculados utilizando dados de imagens dessas pequenas faixas. Os histogramas da Figura 5.4 que correspondem aos histogramas da Figura 5.6 são os histogramas centrais do grupo de três nas figuras 5.4(d), (e) e (k). Vemos que os formatos desses histogramas correspondem de modo bastante aproximado aos formatos dos histogramas da Figura 5.6. Suas alturas diferem em decorrência do ajuste de escala, mas os formatos são claramente similares.

A utilização mais simples dos dados obtidos das faixas de imagem é para o cálculo da média e da variância

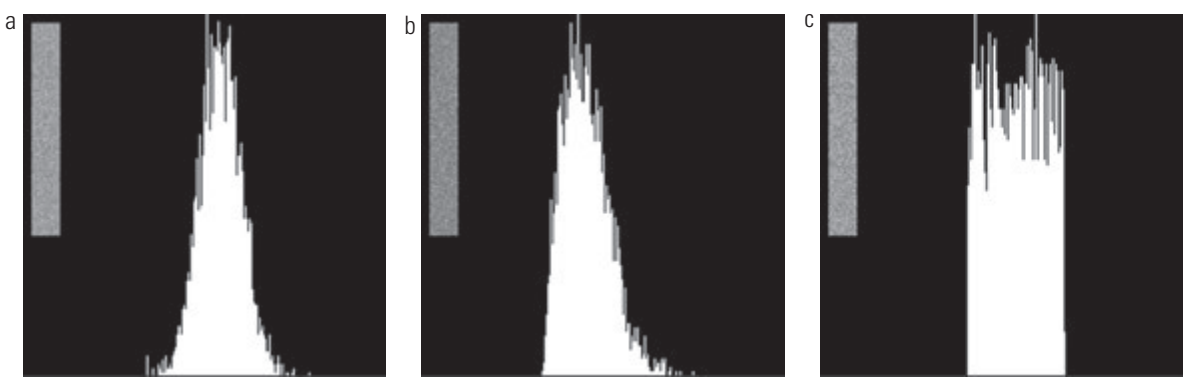


Figura 5.6 Histogramas calculados utilizando pequenas faixas (mostradas à esquerda) da imagem com ruído (a) gaussiano, (b) de Rayleigh e (c) uniforme na Figura 5.4.

dos níveis de intensidade. Consideremos uma faixa (subimagem) expressa por S, com $p_S(z_i)$, $i = 0, 1, 2, ..., L - 1$, expressando as estimativas de probabilidade (valores normalizados de histograma) das intensidades dos pixels em S, onde L é o número de intensidades possíveis em toda a imagem (por exemplo, 256 para uma imagem de 8 bits). Como fizemos no Capítulo 3, estimamos a média e a variância dos pixels em S como se segue:

$$\overline{z} = \sum_{i=0}^{L-1} z_i p_S(z_i) \tag{5.2-15}$$

e

$$\sigma^2 = \sum_{i=0}^{L-1} (z_i - \overline{z})^2 p_S(z_i) \tag{5.2-16}$$

O formato do histograma identifica a melhor correspondência com uma PDF. Se o formato for aproximadamente gaussiano, só precisamos da média e da variância porque a PDF gaussiana é totalmente especificada por esses dois parâmetros. Para os outros formatos discutidos na Seção 5.2.2, utilizamos a média e a variância para calcular os parâmetros a e b. O ruído impulsivo é calculado de modo diferente porque a estimativa necessária é da probabilidade real de ocorrência de pixels brancos e pretos. Obter essa estimativa requer que tanto os pixels pretos quanto os brancos sejam visíveis, de forma que uma área cinza médio relativamente constante é necessária na imagem para poder calcular um histograma. As alturas dos picos correspondentes aos pixels preto e branco são as estimativas de P_a e P_b na Equação 5.2-14.

5.3 Restauração na presença somente de ruído — filtragem espacial

Quando a única degradação presente em uma imagem for o ruído, as equações 5.1-1 e 5.1-2 se tornam

$$g(x, y) = f(x, y) + \eta(x, y) \tag{5.3-1}$$

e

$$G(u, v) = F(u, v) + N(u, v) \tag{5.3-2}$$

Os termos do ruído são desconhecidos, de forma que subtraí-los de $g(x, y)$ ou $G(u, v)$ não é uma opção realista. No caso do ruído periódico, costuma ser possível estimar $N(u, v)$ a partir do espectro de $G(u, v)$, como observamos na Seção 5.2.3. Neste caso, $N(u, v)$ pode ser subtraído de $G(u, v)$ para obter uma estimativa da imagem original. Em geral, contudo, esse tipo de conhecimento é a exceção, e não a regra.

A filtragem espacial é o método preferido em situações nas quais somente o ruído aleatório aditivo estiver presente. Discutimos a filtragem espacial em detalhes no Capítulo 3. Com exceção da natureza do cálculo realizado por um filtro específico, o método para implementar todos os filtros que se seguem são exatamente como vimos nas seções 3.4 a 3.6.

5.3.1 Filtros de média

Nesta seção, analisaremos rapidamente os recursos de redução de ruídos dos filtros espaciais apresentados na Seção 3.5 e desenvolveremos vários outros filtros cujo desempenho é, em muitos casos, superior ao dos filtros discutidos naquela seção.

Filtro de média aritmética

Este é o mais simples dos filtros de média. Seja S_{xy} o conjunto de coordenadas em uma janela de subimagem retangular (vizinhança) de tamanho $m \times n$, centrada no ponto (x, y).* O filtro de média aritmética calcula o valor médio da imagem corrompida $g(x, y)$ na área definida por S_{xy}. O valor da imagem restaurada $\hat{f}$ no ponto (x, y) é simplesmente a média aritmética calculada utilizando os pixels da região definida por S_{xy}. Em outras palavras,

$$\hat{f}(x, y) = \frac{1}{mn} \sum_{(s,t) \in S_{xy}} g(s, t) \tag{5.3-3}$$

Essa operação pode ser implementada utilizando um filtro espacial de tamanho $m \times n$ no qual todos os coeficientes apresentam valor $1/mn$. Um filtro de média atenua variações locais em uma imagem, e o ruído é reduzido em consequência do borramento.

Filtro de média geométrica

Uma imagem restaurada utilizando um filtro de *média geométrica* é dada pela expressão

$$\hat{f}(x, y) = \left[\prod_{(s,t) \in S_{xy}} g(s, t) \right]^{\frac{1}{mn}} \tag{5.3-4}$$

Aqui, cada pixel restaurado é determinado pelo produto dos pixels na janela de subimagem, elevado à potência de $1/mn$. Como mostrado no Exemplo 5.2, um filtro de média geométrica obtém uma suavização comparável ao filtro de média aritmética, mas tende a perder menos detalhes da imagem no processo.

Filtro de média harmônica

A operação de filtragem de *média harmônica* é determinada pela expressão

$$\hat{f}(x, y) = \frac{mn}{\sum_{(s,t) \in S_{xy}} \frac{1}{g(s, t)}} \tag{5.3-5}$$

* Consideramos que m e n são números inteiros ímpares.

O filtro de média harmônica funciona bem para o ruído de sal, mas falha para o ruído de pimenta. Ele também apresenta um bom desempenho com outros tipos de ruído, como o gaussiano.

Filtro de média contra-harmônica

O filtro de média *contra-harmônica* leva a uma imagem restaurada com base na expressão

$$\hat{f}(x,y)=\frac{\sum_{(s,t)\in S_{xy}} g(s,t)^{Q+1}}{\sum_{(s,t)\in S_{xy}} g(s,t)^{Q}} \qquad (5.3\text{-}6)$$

na qual Q é chamado de *ordem* do filtro. Esse filtro é apropriado para reduzir ou praticamente eliminar os efeitos do ruído sal e pimenta. Para valores positivos de Q, o filtro elimina o ruído de pimenta. Para valores negativos de Q, ele elimina o ruído de sal. Ele não pode fazer as duas coisas simultaneamente. Observe que o filtro contra-harmônico é reduzido ao filtro de média aritmética se $Q = 0$ e ao filtro de média harmônica se $Q = -1$.

■

Exemplo 5.2 Ilustração de filtros de média.

A Figura 5.7(a) mostra uma imagem radiográfica de 8 bits de uma placa de circuito e a Figura 5.7(b) mostra a mesma imagem, porém corrompida pelo ruído aditivo gaussiano de média zero e variância 400. Para esse tipo de imagem, trata-se de um nível significativo de ruído. As figuras 5.7(c) e (d) mostram, respectivamente, o resultado da filtragem da imagem com ruído utilizando um filtro de média aritmética de tamanho 3 × 3 e um filtro de média geométrica de mesmo tamanho. Apesar de os dois filtros apresentarem um desempenho razoável na atenuação do ruído, o filtro de média geométrica não borrou a imagem tanto quanto o filtro de média aritmética. Por exemplo, as trilhas do conector na parte superior da imagem são mais nítidas na Figura 5.7(d) do que em c. O mesmo se aplica a outras partes da imagem.

A Figura 5.8(a) mostra a mesma imagem do circuito impresso, mas dessa vez corrompida pelo ruído de pimenta com probabilidade de 0,1. De forma similar, a Figura 5.8(b) mostra a imagem corrompida por ruído de sal com a mesma probabilidade. A Figura 5.8(c) mostra o resultado da filtragem da Figura 5.8(a) utilizando um filtro de média contra-harmônica com $Q = 1,5$, e a Figura 5.8(d) mostra o resultado

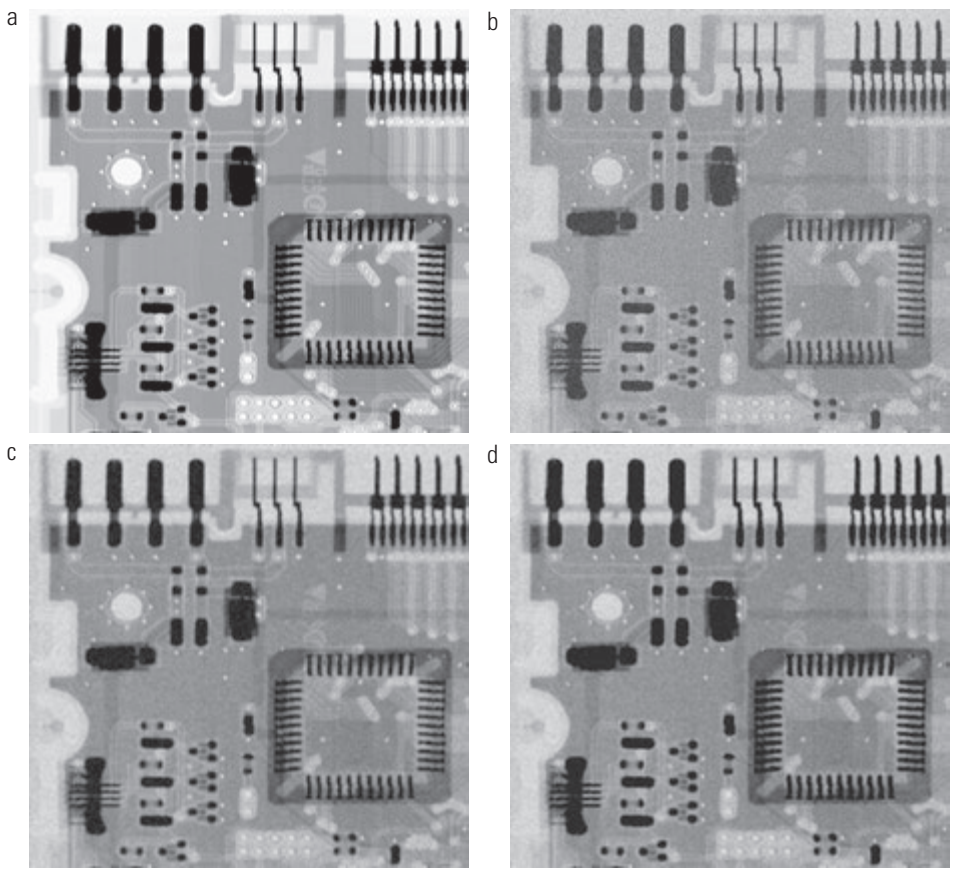


Figura 5.7 (a) Imagem radiográfica. (b) Imagem corrompida pelo ruído aditivo gaussiano. (c) Resultado da filtragem com um filtro de média aritmética de tamanho 3 × 3. (d) Resultado da filtragem com um filtro de média geométrica do mesmo tamanho. (Imagem original: cortesia do Dr. Joseph E. Pascente, Lixi, Inc.)

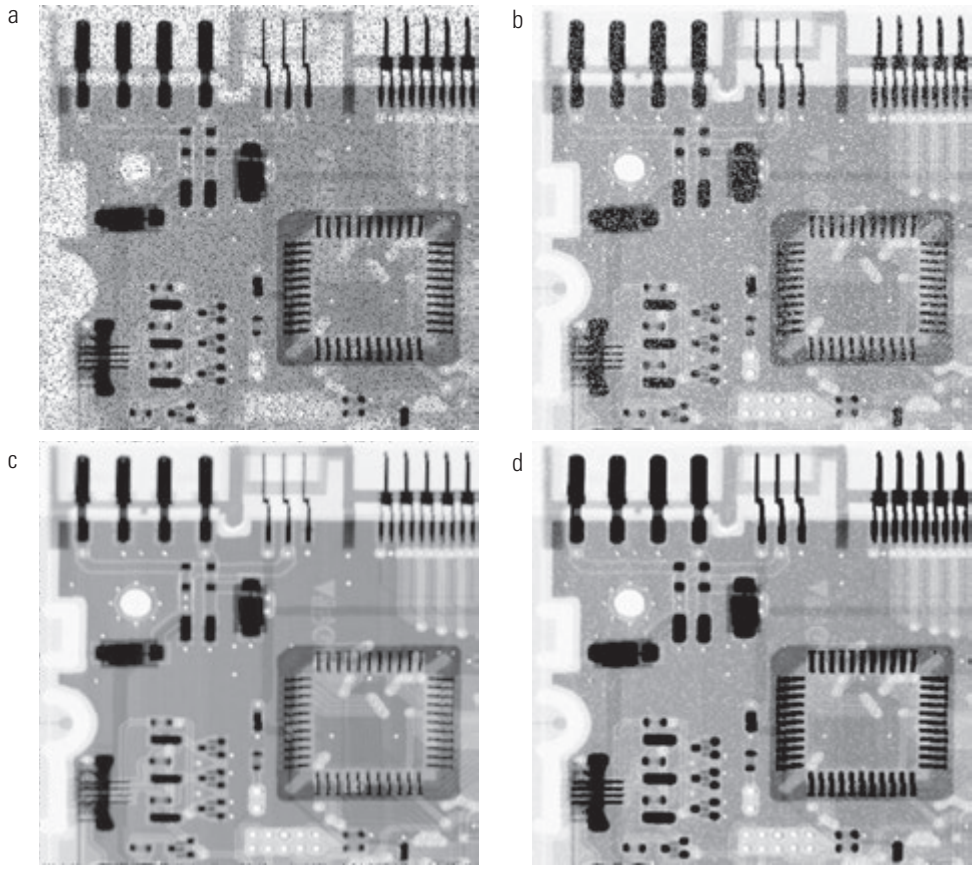


Figura 5.8 (a) Imagem corrompida por ruído de pimenta com probabilidade de 0,1. (b) Imagem corrompida por ruído de sal com a mesma probabilidade. (c) Resultado da filtragem de (a) com um filtro contra-harmônico 3 × 3 de ordem 1,5. (d) Resultado da filtragem de (b) com Q = –1,5.

da filtragem da Figura 5.8(b) com $Q = -1{,}5$. Os dois filtros apresentaram um bom desempenho na redução do efeito do ruído. O filtro de ordem positiva apresentou um desempenho melhor na limpeza do fundo da imagem, à custa de um ligeiro afinamento e borramento das áreas escuras. O oposto se aplica ao filtro de ordem negativa.

Em geral os filtros de média aritmética e geométrica (particularmente o último) são adequados para o ruído aleatório, como o gaussiano ou o uniforme. O filtro contra-harmônico é apropriado para o ruído impulsivo, mas tem a desvantagem de que é necessário saber se o ruído é escuro ou claro para selecionar o sinal adequado de Q. Os resultados da escolha do sinal errado para Q podem ser desastrosos, como mostra a Figura 5.9. Alguns dos filtros discutidos nas seções a seguir eliminam esse problema.

■

5.3.2 Filtros de estatística de ordem

Os filtros de estatística de ordem foram apresentados na Seção 3.5.2. Agora expandiremos a discussão nessa seção e apresentaremos alguns filtros adicionais de estatística de ordem. Como observamos na Seção 3.5.2, os filtros de estatística de ordem são filtros espaciais cuja resposta se baseia na ordenação (classificação) dos valores dos pixels contidos na área da imagem coberta pelo filtro. O resultado da classificação determina a resposta do filtro.

Filtro de mediana

O filtro de estatística de ordem mais conhecido é o *filtro de mediana*, que, como o nome sugere, substitui o valor de um pixel pela mediana dos níveis de intensidade na vizinhança desse pixel:

$$\hat{f}(x,y) = \underset{(s,t)\in S_{xy}}{\text{mediana}} \{g(s,t)\} \qquad (5.3\text{-}7)$$

O valor do pixel em (x, y) é incluído no cálculo da mediana. Os filtros de mediana são bastante populares porque, para certos tipos de ruído aleatório, eles proporcionam excelentes recursos de redução de ruído, com consideravelmente menos borramento do que os filtros lineares de suavização de tamanho similar. Os filtros de mediana são particularmente eficazes na presença do ruído tanto impulsivo bipolar quanto unipolar. Com efeito, como demonstra o Exemplo 5.3, o filtro de mediana gera excelentes resultados para imagens corrompidas por esse tipo de ruído. O cálculo da mediana e a implementação desse filtro foram discutidos na Seção 3.5.2.

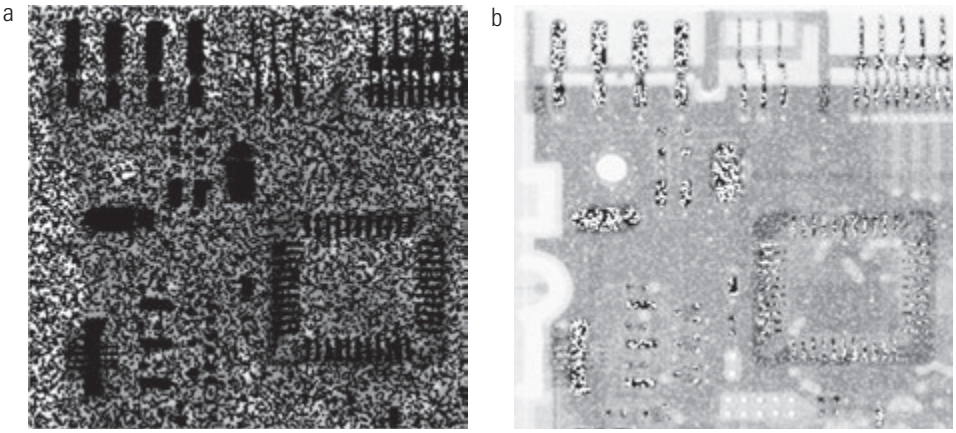


Figura 5.9 Resultados da seleção do sinal errado na filtragem contra-harmônica. (a) Resultado da filtragem da Figura 5.8(a) com filtro contra-harmônico de tamanho 3 × 3 e $Q = -1{,}5$. (b) Resultado da filtragem da Figura 5.8(b) com $Q = 1{,}5$.

Filtros de máximo e de mínimo

Apesar de o filtro de mediana ser o filtro de estatística de ordem mais utilizado no processamento de imagens, ele não é o único. A mediana representa o 50º percentil de um conjunto ordenado de números, mas você deve se lembrar, com base nos fundamentos da estatística, que a classificação tem muitas outras possibilidades. Por exemplo, utilizar o 100º percentil resulta no chamado *filtro de máximo*, dado por

$$\hat{f}(x,y) = \max_{(s,t)\in S_{xy}} \{g(s,t)\} \qquad (5.3\text{-}8)$$

Esse filtro é útil para localizar os pontos mais claros de uma imagem. Além disso, como o ruído de pimenta tem valores muito baixos, ele é reduzido por esse filtro como um resultado do processo de seleção do valor máximo na área da subimagem S_{xy}.

O filtro do 0º percentil é o *filtro de mínimo*:

$$\hat{f}(x,y) = \min_{(s,t)\in S_{xy}} \{g(s,t)\} \qquad (5.3\text{-}9)$$

Esse filtro é útil para encontrar os pontos mais escuros de uma imagem. Além disso, ele reduz o ruído de sal como um resultado da operação de selecionar o valor mínimo.

Filtro de ponto médio

O filtro de ponto médio simplesmente calcula o ponto médio entre os valores máximo e mínimo na área englobada pelo filtro:

$$\hat{f}(x,y) = \frac{1}{2}\left[\max_{(s,t)\in S_{xy}} \{g(s,t)\} + \min_{(s,t)\in S_{xy}} \{g(s,t)\}\right] \qquad (5.3\text{-}10)$$

Observe que esse filtro combina a estatística de ordem e a média. Ele funciona melhor para um ruído aleatoriamente distribuído, como o ruído gaussiano ou o uniforme.

Filtro de média alfa cortada

Suponha que sejam excluídos os valores de intensidade $d/2$ mais baixos e $d/2$ mais altos de $g(s, t)$ na vizinhança S_{xy}. Temos $g_r(s, t)$ representando os $mn - d$ pixels restantes. Um filtro formado pela média desses $mn - d$ pixels restantes é chamado de filtro de *média alfa cortada*:

$$\hat{f}(x,y) = \frac{1}{mn-d} \sum_{(s,t)\in S_{xy}} g_r(s,t) \qquad (5.3\text{-}11)$$

no qual o valor de d pode variar de 0 a $mn - 1$. Quando $d = 0$, o filtro alfa cortada é reduzido ao filtro de média aritmética discutido na seção anterior. Se escolhermos $d = mn - 1$, o filtro se torna um filtro de mediana. Para outros valores de d, o filtro alfa cortado é útil em situações envolvendo múltiplos tipos de ruído, como uma combinação de ruído sal e pimenta e gaussiano.

■

Exemplo 5.3 Ilustração de filtros de estatística de ordem.

A Figura 5.10(a) mostra a imagem da placa de circuito corrompida pelo ruído sal e pimenta com probabilidades $P_a = P_b = 0{,}1$. A Figura 5.10(b) mostra o resultado da filtragem de mediana com um filtro de tamanho 3 × 3. A melhora em relação à Figura 5.10(a) é significativa, mas vários pontos de ruído ainda são visíveis. Uma segunda passagem (na imagem da Figura 5.10(b)) pelo filtro de mediana removeu a maioria desses pontos, deixando apenas alguns poucos pontos de ruído que mal são visíveis. Eles foram removidos por uma terceira passagem do filtro. Esses resultados são bons exemplos do poder da filtragem de mediana para lidar com ruído aditivo impulsivo. Tenha em mente que passagens repetidas de um filtro de mediana borrarão a imagem, de forma que é desejável manter o número de passagens no mínimo possível.

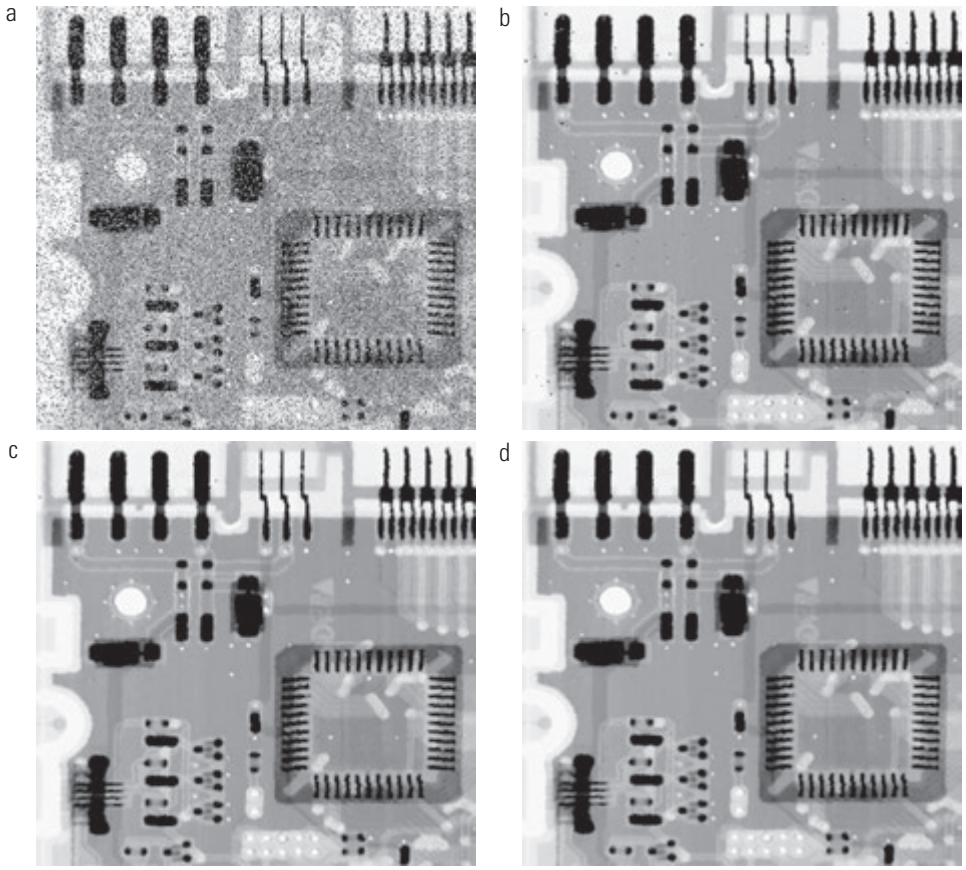


Figura 5.10 (a) Imagem corrompida pelo ruído sal e pimenta com probabilidades $P_a = P_b = 0{,}1$. (b) Resultado de uma passagem de um filtro de mediana de tamanho 3 × 3. (c) Resultado do processamento de (b) com esse filtro. (d) Resultado do processamento de (c) com o mesmo filtro.

A Figura 5.11(a) mostra o resultado da aplicação do filtro de máximo à imagem com ruído de pimenta da Figura 5.8(a). O filtro apresentou um desempenho razoável removendo o ruído de pimenta, mas notamos que ele também removeu (ajustou em um nível de intensidade clara) alguns pixels escuros dos contornos dos objetos escuros. A Figura 5.11(b) mostra o resultado da aplicação do filtro de mínimo à imagem da Figura 5.8(b). Neste caso, o filtro de mínimo apresentou um desempenho melhor do que o filtro de máximo na remoção do ruído, mas removeu alguns pontos brancos do contorno de objetos claros. Isso fez com que os objetos mais claros ficassem menores e alguns dos objetos escuros ficassem maiores (como as trilhas do conector no alto da imagem) porque os pontos brancos ao redor desses objetos foram ajustados em um nível escuro.

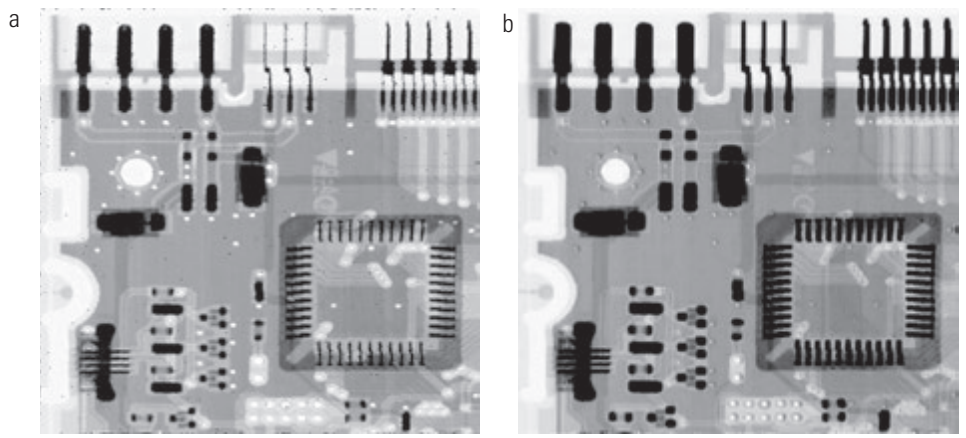


Figura 5.11 (a) Resultado da filtragem da Figura 5.8(a) com um filtro de máximo de tamanho 3 × 3. (b) Resultado da filtragem da Figura 5.8(b) com um filtro de mínimo de mesmo tamanho.

O filtro de média alfa cortada é ilustrado em seguida. A Figura 5.12(a) mostra a imagem da placa de circuito corrompida dessa vez por ruído aditivo uniforme de variância 800 e média zero. Trata-se de um alto nível de corrupção de ruído piorado pelo acréscimo de ruído sal e pimenta com $P_a = P_b = 0{,}1$ como mostra a Figura 5.12(b). O alto nível de ruído nessa imagem requer a utilização de filtros maiores. As figuras 5.12(c) a (f) mostram os resultados obtidos utilizando filtros de média aritmética, média geométrica, mediana e média alfa cortada (com $d = 5$) de tamanho 5×5. Como era de esperar, os filtros de média aritmética e geométrica (especialmente o último) não apresentaram um bom desempenho em razão da presença do ruído impulsivo. Os filtros de mediana e alfa cortada apresentaram um desempenho muito melhor, com o filtro alfa cortada resultando em uma redução de ruído ligeiramente superior. Observe, por exemplo, que a quarta trilha do conector da parte superior esquerda é um pouco mais suave no resultado alfa cortada. Isso não nos surpreende porque, para um valor alto de d, o filtro de média alfa cortada se aproxima do desempenho do filtro de mediana, mas ainda retém alguns recursos de suavização. ■

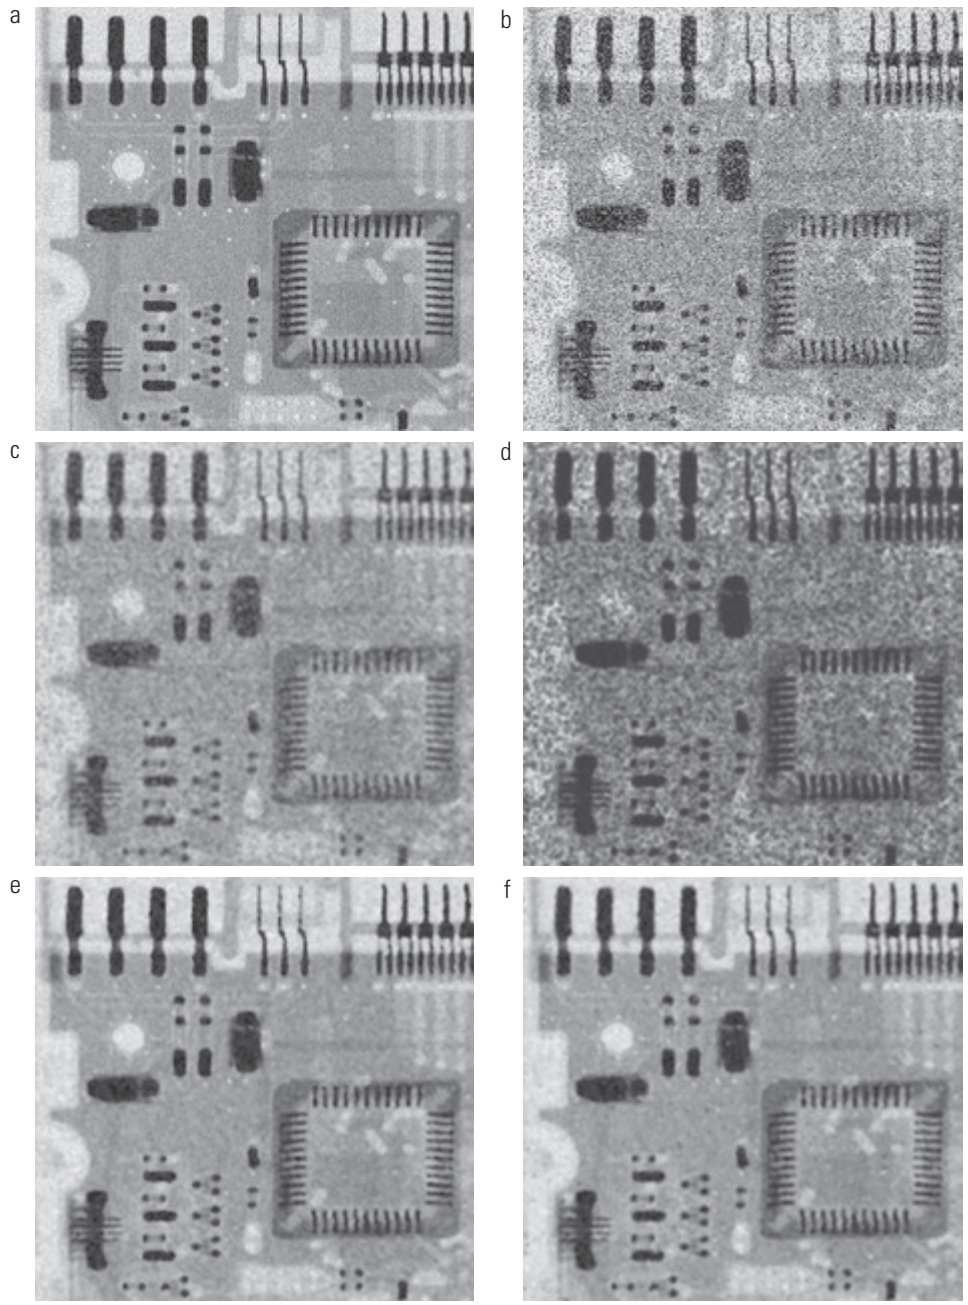


Figura 5.12 (a) Imagem corrompida por ruído uniforme aditivo. (b) Imagem adicionalmente corrompida pelo ruído sal e pimenta aditivo. Imagem (b) filtrada com um: (c) filtro de média aritmética; (d) filtro de média geométrica; (e) filtro de mediana; e (f) filtro de média alfa cortada com $d = 5$. Todos os filtros de tamanho 5×5.

5.3.3 Filtros adaptativos

Uma vez selecionados, os filtros discutidos até agora são aplicados a uma imagem sem levar em consideração como as características da imagem variam de um ponto a outro. Nesta seção, analisaremos dois filtros *adaptativos* cujo comportamento muda com base nas características estatísticas da imagem dentro da região de filtro definida pela janela retangular S_{xy} de tamanho $m \times n$. Como a discussão a seguir demonstra, os filtros adaptativos são capazes de um desempenho superior ao dos filtros discutidos até agora. O preço pago pelo maior poder de filtragem é uma maior complexidade do filtro. Tenha em mente que ainda estamos lidando com o caso no qual a imagem degradada é igual à imagem original mais o ruído. Ainda não estamos considerando outros tipos de degradação.

Filtro adaptativo de redução de ruído local

As medidas estatísticas mais simples de uma variável aleatória são sua média e sua variância. Trata-se de parâmetros razoáveis sobre os quais podemos basear um filtro adaptativo por serem valores estreitamente relacionados à aparência de uma imagem. A média nos proporciona uma medida de intensidade média na região ao longo da qual ela é calculada, e a variância nos proporciona uma medida de contraste nessa região.

Nosso filtro deve operar em uma região local, S_{xy}. A resposta do filtro em qualquer ponto (x, y) no qual a região é centralizada deve se basear em quatro valores: (a) $g(x, y)$, o valor da imagem com ruído em (x, y); (b) σ_η^2, a variância do ruído que corrompe $f(x, y)$ para formar $g(x, y)$; (c) m_L, a média local dos pixels em S_{xy}; e (d) σ_L^2, a variância local dos pixels em S_{xy}. Queremos que o comportamento do filtro seja o seguinte:

1. Se σ_η^2 for zero, o filtro deve simplesmente retornar o valor de $g(x, y)$. Esse é o caso trivial, de ruído zero, no qual $g(x, y)$ é igual a $f(x, y)$.
2. Se a variância local for alta em relação à σ_η^2, o filtro deve retornar um valor próximo de $g(x, y)$. Uma alta variância local costuma ser associada às bordas, que devem ser preservadas.
3. Se as duas variâncias forem iguais, queremos que o filtro retorne o valor da média aritmética dos pixels em S_{xy}. Essa condição ocorre quando a área local tem as mesmas propriedades que a imagem em geral e o ruído local é reduzido pelo simples cálculo da média.

Uma expressão adaptativa a ser obtida com base nessas premissas pode ser expressa como

$$\hat{f}(x,y) = g(x,y) - \frac{\sigma_\eta^2}{\sigma_L^2}\left[g(x,y) - m_L\right] \quad (5.3\text{-}12)$$

O único valor que precisa ser conhecido ou estimado é a variância do ruído geral, σ_η^2. Os outros parâmetros são calculados a partir dos pixels em S_{xy} para cada posição (x, y) na qual a janela do filtro é centralizada. Uma condição implícita na Equação 5.3-12 é que $\sigma_\eta^2 \leq \sigma_L^2$. O ruído no nosso modelo é aditivo e independente da posição, de forma que essa é uma condição aceitável de se fazer, já que S_{xy} é um subconjunto de $g(x, y)$. Contudo, raramente conhecemos σ_η^2 com precisão. Assim, é possível que essa condição seja violada na prática. Por essa razão, um teste deve ser incorporado na implementação da Equação 5.3-12, de forma que a razão seja definida em 1 se a condição $\sigma_\eta^2 > \sigma_L^2$ ocorrer. Isso faz com que esse filtro seja não linear. No entanto, isso impede resultados sem sentido (isto é, níveis de intensidade negativos, dependendo do valor de m_L) em virtude de um potencial desconhecimento da variância do ruído da imagem. Outra abordagem é permitir a ocorrência de valores negativos e reajustar os valores de intensidade no final. O resultado, neste caso, poderia ser uma perda na faixa dinâmica da imagem.

■

Exemplo 5.4 Ilustração de filtragem adaptativa de redução de ruído local.

A Figura 5.13(a) mostra a imagem da placa de circuito, corrompida dessa vez pelo ruído gaussiano aditivo de média zero e variância 1.000. Trata-se de um nível significativo de corrupção por ruído, mas representa um teste ideal para comparar o desempenho relativo do filtro. A Figura 5.13(b) mostra o resultado do processamento da imagem com ruído utilizando um filtro de média aritmética de tamanho 7 × 7. O ruído foi suavizado, mas à custa de um significativo borramento da imagem. Comentários similares são aplicáveis à Figura 5.13(c), que mostra o resultado do processamento da imagem com ruído utilizando um filtro de média geométrica, também de tamanho 7 × 7. As diferenças entre essas duas imagens filtradas são análogas às que discutimos no Exemplo 5.2; a única diferença é o grau de borramento.

A Figura 5.13(d) mostra o resultado da utilização do filtro adaptativo da Equação 5.3-12, com $\sigma_\eta^2 = 1.000$. As melhorias desse resultado em comparação com os dois filtros anteriores são significativas. Em termos de redução de ruído geral, o filtro adaptativo atingiu resultados similares aos dos filtros de média aritmética e geométrica. Contudo, a imagem fil trada com o filtro adaptativo é muito mais nítida. Por exemplo, as trilhas do conector na parte superior da imagem são significativamente mais nítidas na Figura 5.13(d). Outras características, como os buracos e as oito pernas do componente escuro no lado inferior esquerdo da imagem, são muito mais nítidas na Figura 5.13(d). Esses resultados são típicos do que pode ser obtido com um filtro adaptativo. Como mencionamos anteriormente, o preço pago pelo melhor desempenho é uma complexidade adicional do filtro.

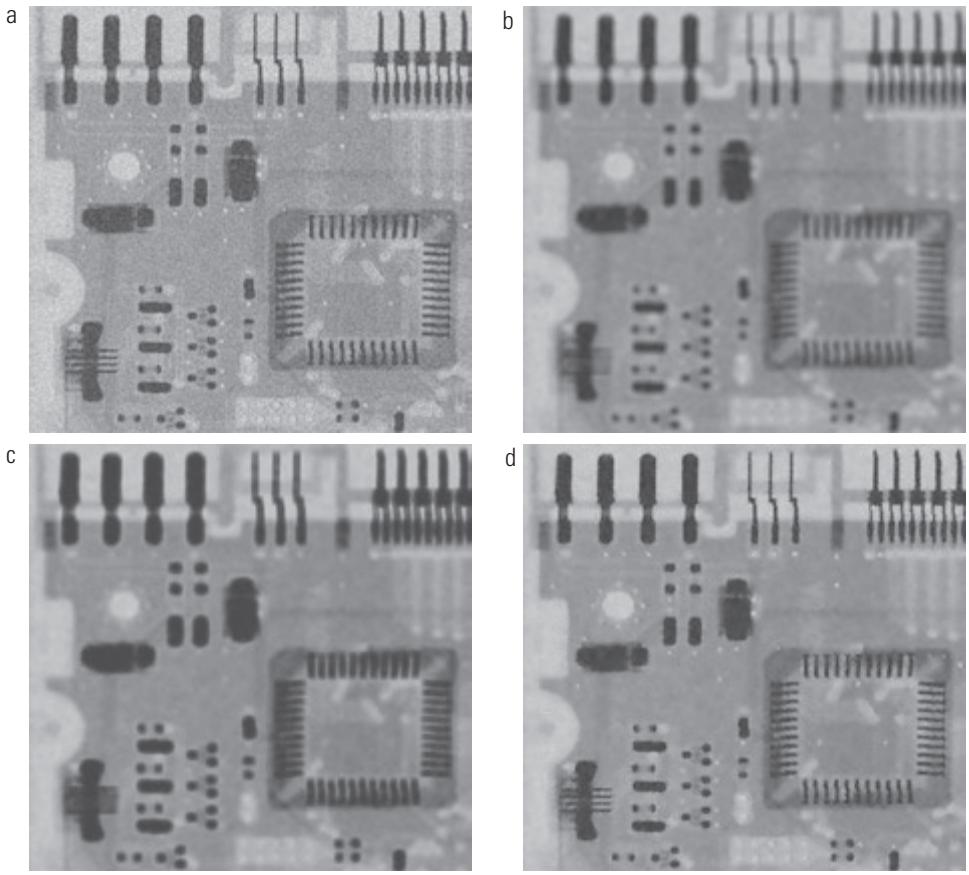


Figura 5.13 (a) Imagem corrompida pelo ruído gaussiano aditivo de média zero e variância 1.000. (b) Resultado da filtragem de média aritmética. (c) Resultado da filtragem de média geométrica. (d) Resultado da filtragem adaptativa de redução de ruído. Todos os filtros são de tamanho 7 × 7.

Os resultados mostrados utilizaram um valor para σ_η^2 que correspondia exatamente à variância do ruído. Se esse valor não for conhecido, e uma estimativa muito baixa for utilizada, o algoritmo retornará uma imagem que se assemelhará bastante à imagem original, porque as correções serão menores do que deveriam ser. Estimativas muito altas farão com que a razão da variância seja cortada em 1,0, e o algoritmo subtrairá a média da imagem com mais frequência do que normalmente faria. Se valores negativos forem permitidos e a intensidade da imagem for reajustada no final, o resultado será uma perda de faixa dinâmica, como mencionamos anteriormente.

■

Filtro adaptativo de mediana

O filtro de mediana discutido na Seção 5.3.2 apresenta um bom resultado se a densidade espacial do ruído impulsivo não for alta (como uma regra geral, P_a e P_b menores que 0,2). Mostramos, nesta seção, que a filtragem adaptativa mediana é capaz de lidar com o ruído impulsivo com probabilidades maiores que essas. Um benefício adicional do filtro adaptativo de mediana é que ele busca preservar os detalhes ao mesmo tempo em que suaviza o ruído não impulsivo, algo que o filtro de mediana "tradicional" não faz. Como em todos os filtros discutidos nas seções anteriores, o filtro adaptativo de mediana também funciona em uma área de janela retangular S_{xy}. Diferentemente desses filtros, contudo, o filtro adaptativo de mediana altera (aumenta) o tamanho de S_{xy} durante a operação de filtragem, dependendo de certas condições apresentadas nesta seção. Tenha em mente que a saída do filtro é um valor único utilizado para substituir o valor do pixel em (x, y), o ponto no qual a janela S_{xy} está centralizada em um determinado momento.

Considere a seguinte notação:

$z_{\text{mín}}$ = valor mínimo de intensidade em S_{xy}

$z_{\text{máx}}$ = valor máximo de intensidade em S_{xy}

z_{med} = mediana dos valores de intensidade em S_{xy}

z_{xy} = valor da intensidade nas coordenadas (x, y)

$S_{\text{máx}}$ = tamanho máximo permitido de S_{xy}

O algoritmo da filtragem mediana adaptativa funciona em duas etapas, chamadas de estágio *A* e estágio *B*, como segue:

Estágio A: $A1 = z_{med} - z_{mín}$

$A2 = z_{med} - z_{máx}$

Se $A1 > 0$ E $A2 < 0$, vá para o estágio B

Senão, aumente o tamanho da janela

Se o tamanho da janela $\leq S_{máx}$, repita o estágio A

Senão, a saída é z_{med}

Estágio B: $B1 = z_{xy} - z_{mín}$

$B2 = z_{xy} - z_{máx}$

Se $B1 > 0$ E $B2 < 0$, a saída é z_{xy}

Senão, a saída é z_{med}

A chave para compreender o funcionamento desse algoritmo é ter em mente que ele tem três principais finalidades: remover o ruído sal e pimenta (impulsivo), proporcionar suavização para outros ruídos que possam não ser impulsivos e reduzir a distorção, como o afinamento ou o espessamento excessivo das fronteiras dos objetos. Os valores $z_{mín}$ e $z_{máx}$ são estatisticamente considerados pelo algoritmo como componentes de ruído "similares a impulsos", mesmo se eles não forem o mais baixo e o mais alto valor de pixel possível na imagem.

Com essas observações em mente, vemos que o propósito do estágio A é verificar se a saída do filtro de mediana, z_{med}, é um impulso (preto *ou* branco) ou não. Se a condição $z_{mín} < z_{med} < z_{máx}$ for verdadeira, então z_{med} não pode ser um impulso pela razão mencionada no parágrafo anterior. Neste caso, vamos para o estágio B e verificamos se o ponto no centro da janela, z_{xy}, é um impulso (lembre-se que se trata do ponto sendo processado). Se a condição $B1 > 0$ E $B2 < 0$ for verdadeira, então $z_{mín} < z_{xy} < z_{máx}$ e z_{xy} não pode ser um impulso pela mesma razão pela qual z_{med} não era um impulso. Nesse caso, o algoritmo resulta no valor inalterado do pixel, z_{xy}. Por não alterar esses pontos de "nível intermediário", a distorção é reduzida na imagem. Se a condição $B1 > 0$ E $B2 < 0$ for falsa, então $z_{xy} = z_{mín}$ ou $z_{xy} = z_{máx}$. Em qualquer um dos casos, o valor do pixel é um valor extremo e o algoritmo resulta no valor de mediana z_{med}, que sabemos, com base no estágio A, não se tratar de um ruído impulsivo. O último passo é o que o filtro de mediana padrão faz. O problema é que o filtro de mediana padrão substitui todos os pontos da imagem pela mediana da vizinhança correspondente. Isso provoca uma perda desnecessária de detalhes.

Prosseguindo com a explicação, suponha que o estágio A *de fato* encontre um impulso (isto é, não passe no teste que faria com que ele prosseguisse ao estágio B). O algoritmo então aumenta o tamanho da janela e repete o estágio A. Esse procedimento prossegue até que o algoritmo encontre um valor de mediana que não seja um impulso (e passe para o estágio B) ou o tamanho máximo da janela seja atingido. Se o tamanho máximo da janela for atingido, o algoritmo retorna ao valor de z_{med}. Observe que não há garantia de que esse valor não seja um impulso. Quanto mais baixas forem as probabilidades P_a e/ou P_b de ruído, ou quanto maior se permite que $S_{máx}$ seja, menos provável será a ocorrência de uma condição de saída prematura. Isso é plausível. À medida que a densidade dos impulsos aumenta, nós logicamente precisaríamos de uma janela maior para "limpar" os picos de ruído.

Cada vez que o algoritmo gera um valor, a janela S_{xy} é movida para a próxima posição na imagem. O algoritmo então é reiniciado e aplicado aos pixels da próxima posição. Como indicado no Exercício 3.18, o valor da mediana pode ser atualizado iterativamente utilizando apenas os novos pixels, reduzindo, dessa forma, a carga computacional.

■

Exemplo 5.5 Ilustração da filtragem adaptativa de mediana.

A Figura 5.14(a) mostra a imagem da placa de circuito corrompida pelo ruído sal e pimenta com probabilidades $P_a = P_b = 0{,}25$, que é 2,5 vezes o nível de ruído utilizado na



Figura 5.14 (a) Imagem corrompida por ruído sal e pimenta com probabilidades $P_a = P_b = 0{,}25$. (b) Resultado da filtragem com um filtro de mediana 7 × 7. (c) Resultado da filtragem adaptativa de mediana com $S_{máx} = 7$.

Figura 5.10(a). Aqui, o nível de ruído é alto o suficiente para obscurecer a maior parte dos detalhes da imagem. Como uma base para comparação, a imagem foi primeiro filtrada utilizando o menor filtro de mediana necessário para remover a maior parte dos traços visíveis do ruído impulsivo. Para isso, precisamos de um filtro de mediana 7 × 7 e o resultado é mostrado na Figura 5.14(b). Apesar de o ruído ter sido removido com eficácia, o filtro provocou perda significativa de detalhes na imagem. Por exemplo, as trilhas do conector na parte superior da imagem aparecem distorcidas ou incompletas. Outros detalhes da imagem são distorcidos de forma similar.

A Figura 5.14(c) mostra o resultado da utilização do filtro adaptativo de mediana com $S_{máx} = 7$. O desempenho da remoção de ruído foi similar ao do filtro de mediana. Contudo, o filtro adaptativo apresentou um desempenho melhor na preservação da nitidez e dos detalhes. As trilhas do conector aparecem menos distorcidas e alguns outros traços que foram obscurecidos ou distorcidos pelo filtro de mediana, a ponto de serem irreconhecíveis, aparecem mais nítidos e mais bem definidos na Figura. 5.14(c). Dois exemplos notáveis são os pequenos buracos brancos de passagem e o componente escuro de oito pernas no quadrante inferior esquerdo da imagem.

Considerando o alto nível de ruído da Figura 5.14(a), o algoritmo adaptativo apresentou um desempenho bastante bom. A escolha do tamanho máximo permitido para a janela depende da aplicação, mas um valor inicial razoável pode ser estimado antes por meio da experimentação com vários tamanhos do filtro de mediana padrão. Isso estabelecerá uma referência visual para as expectativas do desempenho do algoritmo adaptativo.

■

5.4 Redução de ruído periódico pela filtragem no domínio da frequência

O ruído periódico pode ser analisado e filtrado com bastante eficácia utilizando técnicas do domínio da frequência. A ideia básica é que o ruído periódico apareça como picos concentrados de energia na transformada de Fourier, em posições correspondentes às frequências da interferência periódica. A técnica consiste em utilizar um filtro seletivo (veja a Seção 4.10) para isolar o ruído. Os três tipos de filtros seletivos (rejeita-banda, passa-banda e *notch*, apresentados na Seção 4.10) serão utilizados nas seções 5.4.1 a 5.4.3 para a redução de ruído periódico básico. Também apresentaremos um método ótimo para a filtragem *notch* na Seção 5.4.4.

5.4.1 Filtros rejeita-banda

As funções de transferência dos filtros rejeita-banda ideal, Butterworth e gaussiano, apresentados na Seção 4.10.1, são resumidas na Tabela 4.6. A Figura 5.15 mostra gráficos em perspectiva desses filtros, e o exemplo a seguir ilustra a utilização do filtro rejeita-banda para reduzir os efeitos do ruído periódico.

■

Exemplo 5.6 Utilização da filtragem rejeita-banda para a remoção de ruído periódico.

Uma das principais aplicações da filtragem rejeita-banda é a remoção de ruído em aplicações nas quais a posição geral do(s) componente(s) de ruído no domínio da frequência é aproximadamente conhecida. Um bom exemplo é uma imagem corrompida por ruído periódico aditivo que pode ser aproximadamente estimado como funções senoidais bidimensionais. Não é difícil demonstrar que a transformada de Fourier de um seno consiste em dois impulsos que são imagens espelhadas uma da outra a partir da origem da transformada. Suas localizações são dadas na Tabela 4.3. Os impulsos são ao mesmo tempo imaginários (a parte real da transformada de Fourier de um seno é zero) e conjugados complexos um do outro. Teremos mais a dizer a respeito nas seções 5.4.3 e 5.4.4. Nosso objetivo por enquanto é ilustrar a filtragem rejeita-banda.

A Figura 5.16(a), que é a mesma que a Figura 5.5(a), mostra uma imagem substancialmente corrompida por ruído senoidal de várias frequências. Os componentes de ruído são facilmente vistos como pares simétricos de pontos claros no espectro de Fourier mostrado na Figura 5.16(b). Neste exemplo, os componentes se localizam em um círculo aproximado a partir da origem da transformada, de forma que um filtro rejeita-banda circularmente simétrico representa uma boa escolha. A Figura 5.16(c) mostra um filtro rejeita-banda Butterworth de ordem 4, com raio e largura apropriados para englobar completamente os impulsos de ruído. Como em geral é desejável remover o mínimo possível da transformada, filtros abruptos e estreitos são comuns na filtragem rejeita-banda. O resultado da filtragem da Figura 5.16(a) com esse

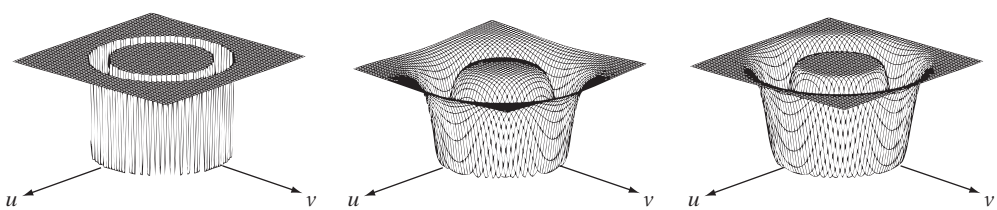


Figura 5.15 Da esquerda para a direita, gráficos em perspectiva de filtros rejeita-banda ideal, Butterworth (de ordem 1) e gaussiano.

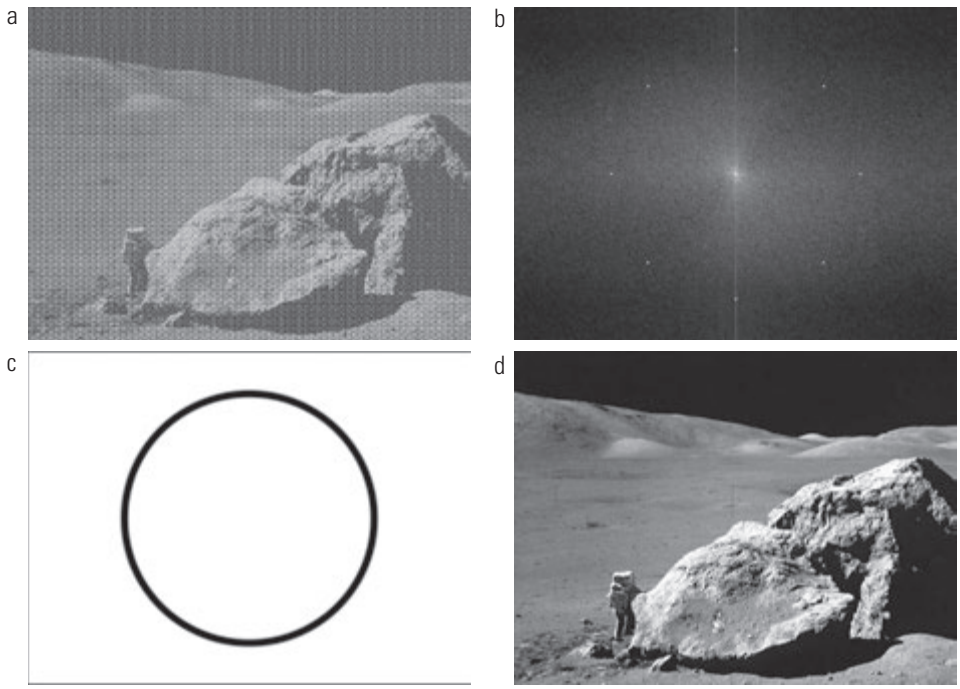


Figura 5.16 (a) Imagem corrompida por ruído senoidal. (b) Espectro de (a). (c) Filtro rejeita-banda Butterworth (o branco representa 1). (d) Resultado da filtragem. (Imagem original: cortesia da Nasa.)

filtro é mostrado na Figura 5.16(d). A melhora é bastante evidente. Até pequenos detalhes e texturas foram restaurados com eficácia por esse método simples de filtragem. Também cabe ressaltar que não seria possível obter resultados equivalentes por um método de filtragem direta no domínio espacial utilizando pequenas máscaras de convolução.

■

5.4.2 Filtros passa-banda

Um filtro *passa-banda* realiza a operação oposta de um filtro rejeita-banda. Mostramos, na Seção 4.10.1, como a função de transferência $H_{BP}(u, v)$ de um filtro passa-banda é obtida a partir de um filtro rejeita-banda correspondente com função de transferência $H_{BR}(u, v)$ utilizando a equação

$$H_{BP}(u, v) = 1 - H_{BR}(u, v) \qquad (5.4\text{-}1)$$

Deixamos como um exercício (Exercício 5.12) deduzir as expressões para os filtros passa-banda correspondentes às equações rejeita-banda da Tabela 4.6.

■

Exemplo 5.7 Filtragem passa-banda para extrair padrões de ruído.

Não é um procedimento comum realizar a filtragem passa-banda direta em uma imagem porque isso geralmente remove detalhes demais da imagem. No entanto, a filtragem passa-banda é bastante útil para isolar os efeitos sobre uma imagem causados por bandas de frequência selecionadas. Isso é ilustrado na Figura 5.17. Essa imagem foi gerada (1) utilizando a Equação 5.4-1 para obter o filtro passa-banda correspondente ao filtro rejeita-banda da Figura 5.16; e (2) utilizando a transformada inversa da transformada filtrada pelo passa-banda. A maior parte dos detalhes da imagem foi perdida, mas as informações remanescentes são bastante úteis, já que fica claro que o padrão de ruído recuperado utilizando esse método é bastante parecido com o ruído que corrompeu a imagem na Figura 5.16(a). Em outras palavras, a filtragem passa-banda ajudou a isolar o padrão de ruído. Trata-se de um resultado útil por simplificar a análise do ruído, de forma razoavelmente independente do conteúdo da imagem.

■

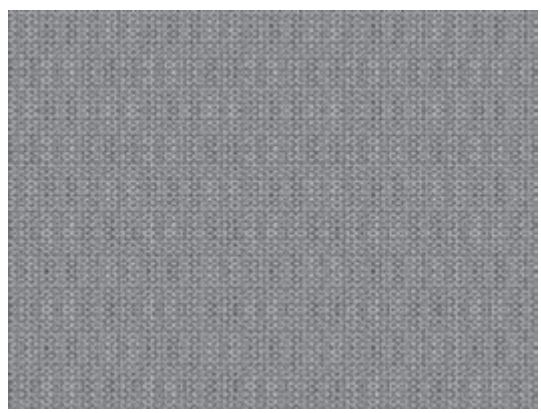


Figura 5.17 Padrão de ruído da imagem da Figura 5.16a obtido pela filtragem passa-banda.

5.4.3 Filtros *notch*

Um filtro *notch* rejeita (ou passa) frequências em vizinhanças predefinidas em relação a uma frequência central. As equações para a filtragem *notch* são detalhadas na Seção 4.10.2. A Figura 5.18 mostra gráficos em 3-D de filtros *notch* (rejeita) ideal, Butterworth e gaussiano. Em virtude da simetria da transformada de Fourier, filtros *notch* devem aparecer em pares simétricos em relação à origem para obter resultados significativos. A única exceção a essa regra é se o filtro *notch* se localizar na origem, caso em que ele aparece sozinho. Apesar de mostrarmos apenas um par para fins de ilustração, o número de pares de filtros *notch* que podem ser implementados é arbitrário. O formato das áreas selecionadas também pode ser arbitrário (por exemplo, retangular).

Como explicamos na Seção 4.10.2, podemos obter filtros *notch* que *passam*, em vez de suprimir, as frequências contidas nas áreas selecionadas. Como esses filtros realizam exatamente a função oposta à dos filtros rejeita-*notch*, suas funções de transferência são dadas por

$$H_{\mathrm{PN}}(u, v) = 1 - H_{\mathrm{RN}}(u, v) \qquad (5.4\text{-}2)$$

na qual $H_{\mathrm{PN}}(u, v)$ é a função de transferência do filtro passa-*notch* correspondente ao filtro rejeita-*notch* com função de transferência $H_{\mathrm{RN}}(u, v)$.

■

Exemplo 5.8 Remoção do ruído periódico pela filtragem *notch*.

A Figura 5.19(a) mostra a mesma imagem que a Figura 4.51(a). O método de filtragem *notch* que se segue reduz o ruído dessa imagem sem acrescentar o borramento significativo que vimos na Seção 4.8.4. A menos que o borramento seja desejável por razões que discutimos naquela seção, a filtragem *notch* é preferível se um filtro adequado puder ser encontrado.

Só de olhar as linhas quase horizontais do padrão de ruído da Figura 5.19(a), esperamos que sua contribuição ao domínio da frequência se concentre ao longo do eixo vertical. Contudo, o ruído não é suficientemente dominante para ter um padrão claro ao longo desse eixo, como é evidenciado no espectro mostrado na Figura 5.19(b). Podemos ter uma ideia da contribuição do ruído construindo um filtro passa-*notch* ideal simples ao longo do eixo vertical da transformada de Fourier, como mostra a Figura 5.19(c). A representação espacial do padrão de ruído (transformada inversa do resultado do filtro passa-*notch*) é mostrada na Figura 5.19(d). Esse padrão de ruído corresponde aproximadamente ao padrão da Figura 5.19(a). Tendo construído, dessa forma, um filtro passa-*notch* apropriado que isola o ruído em um grau razoável, podemos obter o filtro rejeita-*notch* correspondente a partir da Equação 5.4-2. O resultado do processamento da imagem com o filtro rejeita-*notch* é mostrado na Figura 5.19(e). Essa imagem contém significativamente menos ruído visível de linhas de varredura do que a Figura 5.19(a).

■

5.4.4 Filtragem *notch* ótima

A Figura 5.20(a), outro exemplo de degradação periódica de imagem, mostra uma imagem digital da superfície de Marte obtida pela espaçonave *Mariner 6*. O padrão de interferência é, de certa forma, similar ao da Figura. 5.16(a), mas o padrão anterior é consideravelmente mais sutil e,

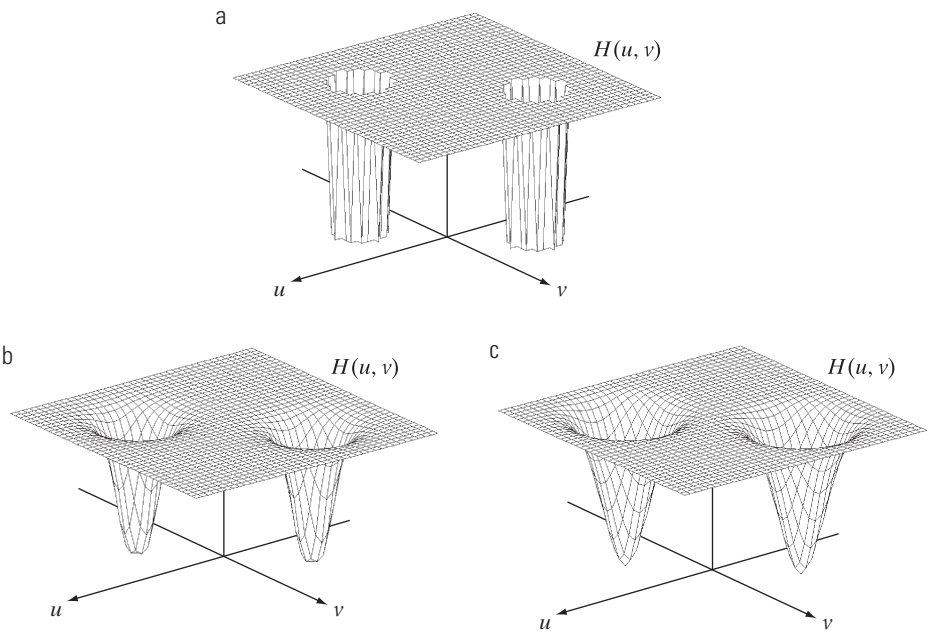


Figura 5.18 Gráficos em perspectiva de filtros *notch* (rejeita) (a) ideal, (b) Butterworth (de ordem 2) e (c) gaussiano.

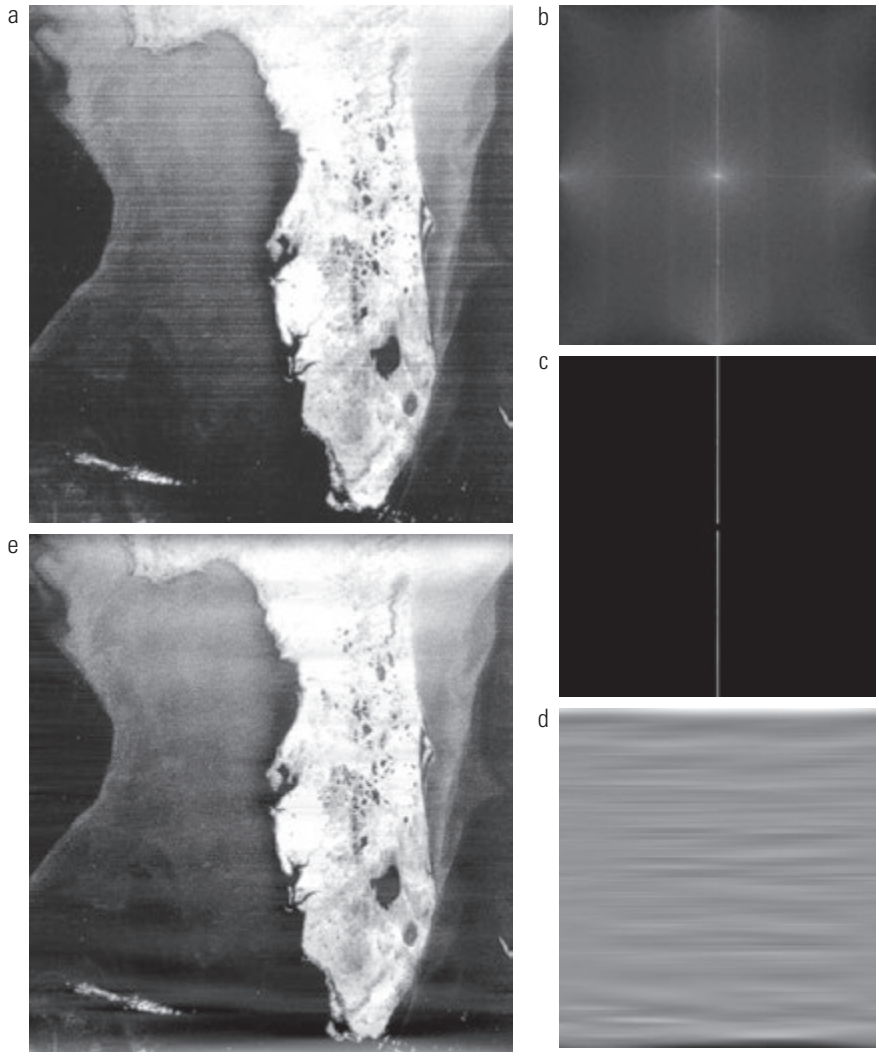


Figura 5.19 (a) Imagem de satélite da Flórida e do Golfo do México mostrando linhas de varredura horizontais. (b) Espectro. (c) Filtro passa-*notch* sobreposto a (b). (d) Padrão de ruído espacial. (e) Resultado da filtragem rejeita-*notch*. (Imagem original: cortesia da Noaa.)

em consequência, de mais difícil detecção no plano da frequência. A Figura 5.20(b) mostra o espectro de Fourier da imagem em questão. Os componentes parecidos com estrelas foram causados pela interferência, e vários pares de componentes estão presentes, indicando que o padrão contém mais do que apenas um componente senoidal.

Quando vários componentes de interferência estão presentes, os métodos discutidos nas seções anteriores nem sempre são aceitáveis porque podem remover muitas informações da imagem no processo de filtragem (uma característica muito indesejável quando as imagens são únicas e/ou de aquisição dispendiosa). Além disso, os componentes de interferência em geral não são picos de uma única frequência. Em vez disso, eles tendem a ter margens maiores que carregam informações sobre o padrão de interferência. Essas margens nem sempre são facilmente detectáveis a partir do fundo da transformada normal. Métodos de filtragem alternativos que reduzem o efeito dessas degradações são bastante úteis em muitas aplicações. O método discutido aqui é ótimo, no sentido de minimizar as variâncias locais da estimativa restaurada $\hat{f}(x, y)$.

O procedimento consiste em primeiro isolar as principais contribuições do padrão de interferência e depois subtrair uma parcela variável e ponderada do padrão da imagem corrompida. Apesar de desenvolvermos o procedimento no contexto de uma aplicação específica, a abordagem básica é bastante genérica e pode ser aplicada a outras tarefas de restauração nas quais a interferência periódica múltipla constitui um problema.

O primeiro passo é extrair os principais componentes de frequência do padrão de interferência. Assim como antes, isso pode ser feito com um filtro passa-*notch*, $H_{\text{PN}}(u, v)$,

a



b

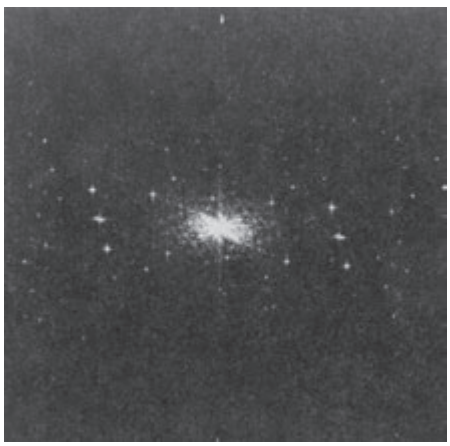


Figura 5.20 (a) Imagem da superfície de Marte obtida pelo *Mariner 6*. (b) Espectro de Fourier mostrando a interferência periódica. (Cortesia da Nasa.)

na posição de cada pico. Se o filtro for construído para passar apenas componentes associados ao padrão de interferência, a transformada de Fourier do padrão do ruído de interferência é dada pela expressão

$$N(u, v) = H_{PN}(u, v)G(u, v) \qquad (5.4\text{-}3)$$

na qual, como sempre, $G(u, v)$ expressa a transformada de Fourier da imagem corrompida.

A formulação de $H_{PN}(u, v)$ requer uma análise considerável do que constitui ou não um pico de interferência. Por essa razão, o filtro passa-*notch* em geral é interativamente construído observando o espectro de $G(u, v)$ em uma exibição. Depois que um filtro particular é selecionado, um padrão correspondente no domínio espacial é obtido a partir da expressão

$$\eta(x, y) = \Im^{-1}\{H_{PN}(u, v)G(u, v)\} \qquad (5.4\text{-}4)$$

Como presumimos que a imagem corrompida é formada pela adição da imagem não corrompida $f(x, y)$ com a interferência, se $\eta(x, y)$ fosse completamente conhecido, seria simples subtrair o padrão de $g(x, y)$ para obter $f(x, y)$. O problema, obviamente, é que esse procedimento de filtragem normalmente resulta em apenas uma aproximação do padrão verdadeiro. Em vez disso, o efeito dos componentes não presentes na estimativa de $\eta(x, y)$ pode ser minimizado subtraindo de $g(x, y)$ uma parcela *ponderada* de $\eta(x, y)$ para obter uma estimativa de $f(x, y)$:

$$\hat{f}(x, y) = g(x, y) - w(x, y)\eta(x, y) \qquad (5.4\text{-}5)$$

na qual, como antes, $\hat{f}(x, y)$ é a estimativa de $f(x, y)$, e $w(x, y)$ deve ser calculada. A função $w(x, y)$ é chamada de função de *ponderação* ou *modulação*, e o objetivo do procedimento é selecionar essa função de forma que o resultado seja otimizado de algum modo significativo. Uma abordagem consiste em selecionar $w(x, y)$ de forma que a variância da estimativa $\hat{f}(x, y)$ seja minimizada ao longo de uma vizinhança especificada de cada ponto (x, y).

Considere uma vizinhança de tamanho $(2a + 1)$ por $(2b + 1)$ em relação ao um ponto (x, y). A variância "local" de $\hat{f}(x, y)$ nas coordenadas (x, y) pode ser estimada com base nas amostras, como segue:

$$\sigma^2(x, y) = \frac{1}{(2a+1)(2b+1)} \sum_{s=-a}^{a} \sum_{t=-b}^{b} \left[\hat{f}(x+s, y+t) - \bar{\hat{f}}(x, y) \right]^2 \qquad (5.4\text{-}6)$$

sendo que $\bar{\hat{f}}(x, y)$ expressa o valor médio de $\hat{f}$ na vizinhança; isto é

$$\bar{\hat{f}}(x, y) = \frac{1}{(2a+1)(2b+1)} \sum_{s=-a}^{a} \sum_{t=-b}^{b} \hat{f}(x+s, y+t) \qquad (5.4\text{-}7)$$

Os pontos na borda da imagem ou perto dela podem ser tratados considerando vizinhanças parciais ou preenchendo o contorno com zeros.

Substituir a Equação 5.4-5 na Equação 5.4-6 resulta em

$$\sigma^2(x, y) = \frac{1}{(2a+1)(2b+1)} \sum_{s=-a}^{a} \sum_{t=-b}^{b} \left\{ [g(x+s, y+t) - w(x+s, y+t)\eta(x+s, y+t)] - [\bar{g}(x, y) - \overline{w(x, y)\eta(x, y)}] \right\}^2 \qquad (5.4\text{-}8)$$

Considerando que $w(x, y)$ permanece essencialmente constante ao longo da vizinhança, isso nos dá a aproximação

$$w(x + s, y + t) = w(x, y) \qquad (5.4\text{-}9)$$

para $-a \leq s \leq a$ e $-b < t < b$. Esse pressuposto também resulta na expressão

$$\overline{w(x, y)\eta(x, y)} = w(x, y)\bar{\eta}(x, y) \qquad (5.4\text{-}10)$$

na vizinhança. Com essas aproximações, a Equação 5.4-8 passa a ser

$$\sigma^2(x,y)=\frac{1}{(2a+1)(2b+1)}\sum_{s=-a}^{a}\sum_{=-b}^{b}\Big\{[g(x+s,y+t)-w(x,y)\eta(x+s,y+t)]-[\bar{g}(x,y)-w(x,y)\bar{\eta}(x,y)]\Big\}^2 \qquad (5.4\text{-}11)$$

Para minimizar $\sigma^2(x,y)$, calculamos

$$\frac{\partial\sigma^2(x,y)}{\partial w(x,y)}=0 \qquad (5.4\text{-}12)$$

para $w(x, y)$. O resultado é

$$w(x,y)=\frac{\overline{g(x,y)\eta(x,y)}-\bar{g}(x,y)\bar{\eta}(x,y)}{\overline{\eta^2}(x,y)-\bar{\eta}^2(x,y)}=0 \qquad (5.4\text{-}13)$$

Para obter a imagem restaurada $\hat{f}(x,y)$, calculamos $w(x, y)$ a partir da Equação 5.4-13 e depois utilizamos a Equação 5.4-5. Como assumimos que $w(x, y)$ é constante em uma vizinhança, é desnecessário calcular essa função para cada valor de x e y na imagem. Em vez disso, $w(x, y)$ é calculada para *um* ponto em cada vizinhança não sobreposta (de preferência o ponto central) e depois utilizada para processar todos os pontos da imagem contidos nessa vizinhança.

■

Exemplo 5.9 Ilustração da filtragem *notch* ótima.

As figuras 5.21 a 5.23 mostram o resultado da aplicação da técnica discutida anteriormente à imagem da Figura 5.20(a). O tamanho dessa imagem é 512 × 512 pixels, e foi selecionada uma vizinhança com $a = b = 15$. A Figura 5.21 mostra o espectro de Fourier da imagem corrompida. A origem não foi deslocada para o centro do plano da frequência neste caso específico, de forma que $u = v = 0$ se posiciona no canto superior esquerdo da imagem da transformada na Figura 5.21. A Figura 5.22(a) mostra o espectro de $N(u, v)$, no qual apenas os picos de ruído estão presentes. A Figura 5.22(b) mostra o padrão de interferência $\eta(x, y)$ obtido com a transformada inversa de Fourier de $N(u, v)$. Observe a semelhança entre esse padrão e a estrutura do ruído presente na Figura 5.20(a). Por fim, a Figura 5.23 mostra a imagem processada obtida com a Equação 5.4-5. A interferência periódica foi removida para todos os fins práticos.

■

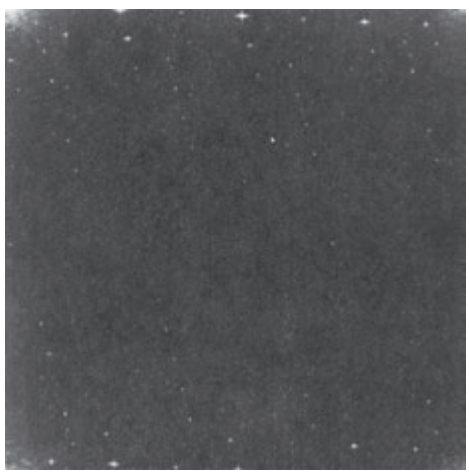


Figura 5.21 Espectro de Fourier (sem deslocamento) da imagem mostrada na Figura 5.20(a). (Cortesia da Nasa.)

5.5 Degradações lineares, invariantes no espaço

A relação entre entrada e saída na Figura 5.1 antes do estágio de restauração é expressa como

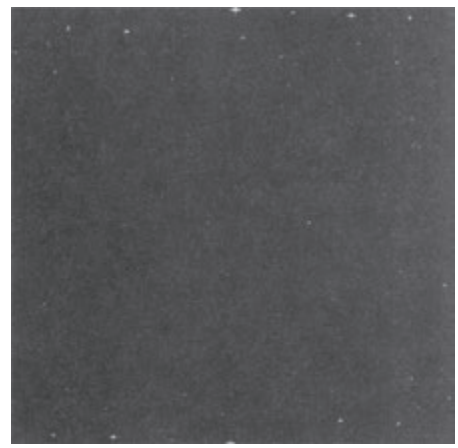
$$g(x, y) = H[f(x, y)] + \eta(x, y) \qquad (5.5\text{-}1)$$

Por enquanto, vamos supor que $\eta(x, y) = 0$, de forma que $g(x, y) = H[f(x, y)]$.

Com base na análise da Seção 2.6.2, H é *linear* se

$$H[af_1(x, y) + bf_2(x, y)] = aH[f_1(x, y)] + bH[f_2(x, y)] \qquad (5.5\text{-}2)$$

a



b

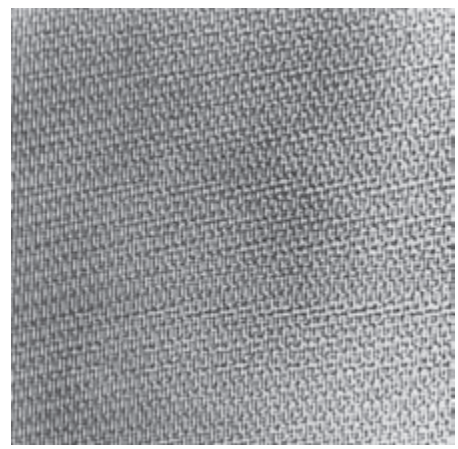


Figura 5.22 (a) Espectro de Fourier de $N(u, v)$. (b) Padrão de interferência do ruído correspondente, $\eta(x, y)$. (Cortesia da Nasa.)

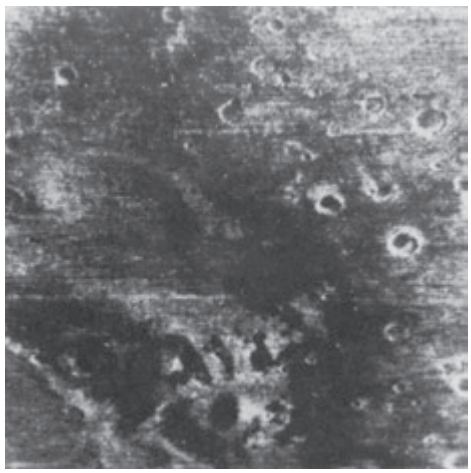


Figura 5.23 Imagem processada. (Cortesia da Nasa.)

na qual a e b são escalares e $f_1(x, y)$ e $f_2(x, y)$ representam quaisquer duas imagens de entrada.*

Se $a = b = 1$, a Equação 5.5-2 passa a ser

$$H[f_1(x, y) + f_2(x, y)] = H[f_1(x, y)] + H[f_2(x, y)] \quad (5.5\text{-}3)$$

que é chamada de propriedade de *aditividade*. Essa propriedade simplesmente diz que, se H for um operador linear, a resposta a uma soma de duas entradas será igual à soma das duas respostas.

Com $f_2(x, y) = 0$, a Equação 5.5-2 passa a ser

$$H[af_1(x, y)] = aH[f_1(x, y)] \quad (5.5\text{-}4)$$

que é chamada de propriedade de *homogeneidade*. Segundo essa propriedade, a resposta a um múltiplo constante de qualquer entrada é igual à resposta a essa entrada multiplicada pela mesma constante. Dessa forma, um operador linear apresenta tanto a propriedade de aditividade quanto a propriedade de homogeneidade.

Diz-se que um operador com a relação entrada-saída $g(x, y) = H[f(x, y)]$ é *invariante no espaço* (ou na *posição*) se

$$H[f(x - \alpha, y - \beta)] = g(x - \alpha, y - \beta) \quad (5.5\text{-}5)$$

para qualquer $f(x, y)$ e qualquer α e β. Essa definição indica que a resposta em qualquer ponto da imagem depende somente do *valor* da entrada nesse ponto, não de sua *posição*.

Com uma ligeira (mas equivalente) variação de notação na definição do impulso na Equação 4.5-3, $f(x, y)$ pode ser formulada como:

$$f(x, y) = \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f(\alpha, \beta)\delta(x - \alpha, y - \beta)\, d\alpha\, d\beta \quad (5.5\text{-}6)$$

Suponha novamente que $\eta(x, y) = 0$. Então, a substituição da Equação 5.5-6 na Equação 5.5-1 resulta na expressão

$$g(x, y) = H\big[f(x, y)\big] = H\left[\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f(\alpha, \beta)\delta(x - \alpha, y - \beta)\, d\alpha\, d\beta\right] \quad (5.5\text{-}7)$$

Se H for um operador linear e estendermos a propriedade de aditividade às integrais, então

$$g(x, y) = \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} H\big[f(\alpha, \beta)\delta(x - \alpha, y - \beta)\big]\, d\alpha\, d\beta \quad (5.5\text{-}8)$$

Como $f(\alpha, \beta)$ é independente de x e y, e utilizando a propriedade de homogeneidade, segue-se que

$$g(x, y) = \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f(\alpha, \beta)H\big[\delta(x - \alpha, y - \beta)\big]\, d\alpha\, d\beta \quad (5.5\text{-}9)$$

O termo

$$h(x, \alpha, y, \beta) = H[\delta(x - \alpha, y - \beta)] \quad (5.5\text{-}10)$$

é chamado de *resposta ao impulso* de H. Em outras palavras, se $\eta(x, y) = 0$ na Equação 5.5-1, então $h(x, \alpha, y, \beta)$ é a resposta de H a um impulso nas coordenadas (x, y). Na ótica, o impulso passa a ser um ponto de luz, e $h(x, \alpha, y, \beta)$ costuma ser chamado de *função de espalhamento de ponto* (PSF, de *point spread function*). Esse termo se origina do fato de que todos os sistemas óticos físicos borram (espalham) um ponto de luz em uma certa extensão, com a quantidade de borramento determinada pela qualidade dos componentes óticos.

Substituir a Equação 5.5-10 na Equação 5.5-9 resulta na expressão

$$g(x, y) = \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f(\alpha, \beta)h(x, \alpha, y, \beta)\, d\alpha\, d\beta \quad (5.5\text{-}11)$$

que é chamada de *integral de superposição* (ou *de Fredholm*) *de primeira espécie*. Essa expressão é um resultado fundamental que reside no "coração" da teoria dos sistemas lineares. Ela afirma que, se a resposta de H a um impulso for conhecida, a resposta para *qualquer* entrada $f(\alpha, \beta)$ pode ser calculada com base na Equação 5.5-11. Em outras palavras, um sistema linear H é completamente caracterizado por sua resposta ao impulso.

Se H for invariante no espaço, então, a partir da Equação 5.5-5,

$$H[\delta(x - \alpha, y - \beta)] = h(x - \alpha, y - \beta) \quad (5.5\text{-}12)$$

* Consulte o site do livro para uma breve revisão da teoria de sistemas lineares.

Nesse caso, a Equação 5.5-11 é reduzida a

$$g(x,y)=\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f(\alpha,\beta)h(x-\alpha,y-\beta)\,d\alpha\,d\beta \tag{5.5-13}$$

Essa expressão é a *integral de convolução* para uma variável apresentada na Equação 4.2-20 e estendida para 2-D no Exercício 4.11. Essa integral nos indica que conhecer a resposta ao impulso de um sistema linear nos permite calcular sua resposta, *g*, para *qualquer* entrada *f*. O resultado é simplesmente a convolução da resposta ao impulso com a função de entrada.

Na presença de ruído aditivo, a expressão do modelo de degradação linear (Equação 5.5-11) passa a ser

$$g(x,y)=\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f(\alpha,\beta)h(x,\alpha,y,\beta)\,d\alpha\,d\beta+\eta(x,y) \tag{5.5-14}$$

Se *H* for invariante no espaço, a Equação 5.5-14 passa a ser

$$g(x,y)=\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f(\alpha,\beta)h(x-\alpha,y-\beta)\,d\alpha\,d\beta+\eta(x,y) \tag{5.5-15}$$

Os valores do termo de ruído $\eta(x, y)$ são aleatórios, e considera-se que eles sejam independentes da posição. Utilizando a notação já conhecida para a convolução, podemos formular a Equação 5.5-15 como

$$g(x, y) = h(x, y) \star f(x, y) + \eta(x, y) \tag{5.5-16}$$

ou, com base no teorema da convolução (veja a Seção 4.6.6), podemos expressá-la no domínio da frequência como

$$G(u, v) = H(u, v)F(u, v) + N(u, v) \tag{5.5-17}$$

Essas duas expressões estão de acordo com as equações 5.1-1 e 5.1-2. Tenha em mente que, para valores discretos, todos os produtos são termo por termo. Por exemplo, o termo *ij* de $H(u, v)F(u, v)$ é o produto do termo *ij* de $H(u, v)$ e do termo *ij* de $F(u, v)$.

Em resumo, a análise anterior sugere que um sistema de degradação linear e invariante no espaço com ruído aditivo pode ser modelado no domínio espacial como a convolução da função de degradação (espalhamento de ponto) com uma imagem, seguida da adição do ruído. Com base no teorema da convolução, o mesmo processo pode ser expresso no domínio da frequência como o produto das transformadas da imagem e da função de degradação, seguido da adição da transformada do ruído. Ao trabalhar no domínio da frequência, utilizamos um algoritmo FFT, como vimos na Seção 4.11. Tenha em mente também a necessidade de preenchimento de função na implementação das transformadas discretas de Fourier, como mostrado na Seção 4.6.6.

Muitos tipos de degradações podem ser aproximados por processos lineares, invariantes no espaço. A vantagem desse método é que as extensas ferramentas de teoria dos sistemas lineares tornam-se disponíveis para solucionar problemas de restauração de imagens. Técnicas não lineares e dependentes da posição, apesar de mais gerais (e normalmente mais precisas), apresentam dificuldades que muitas vezes não têm solução conhecida ou são de difícil resolução em termos computacionais. Este capítulo se concentra em técnicas de restauração lineares, invariantes no espaço. Como as degradações são formuladas como sendo o resultado da convolução, e a restauração busca encontrar filtros que aplicam o processo inverso, o termo *deconvolução de imagens* normalmente é utilizado em referência à restauração linear de imagens. De forma similar, os filtros utilizados no processo de restauração muitas vezes são chamados de *filtros de deconvolução*.

5.6 Estimativa da função de degradação

Existem três principais métodos para estimar a função de degradação para a utilização na restauração de imagens: (1) observação, (2) experimentação e (3) modelamento matemático. Esses métodos serão discutidos nas seções a seguir. O processo para restaurar uma imagem utilizando uma função de degradação que foi de alguma forma estimada algumas vezes é chamado de *deconvolução cega*, pelo fato de a verdadeira função de degradação raramente ser conhecida em sua totalidade.

5.6.1 Estimativa pela observação da imagem

Suponha que recebamos uma imagem degradada sem qualquer informação sobre a função de degradação *H*. Com base na premissa de que a imagem foi degradada por um processo linear, invariante no espaço, uma forma de estimar *H* é coletando informações da própria imagem. Por exemplo, se a imagem estiver borrada, podemos analisar uma pequena seção retangular da imagem contendo estruturas da amostra, como parte de um objeto e do fundo. Para reduzir o efeito do ruído, procuraríamos uma área na qual o conteúdo de sinal fosse intenso (por exemplo, uma área com alto contraste). O próximo passo seria processar a subimagem para chegar a um resultado que seja o menos borrado possível. Por exemplo, podemos fazer isso aumentando a nitidez da subimagem com um filtro de aguçamento e até mesmo processando pequenas áreas manualmente.

Seja a subimagem observada expressa por $g_s(x, y)$ e a subimagem processada (que, na realidade, é a nossa estimativa da imagem original nessa área) expressa por $\hat{f}_s(x,y)$. Depois, considerando que o efeito do ruído é desprezível em razão da nossa escolha de uma área de sinal forte, segue-se, da Equação 5.5-17, que

$$H_s(u,v) = \frac{G_s(u,v)}{\hat{F}_s(u,v)} \tag{5.6-1}$$

Com base nas características dessa função, deduzimos a função de degradação completa $H(u, v)$ com base no nosso pressuposto de invariância no espaço. Por exemplo, suponha que um gráfico radial de $H_S(u, v)$ tenha o formato aproximado de uma curva gaussiana. Podemos utilizar essa informação para construir uma função $H(u, v)$ em uma escala maior, mas com o mesmo formato básico. Depois utilizamos $H(u, v)$ em uma das abordagens de restauração que serão analisadas nas seções seguintes. Claramente, trata-se de um processo laborioso utilizado apenas em circunstâncias muito específicas, por exemplo, na restauração de uma antiga fotografia de valor histórico.

5.6.2 Estimativa por experimentação

Se um equipamento similar ao utilizado na aquisição da imagem degradada estiver disponível, é possível, em princípio, obter uma estimativa precisa da degradação. Imagens similares à imagem degradada podem ser adquiridas com várias configurações de sistema até serem degradadas o mais próximo possível da imagem que desejamos restaurar. Então, a ideia é obter a resposta ao impulso da degradação a partir da aquisição da imagem de um impulso (pequeno ponto de luz) utilizando as mesmas configurações do sistema. Como observado na Seção 5.5, um sistema linear, invariante no sistema, é completamente caracterizado por sua resposta ao impulso. Um impulso é simulado por um ponto claro de luz, o mais claro possível para reduzir o efeito do ruído a valores desprezíveis. Então, lembrando que a transformada de Fourier de um impulso é uma constante, segue-se da Equação 5.5-17 que

$$H(u,v) = \frac{G(u,v)}{A} \tag{5.6-2}$$

sendo que, como antes, $G(u, v)$ é a transformada de Fourier da imagem observada e A é uma constante descrevendo a intensidade do impulso. A Figura 5.24 mostra um exemplo.

5.6.3 Estimativa por modelamento

O modelamento da degradação tem sido utilizado durante muitos anos por permitir uma solução ao problema de restauração de imagens. Em alguns casos, o modelo pode até levar em consideração condições ambientais que causam as degradações. Por exemplo, um modelo de degradação proposto por Hufnagel e Stanley (1964) se baseia nas características físicas da turbulência atmosférica. Esse modelo tem uma fórmula já conhecida:

$$H(u,v) = e^{-k(u^2+v^2)^{5/6}} \tag{5.6-3}$$

na qual k é uma constante que depende da natureza da turbulência. Com exceção da potência 5/6 no expoente, essa equação tem a mesma forma que o filtro passa-baixa gaussiano discutido na Seção 4.8.3. Com efeito, o LPF gaussiano algumas vezes é utilizado para modelar um borramento leve, uniforme. A Figura 5.25 mostra exemplos obtidos simulando o borramento de uma imagem utilizando a Equação 5.6-3 com valores de k = 0,0025 (turbulência grave), k = 0,001 (turbulência suave) e k = 0,00025 (turbulência baixa). Todas as imagens são de tamanho 480 × 480 pixels.

Outra importante abordagem no modelamento consiste em deduzir um modelo matemático a partir de princípios básicos. Ilustraremos esse procedimento tratando, em alguns detalhes, o caso no qual uma imagem foi borrada por movimento linear uniforme entre a imagem e o sensor durante sua aquisição. Suponha que uma imagem $f(x, y)$ passe por um movimento planar e que $x_0(t)$ e $y_0(t)$ sejam os componentes de movimento que variam com o tempo nas direções x e y, respectivamente. A exposição total em qualquer ponto do meio de gravação (digamos, filme ou memória digital) é obtida integrando a exposição instantânea ao longo do intervalo de tempo durante o qual o obturador do sistema de aquisição de imagens estiver aberto.

Assumir que a abertura e o fechamento do obturador ocorrem instantaneamente e que o processo de aquisição ótica de imagens é perfeito, isola o efeito do movimento da imagem. Então, se T for a duração da exposição, segue-se que

$$g(x,y) = \int_0^T f\left[x - x_0(t), y - y_0(t)\right] dt \tag{5.6-4}$$

sendo $g(x, y)$ a imagem borrada.

Com base na Equação 4.5-7, a transformada de Fourier da Equação 5.6-4 é

$$\begin{aligned} G(u,v) &= \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} g(x,y) e^{-j2\pi(ux+vy)} dx dy \\ &= \int_{-\infty}^{\infty}\int_{-\infty}^{\infty}\left[\int_0^T f[x - x_0(t), y - \right. \\ &\quad \left. y_0(t)]dt\right] e^{-j2\pi(ux+vy)} dx dy \end{aligned} \tag{5.6-5}$$

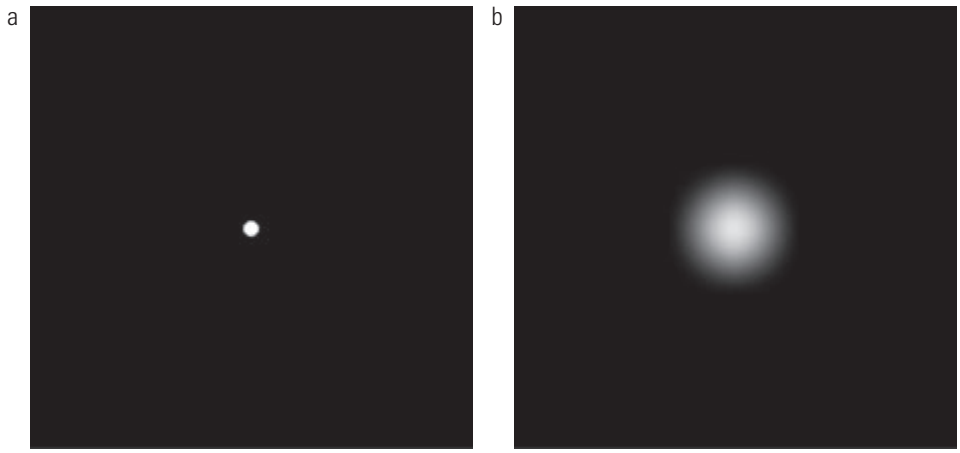


Figura 5.24 Estimativa da degradação pela caracterização do impulso. (a) Impulso de luz (mostrado ampliado). (b) Imagem desse impulso (degradado).

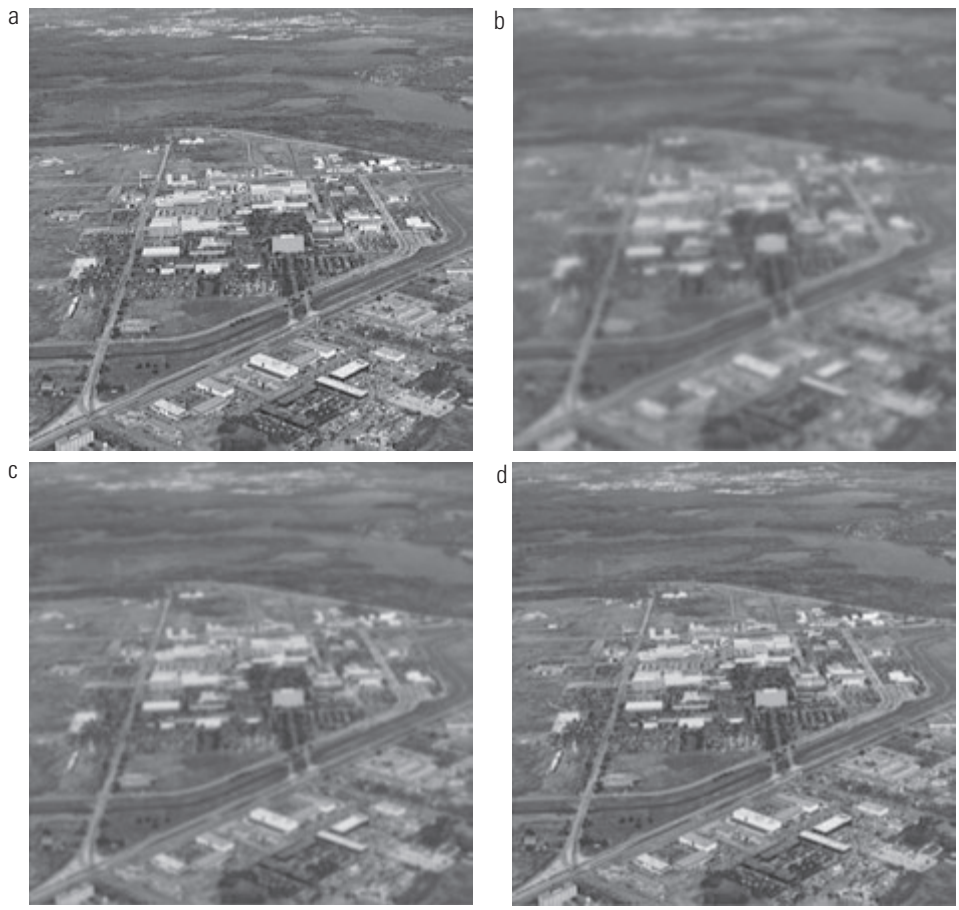


Figura 5.25 Exemplo de modelo de turbulência atmosférica. (a) Turbulência desprezível. (b) Turbulência grave, $k = 0{,}0025$. (c) Turbulência suave, $k = 0{,}001$. (d) Turbulência baixa, $k = 0{,}00025$. (Imagem original: cortesia da Nasa.)

Inverter a ordem da integração permite que a Equação 5.6-5 seja expressa na forma

$$G(u,v)=\int_0^T\left[\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f[x-x_0(t),y-y_0(t)]e^{-j2\pi(ux+vy)}dxdy\right]dt \qquad (5.6\text{-}6)$$

O termo entre os colchetes externos é a transformada de Fourier da função deslocada $f[x-x_0(t), y-y_0(t)]$. Utilizar a Equação 4.6-4 resulta na expressão

$$G(u,v)=\int_0^T F(u,v)e^{-j2\pi[ux_0(t)+vy_0(t)]}dt$$
$$=F(u,v)\int_0^T e^{-j2\pi[ux_0(t)+vy_0(t)]}dt \qquad (5.6\text{-}7)$$

na qual o último passo resulta do fato de que $F(u, v)$ independe de t.

Definindo

$$H(u,v)=\int_0^T e^{-j2\pi[ux_0(t)+vy_0(t)]}\,dt \qquad (5.6\text{-}8)$$

A Equação 5.6-7 pode ser expressa na fórmula com a qual já estamos familiarizados

$$G(u,v)=H(u,v)F(u,v) \qquad (5.6\text{-}9)$$

Se as variáveis de movimento $x_0(t)$ e $y_0(t)$ forem conhecidas, a função de transferência $H(u, v)$ pode ser obtida diretamente da Equação 5.6-8. A título de exemplo, suponha que a imagem em questão passe por um movimento linear uniforme somente na direção x, em uma velocidade dada por $x_0(t) = at/T$. Quando $t = T$, a imagem foi deslocada por uma distância total a. Com $y_0(t) = 0$, a Equação 5.6-8 resulta em

$$H(u,v)=\int_0^T e^{-j2\pi ux_0(t)}\,dt$$
$$=\int_0^T e^{-j2\pi uat/T}\,dt \qquad (5.6\text{-}10)$$
$$=\frac{T}{\pi ua}\operatorname{sen}(\pi ua)e^{-j\pi ua}$$

Observe que H desaparece em valores de u dados por $u = n/a$, sendo n um número inteiro. Se permitirmos a variação também do componente y, com o movimento dado por $y_0 = bt/T$, então a função de degradação passará a ser*

$$H(u,v)=\frac{T}{\pi(ua+vb)}sen\left[\pi(ua+vb)\right]e^{-j\pi(ua+vb)} \qquad (5.6\text{-}11)$$

■

Exemplo 5.10 Borramento de imagem em razão do movimento.

A Figura 5.26(b) é uma imagem borrada obtida pelo cálculo da transformada de Fourier da imagem na Figura 5.26(a), multiplicada por $H(u, v)$ da Equação 5.6-11 e calculando a transformada inversa. As imagens são de tamanho 688 × 688 pixels, e os parâmetros utilizados na Equação 5.6-11 foram $a = b = 0{,}1$ e $T = 1$. Como discutido nas seções 5.8 e 5.9, a recuperação da imagem original a partir de sua contraparte borrada apresenta alguns desafios interessantes, particularmente quando o ruído estiver presente na imagem degradada.

■

5.7 Filtragem inversa

O material apresentado nesta seção constitui nosso primeiro passo no estudo da restauração de imagens degradadas por uma função de degradação H, que é dada ou obtida por um método como os discutidos na seção anterior. A abordagem mais simples à restauração é a filtragem inversa direta, na qual calculamos uma estimativa, $\hat{F}(u,v)$, da transformada da imagem original simplesmente dividindo a transformada da imagem degradada, $G(u, v)$, pela função de degradação:

$$\hat{F}(u,v)=\frac{G(u,v)}{H(u,v)} \qquad (5.7\text{-}1)$$

A divisão é uma operação de arranjo matricial, como definimos na Seção 2.6.1 e em relação à Equação 5.5-17.

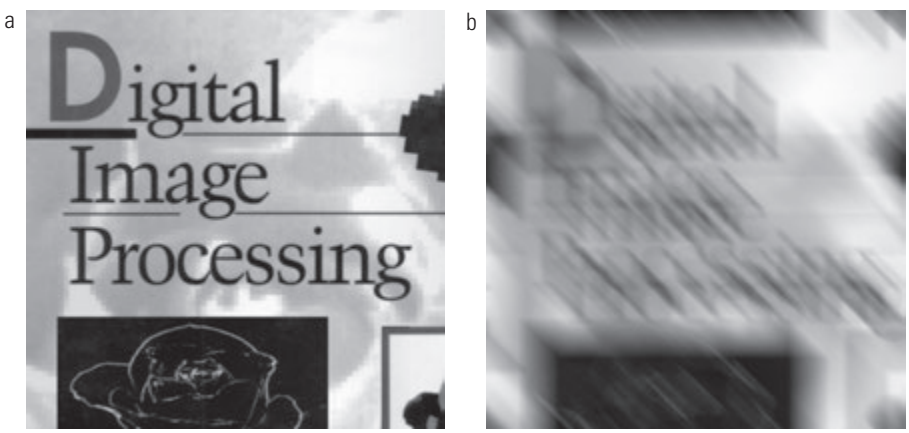


Figura 5.26 (a) Imagem original. (b) Resultado do borramento utilizando a função da Equação 5.6-11 com $a = b = 0{,}1$ e $T = 1$.

* Como explicado no final da Tabela 4.3, amostramos a Equação 5.6-11 em u e v para gerar um filtro discreto.

Substituir $G(u, v)$ da Equação 5.7-1 pelo lado direito da Equação 5.1-2 resulta em

$$\hat{F}(u,v) = F(u,v) + \frac{N(u,v)}{H(u,v)} \qquad (5.7\text{-}2)$$

Trata-se de uma expressão interessante. Ela nos indica que, mesmo se soubermos a função de degradação, não podemos recuperar a imagem não degradada [a transformada inversa de Fourier de $F(u, v)$] justamente porque $N(u, v)$ não é conhecida. E temos mais más notícias. Se a função de degradação tiver zeros ou valores muito pequenos, a razão $N(u, v)/H(u, v)$ pode facilmente dominar a estimativa $\hat{F}(u,v)$. Isso, na verdade, costuma ser o caso, como será demonstrado em breve.

Uma abordagem para contornar o problema do valor zero ou valor pequeno consiste em limitar as frequências de filtro a valores próximos à origem. A partir da análise da Equação 4.6-21 sabemos que $H(0, 0)$ costuma ser o mais alto valor de $H(u, v)$ no domínio da frequência. Assim, limitando a análise a frequências próximas à origem, reduzimos as chances de encontrar valores iguais a zero. Essa abordagem é ilustrada no exemplo a seguir.

■

Exemplo 5.11 Filtragem inversa.

A imagem da Figura 5.25(b) foi submetida à filtragem inversa com a Equação 5.7-1 utilizando exatamente a inversa da função de degradação que gerou essa imagem. Isto é, a função de degradação utilizada foi

$$H(u,v) = e^{-k[(u-M/2)^2+(v-N/2)^2]^{5/6}}$$

com $k = 0{,}0025$. As constantes $M/2$ e $N/2$ são valores utilizados para deslocamento; eles centralizam a função de forma que ela corresponderá à transformada de Fourier centralizada, como vimos em várias ocasiões no capítulo anterior. Neste caso, $M = N = 480$. Sabemos que uma função de formato gaussiano não tem zeros, de forma que não precisamos nos preocupar com isso aqui. Contudo, apesar disso, os valores de degradação se tornam tão pequenos que o resultado da filtragem inversa completa (Figura 5.27(a)) é inútil. As razões para esse resultado insuficiente são as mesmas que vimos em relação à Equação 5.7-2.

As figuras 5.27(b) e (d) mostram os resultados do recorte dos valores da razão $G(u, v)/H(u, v)$ que estão fora de um raio de 40, 70 e 85, respectivamente. O recorte foi implementado pela aplicação de uma função passa-baixa Butterworth

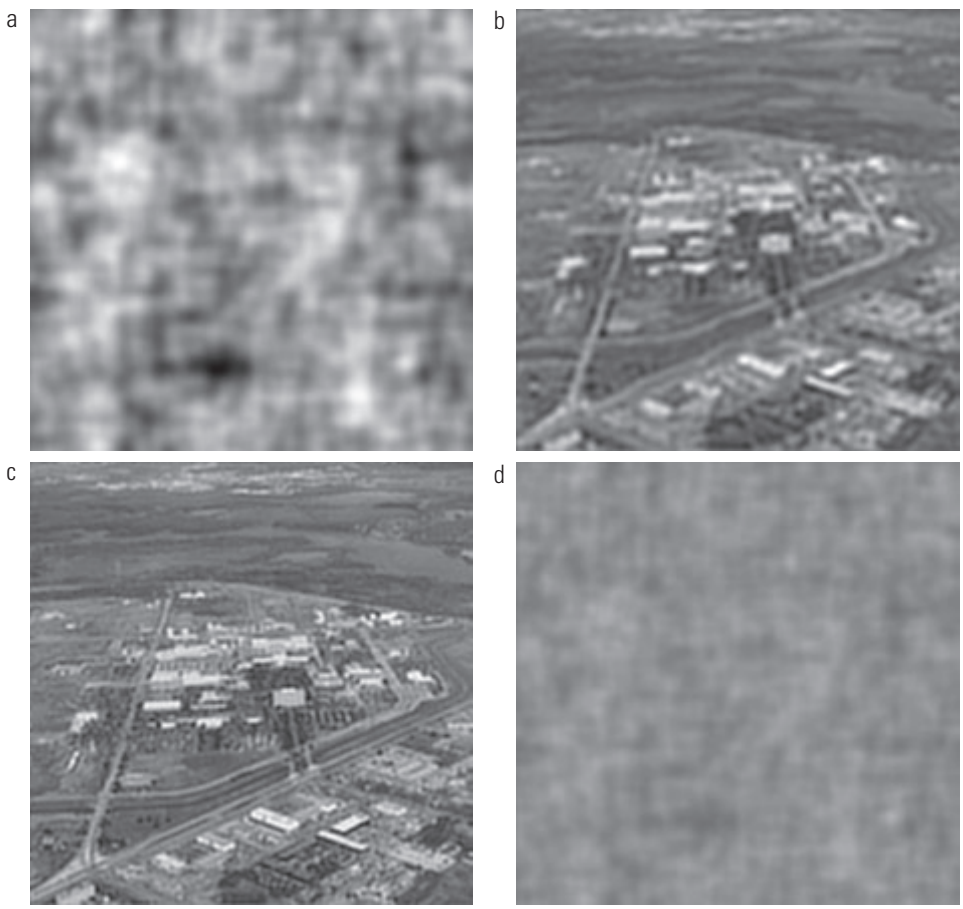


Figura 5.27 Restauração da Figura 5.25(b) com a Equação 5.7-1. (a) Resultado da utilização do filtro inverso completo. (b) Resultado com H recortado fora de um valor de raio igual a 40; (c) fora de um raio de 70; e (d) fora de um raio de 85.

de ordem 10 na razão $G(u, v)/H(u, v)$. Isso proporcionou uma transição acentuada (porém suave) no raio desejado. Os raios próximos a 70 geraram os melhores resultados visuais (Figura 5.27(c)). Os valores de raio inferiores a isso tenderam a produzir imagens borradas, como ilustrado na Figura 5.27(b), que foi obtida utilizando um valor de raio igual a 40. Valores acima de 70 começaram a produzir imagens degradadas, como ilustrado na Figura 5.27(d), que foi obtida utilizando um valor de raio igual a 85. O conteúdo da imagem é quase visível nessa imagem por trás de uma "cortina" de ruído, mas o ruído definitivamente domina o resultado. Aumentos maiores dos valores do raio produziram imagens cada vez mais parecidas com a Figura 5.27(a).

■

Os resultados do exemplo anterior exemplificam o desempenho insuficiente da filtragem inversa direta em geral. O tema básico das três seções a seguir é como melhorar a filtragem inversa direta.

5.8 Filtragem de mínimo erro quadrático médio (Wiener)

A abordagem da filtragem inversa que vimos na seção anterior não lida diretamente com o ruído. Nesta seção, veremos uma técnica que incorpora tanto a função de degradação quanto as características estatísticas do ruído no processo de restauração. O método se baseia em considerar imagens e ruído como variáveis aleatórias, e o objetivo é encontrar uma estimativa $\hat{f}$ da imagem não corrompida f, de forma que o erro quadrático médio entre eles seja minimizado.* Essa medida de erro é dada por

$$e^2 = E\{(f - \hat{f})^2\} \tag{5.8-1}$$

na qual $E\{\cdot\}$ é o valor esperado do argumento. Presume-se que o ruído e a imagem não sejam correlacionados, que o ruído ou a imagem tenha média zero e que os níveis de intensidade da estimativa sejam uma função linear dos níveis da imagem degradada. Com base nessas condições, o mínimo da função de erro da Equação 5.8-1 é dado no domínio da frequência pela expressão

$$\begin{aligned}\hat{F}(u,v) &= \left[\frac{H^*(u,v)S_f(u,v)}{S_f(u,v)\left|H(u,v)\right|^2 + S_f(u,v)}\right]G(u,v)\\ &= \left[\frac{H^*(u,v)}{\left|H(u,v)\right|^2 + S_\eta(u,v)/S_f(u,v)}\right]G(u,v)\\ &= \left[\frac{1}{H(u,v)}\frac{\left|H(u,v)\right|^2}{\left|H(u,v)\right|^2 + S_\eta(u,v)/S_f(u,v)}\right]G(u,v)\end{aligned} \tag{5.8-2}$$

na qual utilizamos o fato de que o produto de um valor complexo com seu conjugado é igual à magnitude do valor complexo ao quadrado. Esse resultado é conhecido como *filtro de Wiener*, em homenagem a N. Wiener (1942), o primeiro a propor esse conceito em 1942. O filtro, que consiste nos termos entre colchetes, também costuma ser chamado de *filtro de mínimo erro quadrático médio* ou *filtro de mínimo erro quadrático*. Incluímos referências no final do capítulo de textos contendo análises detalhadas do filtro de Wiener. Observe, na primeira linha da Equação 5.8-2, que o filtro de Wiener não apresenta o mesmo problema que o filtro inverso com zeros na função de degradação, a menos que todo o denominador seja zero para o(s) mesmo(s) valor(es) de u e v.

Os termos da Equação 5.8-2 são os seguintes:

$H(u, v)$ = função de degradação

$H^*(u, v)$ = conjugado complexo *de* $H(u, v)$

$|H(u, v)|^2 = H^*(u, v)\ H(u, v)$

$S_\eta(u, v) = |N(u, v)|^2$ = espectro de potência do ruído (veja a Equação 4.6-18)**

$S_f(u, v) = |F(u, v)|^2$ = espectro de potência da imagem não degradada

Como antes, $H(u, v)$ é a transformada da função de degradação e $G(u, v)$ é a transformada da imagem degradada. A imagem restaurada no domínio espacial é dada pela transformada inversa de Fourier da estimativa no domínio da frequência, $\hat{F}(u,v)$. Observe que, se o ruído for zero, o espectro de potência do ruído desaparece, e o filtro de Wiener é reduzido ao filtro inverso.

Várias medidas úteis se baseiam nos espectros de potência do ruído e da imagem não degradada. Um dos mais importantes é a *relação sinal-ruído* (SNR, de *signal-to-noise ratio*), cuja estimativa aproximada é calculada utilizando valores no domínio da frequência como

$$\text{SNR} = \frac{\sum_{u=0}^{M-1}\sum_{v=0}^{N-1}\left|F(u,v)\right|^2}{\sum_{u=0}^{M-1}\sum_{v=0}^{N-1}\left|N(u,v)\right|^2} \tag{5.8-3}$$

Essa razão dá uma medida do nível de informação que relaciona a potência do sinal (isto é, da imagem original, não degradada) e a potência do ruído. Imagens com baixo nível de ruído tendem a apresentar uma alta SNR e, por ou-

* Observe que imagens inteiras estão sendo consideradas variáveis aleatórias, como vimos no final da Seção 2.6.8.

** O termo $|N(u, v)|^2$ também é chamado de autocorrelação do ruído. Essa terminologia provém do teorema da correlação (primeira linha do item 7 da Tabela 4.3). Quando as duas funções são iguais, a correlação passa a ser uma autocorrelação, e o lado direito dessa relação passa a ser $N^*(u, v)\ N(u, v)$, que é igual a $|N(u, v)|^2$. Comentários similares se aplicam a $|F(u, v)|^2$, que é a autocorrelação da imagem. Discutiremos a correlação em mais detalhes no Capítulo 12.

tro lado, a mesma imagem com um nível mais alto de ruído apresenta uma SNR mais baixa. Essa relação em si tem valor limitado, mas é uma medida importante utilizada na caracterização do desempenho dos algoritmos de restauração.

O *erro quadrático médio* (MSE, de *mean square error*), expresso na forma estatística na Equação 5.8-1, também pode ser aproximadamente estimado em termos de um somatório envolvendo as imagens original e restaurada:

$$\text{MSE} = \frac{1}{MN}\sum_{x=0}^{M-1}\sum_{y=0}^{N-1}\left[f(x,y) - \hat{f}(x,y)\right]^2 \quad (5.8\text{-}4)$$

Na verdade, se considerarmos a imagem restaurada como um "sinal" e a diferença entre essa imagem e a original como ruído, podemos determinar a relação sinal–ruído no domínio do espaço como

$$\text{SNR} = \frac{\sum_{x=0}^{M-1}\sum_{y=0}^{N-1}\hat{f}(x,y)^2}{\sum_{u=0}^{M-1}\sum_{y=\mathbf{0}}^{N-1}\left[f(x,y) - \hat{f}(x,y)\right]^2} \quad (5.8\text{-}5)$$

Quanto mais próximos forem f e $\hat{f}$, maior será a SNR. Algumas vezes a raiz quadrada dessas medidas é utilizada, caso no qual elas são chamadas de *erro da raiz quadrática média* e *raiz quadrática média da relação sinal-ruído*, respectivamente. Como mencionamos várias vezes antes, tenha em mente que as métricas quantitativas não necessariamente se relacionam bem com a qualidade percebida na imagem.

Quando estamos lidando com o ruído espectralmente branco, o espectro $|N(u, v)|^2$ é uma constante, o que simplifica consideravelmente as coisas. No entanto, o espectro de potência da imagem não degradada raramente é conhecido. Uma abordagem utilizada frequentemente quando esses valores não são conhecidos ou não podem ser estimados consiste em aproximar a Equação 5.8-2 pela expressão

$$\hat{F}(u,v) = \left[\frac{1}{H(u,v)}\frac{|H(u,v)|^2}{|H(u,v)|^2 + K}\right]G(u,v) \quad (5.8\text{-}6)$$

sendo K uma constante especificada adicionada a todos os termos de $|H(u, v)|^2$. Os exemplos a seguir ilustram a utilização dessa expressão.

■

Exemplo 5.12 Comparação entre a filtragem inversa e a filtragem de Wiener.

A Figura 5.28 mostra a vantagem da filtragem de Wiener em relação à filtragem inversa direta. A Figura 5.28(a) apresenta o resultado da filtragem inversa completa da Figura 5.27(a). De forma similar, a Figura 5.28(b) é o resultado do filtro inverso radialmente limitado da Figura 5.27(c). Essas imagens são duplicadas aqui para facilitar as comparações. A Figura 5.28(c) mostra o resultado obtido utilizando a Equação 5.8-6 com a função de degradação utilizada no Exemplo 5.11. O valor de K foi escolhido interativamente para gerar os melhores resultados visuais. A vantagem do filtro de Wiener sobre o filtro inverso direto fica clara neste exemplo. Comparando as figuras 5.25(a) e 5.28(c), vemos que o filtro de Wiener gerou um resultado muito similar à imagem original.

■

■

Exemplo 5.13 Outras comparações da filtragem de Wiener.

A primeira linha da Figura 5.29 mostra, da esquerda para a direita, a imagem borrada da Figura 5.26(b) fortemente corrompida por ruído gaussiano aditivo de média zero e variância 650; o resultado da filtragem inversa direta; e o resultado da filtragem de Wiener. O filtro de Wiener da Equação 5.8-6 foi utilizado, com $H(u, v)$ do Exemplo 5.10 e com K escolhido interativamente para produzir o melhor resultado visual possível. Como era de esperar, o filtro inverso produziu uma imagem inútil. Observe que o ruído da



Figura 5.28 Comparação entre a filtragem inversa e a filtragem de Wiener. (a) Resultado da filtragem inversa completa da Figura 5.25(b). (b) Resultado do filtro inverso radialmente limitado. (c) Resultado do filtro de Wiener.



Figura 5.29 (a) Uma imagem de 8 bits corrompida por borramento de movimento e ruído aditivo. (b) Resultado da filtragem inversa. (c) Resultado da filtragem de Wiener. (d) a (f) Mesma sequência, mas com a variância de ruído reduzida em uma ordem de magnitude. (g) a (i) Mesma sequência, mas com a variância de ruído reduzida em cinco ordens de magnitude em relação a (a). Observe em (h) como a imagem submetida à redução de borramento é relativamente visível através de uma "cortina" de ruído.

imagem submetida à filtragem inversa é tão intenso que sua estrutura tende na direção do filtro de *redução de borramento* (*deblurring*). O resultado do filtro de Wiener está longe de ser perfeito, mas nos dá uma ideia do conteúdo da imagem. Com alguma dificuldade, o texto é legível.

A segunda linha da Figura 5.29 mostra a mesma sequência, mas com o nível de variância do ruído reduzido de uma ordem de magnitude. Essa redução não teve um grande efeito sobre o filtro inverso, mas os resultados do filtro de Wiener foram consideravelmente melhorados. O texto agora é muito mais fácil de ler. Na terceira linha da Figura 5.29, a variância do ruído foi reduzida mais do que cinco ordens de magnitude em relação à primeira linha. Na verdade, a Figura 5.29(g) não apresenta ruído visível. O resultado do filtro inverso é interessante neste caso. O ruído ainda é bastante visível, mas o texto pode ser visto através de uma "cortina" de ruído. Trata-se de um bom exemplo dos nossos comentários em relação à Equação 5.7-2. Em outras palavras, como é evidente na Figura 5.29(h), o filtro inverso foi bastante capaz de eliminar essencialmente o borramento da imagem. Contudo, o ruído ainda domina o resultado. Se pudéssemos "olhar" por trás do ruído nas figuras 5.29(b) e (e), os caracteres também apresentariam muito pouco borramento. O resultado do filtro de Wiener na Figura 5.29(i) é excelente, bastante próximo visualmente da imagem original na Figura 5.26(a). Esses tipos de resultados são representativos do que é possível fazer com a filtragem de Wiener, desde que uma estimativa razoável da função de degradação esteja disponível.

■

5.9 Filtragem por mínimos quadráticos com restrição

O problema de precisarmos saber alguma informação sobre a função de degradação H é comum a todos os métodos discutidos neste capítulo. No entanto, o filtro de Wiener apresenta uma dificuldade adicional: os espectros de potência da imagem não degradada e do ruído devem ser conhecidos. Mostramos na seção anterior que é possível atingir excelentes resultados utilizando a aproximação dada na Equação 5.8-6. No entanto, uma estimativa constante da relação dos espectros de potência nem sempre é uma solução apropriada.

O método discutido nesta seção requer conhecimento apenas da média e da variância do ruído. Como vimos na Seção 5.2.4, esses parâmetros podem normalmente ser calculados a partir de uma dada imagem degradada, de forma que se trata de uma importante vantagem. Uma outra diferença é que o filtro de Wiener se baseia na minimização de um critério estatístico e, como tal, é ótimo no sentido de obter valores aproximados. O algoritmo apresentado nesta seção tem a notável característica de gerar um resultado ótimo para *cada* imagem à qual ele é aplicado. Naturalmente, é importante ter em mente que esses critérios de otimização, apesar de satisfatórios do ponto de vista teórico, não são relacionados à dinâmica da percepção visual. Consequentemente, a escolha de um algoritmo em detrimento de outro quase sempre será determinada (pelo menos em parte) pela qualidade visual percebida das imagens resultantes.

Utilizando a definição da convolução dada na Equação 4.6-23, como explicamos na Seção 2.6.6, pode mos expressar a Equação 5.5-16 na forma matriz-vetor:*

$$\mathbf{g} = \mathbf{H}\mathbf{f} + \boldsymbol{\eta} \tag{5.9-1}$$

Por exemplo, suponha que $g(x, y)$ seja de tamanho $M \times N$. Com isso, podemos calcular os primeiros N elementos do vetor $\mathbf{g}$ utilizando os elementos de imagem da primeira linha de $g(x, y)$, os próximos N elementos da segunda linha e assim por diante. O vetor resultante terá dimensões $MN \times 1$. Essas também são as dimensões de $\mathbf{f}$ e $\boldsymbol{\eta}$, já que esses vetores são formados da mesma maneira. Então, a matriz $\mathbf{H}$ tem dimensões $MN \times MN$. Seus elementos são dados pelos elementos da convolução fornecida pela Equação 4.6-23.

Seria razoável concluir que o problema de restauração agora pode ser reduzido a manipulações matriciais simples. Infelizmente, não é esse o caso. Por exemplo, suponha que estejamos trabalhando com imagens de tamanho médio, digamos $M = N = 512$. Então os vetores na Equação 5.9-1 seriam de dimensões 262.144×1 e a matriz $\mathbf{H}$ seria de dimensões 262.144×262.144. Manipular vetores e matrizes com dimensões dessa magnitude não é uma tarefa simples. O problema fica ainda mais complicado pelo fato de $\mathbf{H}$ ser altamente sensível ao ruído (depois das experiências que tivemos com o efeito do ruído nas duas seções anteriores, isso não deveria ser uma surpresa). No entanto, formular o problema da restauração em formato matricial de fato facilita a dedução de técnicas de restauração.

Apesar de não deduzirmos inteiramente o método dos mínimos quadráticos com restrição, que apresentaremos em breve, esse método tem raízes em uma formulação matricial. As referências apresentadas no final do capítulo citam fontes nas quais as deduções são analisadas em detalhes. O fundamental neste método é a questão da sensibilidade de $\mathbf{H}$ ao ruído. Uma forma de atenuar o problema de sensibilidade ao ruído é basear a otimização da restauração em uma medida de suavidade, como a segunda derivada de uma imagem (nosso velho amigo laplaciano). Para ser significativa, a restauração deve ser restrita pelos parâmetros dos problemas em questão.** Dessa forma, é desejável calcular o mínimo de uma função de critério, C, definida como

$$C = \sum_{x=0}^{M-1}\sum_{y=0}^{N-1}\left[\nabla^2 f(x,y)\right]^2 \tag{5.9-2}$$

sujeita à restrição

$$\left\|\mathbf{g} - \mathbf{H}\hat{\mathbf{f}}\right\|^2 = \|\boldsymbol{\eta}\|^2 \tag{5.9-3}$$

sendo que $\|\mathbf{w}\|^2 \triangleq \mathbf{w}^T\mathbf{w}$ é a norma euclidiana de um vetor*** e $\hat{\mathbf{f}}$ é a estimativa da imagem não degradada. O operador laplaciano ∇^2 é definido na Equação 3.6-3.

A solução no domínio da frequência para esse problema de otimização é dada pela expressão

$$\hat{F}(u,v) = \left[\frac{H^*(u,v)}{|H(u,v)|^2 + \gamma|P(u,v)|^2}\right]G(u,v) \tag{5.9-4}$$

na qual γ é um parâmetro que deve ser ajustado de forma que a restrição na Equação 5.9-3 seja satisfeita e $P(u, v)$ é a transformada de Fourier da função

$$p(x,y) = \begin{bmatrix} 0 & -1 & 0 \\ -1 & 4 & -1 \\ 0 & -1 & 0 \end{bmatrix} \tag{5.9-5}$$

Reconhecemos essa função como o operador laplaciano apresentado na Seção 3.6.2. Como observado an-

* Consulte o site do livro para uma breve revisão sobre vetores e matrizes.

** Consulte a seção Tutoriais no site do livro para um capítulo inteiro dedicado ao tópico das técnicas algébricas para a restauração de imagens.

*** Lembre-se que, para um vetor $\mathbf{w}$ com n componentes, temos $\mathbf{w}^T\mathbf{w} = \sum_{k=1}^{n} w_k^2$, em que w_k é o k-ésimo componente de $\mathbf{w}$.

teriormente, é importante ter em mente que $p(x, y)$, bem como outras funções relevantes no domínio espacial, devem ser adequadamente preenchidas com zeros antes do cálculo de suas transformadas de Fourier para a aplicação na Equação 5.9-4, como vimos na Seção 4.6.6. Observe que a Equação 5.9-4 se reduz à filtragem inversa se γ for zero.

■

Exemplo 5.14 Comparação entre a filtragem de Wiener e a filtragem por mínimos quadráticos com restrição.

A Figura 5.30 mostra o resultado do processamento das figuras 5.29(a), (d) e (g) com filtros de mínimos quadráticos com restrição, nos quais os valores de γ foram manualmente selecionados para obter melhores resultados visuais. Esse é o mesmo procedimento utilizado para gerar os resultados da filtragem de Wiener na Figura 5.29(c), (f) e (i). Comparando os resultados do filtro de mínimos quadráticos com restrição e do filtro de Wiener, observamos que o primeiro filtro gerou resultados ligeiramente melhores para casos com alto e médio nível de ruído, com os dois filtros gerando essencialmente os mesmos resultados para o caso de baixo nível de ruído. Não é de se surpreender que o filtro dos mínimos quadráticos com restrição apresente um desempenho melhor que o filtro de Wiener quando selecionamos manualmente os parâmetros para melhores resultados visuais. O parâmetro γ na Equação 5.9-4 é escalar, ao passo que o valor de K na Equação 5.8-6 é uma aproximação da razão de duas funções desconhecidas no domínio da frequência; essa razão raramente é constante. Dessa forma, é lógico que um resultado baseado na seleção manual de γ seria uma estimativa mais exata da imagem não degradada.

■

Como vimos no exemplo anterior, é possível ajustar interativamente o parâmetro γ até que resultados aceitáveis sejam atingidos. Se estivermos interessados na otimização, contudo, o parâmetro γ deve ser ajustado de forma que a restrição na Equação 5.9-3 seja satisfeita. Apresentamos a seguir um procedimento para o cálculo de γ por interações.

Definimos um vetor "residual" $\mathbf{r}$ como

$$\mathbf{r} = \mathbf{g} - \mathbf{H}\hat{\mathbf{f}} \tag{5.9-6}$$

Como, a partir da solução na Equação 5.9-4, $\hat{F}(u,v)$ (e, por implicação, $\hat{\boldsymbol{f}}$) é uma função de γ, então $\mathbf{r}$ também é uma função desse parâmetro. Pode ser demonstrado [Hunt (1973)] que

$$\begin{aligned}\phi(\gamma) &= \mathbf{r}^T\mathbf{r} \\ &= \|\mathbf{r}\|^2\end{aligned} \tag{5.9-7}$$

é uma função monotonicamente crescente de γ. O que queremos fazer é ajustar γ de forma que

$$\|\mathbf{r}\|^2 = \|\boldsymbol{\eta}\|^2 \pm a \tag{5.9-8}$$

sendo a um fator de exatidão. Como resultado da Equação 5.9-6, se $\|\mathbf{r}\|^2 > \|\boldsymbol{\eta}\|^2$, a restrição na Equação 5.9-3 s erá rigorosamente satisfeita.

Como $\phi(\gamma)$ é monotônico, não é difícil encontrar o valor desejado de γ. Uma metodologia seria a seguinte:

1. Especifique um valor inicial de γ.
2. Calcule $\|\mathbf{r}\|^2$.
3. Pare se a Equação 5.9-8 for satisfeita; se não, volte ao passo 2 depois de aumentar γ se $\|\mathbf{r}\|^2 < \|\boldsymbol{\eta}\|^2 - a$ ou reduzir γ se $\|\mathbf{r}\|^2 > \|\boldsymbol{\eta}\|^2 + a$. Use o novo valor de γ na Equação 5.9-4 para recalcular a estimativa ótima, $\hat{F}(u, v)$.

Outros procedimentos, como o algoritmo de Newton–Raphson, podem ser utilizados para melhorar a velocidade da convergência.

Para utilizar esse algoritmo, precisamos dos valores de $\|\mathbf{r}\|^2$ e $\|\boldsymbol{\eta}\|^2$. Para calcular $\|\mathbf{r}\|^2$, observamos, a partir da Equação 5.9-6, que

$$R(u,v) = G(u,v) - H(u,v)\hat{F}(u,v) \tag{5.9-9}$$

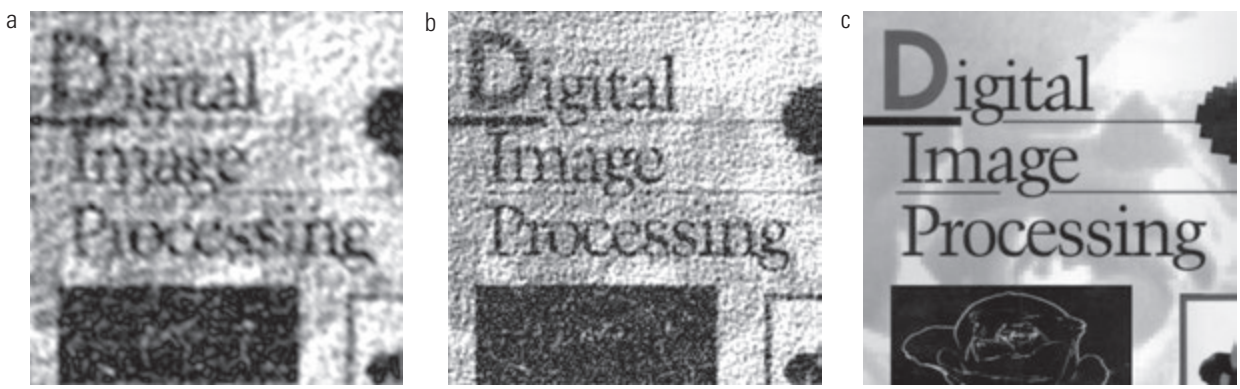


Figura 5.30 Resultados da filtragem por mínimos quadráticos com restrição. Compare (a), (b) e (c) com os resultados da filtragem de Wiener das figuras 5.29(c), (f) e (i), respectivamente.

Com isso, obtemos $r(x, y)$ pelo cálculo da transformada inversa de $R(u, v)$. Então

$$\|\mathbf{r}\|^2 = \sum_{x=0}^{M-1}\sum_{y=0}^{N-1} r^2(x,y) \qquad (5.9\text{-}10)$$

O cálculo de $\|\boldsymbol{\eta}\|^2$ leva a um resultado interessante. Para começar, considere a variância do ruído ao longo de toda a imagem, que estimamos pelo método da média amostral, como vimos na Seção 3.3.4:

$$\sigma_\eta^2 = \frac{1}{MN}\sum_{x=0}^{M-1}\sum_{y=0}^{N-1}\left[\eta(x,y) - m_\eta\right]^2 \qquad (5.9\text{-}11)$$

sendo que

$$m_\eta = \frac{1}{MN}\sum_{x=0}^{M-1}\sum_{y=0}^{N-1}\eta(x,y) \qquad (5.9\text{-}12)$$

é a média da amostra. No que se refere à *fórmula* da Equação 5.9-10, observamos que o duplo somatório na Equação 5.9-11 é igual a $\|\boldsymbol{\eta}\|^2$. Isso nos dá a expressão

$$\|\boldsymbol{\eta}\|^2 = MN[\sigma_\eta^2 + m_\eta^2] \qquad (5.9\text{-}13)$$

Trata-se de um resultado bastante útil. Ele nos informa que podemos implementar um algoritmo de restauração ótimo conhecendo apenas a média e a variância do ruído. Não é difícil estimar esses valores (Seção 5.2.4), considerando que os valores de intensidade do ruído e da imagem não são correlacionados. Trata-se de um pressuposto básico de todos os métodos discutidos neste capítulo.

■

Exemplo 5.15 Estimativa iterativa do filtro ótimo por mínimos quadráticos com restrição.

A Figura 5.31(a) mostra o resultado obtido utilizando o algoritmo que acabamos de descrever para estimar o filtro ótimo de restauração da Figura 5.25(b). O valor inicial utilizado para γ foi 10^{-5}, o fator de correção para ajustar γ foi 10^{-6} e o valor de a foi 0,25. Os parâmetros de ruído especificados foram os mesmos utilizados para gerar a Figura 5.25(a): uma variância de ruído de 10^{-5} e média zero. O resultado restaurado é quase tão bom quanto a Figura 5.28(c), que foi obtida pela filtragem de Wiener com K especificada manualmente para os melhores resultados visuais. A Figura 5.31(b) mostra o que pode acontecer se utilizarmos a estimativa errada dos parâmetros de ruído. Nesse caso, a variância do ruído especificada foi 10^{-2}, e a média foi mantida no valor 0. O resultado, neste caso, é consideravelmente mais borrado.

■

Como afirmamos no início desta seção, é importante ter em mente que a restauração ótima no sentido dos mínimos quadráticos com restrição não implica necessariamente "o melhor" em termos visuais. Dependendo da natureza e da magnitude da degradação e do ruído, os outros parâmetros do algoritmo para determinar iterativamente a estimativa ótima também exercem um papel no resultado final. Em geral, filtros de restauração determinados automaticamente levam a resultados inferiores em relação ao ajuste manual de parâmetros do filtro. Isso é particularmente verdadeiro em relação ao filtro por mínimos quadráticos com restrição, que é completamente especificado por um parâmetro escalar único.

5.10 Filtro de média geométrica

É possível generalizar ligeiramente o filtro de Wiener discutido na Seção 5.8. A generalização é realizada na forma do chamado *filtro de média geométrica*:

$$\hat{F}(u,v) = \left[\frac{H^*(u,v)}{|H(v,v)|^2}\right]^{\alpha}\left[\frac{H^*(u,v)}{|H(v,v)|^2 + \beta\left[\frac{S_\eta(u,v)}{S_f(u,v)}\right]}\right]^{1-\alpha} G(u,v) \qquad (5.10\text{-}1)$$

com α e β sendo constantes reais, positivas. O filtro de média geométrica consiste nas duas expressões entre colchetes elevadas às potências α e $1 - \alpha$, respectivamente.

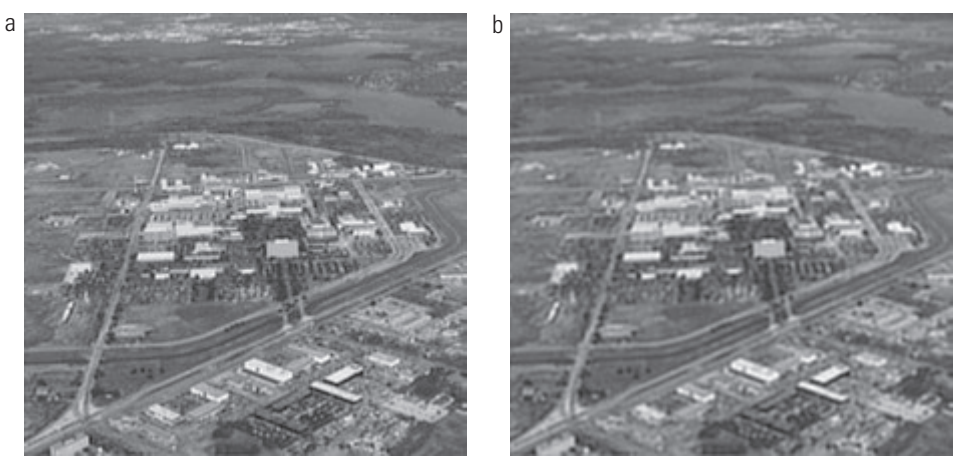


Figura 5.31 (a) Restauração da Figura 5.16(b) por mínimos quadráticos com restrição, determinados iterativamente utilizando parâmetros corretos de ruído. (b) Resultado obtido com parâmetros errados de ruído.

Quando $\alpha = 1$, esse filtro se reduz ao filtro inverso. Com $\alpha = 0$, o filtro se torna o que chamamos de *filtro paramétrico de Wiener*, que se reduz ao filtro de Wiener padrão quando $\beta = 1$. Se $\alpha = 1/2$, o filtro passa a ser um produto dos dois valores elevados à mesma potência, que é a definição da média geométrica, que dá o nome ao filtro. Com $\beta = 1$, à medida que α decresce para valores menores do que 1/2, o desempenho do filtro tende para o filtro inverso. De forma similar, quando α aumenta para valores acima de 1/2, o filtro se comporta mais como o filtro de Wiener. Quando $\alpha = 1/2$ e $\beta = 1$, o filtro também é comumente chamado de *filtro de equalização de espectro*. A Equação 5.10-1 é bastante útil ao implementar filtros de restauração por representar uma família de filtros combinados em uma única expressão.

5.11 Reconstrução de imagens a partir de projeções

Nas seções anteriores deste capítulo, lidamos com técnicas de restauração de uma versão degradada de uma imagem. Nesta seção, analisaremos o problema da *reconstrução* de uma imagem a partir de uma série de projeções, com foco na *tomografia computadorizada* (CT, de *computerized tomography*) de raios X. Trata-se do tipo de CT mais antigo e ainda o mais amplamente utilizado e que atualmente constitui uma das principais aplicações do processamento digital de imagens na medicina.*

5.11.1 Introdução

O problema da reconstrução é em princípio simples, e pode ser qualitativamente explicado de forma direta e intuitiva. Para começar, vejamos a Figura 5.32(a), que consiste em um único objeto sobre um fundo uniforme. Para dar sentido físico à explicação a seguir, suponha que essa imagem seja um corte transversal de uma região 3-D de um corpo humano. Suponha também que o fundo da imagem represente um tecido mole e uniforme, ao passo que o objeto redondo é um tumor, também uniforme, mas com características de maior absorção.

Depois, suponha que passemos um feixe fino e uniforme de raios X da esquerda para a direita (através do plano da imagem), como mostra a Figura 5.32(a), e considere que a energia do feixe seja mais absorvida pelo objeto do que pelo fundo, como costuma ser o caso. Utilizar uma faixa de detectores de absorção de raios X no outro lado da região resultará no sinal (perfil de absorção) mostrado,

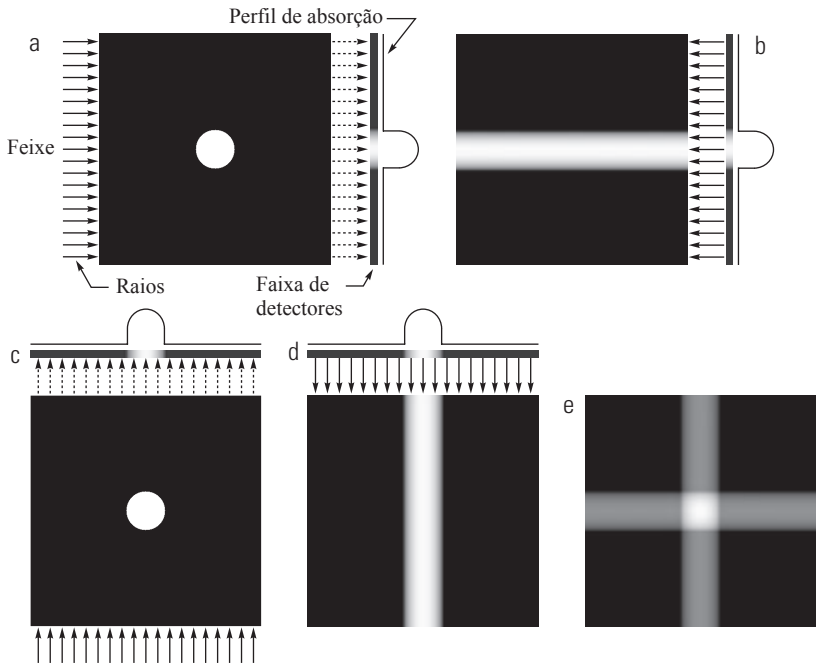


Figura 5.32 (a) Região plana mostrando um objeto simples, um feixe paralelo de entrada e uma faixa de detectores. (b) Resultado da retroprojeção dos dados obtidos com a faixa de sensores (isto é, o perfil de absorção 1-D). (c) O feixe e os detectores rotacionados a 90°. (d) Retroprojeção. (e) A soma de (b) e (d). A intensidade na qual as retroprojeções se cruzam é duas vezes a intensidade das retroprojeções individuais.

* Como observamos no Capítulo 1, o termo *tomografia axial computadorizada* (CAT, de *computerized axial tomography*) é utilizado como sinônimo de *tomografia computadorizada* (CT).

cuja amplitude (intensidade) é proporcional à absorção.* Podemos ver qualquer ponto do sinal como a soma dos valores de absorção de um único raio do feixe que corresponde espacialmente a esse ponto (uma soma como essa muitas vezes é chamada de *soma de raios* ou *raysum*). Neste ponto, toda a informação que temos sobre o objeto é esse sinal de absorção 1-D.

Não temos como saber, a partir de uma única projeção, se estamos lidando com um único objeto ou vários objetos ao longo do caminho do feixe, mas começamos a reconstrução criando uma *imagem* baseada apenas nessa informação. A técnica é voltar a projetar o sinal 1-D na direção da qual o feixe veio, como mostra a Figura 5.32(b). O processo de retroprojeção de um sinal 1-D em uma área 2-D algumas vezes se refere a *espalhar* a projeção no sentido contrário através da área. Em termos de imagens digitais, isso significa duplicar o mesmo sinal 1-D pela imagem perpendicularmente à direção do feixe. Por exemplo, a Figura 5.32(b) foi criada duplicando o sinal 1-D em todas as colunas da imagem reconstruída. Por razões óbvias, a técnica que acabamos de descrever é chamada de *retroprojeção*.

Em seguida, suponha que rotacionemos em 90° a posição do par fonte-detector, como na Figura 5.32(c). Repetir o procedimento explicado no parágrafo anterior resulta em uma imagem de retroprojeção na direção vertical, como mostra a Figura 5.32(d). Continuamos a reconstrução *adicionando* esse resultado à retroprojeção anterior, o que resulta na Figura 5.32(e). Agora podemos dizer que o objeto de interesse está contido no quadrado mostrado, cuja amplitude é duas vezes a amplitude das retroprojeções individuais. Um pouco de reflexão revelará que deveríamos ser capazes de saber mais sobre o formato do objeto em questão obtendo mais projeções pelo procedimento que acabamos de descrever. Na verdade, isso é exatamente o que acontece, como mostra a Figura 5.33. À medida que o número de projeções aumenta, a intensidade das retroprojeções que não se cruzam diminui em relação à intensidade das regiões nas quais as múltiplas retroprojeções se cruzam. O efeito final é que as regiões mais claras dominarão o resultado e as retroprojeções com pouca ou nenhuma intersecção desaparecerão no plano de fundo à medida que a imagem é ajustada para a exibição.

A Figura 5.33(f), formada a partir de 32 projeções, ilustra esse conceito. Observe, contudo, que, apesar de essa imagem reconstruída ser uma aproximação relativamente boa do formato do objeto original, é borrada por um efeito de "halo", cuja formação pode ser vista em estágios progressivos na Figura 5.33. Por exemplo, o halo na Figura 5.33(e) aparece como uma "estrela" cuja intensidade é mais baixa que a do objeto, mas mais alta que a do fundo. À medida que o número de visualizações aumenta, o formato do halo se torna circular, como na Figura 5.33(f). O borramento na reconstrução CT é um problema importante, cuja solução é descrita na Seção 5.11.5. Por fim, concluímos, com base na análise das figuras 5.32 e 5.33, que projeções com 180° entre si são imagens espelhadas

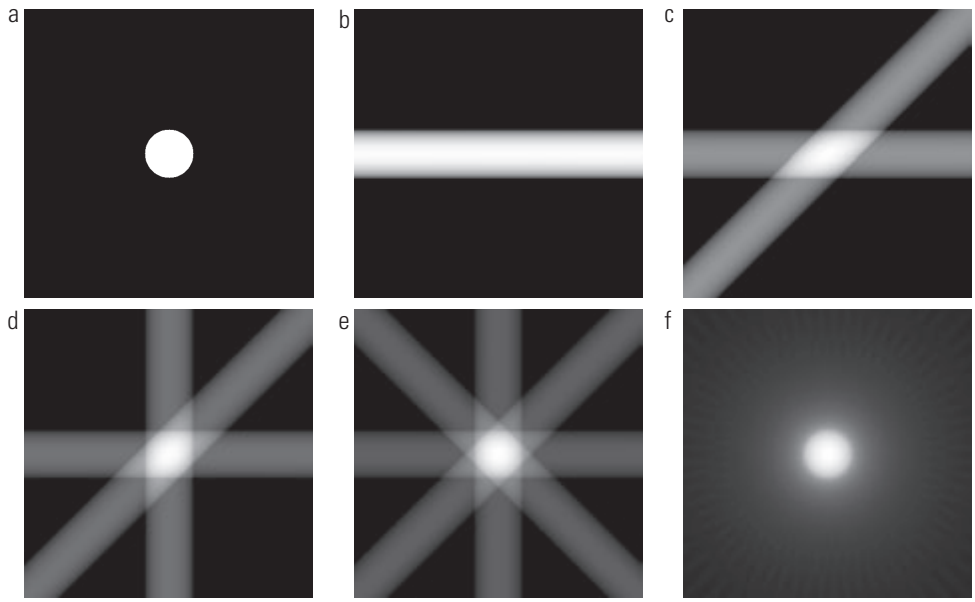


Figura 5.33 (a) Igual à Figura 5.32(a). (b) a (e) Reconstrução usando 1, 2, 3, e 4 projeções com distância de 45°. (f) Reconstrução com 32 projeções com distância de 5,625° (note o efeito borrado).

* Uma análise das características físicas das fontes e detectores de raios X está fora do escopo desta discussão, a qual se concentra apenas nos aspectos de processamento de imagens da CT. Veja Prince e Links (2006) para uma excelente introdução aos aspectos físicos da formação de imagens por raios X.

uma da outra; assim, só precisamos levar em consideração incrementos angulares ao redor de meio círculo para gerar todas as projeções necessárias para a reconstrução.

■

Exemplo 5.16 Retroprojeção de uma região planar simples contendo dois objetos.

A Figura 5.34 ilustra a reconstrução utilizando retroprojeções em uma região ligeiramente mais complicada que contém dois objetos com diferentes propriedades de absorção. A Figura 5.34(b) mostra o resultado da utilização de uma retroprojeção. Observamos três características principais nessa figura, de baixo para cima: uma banda horizontal cinza fina correspondente à porção não concluída do pequeno objeto, uma banda mais clara (mais absorção) acima dela correspondente à área compartilhada pelos dois objetos e uma banda superior correspondente ao resto do objeto elíptico. As figuras 5.34(c) e (d) mostram a reconstrução utilizando duas projeções com 90° entre elas e quatro projeções com 45° entre elas, respectivamente. A explicação dessas figuras é similar à análise das figuras 5.33(c) a (e). As figuras 5.34(e) e (f) mostram reconstruções mais precisas utilizando 32 e 64 retroprojeções, respectivamente. Esses dois resultados são bastante próximos visualmente e os dois mostram o problema do borramento mencionado anteriormente, cuja solução explicaremos na Seção 5.11.5.

■

5.11.2 Princípios da tomografia computadorizada (CT)

A meta da CT de raios X é obter uma representação 3-D da estrutura interna de um objeto radiografando esse objeto de várias direções diferentes. Imagine uma radiografia tradicional de tórax, obtida posicionando o paciente contra uma placa ou um filme sensível aos raios X e "iluminando" a pessoa com um feixe de raios X na forma de um cone. O filme de raios X produz uma imagem cuja intensidade em um ponto é proporcional à energia do raio X que atinge esse ponto depois de ter passado através do paciente. Essa imagem é o equivalente 2-D das projeções que analisamos na seção anterior. Poderíamos realizar a retroprojeção da imagem inteira e criar um volume 3-D. Repetir esse processo para vários ângulos e acrescentar as retroprojeções resultaria na representação 3-D da estrutura da cavidade peitoral. A CT tenta obter as mesmas informações (ou partes localizadas delas) gerando *fatias* através do corpo. Então, uma representação 3-D pode ser obtida empilhando as fatias. Uma implementação de CT é muito mais econômica, porque o número de detectores necessários para obter uma fatia de alta resolução é muito menor que o número de detectores necessários para gerar uma projeção 2-D completa com a mesma resolução. O custo computacional e as dosagens de raios X também são reduzidos, fazendo da projeção CT 1-D uma abordagem muito mais prática.

Como no caso da transformada de Fourier que vimos no capítulo anterior, conceitos matemáticos básicos necessários para a CT já haviam sido desenvolvidos anos antes de se tornarem viáveis, graças à disponibilidade dos computadores digitais. As bases teóricas da CT remontam de Johann Radon, um matemático de Viena que em 1917 deduziu um método para projetar um objeto 2-D

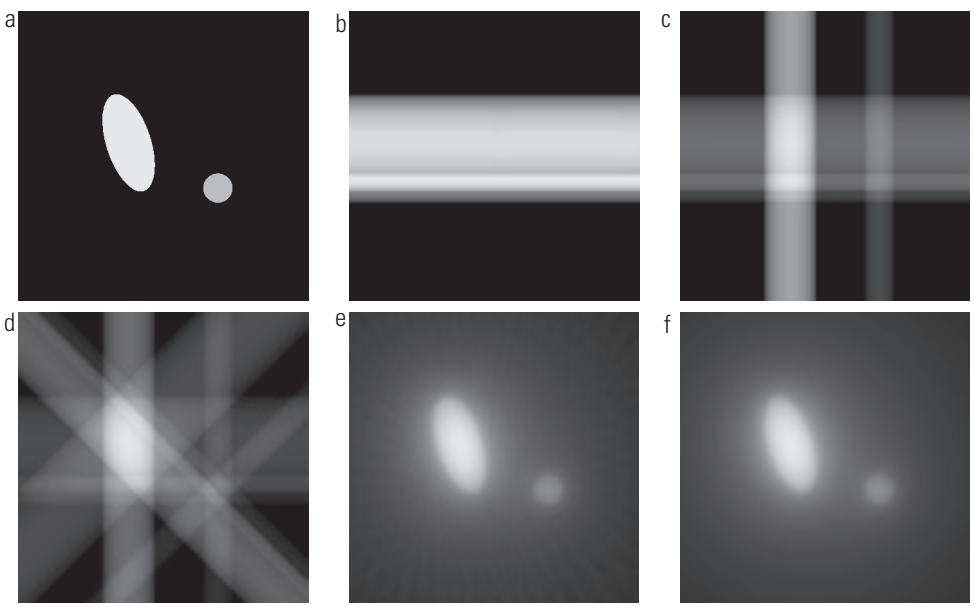


Figura 5.34 (a) Uma região com dois objetos. (b) a (d) Reconstrução utilizando 1, 2 e 4 retroprojeções separadas de 45°. (e) Reconstrução com 32 retroprojeções separadas de 5,625°. (f) Reconstrução com 64 retroprojeções separadas de 2,8125°.

ao longo de raios paralelos como parte de seu trabalho com integrais de linha. O método atualmente costuma ser chamado de *transformada de Radon*, um tópico que analisaremos na seção a seguir. Quarenta e cinco anos mais tarde, Allan M. Cormack, um físico da Tufts University, "redescobriu" parcialmente esses conceitos e os aplicou à CT. Cormack publicou seus primeiros resultados em 1963 e 1964 e demonstrou como eles poderiam ser utilizados para reconstruir imagens de corte transversal do corpo a partir de imagens de raios X obtidas em diferentes direções angulares. Ele desenvolveu as fórmulas matemáticas necessárias para a reconstrução e desenvolveu um protótipo de CT para mostrar a viabilidade de suas ideias. Trabalhando independentemente, o engenheiro eletricista Godfrey N. Hounsfield e seus colegas da EMI, em Londres, formularam uma solução similar e construíram o primeiro aparelho de CT de aplicação médica. Cormack e Hounsfield receberam juntos o Prêmio Nobel de Medicina de 1979 por suas contribuições para a tomografia médica.

Os *scanners CT de primeira geração (G1)* utilizavam um feixe de raios X em forma de "lápis" e um único detector, como mostra a Figura 5.35(a). Para um dado ângulo de rotação, o par fonte/detector é transladado em incrementos ao longo da direção linear mostrada. Uma projeção (como as da Figura 5.32) é gerada medindo a saída do detector em cada incremento de translação. Após uma translação linear completa, o conjunto fonte/detector é rotacionado e o procedimento é repetido para gerar uma outra projeção em um ângulo diferente. O procedimento é repetido para todos os ângulos desejados no intervalo [0°, 180°] para gerar um conjunto completo de projeções, das quais uma imagem é gerada pela retroprojeção, como explicamos na seção anterior. A marca de um "x" na cabeça do paciente indica movimento na direção perpendicular ao plano do par fonte/detector. Um conjunto de imagens de corte transversal (fatias) é gerado movendo gradativamente o paciente após cada varredura completa (*scan*) no plano fonte/detector. Empilhar computacio-

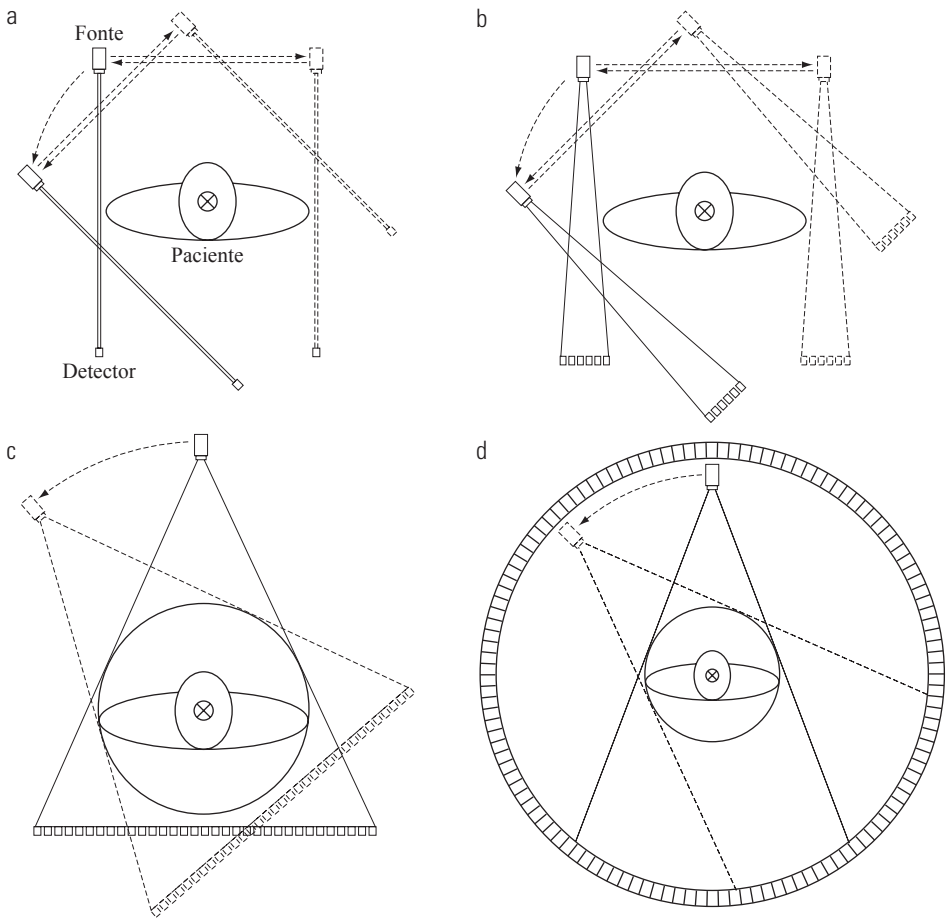


Figura 5.35 Quatro gerações de *scanners* CT. As linhas tracejadas com setas indicam o movimento linear incremental. Os arcos tracejados com setas indicam a rotação incremental. A marca de um "x" na cabeça do paciente indica o movimento linear perpendicular ao plano do papel. As setas duplas em (a) e (b) indicam que o conjunto fonte/detector é transladado e depois retornado à posição original.

nalmente essas imagens produz um volume 3-D de uma seção do corpo. Os *scanners* G1 não são mais fabricados para a obtenção de imagens médicas, mas, por produzirem um feixe de raios paralelos (como na Figura 5.32), sua geometria é a mais utilizada para apresentar os fundamentos da aquisição de imagens de CT. Como veremos na próxima seção, essa geometria é o ponto de partida para deduzir as equações necessárias para implementar a reconstrução de imagens a partir de projeções.

Os *scanners CT de segunda geração (G2)* (Figura 5.35(b)) funcionam com base no mesmo princípio que os *scanners* G1, mas o feixe utilizado tem o formato de um "leque". Isso permite a utilização de múltiplos detectores, o que requer menos translações do par fonte/detector. Os *scanners de terceira geração (G3)* representam uma melhora significativa em relação às duas gerações anteriores de geometrias de CT. Como mostra a Figura 5.35(c), os *scanners* G3 empregam um banco de detectores longo o suficiente (da ordem de mil detectores individuais) para cobrir todo o campo de visão de um feixe mais amplo. Consequentemente, cada incremento de ângulo produz uma projeção completa, eliminando a necessidade de transladar o par fonte/detector, como requer a geometria dos *scanners* G1 e G2. *Os scanners de quarta geração (G4)* vão um passo além. Ao empregar um anel circular de detectores (da ordem de 5 mil detectores individuais), só a fonte precisa ser rotacionada. A principal vantagem dos *scanners* G3 e G4 é a velocidade. As principais desvantagens são o custo e um maior espalhamento de raios X, o que requer doses mais altas do que os *scanners* G1 e G2 para atingir características comparáveis de relação sinal-ruído.

Modalidades mais recentes de varredura estão começando a ser adotadas. Por exemplo, os *scanners CT de quinta geração (G5)*, também conhecidos como *scanners de tomografia computadorizada por feixe de elétrons* (EBCT, de *electron beam computed tomography*), eliminam todo o movimento mecânico empregando feixes de elétrons controlados eletromagneticamente. Ao atingir anodos de tungstênio que cercam o paciente, esses feixes produzem raios X que então são moldados em um feixe no formato de leque que passa através do paciente e estimula um anel de detectores, como nos *scanners* G4.

A forma convencional na qual as imagens CT são obtidas consiste em manter o paciente imóvel durante o tempo de varredura necessário para gerar uma imagem. A varredura é interrompida enquanto a posição do paciente é incrementada na direção perpendicular ao plano de aquisição de imagens utilizando uma mesa motorizada. A próxima imagem é então obtida e o procedimento é repetido o número de incrementos necessários para cobrir uma seção especificada do corpo. Apesar de uma imagem poder ser obtida em menos de um segundo, existem procedimentos (por exemplo, para imagens de abdome e tórax) que requerem que o paciente prenda a respiração durante a aquisição da imagem. Concluir esses procedimentos para, digamos, 30 imagens, pode demandar vários minutos. Uma abordagem cuja utilização está se popularizando é a *CT helicoidal*, algumas vezes chamada de *CT de sexta geração (G6)*. Com esse método, um scanner G3 ou G4 é configurado utilizando os chamados anéis de contato (*slip rings*), que eliminam a necessidade de cabeamento elétrico e de sinais entre as fontes/detectores e a unidades de processamento. O par fonte/detector é continuamente rotacionado a 360° enquanto o paciente é movido em uma velocidade constante ao longo do eixo perpendicular à varredura. O resultado é um volume helicoidal contínuo de dados que é processado para obter imagens de fatias individuais.

Scanners de sétima geração (G7) (também chamados de *multislice CT scanners*) estão surgindo com feixes "espessos" em forma de leque utilizados em conjunto com bancos paralelos de detectores para coletar simultaneamente dados volumétricos de CT. Dessa forma, fatias "grossas" 3-D de corte transversal, em vez de imagens únicas de corte transversal, são geradas para cada descarga de raios X. Além de um aumento significativo de detalhes, essa abordagem tem a vantagem de utilizar tubos de raios X de modo mais econômico, reduzindo, assim, o custo e, potencialmente, a dosagem.

A partir da próxima seção, desenvolveremos as ferramentas matemáticas necessárias para formular a projeção de imagens e os algoritmos de reconstrução. Nosso foco será nas bases do processamento de imagens que fundamentam todas as abordagens de CT que acabamos de discutir. Informações relativas às características mecânicas e de fonte/detector dos sistemas CT são fornecidas nas referências citadas no final do capítulo.

5.11.3 Projeções e a transformada de Radon*

A seguir, desenvolveremos em detalhes a matemática necessária para a reconstrução de imagens no contexto da tomografia computadorizada por raios X, mas os mesmos princípios básicos são aplicáveis em outras modalidades de aquisição de imagens tomográficas, como o SPECT (tomografia por emissão de fóton único), PET (tomografia por emissão de pósitrons), MRI (ressonância magnética) e algumas modalidades da aquisição de imagens por ultrassom.

* Ao longo desta seção, seguimos a convenção da CT e posicionamos a origem do plano xy no centro, e não no canto superior esquerdo, como vínhamos fazendo até agora (veja a Seção 2.4.2). Observe, contudo, que ambos são sistemas de coordenadas destros, e a única diferença é que o nosso sistema de coordenadas de imagens não tem eixos negativos. Podemos dar conta da diferença com uma simples translação da origem, de forma que as duas representações sejam equivalentes.

Uma linha reta em coordenadas cartesianas pode ser descrita na forma *inclinação-intersecção*, $y = ax + b$, ou, como na Figura 5.36, por sua representação *normal*:

$$x\cos\theta + y\,\text{sen}\,\theta = \rho \qquad (5.11\text{-}1)$$

A projeção de um feixe de raios paralelos pode ser formada por um conjunto dessas linhas, como mostra a Figura 5.37. Um ponto arbitrário no sinal de projeção é dado pela soma de raios ao longo da linha $x\ cos\ \theta_k + y\ \text{sen}\ \theta_k = \rho_j$. Trabalhando com valores contínuos* por enquanto, a soma de raios é uma integral de linha, dada por

$$g(\rho_j,\theta_k) = \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f(x,y)\delta(x\cos\theta_k + y\,\text{sen}\,\theta_k - \rho_j)\,dx\,dy \qquad (5.11\text{-}2)$$

na qual utilizamos as propriedades do impulso, δ, discutidas na Seção 4.5.1. Em outras palavras, o lado direito da Equação 5.11-2 é zero a não ser que o argumento de δ seja zero, indicando que a integral é calculada apenas ao longo da linha $x\cos\theta_k + y\,\text{sen}\,\theta_k = \rho_j$. Se considerarmos todos os valores de ρ e θ, a equação anterior é generalizada a

$$g(\rho,\theta) = \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f(x,y)\delta(x\cos\theta + y\,\text{sen}\,\theta - \rho)\,dx\,dy \qquad (5.11\text{-}3)$$

Essa equação, que nos dá a projeção (integral de linha) de $f(x, y)$ ao longo de uma linha arbitrária no plano xy, é a *transformada de Radon* que mencionamos na seção anterior. A notação $\Re\{f(x, y)\}$ ou $\Re\{f\}$ por vezes é utilizada no lugar de $g(\rho,\theta)$ na Equação 5.11-3 para expressar a transformada de Radon de f, mas o tipo de notação utilizada na Equação 5.11-3 é mais comum. Como ficará claro na análise a seguir, a transformada de Radon representa a base da reconstrução a partir de projeções, com a tomografia computadorizada sendo sua principal aplicação na área do processamento de imagens.

No caso discreto, a Equação 5.11-3 passa a ser

$$g(\rho,\theta) = \sum_{x=0}^{M-1}\sum_{y=0}^{N-1} f(x,y)\delta(x\cos\theta + y\,\text{sen}\,\theta - \rho) \qquad (5.11\text{-}4)$$

na qual x, y, ρ e θ agora são variáveis discretas. Se mantivermos θ fixo e permitirmos que ρ varie, veremos que 5.11-4 simplesmente soma os pixels de $f(x, y)$ ao longo da linha definida pelos valores especificados desses dois parâmetros. Incrementar todos os valores de ρ necessários para incluir a imagem (com θ fixo) resulta em *uma* projeção. Alterar θ e repetir o procedimento anterior resulta em outra projeção e assim por diante. As projeções da Seção 5.11.1 foram geradas justamente dessa forma.

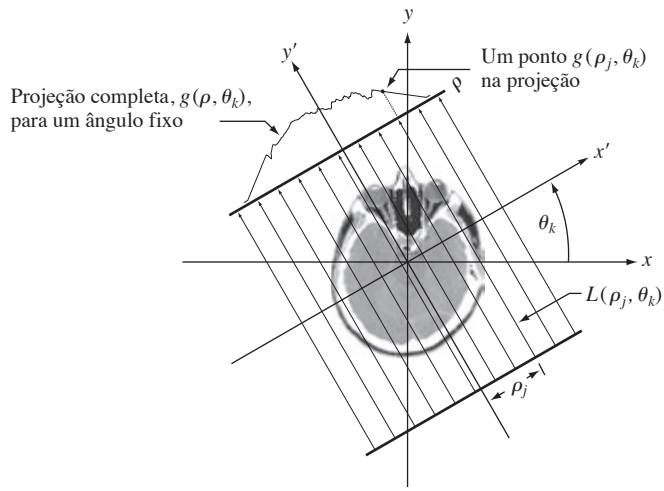


Figura 5.37 Geometria de um feixe de raios paralelos.

■

Exemplo 5.17 Utilização da transformada de Radon para obter a projeção de uma região circular.

Antes de prosseguir, ilustraremos como utilizar a transformada de Radon para obter uma expressão analítica para a projeção do objeto circular da Figura 5.38(a):

$$f(x,y) = \begin{cases} A & x^2 + y^2 \le r^2 \\ 0 & \text{caso contrário} \end{cases}$$

na qual A é uma constante e r é o raio do objeto. Consideramos que o círculo está centralizado na origem do plano xy. Como o objeto é circularmente simétrico, suas projeções

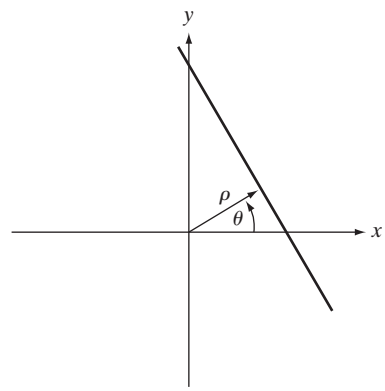


Figura 5.36 Representação normal de uma linha reta.

* No Capítulo 4, tomamos muito cuidado ao indicar coordenadas contínuas de imagens por (t, z) e coordenadas discretas por (x, y). Na ocasião, essa distinção era importante porque estávamos desenvolvendo conceitos básicos para nos levar de valores contínuos a amostrados. Já na presente discussão, passaremos tantas vezes de coordenadas contínuas para discretas e vice-versa, que seguir essa convenção pode gerar uma confusão desnecessária. Por esse motivo, e também para seguir a literatura publicada na área [por exemplo, veja Prince e Links (2006)], deixaremos que o contexto determine se as coordenadas (x, y) são contínuas ou discretas. Quando elas forem contínuas, você verá integrais; se não, você verá somatórios.

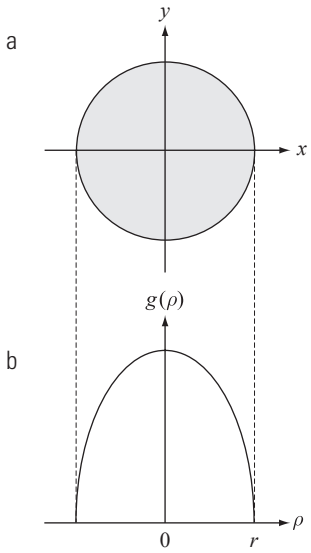


Figura 5.38 (a) Um disco e (b) um gráfico de sua transformada de Radon, deduzido analiticamente. Neste caso, podemos traçar o diagrama da transformada porque ela depende de apenas uma variável. Quando g depende tanto de ρ quanto de θ, a transformada de Radon se torna uma imagem cujos eixos são ρ e θ e a intensidade de um pixel é proporcional ao valor de g na posição desse pixel.

são as mesmas para todos os ângulos, de forma que tudo o que precisamos fazer é obter a projeção para $\theta = 0^o$. Então, a Equação 5.11-3 passa a ser

$$g(\rho,\theta) = \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f(x,y)\delta(x-\rho)\,dx\,dy$$
$$= \int_{-\infty}^{\infty} f(\rho,y)\,dy$$

na qual a segunda linha resulta da Equação 4.2-10. Como observamos anteriormente, trata-se de uma integral de linha (ao longo da linha $L(\rho, 0)$, neste caso). Além disso, note que $g(\rho,\theta) = 0$ quando $|\rho| > r$. Quando $|\rho| \le r$, a integral é calculada de $y = -\sqrt{r^2-\rho^2}$ para $y = \sqrt{r^2-\rho^2}$.

Dessa forma,

$$g(\rho,\theta) = \int_{-\sqrt{r^2-\rho^2}}^{\sqrt{r^2-\rho^2}} f(\rho,y)\,dy$$
$$= \int_{-\sqrt{r^2-\rho^2}}^{\sqrt{r^2-\rho^2}} A\,dy$$

Realizar a integração resulta em

$$g(\rho,\theta) = g(\rho) = \begin{cases} 2A\sqrt{r^2-\rho^2} & |\rho| \le r \\ 0 & \text{se não} \end{cases}$$

na qual utilizamos o fato mencionado de que $g(\rho,\theta) = 0$, quando $|\rho| > r$. A Figura 5.38(b) mostra o resultado, que está de acordo com as projeções ilustradas nas figuras 5.32 e 5.33. Note que $g(\rho,\theta) = g(\rho)$, isto é, que g é independente de θ porque o objeto é simétrico em relação à origem.

■

Quando a transformada de Radon, $g(\rho,\theta)$, é exibida como uma imagem com ρ e θ como coordenadas retilíneas, o resultado é chamado de *senograma*, conceitualmente similar à exibição do espectro de Fourier (diferentemente da transformada de Fourier, contudo, $g(\rho,\theta)$ é sempre uma função real). Da mesma forma que a transformada de Fourier, um senograma contém os dados necessários para reconstruir $f(x, y)$. Como no caso de visualização do espectro de Fourier, um senograma pode ser facilmente interpretado para regiões simples, mas se torna cada vez mais difícil de "ler" à medida que a região sendo projetada se torna mais complexa. Por exemplo, a Figura 5.39(b) é o senograma do retângulo à esquerda. Os eixos vertical e horizontal correspondem a θ e ρ, respectivamente. Dessa forma, a linha inferior é a projeção do retângulo na direção horizontal (isto é, $\theta = 0^o$) e a linha do meio é a projeção na direção vertical ($\theta = 90^o$). O fato de a porção diferente de zero da linha inferior ser menor que a porção diferente de zero da linha do meio nos indica que o objeto é mais estreito na direção horizontal. O fato de o senograma ser simétrico nas duas direções em relação ao centro da imagem nos informa que estamos lidando com um objeto simétrico e paralelo aos eixos x e y. Por fim, o senograma é suave, indicando que o objeto tem intensidade uniforme. Além desses tipos de observações gerais, não podemos dizer muito mais sobre esse senograma.*

A Figura 5.39(c) mostra uma imagem do *phantom de Shepp-Logan*, uma imagem sintética amplamente utilizada desenvolvida para simular a absorção de importantes áreas do cérebro, incluindo pequenos tumores. O senograma dessa imagem é consideravelmente mais difícil de interpretar, como mostra a Figura 5.39(d). Ainda é possível inferir algumas propriedades de simetria, mas não podemos dizer muito mais do que isso. A análise visual de senogramas tem utilização prática limitada, mas algumas vezes é útil no desenvolvimento de algoritmos.

O principal objetivo da CT é obter uma representação 3-D de um volume a partir de suas projeções. Como apresentamos intuitivamente na Seção 5.11.1, o método utilizado consiste em realizar a retroprojeção de cada projeção e depois somar todas as retroprojeções para gerar uma imagem (fatia). Empilhar todas as imagens resultan-

* Para gerar arranjos matriciais com linhas de mesmo tamanho, a dimensão mínima do eixo ρ nos senogramas corresponde à maior dimensão encontrada durante a projeção. Por exemplo, o tamanho mínimo de um senograma de um quadrado de tamanho $M \times M$ obtido utilizando incremento de 1° é $180 \times Q$, sendo Q o menor número inteiro maior que $\sqrt{2}M$.

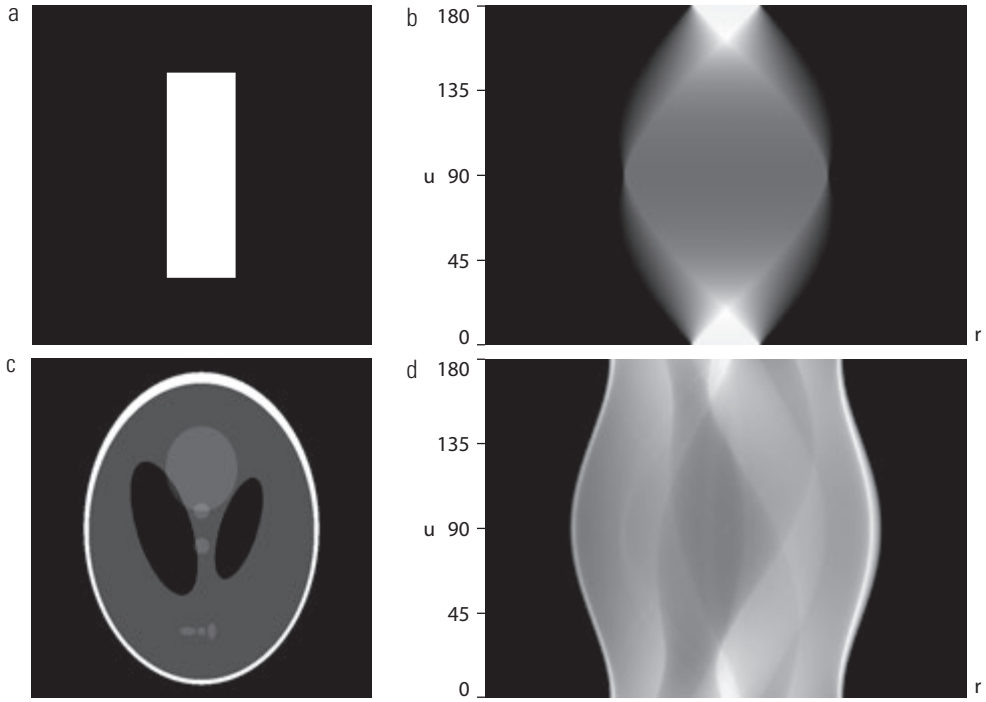


Figura 5.39 Duas imagens e seus senogramas (transformadas de Radon). Cada linha de um senograma é uma projeção ao longo do ângulo correspondente no eixo vertical. A imagem (c) é chamada de *phantom de Shepp-Logan*. Em sua forma original, o contraste do *phantom* é bastante baixo. Aqui ele é mostrado realçado para facilitar a visualização.

tes produz uma representação 3-D do volume. Para obter uma expressão formal de uma imagem retroprojetada da transformada de Radon, vamos começar com um *único* ponto, $g(\rho_j, \theta_k)$ da projeção completa, $g(\rho, \theta_k)$, para um valor *fixo* de rotação, θ_k (veja a Figura 5.37). Formar parte de uma imagem a partir da retroprojeção desse *único* ponto equivale a copiar a linha $L(\rho_j, \theta_k)$ na imagem, na qual o valor de cada ponto dessa linha é $g(\rho_j, \theta_k)$. Repetir esse procedimento para todos os valores de ρ_j no sinal projetado (mas mantendo o valor de θ fixo em θ_k) resulta na expressão a seguir:

$$\begin{aligned} f_{\theta_k}(x, y) &= g(\rho, \theta_k) \\ &= g(x \cos\theta_k + y \operatorname{sen}\theta_k, \theta_k) \end{aligned}$$

para a imagem correspondente à retroprojeção da projeção obtida com um ângulo fixo, θ_k, como na Figura 5.32(b). Essa equação se mantém para um valor arbitrário de θ_k, de forma que podemos escrever, em geral, que a imagem formada a partir de uma *única* retroprojeção obtida em um ângulo θ é dada por

$$f_\theta(x, y) = g(x \cos\theta + y \operatorname{sen}\theta, \theta) \qquad (5.11\text{-}5)$$

Formamos a imagem final por meio da integração de todas as imagens retroprojetadas:

$$f(x, y) = \int_0^\pi f_\theta(x, y)\, d\theta \qquad (5.11\text{-}6)$$

No caso discreto, a integral se torna uma soma de todas as imagens retroprojetadas:

$$f(x, y) = \sum_{\theta=0}^{\pi} f_\theta(x, y) \qquad (5.11\text{-}7)$$

sendo que x, y e θ agora são variáveis discretas. Lembre-se, com base na análise apresentada na Seção 5.11.1, que as projeções em 0° e 180° são imagens espelhadas uma da outra, de forma que os somatórios são realizados até o último incremento angular antes de 180°. Por exemplo, se estivermos utilizando incrementos de 0,5°, o somatório é de 0 a 179,5 em incrementos de meio grau. Uma imagem retroprojetada formada do modo que acabamos de descrever algumas vezes é chamada de *laminograma*. Está implícito que um laminograma é apenas uma aproximação da imagem da qual as projeções foram geradas, um fato que é ilustrado claramente no exemplo a seguir.

■

Exemplo 5.18 Obtenção de imagens retroprojetadas a partir de senogramas.

A Equação 5.11-7 foi utilizada para gerar imagens retroprojetadas nas figuras 5.32 a 5.34, a partir de proje-

ções obtidas com a Equação 5.11-4. De forma similar, essas equações foram utilizadas para gerar as figuras 5.40(a) e (b), que mostram as imagens retroprojetadas correspondentes aos senogramas das figuras 5.39(b) e (d), respectivamente. Como no caso de figuras anteriores, notamos um borramento significativo, de forma que fica claro que uma utilização direta das equações 5.11-4 e 5.11-7 não gerará resultados aceitáveis. Sistemas experimentais de CT mais antigos eram baseados nessas equações. No entanto, como veremos na Seção 5.11.5, é possível realizar melhoras significativas na reconstrução reformulando o método da retroprojeção. ■

5.11.4 O teorema da fatia de Fourier

Nesta seção, deduzimos um resultado fundamental relacionando a transformada de Fourier 1-D de uma projeção e a transformada de Fourier 2-D da região a partir da qual a projeção foi obtida. Essa relação constitui a base dos métodos de reconstrução capazes de lidar com o problema do borramento que acabamos de discutir.

A transformada de Fourier 1-D de uma projeção em relação a ρ é

$$G(\omega,\theta)=\int_{-\infty}^{\infty} g(\rho,\theta)e^{-j2\pi\omega\rho}\,dp \qquad (5.11\text{-}8)$$

na qual, como na Equação 4.2-16, ω é a variável de frequência, e entende-se que essa expressão é válida para um dado valor de θ. Substituir $g(\rho,\theta)$ pela Equação 5.11-3 resulta na expressão

$$\begin{aligned}G(\omega,\theta)&=\int_{-\infty}^{\infty}\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f(x,y)\delta(x\cos\theta+\\&\quad y\,\mathrm{sen}-\rho)e^{-j2\pi\omega\rho}\,dxdyd\rho\\&=\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f(x,y)\left[\int_{-\infty}^{\infty}\delta(x\cos\theta+\right.\\&\quad\left. y\,\mathrm{sen}\,\theta-\rho)e^{-j2\pi\omega\rho}\,dp\right]dx\,dy\\&=\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f(x,y)e^{-j2\pi\omega(x\cos\theta+y\,\mathrm{sen}\,\theta)}\,dx\,dy\end{aligned} \qquad (5.11\text{-}9)$$

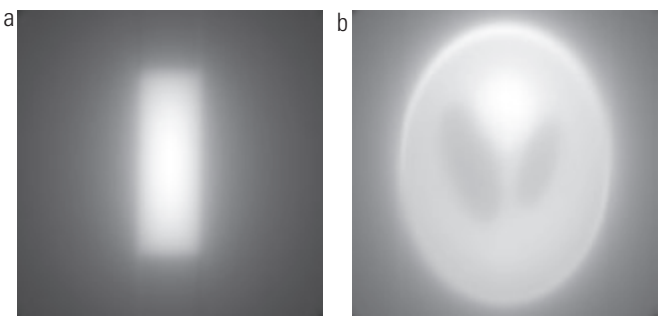


Figura 5.40 Retroprojeções dos senogramas da Figura 5.39.

sendo que o último passo resulta da propriedade do impulso que mencionamos anteriormente nesta seção. Com $u = \omega\cos\theta$ e $v = \omega\,\mathrm{sen}\,\theta$, a Equação 5.11-9 passa a ser

$$G(\omega,\theta)=\left[\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f(x,y)\,e^{-j2\pi(ux+vy)}dxdy\right]_{u=\omega\cos\theta;v=\omega\,\mathrm{sen}\,\theta} \qquad (5.11\text{-}10)$$

Reconhecemos essa expressão como a transformada de Fourier 2-D de $f(x, y)$ (veja a Equação 4.5-7), calculada para os valores indicados de u e v. Isto é,

$$\begin{aligned}G(\rho,\theta)&=\left[F(u,v)\right]_{u=\omega\cos\theta;v=\omega\,\mathrm{sen}\,\theta}\\&=F(\omega\cos\theta,\omega\,\mathrm{sen}\,\theta)\end{aligned} \qquad (5.11\text{-}11)$$

na qual, como de costume, $F(u, v)$ expressa a transformada de Fourier 2-D de $f(x, y)$.

A Equação 5.11-11 é conhecida como o *teorema da fatia de Fourier* (ou *teorema da projeção-fatia*). O teorema afirma que a transformada de Fourier de uma projeção é uma *fatia* da transformada de Fourier 2-D da região a partir da qual a projeção foi obtida. A razão para essa terminologia pode ser explicada com a ajuda da Figura 5.41. Como mostra essa figura, a transformada de Fourier 1-D de uma projeção arbitrária é obtida extraindo os valores de $F(u, v)$ ao longo de uma linha orientada no mesmo ângulo que o utilizado para gerar a projeção. Em princípio, poderíamos obter $f(x, y)$ simplesmente obtendo a transformada inversa de Fourier de $F(u, v)$.* No entanto, isso tem um alto custo computacional e envolve inverter uma transformada 2-D. A metodologia discutida na seção a seguir é muito mais eficiente.

5.11.5 Reconstrução utilizando retroprojeções filtradas por feixes paralelos

Como vimos na Seção 5.11.1 e no Exemplo 5.18, obter as retroprojeções de maneira direta gera resultados inaceitavelmente borrados. Felizmente, esse problema tem uma solução direta baseada apenas na filtragem das projeções antes de calcular as retroprojeções. A partir da Equação 4.5-8, temos que a transformada inversa de Fourier 2-D de $F(u, v)$ é

$$f(x,y)=\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} F(u,v)\,e^{j2\pi(ux+vy)}dudv \qquad (5.11\text{-}12)$$

Se, como nas equações 5.11-10 e 5.11-11, fizermos $u = \omega\cos\theta$ e $v = \omega\,\mathrm{sen}\,\theta$, os diferenciais passam a ser

* Tenha em mente que o borramento também estará presente em uma imagem recuperada utilizando a transformada inversa de Fourier, porque o resultado é equivalente ao obtido utilizando o método analisado na seção anterior.

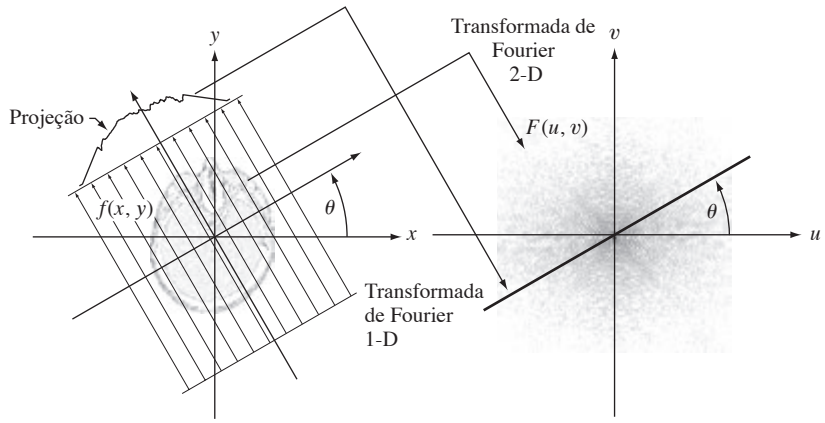


Figura 5.41 Ilustração do teorema da fatia de Fourier. A transformada de Fourier 1-D de uma projeção é uma fatia da transformada de Fourier 2-D da região a partir da qual a projeção foi obtida. Observe a correspondência do ângulo .

du dv = $\omega\, d\omega\, d\theta$, e podemos expressar a Equação 5.11-12 em coordenadas polares:*

$$f(x,y)=\int_0^{2\pi}\int_0^{\infty} F(\omega\cos\theta,\omega\,\mathrm{sen}\,\theta)\, e^{j2\pi\omega(x\cos\theta+y\,\mathrm{sen}\,\theta)}\omega\, d\omega\, d\theta \qquad (5.11\text{-}13)$$

Então, utilizando o teorema da fatia de Fourier,

$$f(x,y)=\int_0^{2\pi}\int_0^{\infty} G(\omega,\theta)\, e^{j2\pi\omega(x\cos\theta+y\,\mathrm{sen}\,\theta)}\omega\, d\omega\, d\theta \qquad (5.11\text{-}14)$$

Ao dividir essa integral em duas expressões, uma para θ no intervalo 0° a 180° e a outra no intervalo 180° a 360°, e utilizando o fato de que $G(\omega, \theta + 180^{o}) = G(-\omega, \theta)$ (veja o Exercício 5.32), podemos expressar a Equação 5.11-14 como

$$f(x,y)=\int_0^{\pi}\int_0^{\infty} |\omega| G(\omega,\theta)\, e^{j2\pi\omega(x\cos\theta+y\,\mathrm{sen}\,\theta)} d\omega\, d\theta \qquad (5.11\text{-}15)$$

Em termos de integração referente a ω, o termo $x \cos\theta + y\,\mathrm{sen}\,\theta$ é uma constante que reconhecemos como ρ a partir da Equação 5.11-1. Dessa forma, a Equação 5.11-15 pode ser expressa como:

$$f(x,y)=\int_0^{\pi}\left[\int_{-\infty}^{\infty} |\omega| G(\omega,\theta)\, e^{j2\pi\omega\rho} d\omega\right]_{\rho=x\cos\theta+y\,\mathrm{sen}\,\rho} \qquad (5.11\text{-}16)$$

A expressão interna é expressa na forma de uma transformada *inversa* de Fourier 1-D (veja a Equação 4.2-17), com o termo adicionado |ω| que, com base na análise da Seção 4.7, reconhecemos como uma função filtro *unidimensional*. Observe que |ω| é um filtro *rampa* (veja a Figura 5.42(a)).** Essa função não é integrável porque sua amplitude se estende a +∞ em ambas as direções, de forma que a transformada inversa de Fourier é indefinida. Teoricamente, isso é solucionado com métodos como a utilização das chamadas *funções delta generalizadas*. Na prática, a técnica consiste em aplicar uma janela à rampa de forma que ela passe a ser zero fora de um intervalo de frequência definido. Isto é, uma janela *limita a banda* do filtro rampa.

A abordagem mais simples para limitar a banda de uma função é utilizar um filtro retangular no domínio da frequência. No entanto, como vimos na Figura 4.4, um filtro retangular tem propriedades indesejáveis de *ringing*, de forma que uma janela suave é utilizada em seu lugar. A Figura 5.42(a) mostra um gráfico do filtro rampa depois de ter a banda limitada por uma janela retangular, e a Figura 5.42(b) mostra sua representação no domínio do espaço, obtida calculando sua transformada inversa de Fourier. Como esperávamos, o filtro de janelamento resultante apresenta um *ringing* visível no domínio do espaço. Sabemos, com base no Capítulo 4, que a filtragem no domínio da frequência equivale à convolução no domínio do espaço, de forma que a filtragem espacial com uma função que apresenta *ringing* também produzirá um resultado também corrompido pelo *ringing*. O janelamento com uma função suave ajuda nessa situação. Uma função de janela discreta de *M* pontos, utilizada frequentemente para implementação com a FFT 1-D, é dada por

$$h(\omega)=\begin{cases} c+(c-1)\cos\dfrac{2\pi\omega}{M-1} & 0\le\omega\le(M-1) \\ 0 & \text{se não} \end{cases} \qquad (5.11\text{-}17)$$

* A relação $du\,dv = \omega\, d\omega\, d\theta$ provém do cálculo integral básico, no qual o jacobiano é utilizado como a base para uma alteração das variáveis.

** O filtro rampa é muitas vezes chamado de filtro de Ram-Lak, em homenagem a Ramachandran e Lakshminarayanan (1971), que em geral são considerados os primeiros a sugeri-lo.

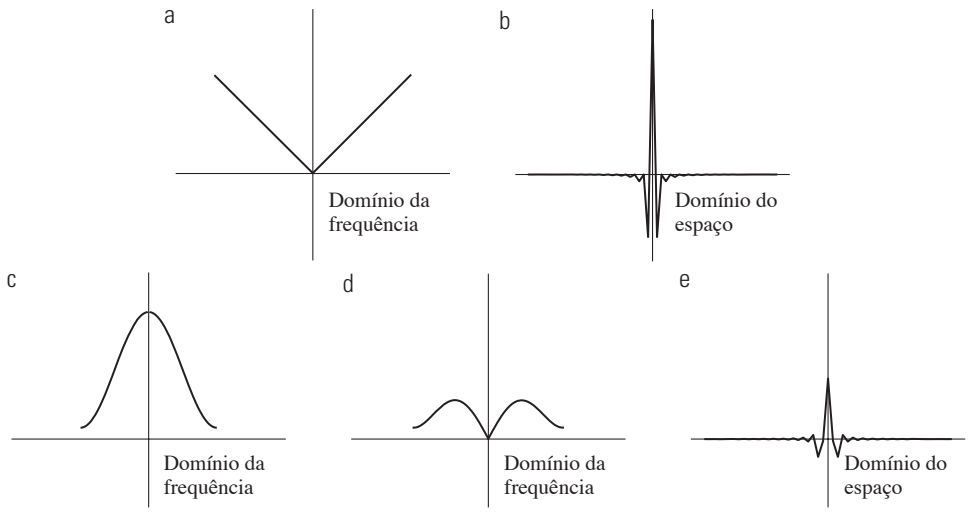


Figura 5.42 (a) Gráfico no domínio da frequência do filtro $|\omega|$ depois ter sua banda limitada por um filtro retangular. (b) Representação no domínio do espaço. (c) Função de janelamento de Hamming. (d) Filtro de rampa janelado, formado pelo produto de (a) e (c). (e) Representação espacial do produto (observe a redução do efeito de *ringing*).

Quando $c = 0{,}54$, essa função é chamada de *janela de Hamming* (em homenagem a Richard Hamming) e, quando $c = 0{,}5$, ela é chamada de *janela de Hann* (em homenagem a Julius von Hann). A principal diferença entre as janelas de Hamming e de Hann é que, na janela de Hann, os pontos finais são zero. A diferença entre as duas geralmente é imperceptível nas aplicações de processamento de imagens.

A Figura 5.42(c) mostra um gráfico da janela de Hamming, e a Figura 5.42(d) mostra o produto dessa janela e do filtro de rampa de banda limitada da Figura 5.42(a). A Figura 5.42(e) mostra a representação do produto no domínio do espaço, obtido, como de costume, pelo cálculo da FFT inversa. É evidente, pela comparação entre essa figura e a Figura 5.42(b), que o *ringing* foi reduzido na rampa com janelamento (as razões do pico ao vale nas figuras 5.42(b) e (e) são 2,5 e 3,4, respectivamente). Por outro lado, como a largura do lóbulo central na Figura 5.42(e) é ligeiramente maior que na Figura 5.42(b), é esperado que retroprojeções baseadas na utilização de uma janela de Hamming apresentem menos *ringing*, mas sejam ligeiramente mais borradas. Como mostra o Exemplo 5.19, isso é de fato o que acontece.

Lembre-se da Equação 5.11-8, que $G(\omega, \theta)$ é a transformada de Fourier 1-D de $g(\rho, \theta)$, que é uma projeção *única* obtida em um ângulo fixo, θ. A Equação 5.11-16 mostra que a imagem *completa*, retroprojetada $f(x, y)$ é obtida como se segue:

1. Calcule a transformada de Fourier 1-D de cada projeção.
2. Multiplique cada transformada de Fourier pela função filtro $|\omega|$, a qual, como explicamos anteriormente, foi multiplicada por uma janela apropriada (como, por exemplo, a janela de Hamming).
3. Obtenha a transformada inversa de Fourier 1-D de cada transformada filtrada resultante.
4. Integre (some) todas as transformadas inversas 1-D do passo 3.

Como uma função filtro é utilizada, essa abordagem de reconstrução de imagem é apropriadamente chamada de *retroprojeção filtrada*. Na prática, os dados são discretos, de forma que todos os cálculos no domínio da frequência são realizados utilizando um algoritmo FFT 1-D, e a filtragem é implementada utilizando o mesmo procedimento básico que explicamos no Capítulo 4 para funções 2-D. Também é possível implementar a filtragem no domínio do espaço utilizando a convolução, como explicaremos mais adiante nesta seção.

A discussão anterior abordou os aspectos de janelamento de retroprojeções filtradas. Como ocorre com qualquer sistema de dados amostrados, também precisamos levar em consideração as taxas de amostragem. Sabemos, com base no Capítulo 4, que a seleção das taxas de amostragem tem uma profunda influência sobre os resultados do processamento de imagens. Na presente discussão, temos duas considerações de amostragem. A primeira é o número de raios utilizados, o que determina o número de amostras em cada projeção. A segunda é o número de incrementos do ângulo de rotação, que determina o número de imagens reconstruídas (cuja soma resulta na

imagem final). A subamostragem resulta em *aliasing* que, como vimos no Capítulo 4, pode se manifestar na forma de artefatos na imagem, como listras. Veremos as questões da amostragem na CT em mais detalhes na Seção 5.11.6.

■

Exemplo 5.19 Reconstrução de imagens utilizando retroprojeções filtradas.

O foco deste exemplo é mostrar a reconstrução utilizando retroprojeções filtradas, primeiro com um filtro rampa e depois utilizando um filtro rampa modificado por uma janela de Hamming. Essas retroprojeções filtradas são comparadas com os resultados de retroprojeções "brutas" na Figura 5.40. Para nos concentrar na diferença devida apenas à filtragem, os resultados deste exemplo foram gerados com incrementos de rotação de 0,5°, que é o incremento que utilizamos para gerar a Figura 5.40. A separação entre os raios foi de um pixel nos dois casos. As imagens nos dois exemplos são de tamanho 600 × 600 pixels, de forma que o comprimento da diagonal é $\sqrt{2} \times 600 \approx 849$. Em consequência, 849 raios foram utilizados para cobrir toda a região quando o ângulo da rotação era de 45° e 135°.

A Figura 5.43(a) mostra o retângulo reconstruído utilizando um filtro rampa. O aspecto mais notável desse resultado é a ausência de qualquer borramento visualmente detectável. Entretanto, como esperado, o *ringing* está presente, visível como linhas fracas, especialmente ao redor das bordas do retângulo. Essas linhas são mais visíveis no detalhe ampliado da Figura 5.43(c). A utilização da janela de Hamming no filtro rampa ajudou a minimizar consideravelmente o problema do *ringing*, à custa de um ligeiro borramento, com mostram as figuras 5.43(b) e (d). As melhorias (mesmo com o filtro rampa sem janelamento) em relação à Figura 5.40(a) são evidentes. A imagem do *phantom* não apresenta transições tão acentuadas e proeminentes quanto o retângulo, de forma que o *ringing*, mesmo com o filtro rampa sem janelamento, é imperceptível no caso, como podemos ver na Figura 5.44(a). A utilização de uma janela de Hamming resultou em uma imagem ligeiramente mais suave, como mostra a Figura 5.44(b).

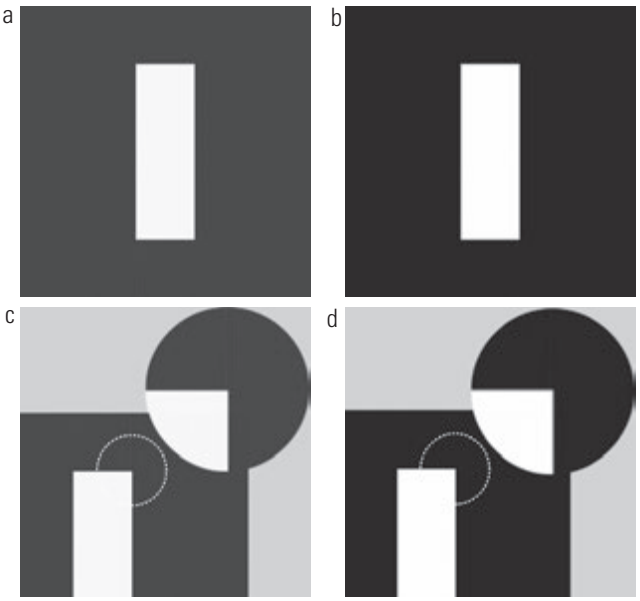


Figura 5.43 Retroprojeções filtradas do retângulo utilizando (a) um filtro rampa e (b) um filtro rampa com janelamento de Hamming. A segunda linha mostra detalhes ampliados das imagens da primeira linha. Compare com a Figura 5.40(a).

Esses dois resultados representam melhorias consideráveis em relação à Figura 5.40(b), ilustrando mais uma vez a vantagem significativa inerente à técnica da retroprojeção filtrada.

Na maioria das aplicações da CT (especialmente na medicina), artefatos como o *ringing* representam uma grande preocupação, de forma que esforços significativos são dedicados à sua minimização. O ajuste dos algoritmos de filtragem e, como explicamos na Seção 5.11.2, a utilização de um grande número de detectores estão entre as considerações de projeto que ajudam a reduzir esses efeitos.

■

A discussão mencionada se baseia na obtenção de retroprojeções filtradas por meio da implementação de uma

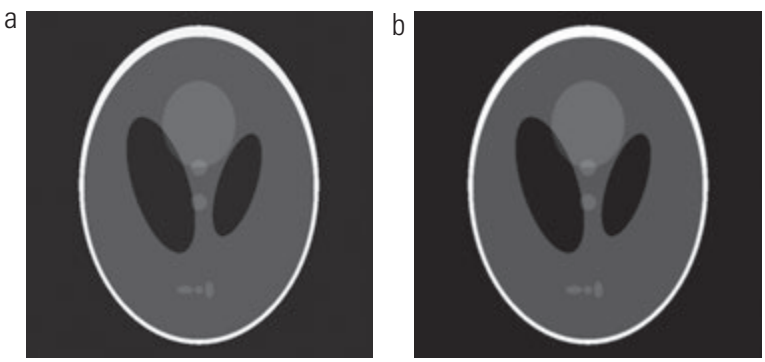


Figura 5.44 Retroprojeções filtradas de um *phantom* de cabeça utilizando (a) um filtro rampa e (b) um filtro rampa com janelamento de Hamming. Compare com a Figura 5.40(b).

FFT. No entanto, sabemos, com base no teorema da convolução apresentado no Capítulo 4, que resultados equivalentes podem ser obtidos utilizando a convolução espacial. Mais especificamente, observe que o termo entre colchetes na Equação 5.11-16 é a transformada inversa de Fourier do produto de duas funções no domínio da frequência que, de acordo com o teorema da convolução, sabemos ser igual à convolução das representações espaciais (transformadas inversas de Fourier) dessas duas funções. Em outras palavras, sendo $s(\rho)$ a transformada inversa de Fourier de $|\omega|$*, escrevemos a Equação 5.11-16 como

$$\begin{aligned} f(x,y) &= \int_0^{\pi}\left[\int_{-\infty}^{\infty}|\omega|G(\omega,\theta)e^{j2\pi\omega\rho}\,d\omega\right]_{\rho=x\cos\theta+y\,\mathrm{sen}\,\rho} \\ &= \int_0^{\pi}\left[s(\rho)\bigstar g(\rho,\theta)\right]_{\rho=x\cos\theta+y\,\mathrm{sen}\,\theta}\mathrm{d}\theta \\ &= \int_0^{\pi}\left[\int_{-\infty}^{\infty}g(\rho,\theta)s(x\cos\theta+y\,\mathrm{sen}\,\theta-\rho)\,d\rho\right]d\theta \end{aligned} \tag{5.11-18}$$

na qual, como no Capítulo 4, "★" indica a convolução. A segunda linha resulta da primeira pelas razões explicadas no parágrafo anterior. A terceira linha resulta da definição da convolução dada na Equação 4.2-20.

As duas últimas linhas da Equação 5.11-18 dizem a mesma coisa: retroprojeções individuais em um ângulo podem ser obtidas pela convolução da projeção correspondente, $g(\rho, \theta)$, e a transformada inversa de Fourier do filtro rampa, $s(\rho)$. Como antes, a imagem retroprojetada completa é obtida integrando (somando) todas as imagens retroprojetadas individuais. Com exceção das diferenças de arredondamento no cálculo, os resultados da utilização da convolução serão idênticos aos resultados utilizando a FFT. Em implementações práticas da CT, a convolução geralmente se mostra mais eficiente em termos computacionais, de forma que a maioria dos sistemas modernos de CT utiliza esse método. A transformada de Fourier de fato exerce um papel fundamental nas formulações teóricas e no desenvolvimento de algoritmos (por exemplo, o processamento de imagens por CT no Matlab se baseia na FFT). Além disso, notamos que não há necessidade de armazenar todas as imagens retroprojetadas durante a reconstrução. Em vez disso, uma única soma é atualizada com a imagem retroprojetada mais recente. No final do procedimento, a soma será igual à soma total de todas as retroprojeções.

Por fim, observamos que, como o filtro rampa (mesmo com janelamento) zera o termo dc no domínio da frequência, cada imagem de retroprojeção terá um valor médio zero (veja a Figura 4.30). Isso significa que cada imagem da retroprojeção terá pixels negativos e positivos. Quando todas as retroprojeções são adicionadas para formar a imagem final, algumas posições negativas podem se tornar positivas, e o valor médio pode não ser zero, mas, normalmente, ainda assim a imagem final terá pixels negativos.

Há várias maneiras de solucionar esse problema. O método mais simples, quando não temos informações sobre quais deveriam ser os valores médios, é aceitar o fato de que valores negativos são inerentes ao método e ajustar o resultado utilizando o procedimento descrito nas equações 2.6-10 e 2.6-11. Essa é a técnica que utilizamos nesta seção. Quando temos informações sobre qual deveria ser um valor médio "típico", esse valor pode ser adicionado ao filtro no domínio da frequência, compensando, dessa forma, a rampa e impedindo que o termo dc seja zerado (veja a Figura 4.31(c)). Ao trabalhar no domínio espacial com a convolução, o simples ato de truncar o comprimento do filtro espacial (transformada inversa de Fourier da rampa) o impede de ter um valor médio zero, assim, evitando o problema da zeragem totalmente.

5.11.6 Reconstrução utilizando retroprojeções filtradas por feixes em formato de leque

Até este ponto as discussões se concentraram em feixes paralelos. Em virtude de sua implementação simples e intuitiva, essa é a geometria de aquisição de imagens normalmente utilizada para introduzir os conceitos de tomografia computadorizada. No entanto, sistemas modernos de CT utilizam uma geometria em formato de leque (veja a Figura 5.35), o tema da discussão para o restante desta seção.

A Figura 5.45 mostra uma geometria básica de aquisição de imagens em formato de leque na qual os detectores são dispostos em um arco circular, e presume-se que os incrementos angulares da fonte sejam iguais. Seja $p(\alpha, \beta)$ uma projeção em formato de leque, na qual α é a posição angular de um detector particular mensurado em relação ao *raio central*, e β é o deslocamento angular da fonte, medido em relação ao eixo y, como mostra a figura. Também observamos na Figura 5.45 que um raio no feixe em leque pode ser representado como uma linha, $L(\rho,\theta)$, na forma normal, que é a abordagem que utilizamos para representar um raio na geometria de aquisição de imagens de feixes paralelos, discutida nas seções anteriores. Isso nos permite utilizar resultados do feixe paralelo como o ponto de partida para deduzir as equações correspondentes para a geometria do feixe em formato de leque.

* Se uma função de janelamento, como a janela de Hamming, for utilizada, então a transformada inversa de Fourier será realizada na rampa janelada. Além disso, podemos ignorar mais uma vez a questão mencionada anteriormente sobre e a existência da transformada inversa de Fourier contínua porque todas as implementações são realizadas utilizando valores discretos de comprimento finito.

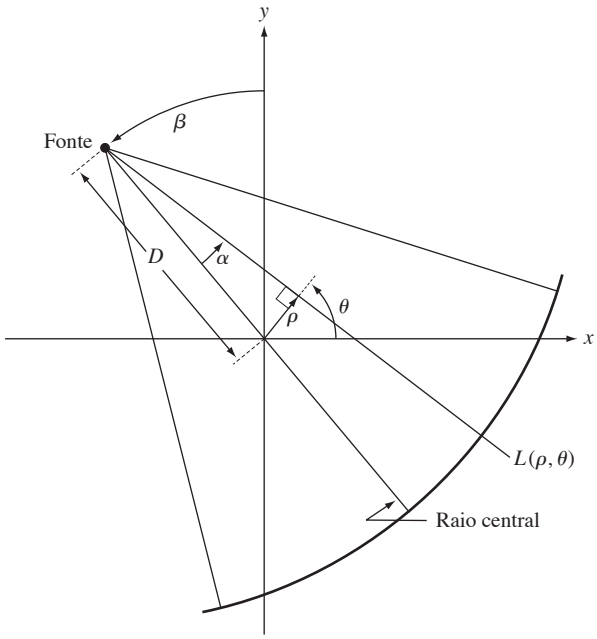


Figura 5.45 Geometria básica do feixe em formato de leque. A linha que passa pelo centro da fonte e da origem (que consideramos aqui como o centro da rotação da fonte) é chamada de *raio central*.

Demonstraremos isso deduzindo a retroprojeção filtrada por feixe em formato de leque com base na convolução.*

Começaremos observando na Figura 5.45 que os parâmetros da linha $L(\rho,\theta)$ são relacionados aos parâmetros de um raio de feixe em formato de leque por

$$\theta = \beta + \alpha \tag{5.11-19}$$

e

$$\rho = D \operatorname{sen} \alpha \tag{5.11-20}$$

sendo D a distância a partir do centro da fonte até a origem do plano xy.

A fórmula da retroprojeção por convolução para a geometria de aquisição de imagens por feixes paralelos é dada pela Equação 5.11-18. Sem perda de generalidade, vamos supor que nossa atenção seja concentrada em objetos englobados em uma área circular de raio T em relação à origem do plano. Então, $g(\rho,\theta) = 0$ para $|\rho| > T$ e a Equação 5.11-18 passa a ser

$$f(x,y) = \frac{1}{2}\int_0^{2\pi}\int_{-T}^{T} g(\rho,\theta)s(x\cos\theta + y\operatorname{sen}\theta - \rho)dpd\theta \tag{5.11-21}$$

* O teorema da fatia de Fourier foi deduzido para uma geometria de feixes paralelos e não é diretamente aplicável a feixes em formato de leque. No entanto, as equações 5.11-19 e 5.11-20 fornecem a base para converter uma geometria de feixes em formato de leque em uma geometria de feixes paralelos, permitindo, dessa forma, a utilização da técnica de retroprojeção filtrada paralela, desenvolvida na seção anterior, para a qual o teorema da fatia pode ser aplicado. Discutiremos esse ponto em mais detalhes no final desta seção.

na qual utilizamos o fato explicado na Seção 5.11.1 de que projeções com 180° entre si são imagens espelhadas umas das outras. Dessa forma, fazemos com que os limites da integral externa na Equação 5.11-21 englobem um círculo completo, como requer um arranjo de feixes em formato de leque no qual os detectores são dispostos em um círculo.

Nosso interesse é na integração em relação a α e β. Para isso, começamos alterando para coordenadas polares (r,φ). Isto é, fazemos com que $x = r\cos\varphi$ e $y = r\operatorname{sen}\varphi$, o que leva a

$$x\cos\theta + y\operatorname{sen}\theta = r\cos\varphi\cos\theta + r\operatorname{sen}\varphi\operatorname{sen}\theta = r\cos(\theta-\varphi) \tag{5.11-22}$$

Utilizando esse resultado, podemos expressar a Equação 5.11-21 como

$$f(x,y) = \frac{1}{2}\int_0^{2\pi}\int_{-T}^{T} g(\rho,\theta)s\left[r\cos(\theta-\varphi)-\rho\right]dp\,d\theta$$

Essa expressão não passa da fórmula de reconstrução por feixes paralelos expressa em coordenadas polares. No entanto, a integração ainda se refere a ρ e θ. A integração em relação a α e β requer uma transformação de coordenadas utilizando as equações 5.11-19 e 5.11-20:

$$f(r,\varphi) = \frac{1}{2}\int_{-\alpha}^{2\pi-\alpha}\int_{\operatorname{sen}^{-1}(-T/D)}^{\operatorname{sen}^{-1}(T/D)} g(D\operatorname{sen}\alpha,\alpha+\beta)\, s[r\cos(\beta+\alpha-\varphi)-D\operatorname{sen}\alpha]D\cos\alpha\,d\alpha\,d\beta \tag{5.11-23}$$

na qual utilizamos $d\rho\,d\theta = D\cos\alpha\,d\alpha\,d\beta$ (veja a explicação da Equação 5.11-13).

Essa equação pode ser simplificada ainda mais. Em primeiro lugar, observe que os limites $-\alpha$ até $2\pi - \alpha$ para β incluem toda a extensão de 360°. Como todas as funções de β são periódicas, com período 2π, os limites da integral externa podem ser substituídos por 0 e 2π, respectivamente. O termo $\operatorname{sen}^{-1}(T/D)$ tem um valor máximo de α_m, correspondente a $|\rho| > T$, acima do qual $g = 0$ (veja a Figura 5.46), de forma que substituímos os limites da integral por $-\alpha_m$ e α_m, respectivamente. Por fim, veja a linha $L(\rho,\theta)$ na Figura 5.45. Uma soma de raios de um feixe em formato de leque ao longo dessa linha deve ser igual à soma de raios de um feixe paralelo ao longo da mesma linha (uma soma de raios é uma soma de todos os valores ao longo de uma linha, de forma que o resultado deve ser o mesmo para um determinado raio, independentemente do sistema de coordenadas no qual ele é expresso). Isso se aplica a qualquer soma de raios para valores correspondentes de (α,β) e (ρ,θ). Assim, sendo $p(\alpha,\beta)$ uma projeção de feixe em formato de leque, segue-se que $p(\alpha,\beta) = g(\rho,\theta)$ e, a partir das equações 5.11-19 e 5.11-20, que $p(\alpha,\beta) = g(D\operatorname{sen}\alpha, \alpha+\beta)$. Incorporando essas observações à Equação 5.11-23 resulta na expressão

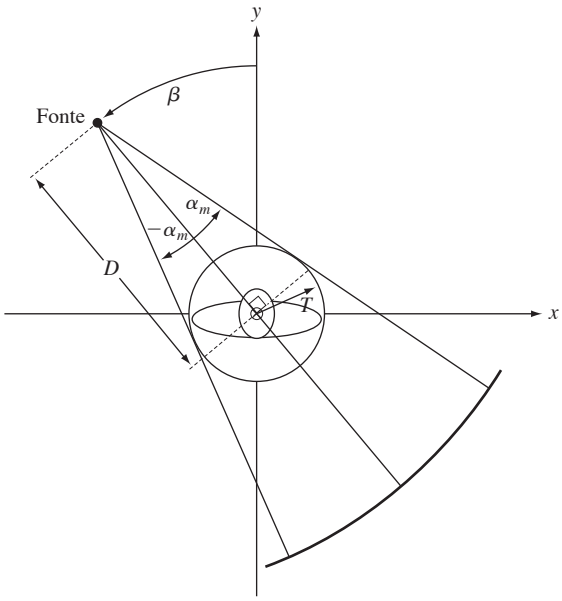


Figura 5.46 Valor máximo de α necessário para englobar uma região de interesse.

$$f(r,\varphi)=\frac{1}{2}\int_0^{2\pi}\int_{-\alpha_m}^{\alpha_m}\rho(\alpha,\beta)s[r\cos(\beta+\alpha-\varphi)-D\,\text{sen}\,\alpha]D\cos\alpha\,d\alpha\,d\beta \qquad (5.11\text{-}24)$$

Essa é a fórmula fundamental da reconstrução por feixe em formato de leque baseada em retroprojeções filtradas.

A Equação 5.11-24 pode ser ainda mais manipulada para ser expressa na fórmula de convolução, com a qual estamos mais familiarizados. Com referência à Figura 5.47, pode ser demonstrado (Exercício 5.33) que

$$r\cos(\beta+\alpha-\varphi)-D\,\text{sen}\,\alpha=R\,\text{sen}(\alpha'-\alpha) \qquad (5.11\text{-}25)$$

na qual R é a distância a partir da fonte para um ponto arbitrário em um raio em formato de leque, e α' é o ângulo entre esse raio e o raio central. Observe que R e α' são determinados pelos valores de r, φ e β. Substituir a Equação 5.11-25 na Equação 5.11-24 resulta em

$$f(r,\varphi)=\frac{1}{2}\int_0^{2\pi}\int_{-\alpha_m}^{\alpha_m}p(\alpha,\beta)s\left[R\,\text{sen}(\alpha'-\alpha)\right]D\cos\alpha\,d\alpha\,d\beta \qquad (5.11\text{-}26)$$

Pode ser demonstrado (Exercício 5.34) que

$$s(R\,\text{sen}\,\alpha)=\left(\frac{\alpha}{R\,\text{sen}\,\alpha}\right)^2 s(\alpha) \qquad (5.11\text{-}27)$$

Utilizando essa expressão, podemos escrever a Equação 5.11-26 como

$$f(r,\varphi)=\int_0^{2\pi}\frac{1}{R^2}\left[\int_{-\alpha_m}^{\alpha_m}q(\alpha,\beta)h(\alpha'-\alpha)\,d\alpha\right]d\beta \qquad (5.11\text{-}28)$$

sendo

$$h(\alpha)=\frac{1}{2}\left(\frac{\alpha}{\text{sen}\,\alpha}\right)^2 s(\alpha) \qquad (5.11\text{-}29)$$

e

$$q(\alpha,\beta)=p(\alpha,\beta)D\cos\alpha \qquad (5.11\text{-}30)$$

Reconhecemos a integral interna na Equação 5.11-28 como uma expressão de convolução, demonstrando, dessa forma, que a fórmula de reconstrução da imagem na Equação 5.11-24 pode ser implementada como a convolução das funções $q(\alpha, \beta)$ e $h(\alpha)$. Diferentemente da fórmula de reconstrução para projeções paralelas, a reconstrução baseada em projeções por feixe em formato de leque envolve um termo $1/R^2$, que é um fator de ponderação inversamente proporcional à distância a partir da fonte. Os detalhes computacionais da implementação da Equação 5.11-28 estão fora do escopo da presente análise (para uma explicação detalhada do assunto, veja Kak e Slaney (2001).

Em vez de implementar diretamente a Equação 5.11-28, um método normalmente utilizado, particularmente em simulações computacionais é (1) converter uma geometria de feixe em formato de leque em uma geometria de feixes paralelos utilizando as equações 5.11-19 e 5.11-20, e (2) utilizar a abordagem de reconstrução por feixes paralelos desenvolvida na Seção 5.11.5. Concluímos esta seção com um exemplo de como isso é feito. Como observamos anteriormente, uma projeção por feixe em formato de leque, p, realizada no ângulo β, tem uma projeção por feixes paralelos correspondente, g, realizada em um ângulo correspondente θ e, portanto,

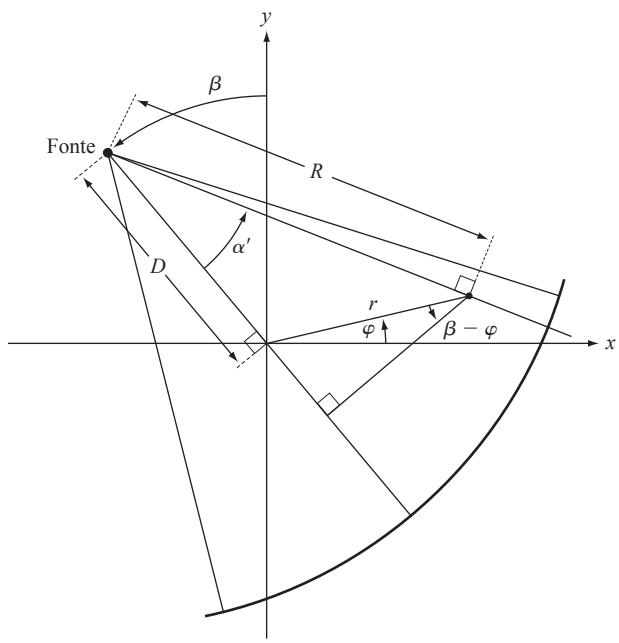


Figura 5.47 Representação polar de um ponto arbitrário em um raio de um feixe em formato de leque.

$$p(\alpha, \beta) = g(\rho, \theta)$$
$$= g(D \operatorname{sen} \alpha, \alpha + \beta) \quad (5.11\text{-}31)$$

sendo que a segunda linha resulta das equações 5.11-19 e 5.11-20.

Seja $\Delta\beta$ o incremento angular entre sucessivas projeções do feixe em formato de leque e seja $\Delta\alpha$ o incremento angular entre os raios, o que determina o número de amostras em cada projeção. Impomos a restrição de que

$$\Delta\beta = \Delta\alpha = \gamma \quad (5.11\text{-}32)$$

Então, temos que $\beta = m\gamma$ e $\alpha = n\gamma$ para alguns valores inteiros de m e n, e podemos escrever a Equação 5.11-31 como

$$p(n\gamma, m\gamma) = g[D \operatorname{sen} n\gamma, (m + n)\gamma] \quad (5.11\text{-}33)$$

Essa equação indica que o n-ésimo raio da m-ésima projeção radial é igual ao n-ésimo raio na $(m + n)$-ésima projeção paralela. O termo $D\operatorname{sen} n\gamma$ no lado direito da Equação 5.11-33 implica que as projeções paralelas convertidas a partir de projeções de feixe em formato de leque não são amostradas uniformemente, o que pode levar a borramento e artefatos de *aliasing* e *ringing* se os intervalos de amostragem $\Delta\alpha$ e $\Delta\beta$ forem grosseiros demais, como ilustra o exemplo a seguir.

■

Exemplo 5.20 Reconstrução de imagem utilizando retroprojeções filtradas em formato de leque.

A Figura 5.48(a) mostra os resultados de (1) gerar projeções em formato de leque da imagem do retângulo com $\Delta\alpha = \Delta\beta = 1^o$, (2) converter cada raio em formato de leque no raio paralelo correspondente utilizando a Equação 5.11-33 e (3) utilizar o método da retroprojeção filtrada desenvolvido na Seção 5.11.5 para raios paralelos. As figuras 5.48(b) a (d) mostram os resultados utilizando incrementos de 0,5°, 0,25° e 0,125°. Uma janela de Hamming foi utilizada em todos os casos. Essa variedade de incrementos angulares foi utilizada para ilustrar os efeitos da subamostragem.

O resultado na Figura 5.48(a) é uma indicação clara de que incrementos de 1° são grosseiros demais, já que o borramento e o *ringing* são bastante claros. O resultado em b é interessante por não se comparar bem com a Figura 5.43(b), que foi gerada utilizando o mesmo incremento angular de 0,5°. De fato, como mostra a Figura 5.48(c), mesmo com incrementos angulares de 0,25°, a reconstrução ainda não é tão boa quanto a da Figura 5.43(b). Precisamos utilizar incrementos angulares da ordem de 0,125° antes de os dois resultados se tornarem comparáveis, como mostra a Figura 5.48(d). Esse incremento angular resulta em projeções com $180 \times (1/0{,}25) = 720$ amostras, que se aproxima dos 849 raios utilizados nas projeções paralelas do Exemplo 5.19. Dessa forma, não é de surpreender que os resultados sejam próximos em termos de aparência ao resultado utilizando $\Delta\alpha = 0{,}125^o$.

Resultados similares foram obtidos com o *phantom* de cabeça, com exceção do fato de o *aliasing* ser muito mais visível como interferência senoidal. Vemos na Figura 5.49(c) que mesmo com $\Delta\alpha = \Delta\beta = 0{,}25$ ainda vemos uma significativa distorção, especialmente na periferia da elipse. Como no caso do retângulo, utilizar incrementos de 0,125° finalmente produziu resultados comparáveis com a imagem re-

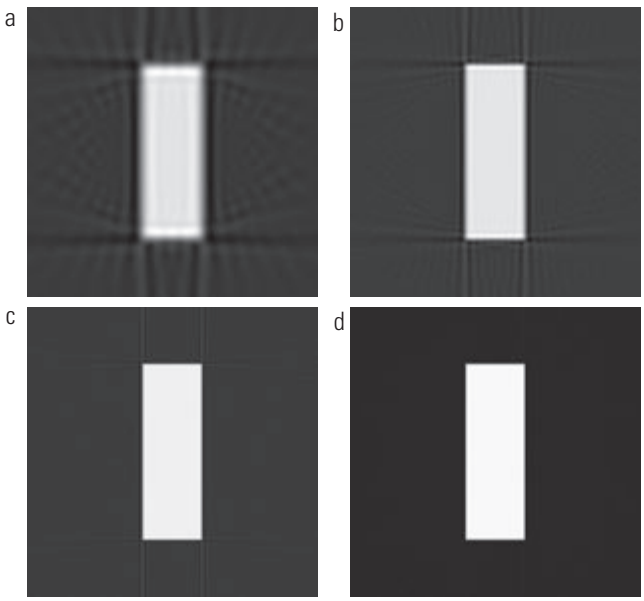


Figura 5.48 Reconstrução da imagem do retângulo a partir de retroprojeções filtradas em formato de leque. (a) Com incrementos de 1° de α e β. (b) Com incrementos de 0,5°. (c) Com incrementos de 0,25°. (d) Com incrementos de 0,125°. Compare (d) com a Figura 5.43(b).

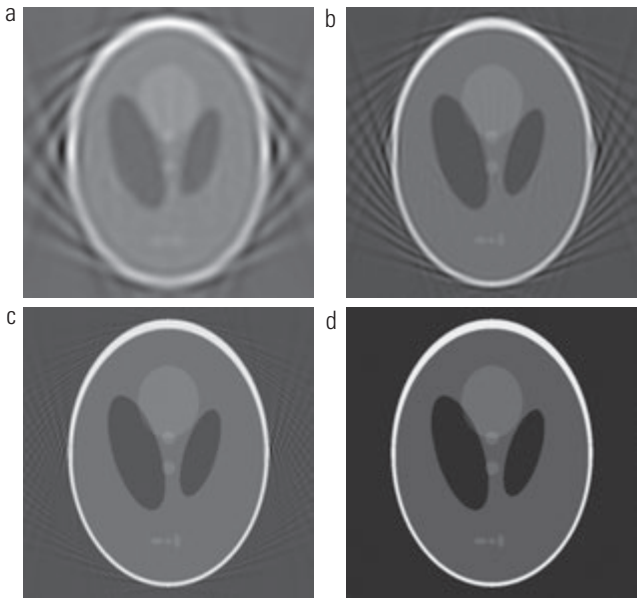


Figura 5.49 Reconstrução da imagem do *phantom* de cabeça a partir de retroprojeções filtradas em formato de leque. (a) Com incrementos de 1° de α e β. (b) Com incrementos de 0,5°. (c) Com incrementos de 0,25°. (d) Com incrementos de 0,125°. Compare (d) com a Figura 5.44(b).

troprojetada do *phantom* de cabeça da Figura 5.44(b). Esses resultados ilustram uma das principais razões pelas quais milhares de detectores precisam ser utilizados na geometria de feixe em formato de leque dos sistemas modernos de CT para reduzir os artefatos de *aliasing*.

■

Resumo

Os resultados das técnicas de restauração apresentados neste capítulo se baseiam na premissa de que a degradação de imagens pode ser modelada como um processo linear, invariante no espaço seguido por um ruído aditivo que não é correlacionado com os valores da imagem. Mesmo quando essas premissas não são totalmente válidas, costuma ser possível obter resultados úteis utilizando os métodos desenvolvidos nas seções anteriores.

Algumas das técnicas de restauração desenvolvidas neste capítulo se baseiam em vários critérios de otimização. A utilização da palavra "ótima", neste contexto, refere-se exclusivamente a um conceito matemático, não à resposta ótima do sistema visual humano. Na verdade, a falta de conhecimento atual sobre a percepção visual impossibilita uma formulação geral do problema de restauração de imagens que leve em consideração as preferências e a capacidade do observador. Diante dessas limitações, a vantagem dos conceitos apresentados neste capítulo é o desenvolvimento de técnicas fundamentais que tenham um comportamento razoavelmente previsível e sustentadas por um conhecimento sólido.

Como nos capítulos 3 e 4, algumas tarefas de restauração, como redução de ruído aleatório, são realizadas no domínio do espaço utilizando máscaras de convolução. O domínio da frequência foi considerado ideal para a redução do ruído periódico e para o modelamento de algumas degradações importantes, como o borramento causado pelo movimento durante a aquisição da imagem. Também descobrimos que o domínio da frequência representa uma ferramenta útil para a formulação de filtros de restauração, como o filtro de Wiener e filtros por mínimos quadráticos com restrição.

Como mencionamos no Capítulo 4, o domínio da frequência oferece uma base sólida e intuitiva para experimentação. Quando uma técnica (filtro) apresenta um desempenho considerado satisfatório para uma dada aplicação, a implementação normalmente é realizada pelo desenvolvimento de um filtro digital que se aproxima da solução no domínio da frequência, mas que funciona muito mais rapidamente em um computador ou em um sistema de hardware/firmware dedicado, como sugerimos no final do Capítulo 4.

Nossa análise da reconstrução de imagens a partir de projeções, apesar de introdutória, constitui as bases para os aspectos de processamento de imagens dessa área. Como observamos na Seção 5.11, a tomografia computadorizada (CT) é a principal área de aplicação da reconstrução de imagens a partir de projeções. Apesar de termos nos concentrado na tomografia por raios X, os princípios desenvolvidos na Seção 5.11 são aplicáveis a outras modalidades de aquisição de imagens de CT, como a SPECT (tomografia por emissão de fóton único), PET (tomografia por emissão de pósitrons), MRI (ressonância magnética) e algumas modalidades de aquisição de imagens por ultrassom.

Referências e leituras complementares

Para leituras adicionais sobre o modelo linear de degradação apresentado na Seção 5.1, veja Castleman (1996) e Pratt (1991). O livro de Peebles (1993) fornece uma análise em nível intermediário das funções de densidade de probabilidade de ruído e suas propriedades (Seção 5.2). O livro de Papoulis (1991) é mais avançado e analisa esses conceitos em mais detalhes. As referências sugeridas para a Seção 5.3 são Umbaugh (2005), Boie e Cox (1992), Hwang e Haddad (1995) e Wilburn (1998). Veja Eng e Ma (2001, 2006) sobre a filtragem adaptativa de mediana. A área geral do desenvolvimento de filtros adaptativos representa uma boa base para os filtros adaptativos discutidos na Seção 5.3. O livro de Haykin (1996) apresenta uma boa introdução para esse tópico. Os filtros da Seção 5.4 são extensões diretas do material apresentado no Capítulo 4. Para leituras adicionais sobre o material da Seção 5.5, veja Rosenfeld e Kak (1982) e Pratt (1991).

O tópico da estimativa da função de degradação (Seção 5.6) atualmente representa uma área de considerável interesse. Algumas das técnicas mais antigas para a estimativa da função de degradação são apresentadas em Andrews e Hunt (1977), Rosenfeld e Kak (1982), Bates e McDonnell (1986) e Stark (1987). Como a função de degradação raramente é conhecida com exatidão, várias técnicas foram propostas ao longo dos anos, nas quais aspectos específicos da restauração são enfatizados. Por exemplo, Geman e Reynolds (1992) e Hurn e Jennison (1996) lidam com questões de preservação de transições de intensidade acentuada, em uma tentativa de enfatizar a nitidez, ao passo que Boyd e Meloche (1998) se concentraram em restaurar objetos finos em imagens degradadas. Exemplos de técnicas que lidam com o borramento de imagens são encontrados em Yitzhaky et al. (1998), Harikumar e Bresler (1999), Mesarovic (2000) e Giannakis